

Informatique

CPGE

Marc de Falco

Copyright © 2020 Marc de Falco

Licensed under the Creative Commons Attribution-NonCommercial 3.0 Unported License (the "License"). You may not use this file except in compliance with the License. You may obtain a copy of the License at <http://creativecommons.org/licenses/by-nc/3.0>. Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "**AS IS**" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

Table des matières

I	Introduction	
1	Introduction	11
I	Feuille de route	11
2	Introduction à l'informatique	13
I	Données, Problème, Algorithme	13
I.1	Données	13
I.2	Problèmes	14
I.3	Algorithme	14
II	Modèle de calcul, Machines, Programmes	14
II.1	Exemple : ordinateur	15
II.2	Exemple : les machines à deux compteurs	15
II.3	Exemple : le noyau fonctionnel pur d'OCaml	16
II.4	Exemple : Jeu de la vie	16
II.5	Exemple : FRACTRAN	16
II.6	Modèle Turing complets	20
III	Langages, Compilateur, Interprète	20
III.1	Langages	20
III.2	Compilateur	21
III.3	Interprète	21
III.4	Unité de compilation, modules	21
IV	Paradigmes	21
IV.1	Impératif structuré	21
IV.2	Fonctionnel déclaratif	22
IV.3	Programmation logique	22

3	Introduction à la programmation (impérative)	25
I	Introduction	25
I.1	Les quatre étages de la programmation	26
I.2	Exemple	26
I.3	Se remettre sans cesse à l'ouvrage	27
II	Représenter	28
II.1	Les données simples	28
II.2	Les données composées ou structurées	28
III	Manipuler	28
III.1	Variables	28
III.2	État d'exécution	29
III.3	Instructions et blocs	29
III.4	Portée	31
III.5	Manipuler des données composées mutables	31
III.6	Instruction conditionnelle	33
III.7	Entrées et sorties	35
IV	Répéter	35
IV.1	Répéter n fois	36
IV.2	Répéter pour chaque élément	36
IV.3	Répéter tant qu'une condition est vérifiée	36
IV.4	Choisir la structure de boucle adaptée	36
IV.5	Boucles imbriquées et dimensionnalité	36
V	Abstraire	36
V.1	Définir et appeler des fonctions	36
V.2	Action d'une fonction et valeur de retour	36
V.3	Fonctions et portée	36
V.4	Structurer des programmes avec des fonctions	36
V.5	Les fonctions comme valeurs	36
4	Récursivité	37
I	La récursivité	37
I.1	Principe et exemples	37
I.2	Implémentation pratique	38
I.3	Programmer en récursif	39
I.4	Récursivité croisée	39
II	L'arbre d'appels	39
II.1	Définition	39
II.2	Complexité en nombre d'appels	39
II.3	Terminaison	39
III	Récursivité terminale	39
III.1	Présentation	39
III.2	Optimisation	39
III.3	Techniques	39
IV	Types inductifs et induction structurelle	39
IV.1	Définition naïve des types inductifs	39

5	Type option en OCaml	41
I	Principe	41
II	Syntaxe	41
III	Utilisation concrète	42
III.1	Définir une fonction partielle	42
III.2	Appeler une fonction partielle	43
III.3	Données partielles	43
III.4	Chaîne de traitement	43
6	Exceptions en OCaml	45
I	Syntaxe des exceptions	45
II	Exceptions pour la gestion d'erreurs	46
III	Programmer avec des exceptions	47
III.1	Retour prématuré	47

III

Structures de données

7	Structures de données abstraites et implémentations	53
I	Introduction	53
II	Structure de données abstraite	53
8	Séquences et ses implémentations : tableaux, listes chaînées	55
I	Structure abstraite séquence ou liste	55
II	Implémentations	55
III	Implémentations concrètes des Listes chaînées	55
III.1	En C	55
III.2	En OCaml	61
III.3	Structure de la mémoire	64
IV	Travaux pratiques	64
IV.1	Tableaux non statiques et tableaux dynamiques	64
IV.2	Listes chaînées	71
9	Piles et files : structures abstraites et implémentations	83
I	Piles	83
I.1	Principe	83
I.2	Représentation visuelle	84
I.3	Implémentations	84
I.4	Applications	86
II	Files	86
II.1	Principe	86
II.2	Implémentations	86
II.3	Applications	88

10	Arbres	89
I	Arbres binaires	89
I.1	Définition inductive	89
I.2	Vocabulaire	90
I.3	Implémentations	91
I.4	Arbres binaires stricts	92
I.5	Arbres binaires complets	93
II	Arbres	93
II.1	Définition	93
II.2	Implémentation	94
II.3	Représentation par un arbre binaire	95
II.4	Applications	95
III	Parcours	96
III.1	Parcours récursif d'un arbre binaire	96
III.2	Parcours impératifs	98
III.3	Parcours d'arbres	100
IV	Arbres binaires de recherche	100
IV.1	Objectif	100
IV.2	Définition	100
IV.3	Opérations	100
IV.4	Équilibrage	100
IV.5	Implémentation d'un dictionnaire	100
V	Tas	100
V.1	Présentation	100
V.2	Implémentation	100
V.3	Application aux files de priorité	100
VI	TP - Arbres en OCaml	100
VI.1	Premières fonctions	100
VI.2	Parcours	102
VI.3	Arbres binaires stricts	105
VI.4	Dessin d'arbres	106
VI.5	Génération aléatoire d'arbres	108
11	Graphes	111
I	Graphes	111

IV	Algorithmique	
12	Introduction à l'analyse des algorithmes	115
I	État d'un programme	115
II	Terminaison	116
II.1	Variant de boucle	117
II.2	Exemple de la recherche dichotomique	117
II.3	Exemple du tri à bulle	119
II.4	Lien avec la récursivité	120
II.5	Boucles imbriquées	120

III	Correction	120
III.1	Invariant de boucle	121
III.2	Exemple du tri par sélection	121
IV	Complexité	123
IV.1	Complexité dans le pire des cas	123
IV.2	Comparer des complexités	123
IV.3	Complexités en temps classiques	127
IV.4	Calculer des complexités	130
IV.5	Complexité à plusieurs paramètres	130
IV.6	Complexité en moyenne	131
IV.7	Complexité amortie	132
IV.8	Pertinence de la complexité spatiale	132
V	Exercices	133
13	Complexité amortie	137
I	Introduction	137
I.1	Implémentation d'une file avec deux piles	137
I.2	Les tableaux dynamiques	138
II	Techniques de calcul	141
II.1	Cadre	141
II.2	Calcul naïf	141
II.3	Méthode du banquier	142
II.4	Méthode du potentiel	145
14	Recherche par Force brute	147
I	Principe	147
I.1	Problème de décision et exploration exhaustive	147
I.2	Problème d'optimisation et exploration exhaustive	148
II	Recherche par retour sur trace (backtracking)	148
II.1	Construction itérative de candidats	148
II.2	Évaluation partielle et raccourcis	150
II.3	Énumération de toutes les solutions	153
II.4	TP : tours du cavalier	155
II.5	TP : jeu du solitaire	155
III	Stratégies d'énumération	160
III.1	Combinatoire élémentaire	160
III.2	Enumération d'arbres	161
IV	Droite de balayage	161
IV.1	Principe	161
IV.2	Plus proche paire	161
15	Algorithmes gloutons	169
I	Principe	169
II	Construction de l'arbre de Huffman	171
III	Preuve d'optimalité	175
IV	Sélection d'activités	175
IV.1	Description	175

IV.2	Algorithme glouton et implémentation	175
IV.3	Preuve d'optimalité	177
V	Ordonnancement de tâches	178
V.1	Description	178
V.2	Algorithme glouton et implémentation	178
V.3	Preuve d'optimalité	180
16	Diviser pour regner	183
I	Diviser pour régner	183
I.1	Principe	183
I.2	Tri fusion	183
I.3	Nombre d'inversions	185
I.4	Points les plus proches	186
I.5	Sous-ensemble de somme donnée	186
I.6	Recherche dichotomique	186
I.7	Couverture par des segments égaux	186
17	Algorithmique des textes	189
I	Recherche dans un texte	189
I.1	Principe de la recherche	189
I.2	Algorithme naïf en force brute	190
I.3	Algorithme de Boyer-Moore	191
I.4	Algorithme de Rabin-Karp	201
II	Compression	204
II.1	Principe	204
II.2	Algorithme d'Huffman	204
II.3	Algorithme de Lempel-Ziv-Welch	210
III	Problèmes supplémentaires	219
III.1	Transformation de Burrows-Wheeler	219
III.2	Move to front	219
III.3	La structure de données corde	219
III.4	L'algorithme de Knuth-Morris-Pratt	219
III.5	Extensions à l'analyse d'images	219

V	Systèmes	
18	Gestion de la mémoire dans un programme compilé	223
I	Organisation de la mémoire	223
II	Pointeurs	226
III	Portée d'un identificateur	226
IV	Piles d'exécution, variables locales et paramètres	228
V	Allocation dynamique	230
V.1	Allocation	230
V.2	Libération	231
V.3	Protection mémoire	232
V.4	Réalisation d'un système d'allocation de mémoire	233



Introduction

1	Introduction	11
I	Feuille de route	
2	Introduction à l'informatique	13
I	Données, Problème, Algorithme	
II	Modèle de calcul, Machines, Programmes	
III	Langages, Compilateur, Interprète	
IV	Paradigmes	

1. Introduction

Ce site présente des documents personnels autour du programme de MP2I/MPI, et donc également du programme d'option informatique de MPSI/MP et du tronc commun.

Il s'agit pour le moment d'un premier jet, et il est amené à beaucoup évoluer. Il correspond à mon interprétation personnelle de certaines notions.

Des problèmes sont présentés au cours des documents, ils peuvent donner lieu à des développements en classe, des séances de travaux pratiques ou des problèmes. Plutôt que de donner un découpage figé en questions, ils sont souvent présentés tels quels.

Mon idée principale avec ces ressources est de proposer un contenu assez riche, plutôt à destination des enseignants. Certains points un peu pointus ne sont pas forcément essentiels pour tous les étudiants.

Le but ici n'est pas de surpasser des références sur chaque domaine, je n'ai pas cette prétention, mais de présenter un livre *tout-en-un* ce qui implique des compromis dans les notions traités et la présentation.

Feuille de route

- Faire une présentation uniforme pour les problèmes avec un index.
- Rajouter des macros pour compiler/exécuter et inclure la sortie des bouts de code.
- Rajouter les TP.
- Des roadmaps sont données dans chaque chapitre.



2. Introduction à l'informatique

■ Note 2.1 Roadmap :

- tout reprendre. Je suis peu satisfait du résultat.

Dans ce chapitre, on présente de manière très survolée l'informatique. On aura l'occasion de revenir en détail sur certaines notions. L'objectif est avant tout d'avoir une vision claire même si elle est naïve de

- ce qu'est un problème informatique
- ce qu'est un programme
- ce qu'est une machine
- ce que signifie de résoudre informatiquement un problème

Cela permet de répondre à des questions comme :

- qu'est-ce qui permet de dire qu'on programme en OCaml alors qu'on a l'impression de ne faire que des suites de définitions ?
- peut-on se contenter de programmer sans chercher à comprendre ?

Précisons ici qu'on parle d'informatique mais que le terme le plus proche de ce que l'on étudie en anglais est *computer science* par complémentarité avec des notions comme celles de *computer engineering* plus proches de considérations matérielles. Il n'y a pas une *unique* vision de l'informatique mais plutôt une grande richesse de point de vue.

I Données, Problème, Algorithme

I.1 Données

Définition I.1 Une donnée informatique est un élément d'information fini qu'on peut stocker ou transmettre.

Selon le niveau d'abstraction auquel on se place, on peut considérer une donnée comme étant une succession de bits, c'est-à-dire de valeur valant 0 ou 1, ou comme une donnée plus structurées, comme un texte, une image, un graphe, ...

En informatique, on adapte souvent son point de vue sur les notions de base comme celle-ci. Si

on fait de la transmission ou de la compression de données, c'est important d'en avoir une représentation la plus primitive possible comme des mots binaires. Mais si s'intéresse à des notions de chemins dans un graphe, il est plus adéquat de considérer un graphe comme un élément de données même si la question de sa représentation n'est pas immédiate.

1.2 Problèmes

Définition 1.2 Un *problème informatique* est un ensemble de questions paramétrées par des données (les *entrées*) et dont les réponses peuvent être

- soit Oui ou Non, auquel cas on parle de problème de *décision*
- ou d'autres données dépendant des entrées : les *sorties*, on parle alors de problème de *recherche* ou de *construction*.

■ **Exemple 2.1** • Étant donné un entier, déterminer s'il est premier ou non.

- Étant donnés deux entiers, calculer leur PGCD.
- Étant donné un graphe pondéré et deux sommets, déterminer un chemin de longueur minimale permettant d'aller de l'un à l'autre.
- Étant un programme informatique et une entrée, déterminer si le programme va s'arrêter ou non.
- Étant donné une image et une base de donnée de visages, déterminer les personnes présentes sur l'image.

On voit que certains de ces problèmes n'ont pas eu besoin d'attendre l'informatique, comme les problèmes d'arithmétique.

On peut prouver qu'un problème comme le problème de l'arrêt ne pourra jamais être résolu par un ordinateur (on dira qu'il est *indécidable*).

1.3 Algorithme

Définition 1.3 Un *algorithme* est un procédé systématique et mécanisable permettant de résoudre un problème informatique.

Ce qu'on signifie ici par le mot *systématique* est que le procédé de calcul est précis et non ambigu et par *mécanisable* qu'il s'agit d'un calcul qui puisse être fait par une *machine* dans un sens à venir.

Une autre manière de voir les problèmes est de dire que ce sont des fonctions mathématiques des entrées vers les sorties. Un algorithme est alors une description de la réalisation d'une telle fonction.

II Modèle de calcul, Machines, Programmes

On donne ici des définitions volontairement naïves et imprécises. Elles pourraient être précisées en fixant un cadre théorique plus conséquent, ce qui est prématûr à ce stade.

Définition II.1 Un modèle de calcul est un cadre permettant de décrire comment calculer la solution de problèmes en fonction des entrées.

Définition II.2 Une *machine* est un modèle de calcul défini par un ensemble de *configurations* et des opérations élémentaires, aussi appelées *instructions*, permettant de passer d'une configuration à une autre.

Ces instructions sont regroupées sous la forme d'une suite finie appelée un *programme*.

Pour exécuter un programme, il y a dans la configuration un entier qui s'appelle le *pointeur*

d'instruction et qui donne le numéro dans le programme de l'insrtuction courante. Généralement, on part de la première instruction en passant ensuite, sauf contre-ordre, à l'instruction suivante, jusqu'à la fin du programme.

II.1 Exemple : ordinateur

Un ordinateur est naturellement un exemple de machine. Une configuration est la donnée de l'état des registres du processeur, de la mémoire et aussi des périphériques d'entrée-sortie. Un programme est une suite d'instructions exécutées par le processeur.

II.2 Exemple : les machines à deux compteurs

Les configurations d'une machine à deux compteurs sont des triplets (A, B, PC) où A et B sont deux compteurs entiers naturels, en général initialisés avec les entrées et dans lesquels on pourra lire les sorties, et PC est le pointeur d'instruction, initialisé à la première instruction.

Un programme est une suite finie et numérotée d'instructions élémentaires parmi les suivantes :

- INCA : incrémenter A , c'est-à-dire ajouter 1 à la valeur qu'il contient
- DECA : décrementer A , c'est-à-dire soustraire 1 à la valeur qu'il contient
- IFA $i \ j$ sauter à l'instruction numéro i si A est nul, sinon sauter à l'instruction numéro j .
- les instructions INCB, DECB et IFB $i \ j$ respectives vis-à-vis du compteur B .

Ainsi, on peut considérer le programme suivant

```

1: IFA 6 2
2: DECA
3: INCB
4: INCB
5: IFA 1 1
6: INCA
7: DECA

```

Si on initialise les compteurs (A, B) à $(n, 0)$ et qu'on exécute le programme, on obtient alors $(0, 2n)$ dans les compteurs. Ce programme réalise ainsi un doublement du compteur A et place le résultat dans le compteur B .

Exercice 2.1 1. Écrire un programme permettant de passer de la configuration (a, b) à $(0, a + b)$.
 2. Écrire un programme permettant de passer de la configuration $(n, 0)$ à $(0, 0)$ si n est pair ou $(0, 1)$ sinon.

1.

```

1: IFA 5 2
2: DECA
3: INCB
4: IFA 1 1
5: INCA
6: DECA

```

2.

```

1: IFA 7 2
2: DECA
3: IFA 6 4
4: DECA
5: IFA 1 1
6: INCA
7: INCA
8: DECA

```

II.3 Exemple : le noyau fonctionnel pur d'OCaml

On considère ici le noyau OCaml avec les entiers, leurs opérations élémentaires, les fonctions, les définitions (récursives ou non) et ce qui correspond à l'évaluation.

Ainsi le terme OCaml suivant `fun n -> 2 * n` peut être vu simplement comme prenant en entrée un entier n et renvoyant son double.

Ce qui est important ici, sans qu'on s'attarde sur la définition précise de l'évaluation, c'est de comprendre qu'il s'agit d'un modèle de calcul sans avoir de notion de machine, d'instructions ou de programme.

Bien entendu, quand on interprète ou qu'on compile un programme OCaml, cela se passe sur un ordinateur, donc une machine.

On considère que les termes sont les programmes dans un tel langage de programmation. La différence principale entre un programme vu ainsi et un dans le sens usuel, comme un programme Python, c'est que l'on n'a pas conscience de la réalité la machine quand on programme : il n'y a pas de notion d'instructions. Bien sûr, on verra qu'il est possible de retrouver cela dans OCaml et ainsi de se ramener en terrain connu, mais c'est important de comprendre que ce noyau existe indépendamment d'une notion de machine.

■ Remarque 2.1 C'est Alonzo Church qui a défini ce noyau, qu'on appelle le λ -calcul, en 1933 alors qu'il souhaitait présenter un cadre pour exprimer les fonctions calculables. ■

II.4 Exemple : Jeu de la vie

Le jeu de la vie défini en 1970 par John Conway dans le but d'être une récréation mathématique s'est révélé être un modèle de calcul très important.

Il s'agit d'un cas particulier d'une plus grande classe de modèles de calcul appelés les **automates cellulaires**.

Une configuration du jeu de la vie est une grille bidimensionnelle de valeur booléenne. On appelle chaque case une *cellule* et on dirait que le booléen permet de déterminer si elle *vivante* ou *morte*.

L'évaluation de ce modèle consiste à définir une nouvelle configuration en appliquant la règle suivante pour chaque cellule :

- si la cellule est vivante et a deux ou trois voisines vivantes, elle reste vivante dans la nouvelle configuration, sinon elle meurt.
- si la cellule est morte, elle devient vivante si et seulement si elle a exactement trois voisines vivantes.

Quand on parle de cellules voisines, on fait référence aux huit voisines directes sur la grille (on compte ainsi les diagonales).

Le point essentiel dans cette procédure permettant de passer d'une configuration à une autre est qu'on ne modifie pas la configuration courante, tout se passe comme si chaque cellule était modifiée simultanément.

La configuration initiale est à la fois le programme et ses entrées. Un point critique ici c'est qu'il n'existe pas de notion de fin d'évaluation. En effet, même des configurations très simples n'atteignent pas un point fixe. On devra donc choisir en fonction du problème que l'on cherche à résoudre, comment déterminer la fin du calcul.

II.5 Exemple : FRACTRAN

FRACTRAN est un modèle de calcul également inventé par John Conway en 1987.

Un programme FRACTRAN est une suite finie de fractions d'entiers naturels comme :

$$P = \left(\frac{17}{91}, \frac{78}{85}, \frac{19}{51}, \frac{23}{38}, \frac{29}{33}, \frac{77}{29}, \frac{95}{23}, \frac{77}{19}, \frac{1}{17}, \frac{11}{13}, \frac{13}{11}, \frac{15}{2}, \frac{1}{7}, \frac{55}{1} \right)$$

Une entrée est un entier et pour exécuter un tel programme, on considère un entier courant n , initialisé à la valeur de l'entrée, et on parcourt les fractions de gauche à droite jusqu'à trouver une fraction $\frac{p}{q}$ tel que $n \frac{p}{q}$ soit un entier. Dans ce cas, c'est la nouvelle valeur de n et on recommence le processus. Sinon, le programme termine.

■ **Exemple 2.2** ($\frac{3}{10}, \frac{4}{3}$) sur l'entrée 14 va s'arrêter tout de suite, sur l'entrée 15, on va avoir 20, 6 puis 8 et s'arrêter. ■

Exercice 2.2 Exécuter P sur l'entrée 2 suffisamment longtemps pour noter les quatre premières puissances de 2 prises par l'entier courant. Attention, cela nécessite sûrement de programmer l'évaluation. ■

Démonstration.

On remarque que les puissances de 2 qui apparaissent sont dans l'ordre : $2^2, 2^3, 2^5, 2^7, 2^{11}, 2^{13}, \dots$. Ainsi ce programme énumère les nombres premiers. ■

Comment fonctionne FRACTRAN ? En fait, chaque fraction va être de la forme

$$\frac{p_1^{a_1} \cdots p_k^{a_k}}{q_1^{b_1} \cdots q_l^{b_l}}$$

où les p_i et les q_j sont des nombres premiers distincts.

Pour qu'on sélectionne cette fraction, il faut que n soit divisible par le dénominateur, donc si on écrit n en produit de facteurs premiers, il faut que les puissances correspondant à chaque q_i soit $\geq b_i$. On va alors les diminuer de b_i puis augmenter les puissances correspondant à chaque p_i de a_i .

Ainsi, si on considère qu'un nombre n s'écrit $n = \prod_{i \in \mathbb{N}} p_i^{a_i}$, avec les a_i presque tous nuls et $p_0 < p_1 < p_2 < \dots$ une énumération des nombres premiers, on voit qu'un nombre n'est alors qu'une configuration d'une infinité de compteurs indexés par des entiers et qui sont presque tous à 0. Une fraction est alors une règle de la forme :

$$C[i_1] \geq b_1, \dots, C[i_k] \geq b_k \rightarrow C[i_1] - b_1, \dots, C[i_k] - b_k, C[j_1] + a_1, \dots, C[j_l] + a_l$$

où on a nommé $C[0], C[1], \dots$ les compteurs.

FRACTRAN est donc une sorte de machine à compteurs dont les instructions sont exécutées comme dans un filtrage OCaml en cherchant de gauche à droite la première règle qui s'applique. Le point le plus délicat c'est que la condition permettant d'appliquer une règle est destructrice : on divise, et on ne peut pas utiliser le même compteur pour la condition et pour le résultat, car sinon on simplifierait la fraction.

■ **Remarque 2.2 Comment fonctionne le programme P ?**

Pour cela, on va réécrire P en suivant la syntaxe précédente, comme on a forcément des décrements de compteurs correspondant à la condition d'application, il est inutile de les répéter et on écrira juste

2:-2 3:-2 |> 1:+2 0:+1

pour la fraction $\frac{18}{1225} = \frac{2 \cdot 3^2}{5^2 \cdot 7^2}$ car $p_0 = 2, p_1 = 3, p_2 = 5$ et $p_3 = 7$. Par soucis de lisibilité, on peut de plus nommer les compteurs par des lettres en commençant à a et donc écrire

c-2 d-2 |> b+2 a+1

Comme les règles de P ne font intervenir que des $+1$ et des -1 , on pourra encore abréger en écrivant $a-$ plutôt que $a-1$ et $b+$ plutôt que $b+1$.

Ainsi, P devient la suite de règles suivantes (numérotées pour y faire référence ensuite).

```

0: d-f- |> g+
1: c-g- |> a+b+f+
2: b-g- |> h+
3: a-h- |> i+
4: b-e- |> j+
5: j- |> d+e+
6: i- |> c+h+
7: h- |> d+e+
8: g- |>
9: f- |> e+
10: e- |> f+
11: a- |> b+c+
12: d- |>
13: |> c+e+

```

On commence avec la configuration $n = 2 = 2^1$ donc uniquement 1 dans le compteur a et 0 dans les autres. On notera

$a : 1$

cette configuration.

On remarque donc que si on a la configuration

$a : n - 1$

on va appliquer la règle 11 jusqu'à obtenir la configuration

$b : n - 1, c : n - 1$

Ensuite, on applique la règle 13 puis successivement les règles 4 et 5 jusqu'à être dans la configuration

$c : n, d : n - 1, e : 1$

La règle 10 permet de passer à

$c : n, d : n - 1, f : 1$

On va effectuer une succession de règle afin de déterminer si $n - 1$ divise n . En fait, cette succession de règle va déterminer si d divise c . Imaginons donc qu'on a la configuration

$$c : n, d : m, f : 1$$

on applique successivement les règles 0 et 1 pour obtenir la configuration

$$a : m, b : m, c : n - m, f : 1$$

La règle 9 s'applique alors pour passer à

$$a : m, b : m, c : n - m, e : 1$$

et on effectue alors la succession des règles 4 et 5 qu'on a déjà vu pour passer à

$$a : m, c : n - m, d : m, e : 1$$

Comme il n'y a plus rien dans b c'est la règle 10 qui s'applique et on repasse à

$$a : m, c : n - m, d : m, f : 1$$

On repasse alors dans les règles 0 et 1 jusqu'à obtenir

$$a : 2m, b : m, c : n - 2m, f : 1$$

et ainsi de suite. Pour l'arrêt, deux cas peuvent alors se produire :

- Soit on a vidé c en effectuant la soustraction de m , ce qui correspond au cas où m ne divise pas n , et alors la règle 1 ne pourra plus s'appliquer car elle nécessite $c \geq 1$. Si $n = qm + r$ avec $0 < r < n$, on aboutit alors avec une dernière application de 0 en

$$a : n, b : r, d : m - r - 1, g : 1$$

Comme la règle 1 ne s'applique plus, on passe alors à la règle 2 vers

$$a : n, b : r, d : m - r - 1, h : 1$$

on enchaîne alors les règles 3 et 6 jusqu'à obtenir la configuration

$$b : r - 1, c : n, d : m - r - 1, h : 1$$

On ne peut alors qu'applicquer la règle 7 qui permet de passer à

$$b : r - 1, c : n, d : m - r, e : 1$$

puis l'alternance 4 et 5 transfère b dans d vers

$$c : n, d : m - 1, e : 1$$

Dans ce cas, si on a $m - 1 > 0$ et on va alors repasser dans la règle 10 pour tester la divisibilité de n par $m - 1$. Mais ce qui est subtil ici, c'est que le cas $m - 1 = 0$ a déjà été pris en compte car il correspond à $m = 1$, c'est-à-dire à une divisibilité qui aboutit forcément et qui est donc traité par le cas suivant.

- Soit m divise n , donc $n = km$ et on va aboutir forcément par soustraction après une règle 0 à une configuration de la forme

$$a : n, d : m - 1, g : 1$$

Donc, contrairement au cas précédent, la règle 2 ne s'applique pas car $b = 0$. On passe donc à la règle 8 qui produit

$$a : n, d : m - 1$$

C'est ici qu'on peut produire un nombre premier, car si $m - 1 = 0$, cela veut dire que la seule divisibilité s'est produite pour 1, donc que n est premier. Or, on a alors uniquement n dans le compteur a , et ainsi ça correspond au 2^n .

On poursuit alors par une étape de nettoyage pour passer à l'entier $n + 1$ et continuer. Pour cela, on applique la règle 11 comme précédemment. Le seul changement c'est qu'avant de passer à la règle 13, on va appliquer la règle 12 pour vider le compteur d .

Ainsi, ce programme pourrait être traduit par le code Python suivant :

```

Python
a = 1
while True:
    a = a+1
    for d in reversed(range(1,a)):
        b = a
        reste = False
        while b != 0:
            for i in range(d):
                if b == 0:
                    reste = True
                    break
                b = b-1
            if not reste:
                break
        if d == 1:
            print(a, 'est premier')
```

II.6 Modèle Turing complets

Tous les exemples présentés ci-dessus sont équivalents : ils permettent de calculer les mêmes fonctions mathématiques pourvu qu'on précise la manière dont on donne l'entrée et comment on lit la sortie.

Par exemple, s'il n'est pas possible de réaliser l'incrémentation en FRACTRAN, il est possible d'écrire un programme permettant de passer de 2^a à 3^{a+1} .

On dit que ces modèles sont **Turing-complet** en référence au modèle de calcul de référence : les machines de Turing.

III Langages, Compilateur, Interprète

III.1 Langages

Un langage de programmation est une manière de représenter textuellement un programme. Cela peut être un programme en lien avec une notion de machine mais aussi une notion plus abstraite comme on va le voir.

Comme on l'a vu, un ordinateur est une machine. Un programme pour cette machine est ce qu'on appelle un binaire et l'ensemble des instructions s'appelle le langage machine. C'est le langage naturel d'un ordinateur et il dépend de son processeur. Ainsi, un binaire pour un téléphone n'est pas directement utilisable sur son ordinateur, car les premiers ont des processeurs utilisant un jeu d'instructions arm et les seconds un jeu d'instructions x86_64.

III.2 Compilateur

Un **compilateur** est un traducteur d'un langage à un autre. On considère le plus souvent des compilateurs vers un langage machine, qu'il soit lié à des processeurs réels ou une machine spécifique appelée une machine virtuelle.

III.3 Interprète

Un interprète est un programme qui va lire un programme écrit dans un langage donné et l'évaluer en interprétant les instructions. Cela diffère d'une machine virtuelle dans le fait que le programme utilise toute la richesse du langage de programmation dans lequel il a été programmé pour son interprète. De plus, le fait de ne pas passer par une machine virtuelle permet de plus facilement relier l'environnement de l'interprète et celui du langage interprété. Un autre avantage discutable et la possibilité dans le langage cible de faire référence à l'interprète. Cela permet notamment de permettre l'évaluation dynamique de code (eval en Python).

Pour autant, les interprètes ont de nombreux défauts qui font qu'on a de plus en plus recours à des compilateurs vers des machines virtuelles. Parmi ceux-ci, citons le fait de devoir relire directement le programme à chaque fois qu'on va l'exécuter, ce qui est particulièrement critique quand on veut faire appels à des fonctions définies ailleurs, ou le fait que l'interprète lui-même est souvent très verbeux.

III.4 Unité de compilation, modules

Un programme est souvent structuré sous la forme de nombreux sous-programmes reliés entre eux. C'est une bonne pratique pour regrouper des fonctions selon un même thème et permettre la réutilisation du code sans duplication. On utilise pour cela la notion de modules ou de bibliothèques. Cela correspond au niveau du programme à rajouter du code existant au moment de la compilation ou de l'interprétation. Il est alors possible de réutiliser une partie de la compilation sur ce code, et ainsi, on utilise en général une version intermédiaire qui est du code pré-compilé utilisable par un autre programme, soit en copiant le résultat dans le programme ou en faisant référence à des versions définies dans le système (bibliothèque dynamique). Un programme est chargé de faire le lien entre les différentes bibliothèques et le programme, c'est l'éditeur de liens.

IV Paradigmes

Un paradigme de programmation est une manière de concevoir des programmes. On va citer ici trois paradigmes.

IV.1 Impératif structuré

Un programme impératif est un programme construit plus ou moins directement en lien avec une notion de machines comme une suite d'instructions. Afin de permettre de programmer convenablement, un tel langage fournit une notion de structure qui permet de structurer le code. D'une certaine manière, la notion de classe et la programmation objet enrichit ce paradigme en permettant de structurer le code autour d'une notion d'objets.

IV.2 Fonctionnel déclaratif

On a vu qu'en programmation fonctionnelle, tout n'est qu'une expression, un terme, qu'on évalue. Un programme fonctionnel déclaratif est ainsi consistué d'une succession de définitions de valeurs ou de fonctions. C'est ainsi qu'en OCaml n'est qu'une suite de `let` ou `let rec`.


Comment calcule un tel programme ? En évaluant chacune des déclarations, certaines vont effectivement produire des effets de bords et permettre la lecture ou l'écriture. L'usage en OCaml est ainsi de finir un programme par une déclaration nommée `main` ou `_` qui va se charger d'appeler les déclarations précédentes.

IV.3 Programmation logique

Le paradigme de la programmation logique est sûrement le plus déroutant des trois. Un programme logique est en fait une formule logique dont une solution correspond à son résultat. Sans rentrer dans les détails, on remarquera que cela correspond à ce qu'on fait en SQL pour les bases de données où une requête de recherche est définie sous une forme de formule logique qui décrit les propriétés qui doivent être vérifiées par les éléments qu'on cherche.

Programmation

3	Introduction à la programmation (impérative)	25
I	Introduction	
II	Représenter	
III	Manipuler	
IV	Répéter	
V	Abstraire	
4	Récursivité	37
I	La récursivité	
II	L'arbre d'appels	
III	Récursivité terminale	
IV	Types inductifs et induction structurelle	
5	Type option en OCaml	41
I	Principe	
II	Syntaxe	
III	Utilisation concrète	
6	Exceptions en OCaml	45
I	Syntaxe des exceptions	
II	Exceptions pour la gestion d'erreurs	
III	Programmer avec des exceptions	



3. Introduction à la programmation (impérative)

Source de l'image : <https://www.flickr.com/photos/binaryape/5151286161/>

■ Note 3.1 Roadmap :

- finir l'écriture avec Python.
- rajouter OCaml et C.
- en profiter pour faire une introduction aux référence en OCaml quitte à rajouter une partie spécifique.
- rajouter beaucoup d'exemples et d'exercices.

Introduction

Dans ce chapitre introductif sur la programmation, on va présenter celle-ci à travers quatre notions permettant de comprendre ce que signifie programmer. Un certain soin a été porté au fait de rendre cette présentation indépendante du langage tout en permettant qu'elle serve de support pour l'apprentissage d'un langage particulier. Ainsi, les éléments propres à un langage donnée sont clairement séparé.

Comme nous l'avons vu dans le chapitre d'introduction, la programmation consiste à décrire des algorithmes et la manière dont ils sont mis en œuvre sur une machine. En cela, le modèle que l'on suit ici est celui de la programmation dite impérative structurée. Pour autant, de nombreuses notions présentées ici restent valides dans d'autres paradigmes.

La présentation faite ici est indépendante du langage sous réserve que celui-ci comporte des traits impératifs structurés. Pour autant, selon les langages certaines notions sont plus ou moins riches. Des paragraphes spécifiques complètent ainsi le texte et on encourage le lecteur à basculer d'un langage à un autre tout au long de la lecture.

OCaml est un langage qui est avant tout fonctionnel déclaratif. Pour autant, il possède des traits impératifs et permet d'écrire aussi naturellement des programmes impératifs que dans des langages comme C ou Python. Cependant, cette couche impérative se rajoute

par-dessus la couche fonctionnelle et on supposera que le lecteur la maîtrise déjà. Ainsi, dans la présentation qui suit, on se concentrera sur l'exposition spécifique des notions impératives.

1.1 Les quatre étages de la programmation

Programmer c'est

- **représenter** des données, allant du booléen valant vrai ou faux, jusqu'aux bases de données permettant de modéliser des relations complexes
- **manipuler** ces données en lien avec un environnement, ce qui signifie autant de pouvoir les stocker que de pouvoir les transformer
- **répéter** ces manipulations élémentaires, car les données sont d'une taille finie, mais non connue à l'avance
- **abstraire** les notions précédentes pour ne pas avoir à se répéter, à travers la notion de fonctions

1.2 Exemple

Prenons un exemple simple pour comprendre les différents étages où le but est final est de pouvoir calculer des sommes comme $1 + 2 + \dots + n$.

Représenter Un entier comme 3 est une donnée qu'on pourra représenter telle quelle dans la plupart des langages avec cependant des limitations à garder en tête : la mémoire étant finie, on ne peut pas représenter des entiers quelconques, car il y en a une infinité. Déjà, à ce stade, on peut se poser la question de savoir si on ne veut représenter que des entiers dans un intervalle fixe, afin de borner leur occupation mémoire, ou si on veut les représenter en arbitraire. On peut opérer sur ces entiers avec un opérateur tel que `+` pour l'addition, mais le choix de la représentation aura son importance sur ce qui se cache derrière cette opération. L'addition de deux très grands entiers en précision arbitraire prendra plus de temps.

A l'aide de cela, on peut ainsi écrire $1 + 2 + 3 + 4 + 5$.

Manipuler On peut aussi les stocker directement en mémoire à l'aide de variable. Ainsi

```
OCaml | let x = ref 3
```

permettra de définir une variable nommée `x` et contenant la valeur entière 3. On peut alors manipuler cette variable en changeant sa valeur à l'aide des opérations :

```
OCaml | x := !x + 2
```

Avec ces instructions de manipulation, on peut reprendre le calcul précédent de $1 + 2 + \dots + 5$ avec une suite d'instructions :

```
OCaml | let s = ref 0 in
      |   s := !s + 1*1;
      |   s := !s + 2*2;
      |   s := !s + 3*3;
      |   s := !s + 4*4;
      |   s := !s + 5*5
```

Répéter En fait, les 5 instructions d'ajout qu'on vient d'écrire ont la même structure : il s'agit d'ajouter une valeur i^2 à la variable `s` avec i prenant tour à tour les valeurs 1, 2, 3, 4 et 5. Une

structure comme une boucle va permettre d'éviter cette répétition et d'écrire qu'il existe une variable `i` prenant ces valeurs et les instructions à réaliser pour chaque valeur de `i`. On pourra donc écrire :

```
Ocaml | let s = ref 0 in
      for i = 1 to 5 do
        s := !s + i*i
      done
```

C'est en fait très proche de la notation $1 + 2 + \dots + 5 = \sum_{i=1}^5 i$. En fait, on cette notation mathématique est très proche d'une boucle.

Abstraire imaginons qu'on ait besoin d'effectuer le calcul précédent $\sum_{i=1}^n i^2$ à plusieurs reprises pour différentes valeurs de n , on pourrait à chaque fois recopier ces lignes en changeant la valeur maximale prise par i . Mais c'est inefficace pour plusieurs raisons :

- en recopiant du code, on risque de propager et répéter des erreurs. Si jamais on découvre une meilleure manière de faire le calcul, il faudra ainsi changer le code à chaque endroit où on l'a copié.
- là où on a besoin de ce calcul, il est possible que ce soit pour faire d'autres choses avec et donc qu'il s'inscrive dans une logique complexe. En copiant le code, on rend le programme plus compliqué à comprendre, car la boucle pour calculer cette somme est mise sur le même plan que le code qui nous intéresse.

Pour faire un parallèle avec les mathématiques, c'est comme si on recopiait une preuve dans un cas particulier chaque fois qu'on a besoin d'appliquer un théorème.

On introduit ainsi une notion d'*abstraction* *les fonctions* qui vont nous permettre de faire un code générique de calcul en prenant n en paramètre.

```
Ocaml | let somme_carres n =
      let s = ref 0 in
      for i = 1 to n do
        s := !s + i*i
      done;
      !s
```

Comme on le verra, une telle fonction est caractérisée par son nom qui nous permet d'y faire référence, comme lorsqu'on applique le théorème de Thalès, ainsi que des arguments qui seront, à l'exécution, remplacé par les valeurs qui nous intéressent, comme le fait que Thalès est démontré dans un triangle *générique* mais on l'applique sur un triangle particulier et une valeur de retour qui correspond à ce que la fonction calcule.

On peut alors, quand on a besoin de faire le calcul de $\sum_{i=1}^5 i^2$ juste écrire :

```
Ocaml | somme_carres 5
```

1.3 Se remettre sans cesse à l'ouvrage

De notre présentation *étagée*, on pourrait retenir une hiérarchisation des différents étages. Il n'en est rien.

Ainsi, autant il peut être assez direct de représenter des données, comme dans le cas précédent, autant cela peut être une étape cruciale que de choisir la meilleure représentation. C'est le cas quand on s'intéresse au choix d'une structure de données la plus adaptée ou quand on conçoit un schéma de base de données.

La programmation, et plus largement l'informatique, sont ainsi à rapprocher d'un art martial comme l'Aïkido où on travaille tout au long de sa pratique les mêmes gestes simples en se perfectionnant sans cesse. Aller au bout de ce chapitre ne sera donc pas le signe qu'on maîtrise la programmation, mais juste qu'on a fait le premier pas sur la voie du perfectionnement.

Tout au long des autres chapitres, on verra ainsi des méthodes, des notions, qui permettent de mieux comprendre et de mieux pratiquer la programmation. Mais au moment où se retrouvera à programmer, on ne sortira pas de ces quatre étages.

II Représenter

Les données sont regroupées en informatique autour de la notion de types. Un type de données peut être vu en première approximation comme un ensemble de données de même nature. On considère, par exemple, usuellement le type des entiers naturels ou celui des nombres à virgule flottante.

II.1 Les données simples

Les données les plus simples sont celles qui correspondent à des valeurs numériques. Elles dépendent assez souvent des langages de programmation, mais on retrouve toujours un type pour les booléens, un type pour les entiers et un type pour les nombres à virgule flottante, c'est-à-dire pour des représentations de certains nombres réels.

Ocaml

II.2 Les données composées ou structurées

Les données simples permettent de tout représenter. En effet, l'élément de donnée le plus primitif est le bit qui correspond à un booléen. Ainsi, la mémoire d'un ordinateur est entièrement constituée de booléens. Mais en disant cela, on ne dit pas grand-chose, car il ne s'agit pas d'une soupe informe de booléens, mais d'une organisation structurée. C'est ainsi qu'on considère des données composées comme les tableaux ou les couples.

On distingue deux types de données composées :

- les données *immuables*, c'est-à-dire celles qui ne permettent pas de changer les valeurs qu'elles regroupent ni leur structure après leur création
- les données *mutables* qui le permettent.

Ocaml

III Manipuler

III.1 Variables

L'élément clé permettant de manipuler des valeurs est de pouvoir les placer à un endroit et de changer la valeur qui s'y trouve. C'est ce qu'on appelle une **variable**. Même si cela ne correspond pas à une réalité selon les langages, il est d'usage de considérer une variable comme une case mémoire disposant d'un nom et dans laquelle on place des valeurs.

On a alors trois éléments :

- définir une variable, souvent en la limitant à un certain type de donnée, on parle de **déclaration**

- accéder à sa valeur
- changer sa valeur, on parle d'**assignation**

Les noms de variables sont le plus souvent composés de lettres, de chiffres et du symbole _, ils doivent commencer par une lettre.

OCaml

III.2 État d'exécution

L'ensemble des variables et des valeurs auxquelles elles sont associées à un moment de l'exécution d'un programme est un état d'exécution. Les instructions de déclaration et d'assignation modifient ainsi l'état.

Suite aux instructions

```
OCaml | let a = ref 3
      | let b = ref 2
```

l'état est alors

variable	valeur
a	3
b	2

Si on exécute ensuite l'instruction

```
OCaml | b := !a
```

il devient

a	3
b	3

Dans la suite, on pourra noter a=3, b=3 un tel état. Ici, le = permet une notation intuitive.

III.3 Instructions et blocs

Les programmes qu'on va écrire vont maintenant être des suites d'instructions, comme

```
OCaml | let x = ref 3 in
      | let y = ref (!x + 3) in
      | x := !y;
      | y := !x + 1
```

Ces instructions sont regroupées ensemble sous une notion de blocs. Suivant les langages, ces blocs sont plus ou moins explicites.

```
OCaml | En OCaml, il n'y a pas à proprement parler de notion de blocs car tout est une expression.
      | Cependant, l'opérateur ; permet d'évaluer successivement deux expressions. On pourra donc écrire
```

```
x := 3;
y := !x + 2;
x := !y
```

pour exécuter successivement ces instructions. On remarque que, contrairement à certains langages, ; n'est pas un séparateur mais un séparateur : il est inutile de terminer par ;. Comme la valeur des expressions à gauche de ; est perdue, on suppose qu'on ne le fait que pour des expressions dont la valeur est () : unit, c'est-à-dire pour les instructions. Si jamais on utilise ; avec une expression ayant une autre valeur à gauche, un avertissement nous indique que l'usage est problématique :

```
# 3 ; 2;;
Warning 10 [non-unit-statement]: this expression should have type unit.
- : int = 2
```

Les blocs ont souvent besoin d'être séparés du reste du programme comme on le verra dans la suite. Pour cela, comme il s'agit de simples expressions, on peut utiliser les parenthèses comme ici :

```
(x := 3;
y := !x + 2;
x := !y)
```

mais il est souvent plus clair d'utiliser la paire begin/end qui, bien qu'elle soit strictement équivalente à une paire de parenthèses, permet de faire apparaître le fait qu'on a un bloc :

```
begin
  x := 3;
  y := !x + 2;
  x := !y
end
```

Derrière cette notion de bloc on trouve une notion implicite qui est celle de flot d'exécution et qui régit la manière dont les instructions sont exécutées. En accord avec la manière dont on écrit les programmes, les instructions sont exécutées de haut en bas. L'état d'exécution est alors modifié le long du flot.

Une analogie qui sera utile dans la suite est de voir l'état d'un programme comme un train qui circule à travers les rails du flot de contrôle, en rajoutant ou modifiant des wagons à chaque instruction présentée comme un arrêt. Cette image assez naïve permet de faire passer une idée très importante qui est celle de l'ordre d'évaluation et du contexte associé.

OCaml

Un exemple important est celui de l'échange du contenu de deux variables a et b. On ne peut pas écrire

```
OCaml
b := !a;
a := !b
```

car comme on vient de le voir, la valeur de b est déjà perdue après la première assignation. Une solution consiste alors à introduire une variable temporaire qui ne va servir que de support pour pouvoir garder la valeur de b. On écrira ainsi :

```
OCaml | let temp = !b in
          b := !a;
          a := temp (* pas besoin que temp soit une ref *)
```

III.4 Portée

Une variable a une durée de vie, souvent, elle n'existe que localement dans un programme. Par exemple, uniquement au sein de la fonction ou du bloc dans laquelle on l'a définie. On parle de portée d'une variable pour désigner l'ensemble des instructions dans lesquelles ont peut y accéder.

```
OCaml |
```

III.5 Manipuler des données composées mutables

Les types de données mutables permettent de modifier leur valeur. Ce sont le plus souvent des **collections**, c'est-à-dire des arrangements structurés de valeurs, comme un tableau qui les arrange en ligne de la première à la dernière. Lorsqu'on peut faire un accès direct à une valeur, on peut alors la modifier comme si c'était une variable. Il peut également être possible de faire des modifications sur la structure de la collection elle-même, comme enlever ou rajouter des éléments.

III.5.i Modification des valeurs des éléments

```
OCaml |
```

III.5.ii Partages de valeurs composées entre plusieurs variables

Il y a une différence fondamentale entre écrire

```
Python | a = 3
          b = a
          a = 2
```

et écrire


```
Python | a = [ 3 ]
          b = a
          a[0] = 2
```

Dans le premier cas, lors de l'assignation `b = a`, il n'y a pas de lien entre la valeur 3 dans `a` et celle dans `b`. Dans le second cas, après `b = a`, on a `b` et `a` qui pointent vers le même tableau. On notera `b, a = [3]` cet état. Ainsi, quand on exécute l'instruction `a[0] = 2` on modifie le tableau qui est également associé à `b`. Donc `a` et `b` sont associées au tableau `[2]`.

En fait, quand on écrit `a = [3]`, on ne stocke pas la valeur du tableau dans `a`. On crée le tableau `[3]` en mémoire et on place dans `a` une référence vers ce tableau. Quand on exécute alors `b = a`, on place dans `b` une autre référence mais vers le même tableau. Une manière simple de voir cela est de représenter les références par des flèches, ainsi l'état pourrait en fait se représenter ainsi :




Si on considère un tableau de tableau comme [[0], [1]] on aura alors dans les cases du tableau principal des références vers les deux tableaux [0] et [1] :



Ainsi, si on écrit

```
Python | t = [ [ 0 ], [ 1 ] ]
t[1] = t[0]
t[1][0] = 2
```

on aura alors les deux références qui pointent vers le même tableau, et quand on modifie $t[1][0]$, on modifie donc forcément $t[0][0]$ également pour aboutir à l'état :



On peut remarquer que plus rien ne fait référence ici au tableau [1]. Il y a un mécanisme dans Python qui détecte cela et qui supprime de la mémoire le tableau.

Ce qui vient d'être dit pour les tableaux en Python est encore vrai avec le dictionnaires, et plus généralement avec la plupart des données.

III.5.iii Modification de la structure des données composées

Pour parler de modification de tableaux ou de dictionnaires, il est nécessaire de comprendre que Python est un langage objet. On se contentera ici de dire qu'un objet est une donnée munie d'opérations de manipulation sur cette donnée.

Ainsi, si t est un tableau, on pourra écrire $t.append(x)$ pour ajouter la valeur x comme une nouvelle case à la fin du tableau. $t.append(x)$ est une instruction, elle ne renvoie pas un nouveau tableau avec cette modification mais elle modifie directement t . On dit que `.append` est une **méthode** de la **classe** `list` de t . Il est tout à fait possible d'utiliser Python sans écrire de classes, mais dans la mesure où c'est un langage objet dans son cœur, on manipulera forcément des objets.

Par exemple, la suite d'instructions :

```
Python | t = []
t.append(2)
t.append(3)
```

va faire passer l'état de $t = []$ à $t = [2]$ puis $t = [2, 3]$.

Il existe beaucoup de méthodes pour les types `list` et `dict`. On les verra selon les besoins dans la suite. Il est toutefois possible, et souhaitable, de se référer à la documentation pour avoir une description détaillée de celles-ci.

III.6 Instruction conditionnelle

L'instruction conditionnelle va permettre d'enrichir le flot de contrôle avec des branchements. Elle permet d'orienter le flot d'exécution dans un bloc ou dans un autre selon qu'une condition soit vérifiée ou non.


On écrit

En OCaml il y a des expressions conditionnelles qui ont déjà été vues mais qui maintenant prennent une autre signification avec des expressions contenant des instructions. Dans le contexte de la programmation impérative, on pourra utiliser `begin/end` pour accentuer les différences :

```
if condition
then
begin
  (* bloc si la condition
  est vérifiée *)
end
else
begin
  (* bloc si la condition
  n'est pas vérifiée *)
end
```


OCaml

Si on reprend l'analogie des trains et des rails, une instruction conditionnelle est un échangeur qui, selon que le train vérifie ou pas la condition va le faire circuler dans une branche ou une autre. Il est important de comprendre qu'une fois une branche exécutée, les flots se rejoignent sur l'instruction qui suit l'instruction conditionnelle.



Il arrive qu'on n'ait rien à faire dans une branche, on peut alors placer un bloc vide, mais, en général, on préfère, quitte à nier la condition, ne pas écrire de `else` comme dans :

```
Python if condition:
    # bloc si la
    # condition est vérifiée
    # le flot saute directement ici si
    # la condition n'est pas vérifiée
```



■ **Remarque 3.1** En Python, un bloc vide se note `pass` comme dans le programme suivant :

```
Python if x == 3:
    y = y + 1 # incrémente y si x vaut 3
else:
    pass # ne fait rien sinon
```

qu'on aurait pu écrire :

```
Python if x == 3:
    y = y + 1 # incrémente y si x vaut 3
```

On pourrait être tenter d'écrire l'instruction a priori inoffensive `y = y` dans le bloc du `else`, mais une telle assignation n'est jamais gratuite. En effet, pour certaines données, il peut se produire une duplication coûteuse pour la réaliser et c'est une bonne pratique de ne pas écrire des opérations qui, si pour nous elles ne font rien comme `y = y + 0`, peuvent en fait avoir un coût caché.

Une principe clé de la programmation est la compositionnalité des instructions de gestion de flot : on peut placer des instructions conditionnelles dans le corps d'une des branches. On pourra donc écrire

Python

```

if condition1:
    if condition2:
        # bloc si condition 1 et condition 2 sont vérifiées
    else:
        # bloc si condition 1 est vérifiée mais condition 2 ne l'est pas
else:
    if condition2:
        # bloc si condition 1 n'est pas vérifiée et condition 2 l'est
    else:
        # bloc si condition 1 et condition 2 ne le sont pas

```

III.6.i Conditions et opérations sur les booléens

Le rôle des conditions est central dans l'usage des instructions conditionnelles et ainsi c'est très important de bien comprendre le fonctionnement des booléens et de leurs opérations.

Une condition est une formule logique constituée

- de formules atomiques portant sur l'état comme $x == 3$, $x < 2$, ...
- d'opérateurs booléens pour relier ces formules : not, and ou or

III.6.ii Inversion de point de vue par rapport aux mathématiques

En mathématiques, il est courant d'avoir des définitions de valeurs par cas. Par exemple, on pourrait écrire

$$x = \begin{cases} \frac{y}{2} & \text{si } y \text{ pair} \\ \frac{y-1}{2} & \text{sinon.} \end{cases}$$

On pourrait le traduire alors aisément ainsi :

Python

```

if y % 2 == 0:
    x = y / 2
else:
    x = (y-1) / 2

```

Mais en faisant cela, on a inversé le point de vue en plaçant la condition avant l'affectation de x .

III.6.iii Instructions conditionnelles en cascade**III.7 Entrées et sorties****IV Répéter**


Jusqu'ici, on a vu des instructions permettant de manipuler l'état d'exécution, éventuellement de manière différente selon sa valeur à l'aide d'instructions conditionnelles. Mais étant donné un état de départ, on connaît déjà les instructions qui seront exécutées et surtout **on connaît leur nombre** qui est majoré par le nombre total d'instructions. En effet, pour reprendre l'analogie des trains, ceux-ci ne font que descendre le long du flot et le nombre d'arrêts rencontrés est majoré par le nombre d'arrêts total.

Cependant, la force principale de l'informatique vient du fait qu'on peut, à l'aide d'un nombre d'instructions fini, avoir la potentialité d'exécuter un nombre arbitrairement grand d'instructions. A cette fin, nous allons introduire un élément fondamental : la notion de répétition ou de boucles.

On pourrait être étonné de la formulation précédente sur ce nombre arbitrairement grand car la mémoire, et même le temps d'exécution en pratique, étant fini, tout est borné. Si on consi-

dère un programme qui va calculer la somme des éléments d'un tableau et qu'on sait que la longueur d'un tel tableau est majorée, on pourrait imaginer une énorme boucle conditionnelle

- IV.1 Répéter n fois**
- IV.2 Répéter pour chaque élément**
- IV.2.i Accumulateur**
- IV.2.ii Drapeau**
- IV.3 Répéter tant qu'une condition est vérifiée**
- IV.4 Choisir la structure de boucle adaptée**
- IV.5 Boucles imbriquées et dimensionnalité**
- V Abstraire**
- V.1 Définir et appeler des fonctions**
- V.2 Action d'une fonction et valeur de retour**
- V.3 Fonctions et portée**
- V.4 Structurer des programmes avec des fonctions**
- V.5 Les fonctions comme valeurs**



4. Récursivité

Source de l'image d'en-tête : Paul Noth. À changer par une image CC

■ Note 4.1 Roadmap :

- finir l'écriture.

I | La récursivité

1.1 Principe et exemples

On dit qu'une fonction est récursive lorsqu'elle va s'appeler elle-même lors de son exécution. Le plus souvent, cet appel sera directement visible depuis le corps de la fonction.

Par exemple, la fonction `fact` suivante permettant de calculer $n!$ est récursive :

OCaml
`let rec fact n =
 if n = 0
 then 1
 else n * fact (n-1)`

On utilise ici un exemple mathématique pour la simplicité des fonctions écrites. En effet, on ne voit rien d'autre dans `fact` que ces appels récursifs et ils correspondent directement à la définition mathématique :

$$n! = \begin{cases} 1 & \text{si } n = 0 \\ n \times (n - 1)! & \text{sinon.} \end{cases}$$

■ Remarque 4.1 En fait, la définition mathématique se fait plutôt en posant :

$$0! = 1 \quad (n + 1)! = (n + 1) \times n!$$


Donc, pour retraduire une telle définition en tant que fonction, il est souvent nécessaire de décaler les rangs.

On remarque tout de suite deux choses :

- il y a un valeur pour laquelle on ne fait aucun appel
- dans les autres cas, quand on fait un appel, l'argument $n - 1$ diminue strictement.

Cela permet d'être sûr qu'on ne va pas s'arrêter indéfiniment. On verra dans la suite comment on peut s'en assurer pour des fonctions plus complexes.

Quand on évalue `fact 5` on va effectuer une série d'appels :



Pour calculer la valeur il faut descendre le long des appels récursifs jusqu'à tomber sur un cas de base puis remonter.

1.2 Implémentation pratique

Comme on vient de le voir, pour calculer une valeur avec une fonction récursive, il est nécessaire de remonter. Pour cela, on a besoin d'interrompre l'évaluation d'une fonction le temps que l'appel récursif se termine, puis de revenir dans l'évaluation là où on en était. On parle alors de contexte d'évaluation ou contexte d'exécution pour l'information qu'il faut sauvegarder afin de reprendre là où on en était. En première approximation, on peut se dire qu'un contexte est la donnée de la position de l'instruction courante, ou de la sous-expression en train d'être évaluée si on raisonne en fonctionnel, ainsi que de l'ensemble des valeurs des variables locales. Il est donc nécessaire de sauvegarder la succession des contextes tout au long des appels récursifs.

On remarque que ce mécanisme est déjà présent pour n'importe quel appel de fonction. La différence principale avec la récursivité, c'est que le nombre d'appels imbriqués à tout moment du programme n'est pas borné à priori, il dépend des paramètres récursifs, et donc il ne peut être connu qu'à l'exécution. On a ainsi besoin d'un mécanisme qui permettent de stocker un nombre quelconque de contextes.

Pour cela, on passe par ce qu'on appelle la pile d'appels. On verra plus tard qu'elle peut être organisée de manière très efficace pour des programmes binaires, mais pour le moment, on se contente d'imaginer que cette pile est vide au début de l'évaluation, puis, à chaque appel, on **empile** le contexte courant, on exécute l'appel, une fois la valeur de retour obtenue, on **dépile** le contexte pour reprendre l'exécution là où on en était avant l'appel mais avec cette valeur de retour calculée.

- I.3 Programmer en récursif
- I.4 Récursivité croisée
- II L'arbre d'appels
 - II.1 Définition
 - II.2 Complexité en nombre d'appels
 - II.3 Terminaison
- III Récursivité terminale
 - III.1 Présentation
 - III.2 Optimisation
 - III.3 Techniques
- IV Types inductifs et induction structurelle
 - IV.1 Définition naïve des types inductifs



OCaml

5. Type option en OCaml

I Principie

Dans de très nombreux contextes, on a besoin de pouvoir exprimer une notion de partialité en programmant. Cela apparaît en général dans deux cas :

- On veut réaliser une fonction qui ne va pas pouvoir renvoyer une valeur dans tous les cas. Exemple : renvoyer la tête d'une liste chaînée ne fonctionne pas si on passe la liste vide. La fonction est en fait une fonction partielle au sens mathématiques
- On souhaite construire progressivement une donnée et il faut qu'on puisse avoir une notion de valeurs indéterminées. Exemple : on veut remplir au fur et à mesure une grille de Sudoku, à la fin, c'est une matrice de nombres, mais il faut pouvoir gérer les cases vides de manière intermédiaires.

En C, on résout ces questions en utilisant des valeurs comme -1 ou le pointeur nul NULL. En OCaml, le système de types nous pousse à chercher une meilleure solution.

II Syntaxe

La solution en OCaml est très simple, mais demande de la pratique pour l'utiliser à bon escient. Il s'agit, pour tout type 'a de définir un type 'a option permettant de représenter, soit une valeur de type 'a, soit une absence de valeur.

Ce type est défini ainsi :

```
OCaml | type 'a option = None | Some of 'a
```

Cela signifie qu'on a remplacé les valeurs b par des valeurs Some b et que l'absence de valeur est maintenant une vraie valeur None.

Aucune difficulté pour définir une valeur de type option, on se contente d'appeler un des deux constructeurs. Ainsi Some 1 est un int option et Some "test" un string option. La valeur None est polymorphe dans le même sens que [].

Pour manipuler une valeur `o` du type `'a option`, on effectue un filtrage comme pour les autres types somme :

```
OCaml | match o with
| None -> (* ... *)
| Some a -> (* ici on peut accéder au contenu a *)
```

Il est également possible de revenir sur le comportement précédent avec une fonction comme

```
OCaml | let unwrap o =
|       match o with
|       | None -> failwith "None"
|       | Some a -> a
```

Qui permet de déballer une valeur `'a option` en faisant l'hypothèse que ce n'est pas `None`.

■ **Remarque 5.1** Une erreur classique avec le type `option`, qui est la même qu'avec le type `list`, c'est de se focaliser sur `None` en commençant par écrire :

```
OCaml | if o = None
|       then (* .. *)
|       else (* et ici on est bloqué, car o est emballé *)
```

Donc, une règle : si on a une valeur `option`, on effectue un filtrage ! ■

III Utilisation concrète

III.1 Définir une fonction partielle

Il se trouve qu'on a déjà vu un mécanisme permettant de définir une fonction qui peut échouer : les exceptions, notamment avec `failwith`. Si on considère une fonction $f : 'a \rightarrow 'b$ on a ainsi deux types de valeurs dans le type `'a` :

- Les valeurs x qui permettent d'obtenir une valeur $f x$ du type `'b`
- Les valeurs y pour lesquelles $f y$ produit une erreur.

Schématiquement, si note A les valeurs du type `'a`, on a donc $A = A_s \cup A_e$ où l'union est disjointe et A_s sont les valeurs pour lesquelles f ne produit pas d'erreurs et A_e les valeurs produisant des erreurs. Si on prend la définition usuelle de fonctions en mathématiques, A_s est le domaine de f et on considère en fait une **application** de A_s dans B les valeurs du type `'b`.

L'idée avec le type `option`, c'est de transformer toute fonction partielle $f : A \rightarrow B$ en une application $f^* : A \rightarrow B \cup \{\star\}$ où \star est un élément spécial $\star \notin B$ qui correspond à une **valeur erreur**. Cela correspond à une *réification* de l'erreur au rang de valeur. L'application f^* est ainsi définie :

$$f^* : A \rightarrow B \cup \{\star\}$$

$$a \mapsto \begin{cases} f(a) & \text{si } a \in A_s \\ \star & \text{si } a \in A_e \end{cases}$$

La valeur \star est ce qu'on appelle un *puit*, c'est ici qu'on redirige toutes les entrées invalides.

Il n'y a pas de type correspondant directement à l'union $B \cup \{\star\}$ en OCaml et c'est pour cela qu'on utilise le type `'b option` qui nous force à *emballer* un retour.

Ainsi à chaque fois qu'on aurait renvoyé une valeur `b`, on va renvoyer plutôt une valeur `Some b`, et à la place de produire une erreur, on renvoie `None`.

Par exemple, le code suivant :

```
Ocaml let tete l =
  match l with
  | t :: q -> t
  | [] -> failwith "Liste vide"
```

va s'écrire

```
Ocaml let tete_opt l =
  match l with
  | t :: q -> Some t
  | [] -> None
```

III.2 Appeler une fonction partielle

Pour appeler une fonction partielle, il n'y a pas de difficulté, il suffit de faire l'appel de fonction et de manipuler ensuite le type option comme vu plus haut. Cela signifie qu'on effectuera en général l'appel directement dans l'expression d'un filtrage :

```
Ocaml match f a with
| None -> (* ... *)
| Some b -> (* ... *)
```

III.3 Données partielles

Pour tout type polymorphe '`a` `t`' on peut en déduire un type partiel '`a` `option t`' dans lequel les valeurs peuvent ne pas être définies. Ainsi, un `int option array` permettra pour chaque case du tableau de :

- soit être définie, et ce sera alors une valeur de la forme `Some k` où `k` est un `int`,
- soit être indéfinie avec la valeur `None`.

Ainsi, une grille de Sudoku qu'on remplirait progressivement aurait le type `int option array array`. Une case valant `None` signifiant qu'elle n'est pas encore remplie. Bien entendu, une fois la grille remplie, toutes les valeurs seraient de la forme `Some k`. On peut ainsi imaginer une transformation de `int option array array` vers `int array array` consistant à passer d'une grille pouvant être partielle, mais pleinement remplie à une grille d'entiers :


```
Ocaml let grille_complete go =
  let g = Array.make_matrix 9 9 0 in
  for i = 0 to 8 do
    for j = 0 to 8 do
      match go.(i).(j) with
      | None -> failwith "Grille incomplète"
      | Some k -> g.(i).(j) <- k
    done
  done;
  g
```

III.4 Chaîne de traitement

On pourrait se dire que le type `option` n'est qu'en fait une version un peu lourde de la production d'erreurs. Mais en fait, la force du type `option` est justement que c'est un type comme

un autre. Cela permet d'effectuer de nombreux traitements en manipulant des fonctions partielles pour définir des données partielles et d'attendre uniquement au dernier moment pour déballer les valeurs. L'idée forte est de manipuler la partialité naturellement.

Un exemple cela peut-être d'avoir une série de traitement à appliquer sur une liste, chaque traitement va possiblement faire apparaître des `None` qu'on va traiter naturellement avec éventuellement une étape finale pour retirer les options :



On remarque que ce style de programmation est de plus en plus privilégié par la bibliothèque standard de OCaml :

- de nombreuses fonctions partielles `f : 'a -> 'b` ont une variante `f_opt : 'a -> 'b option`
- il y a des fonctions manipulant directement des `_opt` comme `List.filter_map` qui effectue un `map` avec une fonction `'a -> 'b option` et filtre les `None` en sortie.
- Le nouveau module `Option` contient beaucoup de fonctions pour se simplifier la vie quand on programme avec les types `option`. **Attention**, cela correspond à une utilisation bien plus pointue de OCaml que dans le reste de ce cours. Notamment, cela fait beaucoup de sens en lien avec l'opérateur `|>` qu'on n'utilise pas ici.



OCaml

6. Exceptions en OCaml

Les exceptions sont un mécanisme présent dans de nombreux langages de programmation afin de permettre à la fois d'indiquer qu'une erreur s'est produite en interrompant l'exécution d'une fonction et aussi de pouvoir, pour l'appelant **rattraper** cette erreur afin de poursuivre l'exécution comme il se doit.

En OCaml, ce mécanisme va permettre, de plus, de pouvoir interrompre le flot de contrôle, notamment de retrouver des mécanismes comme `break`, `continue` et surtout `return`.

Syntaxe des exceptions

Les exceptions forment un type `exn` qui est extensible : il est possible de rajouter un nouveau constructeur pour ce type en écrivant :

```
OCaml (* Pour une exception sans paramètre *)
exception NomDeLException

(* Pour une exception avec paramètre de type t*)
exception NomDeLException of t
```

On peut alors **lancer** cette exception à l'aide de `raise` :

```
OCaml (* Pour une exception sans paramètre *)
raise NomDeLException

(* Pour une exception avec paramètre de valeur v *)
(* Attention aux parenthèses *)
raise (NomDeLException v)
```

Il est possible d'évaluer une expression en permettant d'évaluer une autre expression en cas d'exception :

```
try
  expression
with ExceptionsA attraper -> expression'
```

En fait, ce `with` est un filtrage, un `match`, sur les valeurs du type `exn` mais sans vérification d'exhaustivité. On peut donc effectuer plusieurs cas :

```
try
  expression
with motif1 -> expr1
| motif2 -> expr2
| ...
```

En cas de `try...with` imbriqués, c'est le `try` le plus proche de l'exception qui la rattrape. Si une exception n'est pas rattrapée, elle va produire une erreur qui stoppera l'exécution d'un programme. On peut très bien lancer une exception depuis un `with ... ->`.

II Exceptions pour la gestion d'erreurs

Il s'agit ici de l'utilisation la plus *logique* des exceptions.

On a déjà pu rencontrer des exceptions en OCaml :

```
# let t = [|1;2|];;
val t : int array = [|1; 2|]
# t.(2);;
Exception: Invalid_argument "index out of bounds".
# List.hd [];;
Exception: Failure "hd".
```

Dans les deux cas, ces exceptions sont plutôt le signe d'une erreur de programmation qu'il faut corriger qu'un comportement limite qu'il faudrait prendre en compte. Dans le cas d'une fonction comme `List.hd`, on a également vu qu'il était préférable d'utiliser un type option pour pouvoir gérer l'erreur derrière avec :

```
let hd_opt l =
  match l with
  | [] -> None
  | t :: _ -> Some t
```

Pour autant, il y a des erreurs importantes à gérer en OCaml, ce sont celles qui sont inévitables quand il n'est pas possible de prévoir si un opération va réussir. Citons deux cas :

- la lecture d'un fichier va produire une exception `End_of_file` une fois atteinte la fin de celui-ci;
- des structures de données qui ne fournissent comme seul moyen efficace de savoir si elles sont vides que d'essayer d'en extraire un élément et d'échouer.

Ainsi, dans le premier cas, on pourra écrire une fonction comme :

```
let rec input_all_lines ic =
  try
    let l = input_line ic in
    l :: input_all_lines ic
  with End_of_file -> []
```

Cette fonction prend un `input_channel` et renvoie toutes les lignes qu'il contient sous la forme d'une liste. Le ratrappage d'exception est crucial, c'est lui qui permet d'avoir un cas de base pour la récurrence.

■ **Remarque 6.1 Attention**, on peut être tenté d'écrire :

```
OCaml let rec input_all_lines ic =
  try
    input_line ic :: input_all_lines ic
  with End_of_file -> []
```

Or, il se trouve que OCaml évalue tous les arguments du constructeur `::` et il le fait de la droite vers la gauche. Le code précédent va donc effectuer des appels récursifs sans jamais lire une seule ligne.

III Programmer avec des exceptions

III.1 Retour prématûré

Si on considère le programme C suivant :

```
C int recherche_element(int t[],
                      unsigned int nb_elts, int x)
{
    for(int i = 0; i < nb_elts; i++)
        if(t[i] == x)
            return i;
    return -1;
}
```

On peut l'écrire sous la forme suivante en OCaml :

```
OCaml let recherche_element t x =
  let indice = ref None in
  for i = 0 to Array.length t - 1 do
    if !indice = None && t.(i) = x
      then indice := Some i
  done;
  !indice
```

Cela correspond à ce qu'on aurait fait en C pour se passer du `return` dans la boucle mais cela présente plusieurs problèmes :

- on inhibe les itérations d'une boucle explicitement;
- avec plusieurs boucles imbriquées, c'est peu lisible.

Notons que cette interruption du flux de contrôle est très naturelle dans un langage utilisant beaucoup la récursivité. Le code suivant récursif suivant a la même structure que le code C :

```
OCaml let recherche_element t x =
  let rec rech_aux i =
    if i = Array.length t
    then None
    else if t.(i) = x then Some i
    else rech_aux (i+1)
```

```
OCaml |   in rech_aux 0
```

En effet, on remarque deux feuilles possibles pour l'arbre d'appels récursifs : soit `None` en fin de tableau, soit `Some i` quand on a trouvé l'élément.

Traduire des programmes impératifs sous cette forme est également peu satisfaisant.

À l'aide des exceptions, on peut retrouver exactement la structure du code C initiale ainsi :

```
exception Trouve of int

let recherche_element t x =
  try
    for i = 0 to Array.length t - 1 do
      if t.(i) = x
      then raise (Trouve i)
    done;
    None
  with Trouve i -> Some i
```

Ou même, en utilisant l'exception `Not_found` prédéfinie :

```
exception Trouve of int

let recherche_element t x =
  try
    for i = 0 to Array.length t - 1 do
      if t.(i) = x
      then raise (Trouve i)
    done;
    raise Not_found
  with Trouve i -> i
```

L'expression `raise (Trouve i)` est ainsi exactement le pendant du `return i;`.

Au lieu d'écrire

```
OCaml | ...  
      | return v  
      | ...
```

on écrit

```
OCaml | try  
      | ...  
      | raise (Return v)  
      | ...  
      | failwith "Unreachable"  
      | with Return v -> v
```

III.1.i break et continue

On a déjà vu que `break` permettait de sortir d'une boucle et `continue` de passer à l'itération suivante.

Retrouver ces mécanismes avec OCaml est plus anecdotiques mais on peut le faire. On définit tout d'abord deux exceptions :

```
OCaml | exception Break
      | exception Continue
```

Pour un `break` dans une boucle

Au lieu d'écrire

```
OCaml | for ... do  
      | ...  
      | break  
      | ...  
      | done
```

on écrit

```
try  
for ... do  
...  
raise Break (* sortie *)  
...  
done  
with Break -> ()
```

Et pour un `continue`:

Au lieu d'écrire


```
OCaml | for ... do  
      | ...  
      | continue  
      | ...  
      | done
```

on écrit

```
for ... do  
try  
...  
raise Continue  
...  
with Continue -> ()  
done
```


Structures de données

7	Structures de données abstraites et implémentations	53
I	Introduction	
II	Structure de données abstraite	
8	Séquences et ses implémentations : tableaux, listes chaînées	55
I	Structure abstraite séquence ou liste	
II	Implémentations	
III	Implémentations concrètes des Listes chaînées	
IV	Travaux pratiques	
9	Piles et files : structures abstraites et implémentations	83
I	Piles	
II	Files	
10	Arbres	89
I	Arbres binaires	
II	Arbres	
III	Parcours	
IV	Arbres binaires de recherche	
V	Tas	
VI	TP - Arbres en OCaml	
11	Graphes	111
I	Graphes	



7. Structures de données abstraites et implémentations

I Introduction

On va étudier dans ce chapitre la notion de structures de données. Une structure de données est une manière de stocker des données et d'interagir avec elles. On peut regrouper de grandes classes de structures données en faisant abstraction de la manière dont les données sont stockées en se concentrant uniquement sur les interactions possibles. Cela permet de définir la notion d'une structure de données abstraites.

Dans un second temps, on s'intéresse à la notion d'implémentation d'une structure de données abstraites qui correspond à un choix concret de stockage et donc à une réalisation de l'interface attendue.

II Structure de données abstraite

Définition II.1 On appelle *structure de données abstraite* la donnée d'un type t et d'une interface



8. Séquences et ses implémentations : tableaux, listes

I Structure abstraite séquence ou liste

La structure abstraite *liste*, ou également *séquence* dans des contextes, comme en OCaml, où le terme *liste* fait références aux listes chaînées, est la structure la plus simple pour stocker des données.

Une *séquence* d'éléments de type *t* est un type *S(t)* dont les éléments représentent des valeurs du type *t* rangées séquentiellement dans un ordre, de la première à la dernière valeur. La vision logique la plus proche de cela est d'imaginer des cases ayant un indice, en commençant en général à l'indice 0, et contenant des valeurs.

II Implémentations

III Implémentations concrètes des Listes chaînées

III.1 En C

III.1.i Représentation et type

Il existe de nombreuses possibilités d'implémentation des listes chaînées en C. On présente ici les opérations autour d'une implémentation et on discutera ensuite des alternatives.


Dans les limites du programme, on ne présente que des listes permettant de contenir un même type, ici des entiers.

Une liste est ainsi un pointeur sur un maillon et un maillon est un couple (*valeur*, *suivant*) représenté dans une *struct* où *suivant* pointe vers le prochain maillon de la chaîne. Le pointeur nul, de valeur *NULL*, permet ainsi de représenter la liste vide.

```
struct maillon {
    int valeur;
    struct maillon *suivant;
};

typedef struct maillon maillon;
typedef maillon *liste;
```

On représentera graphiquement le pointeur nul par une croix et les maillons par des blocs contenant une valeur et un pointeur. Ainsi, le dernier maillon de la liste contient une croix. La liste l correspondant à la valeur qu'on pourrait noter [1, 2, 3] sera représentée ainsi :



III.1.ii Constructeur

On parle de constructeur pour des fonctions qui permettent d'allouer et d'initialiser une valeur d'une structure de donnée. Ici, comme les listes sont des pointeurs sur des maillons, il s'agit uniquement de créer un maillon. Pour cela, on va utiliser `malloc` pour allouer dynamiquement un nouveau maillon.

```
maillon *maillon_creer(int valeur, maillon *suivant)
{
    maillon *m = malloc(sizeof(maillon));
    m->valeur = valeur;
    m->suivant = suivant;
    return m;
}
```

En fait, ce constructeur pourrait être découpé en deux parties : l'allocation qui va se charger de récupérer un emplacement mémoire pour le maillon et l'initialisation qui va attribuer des valeurs.


```
maillon *maillon_allouer()
{
    return malloc(sizeof(maillon));
}

void maillon_initialiser(maillon *m, int valeur, maillon *suivant)
{
    m->valeur = valeur;
    m->suivant = suivant;
}

maillon *maillon_creer(int valeur, maillon *suivant)
{
    maillon *m = maillon_allouer();
    maillon_initialiser(m, valeur, suivant);
    return m;
}
```

On peut alors commencer à créer des listes en enchainant les maillons :

```
maillon *m1 = creer_maillon(1, NULL); // pas de suivant, c'est le dernier maillon
maillon *m2 = creer_maillon(2, m1);
maillon *m3 = creer_maillon(3, m2);
liste l = m3; // la liste pointe sur le premier maillon
```



Comme le pointeur sur le premier maillon suffit ici, on aurait pu directement écrire :

```
C | liste l = creer_maillon(3,
                           creer_maillon(2,
                                         creer_maillon(1, NULL)));
```

III.1.iii Déstructeur

Pour détruire un maillon, il suffit de libérer l'espace qu'on lui a attribué.

```
C | void maillon_detruire(maillon *m)
  {
    free(m);
  }
```

Pour détruire une liste, on va par contre avoir besoin de parcourir l'ensemble des maillons qui la constitue. Comme pour les autres parcours, on a alors deux choix :

- **parcours récursif** on a un cas de base quand la liste est vide et dans le cas général, un éventuel appel récursif sur le pointeur suivant.

```
C | void liste_detruire(liste l)
  {
    if (l != NULL)
    {
      liste_detruire(l->suivant);
      maillon_detruire(l); // Attention à l'ordre pour l->suivant
    }
  }
```

- **parcours impératif** on boucle tant que la liste est non nulle. On fait ici attention à ne pas accéder à `->suivant` après avoir libéré le maillon.

```
C | void liste_detruire(liste l)
  {
    while (l != NULL)
    {
      liste suivante = l->suivant;
      maillon_detruire(l);
      l = suivante;
    }
  }
```

III.1.iv Ajout et suppression en tête

Pour ajouter ou supprimer un maillon en tête de la liste, on va avoir besoin de modifier le pointeur vers le premier maillon. Pour cela, on a deux approches possibles :

- passer un pointeur vers la liste elle-même, c'est-à-dire un pointeur sur un pointeur sur un maillon, ce qui en C aura le type `maillon **`, qui s'écrit aussi `liste *`. On aura alors le prototype :

```
C | void liste_ajout_en_tete(liste *l, int valeur);
```


- renvoyer un pointeur vers le nouveau premier maillon. On aura alors le prototype :

```
C | liste liste_ajout_en_tete(liste l, int valeur);
```

On présente ici les versions renvoyant une nouvelle liste :


```
C | liste liste_ajout_en_tete(liste l, int valeur)
{
    maillon *m = maillon_creer(valeur, l);
    return m;
}
```

Si `l` est la liste précédente contenant 3, 2, 1 et qu'on ajoute 4 en tête, on va donc directement créer un nouveau maillon et renvoyer un pointeur vers celui-ci.



```
C | liste liste_suppr_en_tete(liste l)
{
    assert(l != NULL);
    liste queue = l->suivant;
    maillon_detruire(l); // Attention, on détruit juste le maillon, pas la liste
    return queue;
}
```

Si `l` est la liste précédente contenant 3, 2, 1 et qu'on supprime le maillon de tête, on va renvoyer un pointeur sur le second maillon. **Attention**, ici le pointeur initial `l` est devenu invalide.



III.1.v Longueur de la liste

On présente ici le calcul de la longueur comme exemple de parcours de la liste. C'est encore très proche du parcours effectué dans le destructeur.

```
C | int liste_longueur(liste l)
{
    int longueur = 0;
    while(l != NULL)
    {
        longueur = longueur + 1;
        l = l->suivant;
    }
    return longueur;
}
```

III.1.vi Accès au *nième* maillon de la liste

On effectue un parcours similaire pour accéder au *nième* maillon.

```
C maillon *liste_nieme(liste l, int n)
{
    while(n > 0)
    {
        assert(l != NULL);
        l = l->suivant;
        n = n-1;
    }
    assert(l != NULL);
    return l;
}
```

Toujours avec un programme similaire, on peut chercher un maillon avec sa valeur :

```
C maillon *liste_recherche(liste l, int x)
{
    while(l != NULL && l->valeur != x)
    {
        l = l->suivant;
    }
    return l;
}
```

Ici, pas besoin d'asserts, en cas d'échec de la recherche, on renvoie un pointeur nul.

III.1.vii Ajout/Suppression ailleurs qu'en tête

Pour ajouter ou supprimer ailleurs qu'en tête, il est nécessaire de pouvoir repérer précisément un maillon. Pour cela, on peut le faire :

- par son indice, celui utilisé dans `liste_nieme`;
- par sa valeur, avec une recherche ;
- ou encore directement par un pointeur sur le maillon.

Une fois le maillon ajouté/supprimé, on peut procéder comme pour un ajout/suppression en tête, cependant il va falloir reconnecter le pointeur suivant du maillon précédent. Pour cela deux choix :

- soit on considère qu'on ajoute après, auquel cas on dispose du précédent
- soit on considère qu'on ajoute avant/supprime et pour cela on effectue une boucle pour déterminer le maillon précédent.

```
C void liste_ajout_apres(liste l, maillon *m, int x)
{
    m->suivant = liste_ajout_en_tete(m->suivant, x);
}

void liste_ajout_avant(liste l, maillon *m, int x)
{
    liste prec = NULL;


    while(l != m)
    {
        assert(l != NULL);
        prec = l;
        l = l->suivant;
    }
}
```

```


    prec->suivant = liste_ajout_en_tete(m, x);
}

```

Si on reprend la liste `l` contenant 3, 2, 1 et qu'on souhaite insérer la valeur 4 avant la valeur 1, on va passer un pointeur `m` vers le maillon contenant 1 et effectuer un parcours jusqu'à avoir `prec` et `l` dans la configuration :



On dispose alors des pointeurs permettant de réaliser l'ajout :



```

void liste_suppr_non_en_tete(liste l, maillon *m)
{
    liste prec = NULL;

    while(l != m)
    {
        assert(l != NULL);
        prec = l;
        l = l->suivant;
    }
    prec->suivant = liste_suppr_en_tete(m);
}

```

En fait, lorsqu'on regarde le parcours précédent, on remarque deux points :

- comme on a donné le maillon concerné, le parcours a uniquement pour but de repérer le maillon qui le précède;
- on pourrait se contenter d'utiliser uniquement un pointeur sur le maillon précédent lors du parcours car le maillon qui le suit est accessible avec `->suivant`.

III.1.viii Autres implémentations

Une autre implémentation standard consiste à *cacher* le pointeur sur le premier maillon, ce qui permet de donner également un pointeur sur le dernier maillon. En effet, le pointeur sur le dernier maillon permet de réaliser un ajout en fin de liste en $O(1)$ car il n'y a pas besoin de parcourir la liste pour faire cet ajout.

On obtient alors un type comme :

```

struct maillon {
    int valeur;
    struct maillon *suivant;
};

```

```
typedef struct maillon maillon;

struct liste {
    maillon *premier;
    maillon *dernier;
};

typedef struct liste liste;
```

Cette implémentation est l'occasion de se poser la question sur la répartition entre pile et tas pour les données. On peut légitimement penser que les listes ici ne sont que des couples de pointeurs, et qu'ainsi les passer par copie est léger comparativement à la complexité induite par une allocation sur le tas.

III.2 En OCaml

III.2.i Cas des 'a list

Tout d'abord, il faut se rendre compte que le type par défaut

```
type 'a list = (::) of 'a * 'list | []
```

fait intervenir des maillons et des pointeurs. La différence principale avec C est qu'on ne peut pas changer la valeur des pointeurs.

III.2.ii Type des listes chaînées

Pour retrouver la richesse du type précédent, on peut définir un type comme :

OCaml

```
type 'a maillon = {
    mutable valeur : 'a;
    mutable suivant : 'a liste
} and 'a liste = Vide | Lien of 'a maillon
```

Ici, le type est une traduction directe du type précédent. On remarque que les types sont mutuellement récursifs car un maillon contient une liste. Le type somme '`'a liste`' ressemble fortement à un pointeur qui peut être nul ou pointer sur un maillon. On remarque qu'on aurait pu aussi se contenter d'écrire le type suivant :

OCaml

```
type 'a maillon = {
    mutable valeur : 'a;
    mutable suivant : 'a maillon option
}

type 'a liste = 'a maillon option
```

Mais on va préférer le premier type qui a l'avantage de permettre de bien faire apparaître la structure.

III.2.iii Ajout et suppression en tête

Pour rajouter un maillon en tête, on peut écrire :

OCaml

```
let cons x l = Lien { valeur = x; suivant = l}
```

On remarque que la fonction est beaucoup plus simple que celle en C car l'allocation est automatique et l'initialisation se fait naturellement dans la syntaxe. Cette fonction renvoie une

nouvelle liste, on aurait pu aussi rajouter une référence pour les listes afin de permettre de les rendre modifiables, c'est la même discussion que dans la partie précédente.

La suppression en tête, cela revient à renvoyer la queue de la liste comme le fait `List.tl`:

```
OCaml | let tl l = match l with
      | Vide -> failwith "Liste vide"
      | Lien { valeur = _; suivant = q} -> q
```

On remarque le filtrage imbriqué `| Lien { valeur = t; suivant = q } ->` qui correspond au filtrage `| t :: q` du type `a list`.

III.2.iv Exemple de parcours sans modification : calcul de la longueur

Vu les remarques précédentes, il n'est pas étonnant que le parcours d'une liste de manière récursive soit très proche de ce qu'on a déjà pu voir avec les listes de base.

```
OCaml | let rec longueur l = match l with
      | Vide -> 0
      | Lien { valeur = _; suivant = q } -> 1 + longueur q
```

On en déduit de même une fonction renvoyant un maillon par son indice :

```
OCaml | let rec nieme l n = match l with
      | Vide -> failwith "Liste vide"
      | Lien m -> if n = 0 then m else nieme m.suivant (n-1)
```

■ Remarque 8.1 Il est possible de réécrire la fonction précédente en permettant à la fois de donner un nom, ici `m`, au maillon et de faire un filtrage sur ce qu'il contient. Pour cela, on utilise le mot clé `as` en OCaml :

```
OCaml | let rec nieme l n = match l with
      | Vide -> failwith "Liste vide"
      | Lien ({ valeur=_; suivant = q} as m) ->
          if n = 0 then m else nieme q (n-1)
```

III.2.v Exemple de parcours avec modification : ajout d'une maillon en fin de liste

On va montrer un exemple de modification de liste en rajoutant un maillon en fin d'une liste non vide. Ici, on effectue un parcours jusqu'à tomber sur le dernier maillon auquel on rajoute le nouveau à la suite.

```
OCaml | let rec ajout_fin l x =
        match l with
        | Vide -> failwith "Liste vide"
        | Lien m ->
            if m.suivant = Vide
            then m.suivant <- Lien { valeur = x; suivant = Vide }
            else ajout_fin m.suivant x
```

III.2.vi Raffinement pour permettre l'ajout à la fin en temps constant

Le programme précédent est à comparer au programme suivant :

```
OCaml | let rec ajout_fin l x =
        match l with
        | [] -> [x]
        | t::q -> t :: ajout_fin q x
```

On n'a pas l'impression d'avoir vraiment gagné en expressivité ou en efficacité.

Cependant, on peut se dire qu'en changeant le type '`'a liste`' on peut tirer partie des maillons pour obtenir un ajout en fin de liste en temps constant. Le programme suivant présente une interface permettant de le faire.

```
OCaml | type 'a maillon = {
          mutable valeur : 'a;
          mutable suivant : 'a maillon_ptr
        }
and 'a maillon_ptr = 'a maillon option
and 'a liste = {
          mutable premier : 'a maillon_ptr;
          mutable dernier : 'a maillon_ptr
        }

let liste_vide () = { premier = None; dernier = None }

let ajout_debut l x =
  l.premier <- Some { valeur = x; suivant = l.premier };
  if l.dernier = None
  then l.dernier <- l.premier

let suppr_debut l =
  match l.premier with
  | None -> failwith "Liste vide"
  | Some { valeur = _; suivant = l' } ->
    l.premier <- l'


let ajout_fin l x =
  let m = { valeur = x; suivant = None } in
  (match l.dernier with
  | Some m' -> m'.suivant <- Some m
  | None -> ());
  l.dernier <- Some m;
  if l.premier = None
  then l.premier <- l.dernier
```

Quelques remarques sur ce programme :

- comme on change directement `premier` et `dernier`, il est nécessaire de générer une nouvelle liste vide, ce qui est assuré ici par le paramètre `()` ;
- les pointeurs sont représentés par des options dans des champs mutables ;
- afin de préserver l'intégrité des deux pointeurs, on est obligé de gérer les cas où il n'y a qu'un seul maillon ;
- attention à la priorité du cas de filtrage sur `;` qui oblige à mettre des parenthèses dans `ajout_fin`.

III.3 Structure de la mémoire

En mémoire, les maillons d'une liste chaînée, comme celle vue en C, sont sur le tas et de manière désorganisée. Cela signifie qu'il n'y a aucune raison que deux maillons proches dans une liste soient proches en mémoire.



Or, les processeurs optimisent la gestion de la mémoire à l'aide d'un cache qui, au lieu de n'accéder qu'à une seule valeur située à une adresse, va charger une zone mémoire autour de cette adresse. Ceci encourage une cohérence spatiale dans l'organisation de la mémoire afin de profiter au maximum de cette mise en cache.

Une stratégie pour réaliser des listes chaînées efficacement peut consister à allouer un tableau de maillons et à gérer ensuite les allocations parmi cette réserve.

IV Travaux pratiques

On présente ici deux énoncés de travaux pratiques en C en lien avec ce chapitre.

IV.1 Tableaux non statiques et tableaux dynamiques

On va définir ici une structure de donnée pour gérer des tableaux dont la taille ne sera connu qu'à l'exécution. Pour simplifier, ce seront des tableaux d'entiers `int` mais la méthode s'adapte naturellement pour des tableaux de n'importe quoi.

IV.1.i Type array

On définit le type suivant :

```
struct array {
    int *elements;
    unsigned int size;
};
typedef struct array array;
```

Un `array` est donc une structure qui contient :

- un pointeur vers un tableau `elements` d'entiers
- un entier indiquant la taille de ce tableau

Remarque importante quand on copie un pointeur, on copie uniquement un entier qui est l'adresse pointée. Ainsi, quand on copie un array, ce n'est finalement qu'un couple d'entiers qu'on copie. C'est pourquoi, dans la suite, on passe tous les array par valeur. C'est-à-dire que pour définir une fonction de recherche d'un élément dans un array on va écrire :

```
C int search(array t, int x)
{
    for(int i = 0; i < t.size; i++)
    {
        if(t.elements[i] == x)
        {
            return i;
        }
    }

    return -1;
}
```

Quand on va appeler la fonction, on va avoir une copie de l'argument, c'est-à-dire du array, mais le tableau elements lui sera toujours à la même place. L'alternative serait de passer les valeurs array par pointeurs comme dans la variante suivante :

```
C int search(array *t, int x)
{
    for(int i = 0; i < t->size; i++)
    {
        if(t->elements[i] == x)
        {
            return i;
        }
    }

    return -1;
}
```

On n'a rien à gagner au surplus de complexité induit par cela. L'unique avantage serait de permettre de modifier les paramètres de la structure passée en argument, mais on réservera ça aux fonctions qui le nécessitent.

IV.1.ii Allocation, Initialisation, Libération

Pour les fonctions suivantes, on fera usage de malloc et free.

Question IV.1 Écrire une fonction de prototype array array_alloc(unsigned int size) qui alloue un tableau de size entiers avec malloc et renvoie le array pointant dessus.

Conformément à ce qui est écrit au-dessus, on peut créer un array en variable locale et le renvoyer avec return, ce qui compte c'est la mémoire pointée.

Démonstration.

```
C array array_alloc(unsigned int size)
{
    array a;
```

```
a.elements = (int *)malloc(sizeof(int) * size);
a.size = size;
return a;
}
```

Question IV.2 Écrire une fonction de prototype void array_free(array t) qui libère le tableau pointé par t avec free. A partir de ce moment, on ne peut plus utiliser cette adresse sans faire d'erreurs.

Démonstration.

```
void array_free(array a)
{
    free(a.elements);
}
```

Question IV.3 Le tableau alloué n'est pas initialisé, écrire une fonction de prototype array array_make(unsigned int size, int def) qui alloue un tableau et initialise toutes les valeurs de celui-ci à def.

Démonstration.

```
array array_make(unsigned int size, int def)
{
    array a = array_alloc(size);
    for(int i = 0; i < size; i++)
    {
        a.elements[i] = def;
    }
    return a;
}
```

Question IV.4 Il est possible de mesurer le temps pris par un programme à l'aide de la fonction time :

```
$> time ./main
./main 0.38s user 0.00s system 99% cpu 0.379 total
```

Comparer le temps d'exécution d'un programme qui

- alloue puis libère 100 fois un tableau d'un million d'entiers
- alloue *en initialisant à 0* avec make puis libère 100 fois un tableau d'un million d'entiers.

Que peut-on en conclure?

Démonstration.

On se rend compte que l'allocation est presque instantanée alors que l'initialisation prend un temps linéaire en la taille des données. Ceci est cohérent avec le fait que la mémoire est allouée de manière paresseuse. On s'en rend d'autant plus compte en examinant l'empreinte mémoire des programmes.



- **Remarque 8.2** Il existe d'autres fonctions que `malloc` comme

```
void *calloc(size_t nmemb, size_t size);  
void *realloc(void *ptr, size_t size);
```

qui permettent :

- pour `calloc` d'allouer un tableau de `nmemb` membres qui sont chacun de taille `size` et **d'initialiser les octets à 0**. Cette fonction prend donc un temps linéaire en le nombre d'octets.
- pour `realloc` de déplacer en mémoire un tableau en changeant sa taille (en plus ou en moins). Si jamais il y a de la place on ne bouge pas le tableau. C'est donc forcément plus efficace que de le faire à la main.

Ces deux fonctions sont **hors programme**!

**IV.1.iii Affichage, copie**

Question IV.5 Écrire une fonction `void array_print(array a)` qui affiche `[a1,a2,...,an]` si `a` contient les éléments de `a1` à `an`.

Remarque cette fonction vous sera utile pour tester ce que vous avez fait dans la suite.

*Démonstration.*

```
void array_print(array a)  
{  
    printf("[");  
    for(int i = 0; i < a.size; i++)  
    {  
        printf("%d", a.elements[i]);  
        if(i < a.size - 1)  
            printf(",");  
    }  
    printf("]\n");  
}
```



Question IV.6 Écrire une fonction de prototype

```
void array.blit(array src, int src_start,  
               array dst, int dst_start, int len)
```

qui copie `len` éléments depuis le tableau `src` à partir de l'indice `src_start` dans le tableau `dst` à partir de l'indice `dst_start`.



Remarque on a déjà écrit cette fonction en OCaml, vous pouvez vous en inspirer.

Démonstration.

```
void array.blit(array src, int src_start,
                array dst, int dst_start, int len)
{
    for(int i = 0; i < len; i++)
        dst.elements[i + dst_start] =
            src.elements[i + src_start];
```

IV.1.iv Implémentation d'une pile non bornée

Question IV.7 Écrire une fonction de prototype void `array_push(array *a, int x)` qui rajoute `x` à la fin du array `a`, c'est-à-dire :

- on va allouer un nouveau array `b` dont le tableau contient `a->size+1` éléments
- on va copier les anciennes valeurs de `*a` dans `b`
- écrire `x`
- libérer `*a`
- remplacer avec `*a = b`.

Remarque On peut tout à faire écrire `*a = b` pour que `a` ait les mêmes valeurs que `b` en dehors de la fonction ;

Rappel pour une struct par pointeurs, on utilise `->` pour accéder aux champs. Donc `a->elements` et `a->size` ici.

Remarque Faites des tests comme en créant un tableau de taille 0 et en empilant les entiers de 1 à 10 et en affichant le résultat. Faites les tests avec `-fsanitize=address`.

Démonstration.

```
void array.push(array *a, int x)
{
    array b = array.alloc(a->size+1);
    array.blit(*a, 0, b, 0, a->size);
    b.elements[a->size] = x;
    array.free(*a);
    *a = b;
}

// Note qu'on aurait pu proposer une interface persistante pour push/pop ainsi
// pas de pointeurs mais on renvoie le nouveau array
array array.push_2(array a, int x)
{
    array b = array.alloc(a.size+1);
    array.blit(a, 0, b, 0, a.size);
    b.elements[a.size] = x;
    // pas de raison de faire de free ici de a, c'est
    // a l'appelant de gérer.
    return b;
}
```

Question IV.8 Écrire une fonction `int array_pop(array *a)` qui retire le dernier élément du tableau `a` et renvoie sa valeur. Il faudra donc :

- allouer un nouveau `array b` dont le tableau contient `a->size-1` éléments
- copier les anciennes valeurs sauf une
- récupérer dans une variable `x` la valeur de la dernière case de `a` (*parce qu'il n'est pas possible d'y accéder après l'étape suivante*)
- libérer l'ancien tableau
- remplacer avec `*a = b`.

Démonstration.

```
C int array_pop(array *a)
{
    array b = array_alloc(a->size-1);
    array_blt(*a, 0, b, 0, a->size-1);
    int x = a->elements[a->size-1];
    array_free(*a);
    *a = b;
    return x;
}
```

IV.1.v Tableaux dynamiques

Reprendre toutes les questions précédentes en changeant la structure de donnée pour permettre de faire des tableaux dynamiques. Il faudra ainsi avoir deux entiers : `int p_size` qui contiendra la taille *physique* en mémoire et `int l_size` qui contiendra la taille *logique* c'est-à-dire les éléments signifiants stockés.

Quand on a besoin de realloquer la mémoire, on choisira de doubler la taille physique. Le pop ne libérera jamais de taille physique.

Démonstration.

```
C #include <stdio.h>
#include <stdlib.h>

struct array {
    int *elements;
    unsigned int p_size;
    unsigned int l_size;
};

typedef struct array array;

array array_alloc(unsigned int size)
{
    array a;
    a.elements = (int *)malloc(sizeof(int) * size);
    a.p_size = size;
    a.l_size = 0;
}
```

```
        return a;
    }

void array_free(array a)
{
    free(a.elements);
}

array array_make(unsigned int size, int def)
{
    array a = array_alloc(size);
    for(int i = 0; i < size; i++)
    {
        a.elements[i] = def;
    }
    a.l_size = size;
    return a;
}

void array_print(array a)
{
    printf("[");
    for(int i = 0; i < a.l_size; i++)
    {
        printf("%d", a.elements[i]);
        if(i < a.l_size - 1)
            printf(",");
    }
    printf("]\n");
}

void array.blit(array src, int src_start,
                array dst, int dst_start, int len)
{
    for(int i = 0; i < len; i++)
        dst.elements[i + dst_start] =
            src.elements[i + src_start];
}

void array.push(array *a, int x)
{
    if (a->l_size < a->p_size)
    {
        a->elements[a->l_size] = x;
        a->l_size += 1;
    }
    else
    {
        array b = array_alloc(2*a->l_size);
        array.blit(*a, 0, b, 0, a->l_size);
        b.elements[a->l_size] = x;
        b.l_size = a->l_size + 1;
        array_free(*a);
        *a = b;
    }
}
```

```
}

int array_pop(array *a)
{
    a->l_size -= 1;
    return a->elements[a->l_size];
}

int main(void)
{
    array a = array_alloc(0);
    for(int i = 0; i < 10; i++)
        array_push(&a, i);
    for(int i = 0; i < 3; i++)
        printf("Pop %d\n", array_pop(&a));
    array_print(a);
    array_free(a);
}
```



IV.2 Listes chaînées

IV.2.i Listes simplement chaînées

On va définir des fonctions sur les listes chaînées en utilisant le type suivant :

```
struct maillon {
    int valeur;
    struct maillon *suivant;
};

typedef struct maillon maillon;

struct liste {
    maillon *premier;
    maillon *dernier;
};

typedef struct liste liste;
```

■ Remarque 8.3 Invariants à maintenir

- Dans un maillon, `suivant` est soit `NULL` si c'est le dernier maillon de la chaîne, soit un pointeur vers le maillon qui le suit.
- Si la liste est vide alors `premier` et `dernier` valent `NULL`. Sinon, ils pointent respectivement sur le premier et le dernier maillon de la chaîne.



Question IV.9 Écrire une fonction de prototype

```
liste liste_vide();
```

qui renvoie la liste vide. Ici, on pourrait dire **une** liste vide mais cela correspond à une unique valeur de la structure `liste`.



Démonstration.

```

    liste liste_vide()
{
    liste l;
    l.premier = NULL;
    l.dernier = NULL;
    return l;
}

```



Question IV.10 Écrire une fonction de prototype

où

```
void liste_affiche(liste l);
```

qui affiche le contenu de la liste sous la forme [1,2,3].



Démonstration.

```

void liste_affiche(liste l)
{
    putchar('[');
    maillon *m = l.premier;
    while(m != NULL)
    {
        printf("%d", m->valeur);
        if(m->suivant != NULL)
            putchar(',');
        m = m->suivant;
    }
    putchar(']');
    putchar('\n');
}

```



Question IV.11 Écrire une fonction de prototype

où

```
maillon *maillon_creer(int valeur, maillon *suivant);
```

qui alloue et initialise un nouveau maillon.



Démonstration.

```

maillon *maillon_creer(int valeur, maillon *suivant)
{
    maillon *m = malloc(sizeof(maillon));
    m->valeur = valeur;
    m->suivant = suivant;
    return m;
}

```

Question IV.12 Écrire une fonction de prototype

C `void maillon_detruire(maillon *m);`

qui détruit, c'est-à-dire libère, la mémoire associée à un maillon.

Écrire une fonction de prototype

C `void chaine_detruire(maillon *m);`

qui détruit la chaîne de maillon accessible depuis le maillon m.

En déduire une fonction de prototype

C `void liste_detruire(liste l);`

qui détruit la chaîne pointée par une liste.

Démonstration.

```
void maillon_detruire(maillon *m)
{
    free(m);
}

void chaine_detruire(maillon *m)
{
    while(m != NULL)
    {
        maillon *suivant = m->suivant;
        maillon_detruire(m);
        m = suivant;
    }
}

void liste_detruire(liste l)
{
    chaine_detruire(l.premier);
}
```

Question IV.13 Écrire une fonction de prototype

C `int liste_longueur(liste l);`

qui renvoie la longueur de la liste l.

Démonstration.

```
int liste_longueur(liste l)
{
    int longueur = 0;
```

```

maillon *m = l.premier;
while(m != NULL)
{
    longueur += 1;
    m = m->suivant;
}
return longueur;
}

```



Question IV.14 Écrire des fonctions de prototype

○ `int liste_tete(liste l);`
`liste liste_queue(liste l);`

qui renvoient respectivement la tête et la queue d'une liste. **Attention**, ici, contrairement au type vu plus haut, le maillon suivant n'est pas une liste.



Démonstration.

```

int liste_tete(liste l)
{
    assert(l.premier != NULL);
    return l.premier->valeur;
}

liste liste_queue(liste l)
{
    assert(l.premier != NULL);
    liste q;
    q.premier = l.premier->suivant;
    q.dernier = l.dernier;
    return q;
}

```



Question IV.15 Écrire une fonction de prototype

○ `void liste_ajout_en_tete(liste *l, int valeur);`

qui ajoute un maillon en tête de la liste pointée par `l` en $O(1)$. On fera attention au cas où `l` pointe la liste vide.

■ **Note 8.1** Dans cette fonction et les suivantes, on a fait le choix de passer des pointeurs sur des listes pour permettre de modifier les valeurs des pointeurs `premier` et `dernier`. Alternativement, on aurait pu faire en sorte que ces fonctions renvoient des `liste` par copie.



Démonstration.

```
C void liste_ajout_en_tete(liste *l, int valeur)
{
    l->premier = maillon_creer(valeur, l->premier);
    if(l->dernier == NULL) // la liste était vide
        l->dernier = l->premier;
}
```

Question IV.16 Écrire une fonction de prototype

```
C void liste_suppr_en_tete(liste *l);
```

qui supprime un maillon en tête de la liste l supposée non vide en $O(1)$.

On fera attention au cas où on supprime l'unique maillon de la liste.

Démonstration.

```
C void liste_suppr_en_tete(liste *l)
{
    assert(l->premier != NULL);
    maillon *m = l->premier;
    l->premier = m->suivant;
    maillon_detruire(m); // on libère la mémoire
    if(l->premier == NULL) // on a vidé la liste
        l->dernier = NULL;
}
```

Question IV.17 Écrire une fonction de prototype

```
C void liste_ajout_en_fin(liste *l, int valeur);
```

qui ajoute un maillon en fin de la liste l en $O(1)$.

Démonstration.

```
C void liste_ajout_en_fin(liste *l, int valeur)
{
    maillon *m = l->dernier;
    l->dernier = maillon_creer(valeur, NULL);
    m->suivant = l->dernier;
    if(l->premier == NULL) // la liste était vide
        l->premier = l->dernier;
}
```

Question IV.18 Écrire une fonction de prototype

maillon *liste_cherche_maillon(liste l, int valeur);

qui renvoie un pointeur sur le premier maillon de valeur valeur ou renvoie NULL s'il n'y en a pas.

Démonstration.

```
maillon *liste_cherche_maillon(liste l, int valeur)
{
    maillon *m = l.premier;
    while(m != NULL && m->valeur != valeur)
    {
        m = m->suivant;
    }
    return m;
}
```

Question IV.19 Écrire une fonction de prototype

void liste_ajout_maillon_apres(liste *l, maillon *m, int valeur);

qui insère en $O(1)$ un maillon après le maillon m. On fera en sorte que l'insertion soit valide même si m est le dernier maillon de la liste.

Démonstration.

```
void liste_ajout_maillon_apres(liste *l, maillon *m, int valeur)
{
    m->suivant = maillon_creer(valeur, m->suivant);
}
```

Question IV.20 Écrire une fonction de prototype

void

qui ajoute un maillon avant m. Dans le cas où m est le premier ou le dernier maillon, l'insertion sera en $O(1)$.

Démonstration.

```
void liste_ajout_maillon_avant(liste *l, maillon *m, int valeur)
{
    if (m == l->premier)
        liste_ajout_en_tete(l, valeur);
    else if (m == l->dernier)
        liste_ajout_en_fin(l, valeur);
    else
```

```

maillon *prec = l->premier;
while(prec->suivant != m)
{
    prec = prec->suivant;
}
prec->suivant = maillon_creer(valeur, m);
}
}

```

Question IV.21 Écrire une fonction de prototype

↳ `void liste_suppr_maillon(liste *l, maillon *m);`

qui supprime un maillon. Dans le cas où m est le premier maillon, la suppression sera en $O(1)$.

Démonstration.

```

void liste_suppr_maillon(liste *l, maillon *m)
{
    if (m == l->premier)
        liste_suppr_en_tete(l);
    else
    {
        maillon *prec = l->premier;
        while(prec->suivant != m)
        {
            prec = prec->suivant;
        }
        prec->suivant = m->suivant;
        maillon_detruire(m);
    }
}

```

IV.2.ii Listes doublement chaînées

Pour les listes doublement chaînées, on va adapter le type précédent en rajoutant juste un pointeur `precedent` dans les maillons :

```

struct maillon {
    int valeur;
    struct maillon *suivant;
    struct maillon *precedent;
};
typedef struct maillon maillon;

struct liste {
    maillon *premier;
    maillon *dernier;
};
typedef struct liste liste;

```

■ **Remarque 8.4 Invariants à maintenir**

- Dans un maillon, suivant est soit NULL si c'est le dernier maillon de la chaîne, soit un pointeur vers le maillon qui le suit.
- Dans un maillon, précédent est soit NULL si c'est le premier maillon de la chaîne, soit un pointeur vers le maillon qui le précède.
- Si la liste est vide alors premier et dernier valent NULL. Sinon, ils pointent respectivement sur le premier et le dernier maillon de la chaîne.

Question IV.22 Reprendre les questions précédentes avec ce nouveau type.

Démonstration.

Peu de modifications à faire.

```

liste liste_vide()
{
    liste l;
    l.premier = NULL;
    l.dernier = NULL;
    return l;
}

void liste_affiche(liste l)
{
    putchar('[');
    maillon *m = l.premier;
    while(m != NULL)
    {
        printf("%d", m->valeur);
        if(m->suivant != NULL)
            putchar(',');
        m = m->suivant;
    }
    putchar(']');
    putchar('\n');
}

maillon *maillon_creer(int valeur,
                      maillon *precedent, maillon *suivant)
{
    maillon *m = malloc(sizeof(maillon));
    m->valeur = valeur;
    m->suivant = suivant;
    m->precedent = precedent;
    return m;
}

void maillon_detruire(maillon *m)
{
    free(m);
}

```

```
void chaine_detruire(maillon *m)
{
    while(m != NULL)
    {
        maillon *suivant = m->suivant;
        maillon_detruire(m);
        m = suivant;
    }
}

void liste_detruire(liste l)
{
    chaine_detruire(l.premier);
}

int liste_longueur(liste l)
{
    int longueur = 0;
    maillon *m = l.premier;
    while(m != NULL)
    {
        longueur += 1;
        m = m->suivant;
    }
    return longueur;
}

int liste_tete(liste l)
{
    assert(l.premier != NULL);
    return l.premier->valeur;
}

liste liste_queue(liste l)
{
    assert(l.premier != NULL);
    liste q;
    q.premier = l.premier->suivant;
    q.dernier = l.dernier;
    return q;
}

void liste_ajout_en_tete(liste *l, int valeur)
{
    l->premier = maillon_creer(valeur, NULL, l->premier);
    if(l->dernier == NULL) // la liste était vide
        l->dernier = l->premier;
}

void liste_suppr_en_tete(liste *l)
{
    assert(l->premier != NULL);
    maillon *m = l->premier;
    l->premier = m->suivant;
    l->premier->precedent = NULL;
```

```

maillon_detruire(m); // on libère la mémoire
if(l->premier == NULL) // on a vidé la liste
    l->dernier = NULL;
}

void liste_ajout_en_fin(liste *l, int valeur)
{
    maillon *m = l->dernier;
    l->dernier = maillon_creer(valeur, m, NULL);
    m->suivant = l->dernier;
    if(l->premier == NULL) // la liste était vide
        l->premier = l->dernier;
}

maillon *liste_cherche_maillon(liste l, int valeur)
{
    maillon *m = l.premier;
    while(m != NULL && m->valeur != valeur)
    {
        m = m->suivant;
    }
    return m;
}

void liste_ajout_maillon_apres(liste *l, maillon *m, int valeur)
{
    m->suivant = maillon_creer(valeur, m, m->suivant);
}

```

Question IV.23 Écrire une fonction de prototype

□ `void liste_suppr_en_fin(liste *l);`

qui supprime en $O(1)$ le dernier maillon.

Démonstration.

```

void liste_suppr_en_fin(liste *l);
{
    maillon *fin = l->dernier;
    l->dernier = fin->precedent;
    l->dernier->suivant = NULL;
    if (l->dernier == NULL)
        l->premier = NULL;
    maillon_detruire(fin);
}

```

Question IV.24 Écrire une fonction de prototype

□ `void liste_ajout_maillon_avant(liste *l, maillon *m, int valeur);`

qui ajoute un maillon avant m en $O(1)$.

Démonstration.

□ `void liste_ajout_maillon_avant(liste *l, maillon *m, int valeur)`

```
{  
    if (m == l->premier)  
        liste_ajout_en_tete(l, valeur);  
    else if (m == l->dernier)  
        liste_ajout_en_fin(l, valeur);  
    else  
    {  
        // En O(1)  
        m->precedent->suivant = maillon_creer(valeur,  
            m->precedent, m);  
        m->precedent = m->precedent->suivant;  
    }  
}
```

Question IV.25 Écrire une fonction de prototype


□ `void liste_suppr_maillon(liste *l, maillon *m);`

qui supprime en $O(1)$ le maillon m .

Démonstration.

□ `void liste_suppr_maillon(liste *l, maillon *m)`

```
{  
    if (m == l->premier)  
        liste_suppr_en_tete(l);  
    else  
    {  
        m->precedent->suivant = m->suivant;  
        m->suivant->precedent = m->precedent;  
        maillon_detruire(m);  
    }  
}
```

9. Piles et files : structures abstraites et implémentation

I Piles

1.1 Principe

Une pile est une structure de donnée abstraite permettant d'ajouter et de retirer des éléments selon le principe

LIFO : Last In First Out

C'est-à-dire que le premier élément retiré sera celui qui a été ajouté en dernier. La bonne manière de se représenter une pile est donc d'imaginer une pile de dossiers à traiter sur un bureau. Chaque nouveau dossier est empilé et on traite à chaque fois le dossier sur le dessus.

■ **Remarque 9.1** Ce n'est sûrement pas la manière la plus efficace de gérer des dossiers et l'on risque d'avoir des dossiers empilés depuis très longtemps sans être traités.

On va avoir quatre opérations :


- Créer une pile vide
- Tester si une pile est vide
- Ajouter un élément à une pile, on appelle cette opération *empiler* et en anglais *push*
- Retirer un élément à une pile et le renvoie, on appelle cette opération *dépiler* et en anglais *pop*

Le comportement opérationnel de cette structure abstraite est donné par le principe LIFO précédent.

On considère qu'il est très important que ces quatre opérations soient de complexité en temps constante, éventuellement amorti. Par contre, il est possible de limiter le nombre maximum d'éléments. C'est une vision qui est en accord avec le rôle des piles pour gérer des tâches à traiter pour lesquelles on a souvent un majorant sur leur nombre.

1.2 Représentation visuelle

Comme souvent, la représentation visuelle est importante car c'est elle qui permet de raisonner efficacement. Ici, on va représenter une pile verticalement ou horizontalement avec un côté fermé : le *fond* de pile et un côté ouvert permettant d'empiler et de dépiler des éléments.



1.3 Implémentations

1.3.i Dans un tableau borné

Reprenant la remarque précédente, on va présenter une implémentation très standard des piles dans des tableaux de taille fixe. L'idée est de considérer un tableau `t` de taille N muni d'un entier `fond` indiquant l'indice du prochain élément libre.

Au départ, `fond` vaut 0. Chaque fois qu'on empile un élément, on le place à l'indice indiqué par `fond` et on l'incrémente. Pour dépiler, on décrémente `fond` et on renvoie l'élément à cet indice. En fait, les éléments ne sont pas vraiment retirés. Il s'agit exactement du comportement de la pile d'exécution du compilateur vue au chapitre sec:pileexec.

Le choix de la valeur N donnant le nombre maximum d'éléments empilables est critique : il faut qu'elle soit grande devant l'estimation qu'on peut faire du nombre d'empilements. L'implémentation d'une telle pile se fait en général dans des conditions où l'on va éviter de vérifier l'absence de dépassement. Dans le code qui va suivre, on a fait le choix de passer par des `assert` pour vérifier ces conditions uniquement en mode développement.

■ **Remarque 9.2** En C, on passera le plus souvent par un tableau statique avec `N` défini à une grande valeur entière par un `#define`. On présente une version plus dans l'esprit de ces chapitres structures de données.

On va ainsi définir un type `pile` avec des pointeurs :

```
struct pile {
    int *t;
    int fond;
};

typedef struct pile pile;
```

Pour ajouter et retirer un élément, comme on va manipuler l'entier `fond`, il est nécessaire de passer `pile` par pointeur. On fait ainsi ce choix pour l'ensemble des fonctions.

L'opération de création doit faire une allocation et cela va donc nécessiter une opération explicite de destruction :

```
int N = 1000; // La pile sera de 1000 éléments au maximum

pile *pile_creer()
{
    pile *p = malloc(sizeof(pile));
    p->t = malloc(sizeof(int) * N);
    p->fond = 0;
    return p;
}

void pile_detruire(pile *p)
{
    free(p->t);
    free(p);
}
```

Empiler et dépiler correspond directement à la description précédente.

```
void empiler(pile *p, int x)
{
    assert(p->fond < N);
    p->t[p->fond] = x;
    p->fond++;
}

int retirer(pile *p)
{
    assert(p->fond > 0);
    p->fond--;
    return p->t[p->fond];
}

bool est_vide(pile *p)
{
    return p->fond == 0;
}
```

I.3.ii Dans un tableau dynamique

On a vu qu'on pouvait définir des tableaux redimensionnables et que cela permettait d'effectuer des ajouts et des suppressions en complexité amortie constante.

On peut donc directement réaliser une pile à l'aide de cette structure en ajoutant et supprimant des éléments. C'est l'interface usuelle avec le type `list` de Python qui propose déjà cela avec les fonctions `append` et `pop`. On peut rajouter une surcouche superficielle pour retrouver la nomenclature précédente :

```
def creer_pile():
    return []

def est_vide(p):
    return p == []
```

```

def empiler(p, x):
    p.append(x)

def depiler(p):
    return p.pop()

```

1.3.iii Avec des listes chaînées

Avec des listes chaînées, l'idée est d'ajouter et de supprimer des éléments en tête. En effet, on a vu que ces deux opérations étaient en temps constant, ce qui est particulièrement adapté aux piles.

En OCaml, on remarque que les listes par défaut conviennent, cependant, il est nécessaire de changer de liste pour rajouter ou supprimer un élément, c'est pourquoi on définit le type '`'a pile`' comme une '`'a list ref`' c'est-à-dire un pointeur sur un maillon de tête comme on aurait pu le faire en C.

On définit ainsi directement les quatre opérations :

```

type 'a pile = 'a list ref

let cree_pile () = ref []

let est_vide p = !p = []

let empile p x = p := x :: !p

let depile p =
    match !p with
    | [] -> failwith "Pile vide"
    | x::q -> p := q; x

```

OCaml

1.4 Applications

1.4.i Parenthésage

1.4.ii Évaluation d'expressions

!subsubsubsection(Expression postfixe) !subsubsubsection(Expression infixe)

II Files

II.1 Principe

Une file est une structure de donnée abstraite permettant d'ajouter et de retirer des éléments selon le principe

FIFO : First In First Out


C'est-à-dire que le premier élément retiré sera celui qui a été ajouté le plus récemment. La bonne manière de se représenter une file est donc d'imaginer la file d'attente à la caisse d'un magasin.

II.2 Implémentations


II.2.i Dans un tableau borné

On peut reprendre l'implémentation dans un tableau des piles. Ici, on va conserver deux indices : l'indice de fin et l'indice du début de la file.


L'idée est de représenter une file comme une plage de cases dans un tableau circulaire :



Pour enfiler, il suffit de décaler fin d'une case vers la droite et d'ajouter à cette case l'élément. Ainsi si on enfile 3 dans l'exemple précédent on obtient :




Pour défiler, on va renvoyer l'élément pointé par début et décaler celui-ci d'une case vers la droite. Dans l'exemple précédent, on obtient alors la valeur 1 et le tableau devient :



Si, comme pour les piles, on suppose que la taille de la file ne dépassera jamais le nombre de cases du tableau circulaire, il n'y a pas de risques de dépassement. La question qui se pose alors est celle de l'implémentation d'un tableau circulaire de N cases dans un tableau usuel de N cases.

La technique consiste à couper le tableau arbitrairement entre deux cases et à l'aplatir :



Maintenant, la question du bord se pose : les décalages doivent se faire modulo la longueur du tableau pour avoir le même comportement qu'un tableau circulaire.

On traduit ensuite directement cette représentation en C :

```

struct file {
    int *t;
    int debut;
    int fin;
};


typedef struct file file;

```

II.2.ii Avec des listes chaînées

II.2.iii Avec deux piles

II.3 Applications



10. Arbres

Arbres binaires

1.1 Définition inductive

Définition I.1 Un arbre binaire étiqueté par \mathcal{E} est :

- soit vide, et on le note alors nil ou \perp
- soit un triplet (g, x, d) où $x \in \mathcal{E}$ et g et d sont des arbres binaires.

■ **Remarque 10.1** Cette définition inductive ressemble à la définition des listes.

On peut la formaliser en introduisant $T_b(\mathcal{E})$ l'ensemble des arbres étiquetés par \mathcal{E} . C'est le **plus petit ensemble** tel que :

- $\text{nil} \in T_b(\mathcal{E})$
- $\forall x \in \mathcal{E}, \forall g, d \in T_b(\mathcal{E}), (g, x, d) \in T_b(\mathcal{E})$

Les conséquences de la précision **plus petit ensemble** sont importantes :

- les arbres sont nécessairement des expressions finies, c'est-à-dire qu'il ne comportent qu'un nombre fini de constructions. C'est automatique car l'ensemble des arbres finis vérifie les conditions précédentes ;
- pour tout triplet (g, x, d) il ne peut exister qu'un arbre, sinon, en enlevant un arbre en double on vérifierait encore les deux conditions précédentes.

On en déduit directement la notion de preuve par **induction structurelle** sur les arbres :

$$\forall a \in T_b(\mathcal{E}), P(a) \iff \begin{cases} P(\text{nil}) \\ \forall x \in \mathcal{E}, \forall g, d \in T_b(\mathcal{E}), P(g) \wedge P(d) \Rightarrow P(g, x, d) \end{cases}$$


Cette induction correspond à un pseudo principe de récurrence qui nous permettra de faire les preuves.

Pour démontrer cette inégalité, il suffit de vérifier que $T_P = \{t \in T_b(\mathcal{E}), P(t)\}$ vérifie les relations de la définition inductive et $T_P \subset T_b(\mathcal{E})$ et par minimalité, on a bien $T_P = T_b(\mathcal{E})$.

■ **Exemple 10.1** Si $\mathcal{E} = \mathbb{N}$, les éléments suivants sont des arbres :


- nil
- (nil, 2, nil)
- ((nil, 1, nil), 2, nil)

On adoptera une représentation graphique très naturelle pour les arbres binaires où un




■ **Exemple 10.2** Les trois arbres précédentes sont donc représentés par :

nil



Afin d'alléger la notation, on omettra nil, sauf pour l'arbre vide. On fera cependant attention à conserver les arêtes donnant sur nil pour ne pas confondre (nil, 1, nil(nil, 2, nil)) et ((nil, 2, nil), 1, nil). Ainsi on représentera les arbres précédents par :



1.2 Vocabulaire

Définition 1.2 Soit a un arbre binaire. Les arbres non vides présents dans a sont appelés les **nœuds** de a . Parmi ceux-ci on distingue ceux qui sont de la forme (nil, x, nil) , appelés des **feuilles**. Les nœuds qui ne sont pas des feuilles sont appelés des **nœuds internes**. Le nœud a lui-même est appelé la racine de l'arbre. On note $N(a)$ les nœuds de a .

Si $n \in N(a)$ n'est pas la racine, il est le fils gauche ou le fils droit d'un unique nœud appelé le **père** de x .

Si $n \in N(a)$, on appelle **sous-arbre** de a l'arbre dont n est la racine.

■ **Remarque 10.2** En partant de la définition inductive, il y a une identification entre un sous-arbre et sa racine. Mais afin de raisonner, on distinguera un nœud en tant qu'emplacement au sein d'un arbre et le sous-arbre lui-même.

Définition 1.3 Soit a un arbre binaire.

- On appelle **taille** de a , et on note $|a|$ le nombre de nœuds de a .

- On appelle **hauteur** de a l'entier

$$h(a) = \begin{cases} -1 & \text{si } a = \text{nil} \\ 1 + \max(h(g), h(d)) & \text{si } a = (g, x, d) \end{cases}$$

Définition I.4 Soit a un arbre binaire et $n \in N(a)$. On appelle **profondeur** de n l'unique entier $p(a)$ tel qu'il existe une suite finie $(n_0, n_1, \dots, n_{p(a)})$ de n vérifiant :

- n_0 est la racine de a
- $n_{p(a)} = n$
- pour tout i , n_i est le père de n_{i+1}

Cette suite finie est le **chemin** de la racine à n . Il est nécessairement unique car chaque nœud autre que la racine a un unique père.

Théorème I.1 Soit a un arbre, si a est non vide, alors $h(a) = \max_{n \in N(a)} p(n)$.

Démonstration.

Par induction structurelle sur a .

- **Initialisation** Si $a = \text{nil}$ la prémissse est fausse, donc l'implication est trivialement vérifiée.
- **Hérédité** Supposons la propriété vérifiée pour deux arbres g et d , soit $x \in \mathcal{E}$, on va montrer qu'elle est vérifiée pour $a = (g, x, d)$. On a quatre cas pour le couple (g, d) :

- ★ Soit $g \neq \text{nil}$ et $d \neq \text{nil}$. Dans ce cas, par hypothèse $h(g) = \max_{n \in N(g)} p_g(n)$ où p_g est la profondeur de n en tant que nœud de l'arbre g . Or, mis à part la racine de a , le chemin menant dans a au nœud n est dans g . On a donc directement $p_g(n) = p(n) - 1$. Ainsi $h(g) = \max_{n \in N(g)} p(n) - 1$. De même, $h(d) = \max_{n \in N(d)} p(n) - 1$. On a

$$h(a) = 1 + \max(h(g), h(d)) = \max(\max_{n \in N(g)} p(n), \max_{n \in N(d)} p(n))$$

Or, le seul nœud de a qui n'est ni dans g ni dans d est sa racine, qui est de profondeur nulle donc $h(a) = \max_{n \in N(a)} p(n)$.

- ★ Soit $g = \text{nil}$ et $d \neq \text{nil}$. Ainsi $h(g) = -1$ et donc $h(a) = 1 + h(d) = \max_{n \in N(d)} p(n)$ par l'analyse précédente. On conclut donc avec la propriété voulue.
- ★ Soit $g \neq \text{nil}$ et $d = \text{nil}$. Cas symétrique du précédent.
- ★ Soit $g = d = \text{nil}$. Auquel cas, $h(a) = 0$ qui est bien la profondeur de son unique nœud.

On a bien montré la propriété voulue par induction structurelle. ■

I.3 Implémentations

I.3.i En OCaml

En OCaml, on traduit directement la définition inductive par un type récursif :

```
OCaml | type 'a arbre = Noeud of 'a arbre * 'a * 'a arbre | Nil
```

On pourra alors définir des fonctions récursives sur les arbres par induction structurelle à l'aide d'un filtrage.

```
OCaml  let rec taille a = match a with
| Nil -> 0
| Noeud(g,x,d) -> 1 + taille g + taille d

let rec hauteur a = match a with
| Nil -> -1
| Noeud(g, x, d) -> 1 + max (hauteur g) (hauteur d)
```


I.3.ii En C

I.4 Arbres binaires stricts

Définition I.5 Un arbre binaire est dit **strict** lorsqu'aucun de ses nœuds n'a qu'un fils vide.

Cela revient à dire que les seules les feuilles ont des fils vides. On peut donc omettre l'arbre vide et ne garder que les feuilles à la place.

■ **Remarque 10.3** L'arbre de gauche ici est un arbre binaire strict alors que ce n'est pas le cas de l'arbre de droite :



Théorème I.2 Soit a un arbre binaire strict non vide. Si a a n nœuds internes, alors il a $n + 1$ feuilles.

Démonstration.

Par induction structurelle :

- **Initialisation** Si a a 0 nœud interne, c'est une feuille et on a directement la relation.
- **Hérédité** Supposons que la propriété soit vraie pour des arbres g et d , et soit $a = (g, x, d)$ un arbre dont ce sont les fils. On note $n_i(t)$ le nombre de nœuds internes et $n_f(t)$ le nombre de feuilles de l'arbre t . On a $n_i(a) = 1 + n_i(g) + n_i(d)$ et $n_f(a) = n_f(g) + n_f(d) = 2 + n_i(g) + n_i(d) = 1 + n_i(a)$. La propriété est démontrée pour a .

Cela permet naturellement de considérer des arbres où les feuilles et les nœuds internes ont deux types différents d'étiquettes.

L'exemple classique d'un tel arbre est celui des expressions arithmétiques :

- les nœuds internes sont étiquetés par des opérateurs binaires
- les feuilles sont étiquetées par des nombres.

En OCaml, on peut ainsi représenter un tel arbre par le type récursif :

```
OCaml  type ('a, 'b) arbre_bin = Feuille of 'a
      | Noeud of ('a, 'b) arbre_bin * 'b * ('a, 'b) arbre_bin
```

■ **Remarque 10.4** On ne peut plus représenter l'arbre vide avec ce type.

Et pour les expressions, on pourra ainsi définir un type pour les opérateurs et écrire :

```
Ocaml type operator = Plus | Times | Minus | Divides
let e = Noeud(Feuille 2, Plus, Noeud(Feuille 3, Mult, Feuille 4))
```


L'évaluation de telles expressions est étudiée dans le TP si dessous.

1.5 Arbres binaires complets

Définition 1.6 Un arbre binaire dont tous les niveaux sont plein sauf éventuellement le dernier est dit **complet**. Si son dernier niveau est également plein, on dit qu'il est **parfait**.

On peut représenter un arbre complet dans un tableau niveau par niveau en partant de la racine.

Si on place les indices comme étiquettes on aura, par exemple :



Et on pourra donc le représenter par le tableau des étiquettes dans cet ordre d'énumération.
On remarque que :

- le nœud 0 est toujours la racine
- si on considère un nœud i , son fils gauche est le nœud $2i + 1$ et son fils droit est le nœud $2i + 2$.
- le fils gauche de $i + 1$ est $2(i + 1) + 1 = 2i + 3 > 2i + 2$. On est bien directement après.
- le k ème nœud du niveau l , en commençant à numérotier à 0, a pour indices $\sum_{j=0}^{l-1} 2^j + k = 2^l - 1 + k$.
- si $i > 0$, son père est le nœud $\lfloor \frac{i-1}{2} \rfloor$.

On peut donc, avec cette représentation, manipuler assez simplement un arbre binaire **à plat**

II Arbres

II.1 Définition

On étend directement la définition inductive des arbres binaires au cas où les nœuds plus d'éléments.

Définition II.1 Un arbre étiqueté par \mathcal{E} est un couple (x, f) où $x \in \mathcal{E}$ et f une suite **finie** d'arbres.

On étend naturellement le vocabulaire des arbres binaires :

- le nœud de tête d'un arbre, en fin de compte sa **valeur**, est appelé sa **racine**
- les éléments de f sont appelés les **fils** du nœuds
- si f est vide, on dit que le nœud est une **feuille**, sinon, on dit que c'est un nœud **interne**.

- $|f|$, le nombre d'éléments de f , est appelé l'**arité** du nœud. Les feuilles sont donc les nœuds zéroaires.
- une suite finie d'arbres, ou plus généralement un ensemble d'arbres, est appelé une **forêt**. Si on note $T(\mathcal{E})$ l'ensemble des arbres étiquetés par \mathcal{E} , on a

$$\forall x \in \mathcal{E}, \forall n \in \mathbb{N}, \forall a_1, \dots, a_n \in T(\mathcal{E}), (x, (a_1, \dots, a_n)) \in T(\mathcal{E})$$

Attention contrairement à ce que peut laisser entendre la formule précédente, il est tout à fait possible que $n = 0$ ce qui correspond à la suite finie vide et donc à une feuille. On perd ici la possibilité de représenter un arbre vide.

■ **Remarque 10.5** Un arbre binaire est un arbre dont les nœuds sont soit unaires soit binaires. On remarque en disant cela qu'on perd une information : la position gauche ou droite de l'unique fils d'un nœud unaire.

Comme pour les arbres binaires stricts, on pourra être amenés à considérer des arbres dont les nœuds internes et les feuilles sont étiquetés par des arbres ■

II.2 Implémentation

L'implémentation d'un arbre repose sur l'implémentation d'une suite finie. Celle-ci peut être faite par un tableau ou par une liste chaînée.

On retrouve alors des implementations différentes des arbres mais qui sont, au fond, très proches.

En OCaml, on pourra alors avoir les deux implementations suivantes :

```
OCaml | type 'a arbre_l = { etiquette : 'a; enfants : 'a arbre_l list }
      | type 'a arbre_a = { etiquette : 'a; enfants : 'a arbre_a array }
```

On va alors avoir des programmes à la présentation assez différente suivant le type choisi. Voici, par exemple, les deux implémentations du calcul de la taille d'un arbre.

Avec des listes et aucune fonction du module `List`, on écrit souvent une fonction récursive sur les arbres et une fonction récursive sur les forêts.

```
OCaml | let rec taille_arbre a =
      1 + taille_foret a.enfants
      and taille_foret l = match l with
        | [] -> 0
        | t::q -> taille_arbre t + taille_foret q
```

On peut aussi utiliser directement `fold_left` et `map` :

```
OCaml | let rec taille_arbre a =
      1 + List.fold_left (+) 0 (List.map taille_arbre a.enfants)
```

Avec l'autre représentation, on procédera avec un mélange de fonction récursive et de boucles. Cela n'est pas sans rappeler ce qui a été fait pour le backtracking.


```
OCaml | let rec taille_arbre a =
      let t = ref 1 in
      for i = 0 to Array.length a.enfants - 1 do
        t := !t + taille_arbre a.enfants.(i)
```

```
done;
!t
```

II.3 Représentation par un arbre binaire


Pour des raisons d'efficacité ou de réutilisation de programmes existants, on peut vouloir représenter un arbre comme un arbre binaire.

On va définir une application : $\text{bin} : T(\mathcal{E}) \rightarrow T_b(\mathcal{E} \cup \{\star\})$ ainsi : $\text{bin}(x, ()) = (\text{nil}, x, \text{nil})$, $\text{bin}(x, (a)) = (\text{bin}(a), x, \text{nil})$ et pour un nœud d'arité strictement plus grande que 1 :




où $a'_i = \text{bin}(a_i)$. Les nœuds rouges sont des nœuds ayant une étiquette spéciale \star telle que $\star \notin \mathcal{E}$.

■ **Exemple 10.3** L'arbre suivant :



sera alors représenté par l'arbre binaire :



II.4 Applications

II.4.i Arbres d'expressions


On a déjà vu l'utilisation des arbres binaires pour représenter des expressions arithmétiques avec des opérateurs unaires ou binaires. On généralise naturellement cela à des expressions dont les opérateurs sont d'arité quelconque.

C'est ainsi qu'on représente un programme en mémoire, on parle d'arbre syntaxique.

II.4.ii Arbres préfixes ou tries

Un *arbre préfixe* ou *trie* est un arbre permettant de représenter un ensemble de mots. On étiquette les arêtes par des caractères et les nœuds par un booléen indiquant si la suite des étiquettes qui mène de la racine à ce nœud est un mot.

Par exemple, le trie :



permet de représenter l'ensemble de mots : bar, barbe, art, ami, abri, abricot, abonne.

Afin de représenter un tel arbre, il est nécessaire d'avoir une étiquette sur les arêtes, le plus simple pour cela est de remplacer la liste des enfants par une liste de couples (étiquette, enfant) ainsi :

```

OCaml | type trie = {
  mot : bool;
  enfants : (char * trie) list
}
  
```

Les fonctions de manipulations de ce type de donnée sont étudiées dans le TP TODO.

III Parcours


III.1 Parcours récursif d'un arbre binaire

On a déjà vu dans les paragraphes précédent ce qui constitue le cœur du parcours d'un arbre :

```


OCaml | let rec parcours a =
  match a with
  | Nil -> ()
  | Noeud(g, x, d) ->
    parcours g;
    parcours d
  
```

Cette fonction ne fait rien, mais elle va parcourir chacun des nœuds de l'arbre. Si on veut effectuer un traitement sur le nœud, on peut le faire à trois moments :



- Avant l'appel à parcours g, on parle de *traitement préfixe*
- Entre les deux appels, on parle de *traitement infixé*
- Avant l'appel à parcours g, on parle de *traitement préfixe*

On représente ici l'ordre dans lequel on va effectuer chacun de ces trois traitements selon le code couleur : rouge pour préfixe, bleu pour infixé et vert pour postfixe. On a également indiqué, pour les premiers traitements, l'ordre dans lequel ils sont effectués par des numéros.



Pour illustrer ces traitements, on peut rajouter trois arguments au parcours :

```

OCaml
let rec parcours prefixe infixé postfixe a =
  match a with
  | Nil -> ()
  | Noeud(g, x, d) ->
      prefixe a;
      parcours g;
      infixé a;
      parcours d;
      postfixe a
  
```

On peut, par exemple, définir les deux fonctions suivante :

```


OCaml
let idle a = () (* ne fait rien *)
let print a = match a with
  | Nil -> failwith "Vide"
  | Noeud(_,x,_) -> print_char a
  
```

On peut alors observer les nœuds affichés sur l'arbre précédent selon les traitements effectués :

- parcours print idle a: **abdejkvwcfg** on suit uniquement les arêtes rouges

- parcours idle print idle a : *dbejkwafcg* on suit uniquement les arêtes bleues
- parcours idle idle print a : *djvwkebfgca* on suit uniquement les arêtes vertes
- parcours print print print a : **abdddbejjje***kvvvkwwwkeb...* on suit toutes les arêtes

■ **Remarque 10.6** Si on considère un arbre d'expression comme :



On va alors obtenir en affichant à chaque traitement la suite : $+222 + \times 333 \times 444 \times +$. Chaque nombre n étant une feuille, on va observer l'affichage de nnn qu'on peut réduire à n . Pour les opérateurs, si on remplace le premier affichage par (et le dernier par). En procédant ainsi, on affiche $(2 + (3 \times 4))$ et on ainsi retrouvé l'écriture bien parenthésée de l'expression.

■ **Définition III.1** L'ordre dans lequel on effectue un traitement *préfixe* dans un parcours sur les nœuds d'un arbre est appelé l'ordre *préfixe* sur les nœuds.

On définit, de même, l'ordre *infixe* et l'ordre *postfixe*.

III.2 Parcours impératifs

III.2.i Cadre général

On va condiscréer une structure de donnée abstraite qui généralise les piles et les files et permettre de représenter un ensemble de tâches à traiter. Pour cela, on dispose d'un type paramétrique 'a t et de l'interface :

- *cree* : unit \rightarrow 'a t crée un ensemble de tâches
- *ajoute* : 'a t \rightarrow 'a \rightarrow unit ajoute une nouvelle tâche à traiter
- *retire* : 'a t \rightarrow 'a retire une tâche de l'ensemble des tâches à traiter
- *est_vide* : 'a t \rightarrow bool renvoie un booléen indiquant si l'ensemble de tâches est vide

On a ainsi vu deux possibles implémentations, qui sont elles-mêmes des structures abstraites mais un peu moins abstraites que celle-ci :

- les piles pour lesquelles on retire le dernier élément ajouté
- les files pour lesquelles on retire l'élément le plus anciennement ajouté

On écrire un parcours impératif générique :

```

let parcours traitement a =
  let avisiter = cree () in
  ajoute avisiter a;
  while not (est_vide avisiter) do
    let a = retire avisiter in
    match a with
    | Nil -> ()
    | Noeud(g, _, d) -> traitement a;
                           ajoute avisiter g;
                           ajoute avisiter d
done
  
```


III.2.ii Cas du parcours en profondeur

Dans le cas où on utilise une pile, on retrouve essentiellement le parcours récursif précédent avec quelques changements :

- on empile ici d'abord g puis d, donc on va à droite avant d'aller à gauche. Il suffit de permuter les deux ajouts pour retrouver l'ordre précédent
- on effectue un unique traitement préfixe
- si on considère la pile d'appels récursifs du parcours récursif, on constate que le nombre de structure pile est majoré par la hauteur de l'arbre. Ici, on va potentiellement ajouter tous les nœuds sur la pile, donc, on a une complexité en espace en $O(|a|)$ plutôt qu'en $O(h(a))$.

On parle de **parcours en profondeur** ou depth-first search (DFS) en anglais.

■ **Exemple 10.4** Si on considère l'arbre suivant :



En ignorant les arbres vides, par exemple en ne les ajoutant pas, on va avoir le déroulement suivant du parcours :


avisiter	étiquette traitée
$1 \rightarrow$	
$2, 3 \rightarrow$	1
$2, 5, 6 \rightarrow$	3
$2, 5 \rightarrow$	6
$2, 7 \rightarrow$	5
$2 \rightarrow$	7
$4 \rightarrow$	2
	4

III.2.iii Cas du parcours en largeur

Dans le cas où on utilise une file, on obtient un parcours appelé le **parcours en largeur** en breadth-first search (BFS) en anglais.

Dans ce parcours, on va visiter les nœuds *niveau par niveau* en partant de la racine jusqu'aux feuilles de plus grande profondeur.

■ **Exemple 10.5** Si on considère l'arbre suivant :



En ignorant les arbres vides, par exemple en ne les ajoutant pas, on va avoir le déroulement suivant du parcours :

aviser	étiquette traitée
→ 1 →	
→ 3, 2 →	1
→ 4, 3 →	2
→ 6, 5, 4 →	3
→ 6, 5 →	4
→ 7, 6 →	5
→ 7 →	6
	7

Ce parcours est particulièrement intéressant quand on cherche une information avec la plus petite profondeur possible. Par exemple, dans le cas de la recherche d'une solution à un problème, on peut vouloir tester les petites solutions avant les plus grandes.

Pour des problèmes d'énumération, c'est également intéressant, car on va obtenir des éléments par ordre croissant de la longueur du chemin depuis la racine. Par exemple, pour les tries, on en déduit les mots par ordre croissant de longueur.

III.3 Parcours d'arbres

Pour des arbres, on va suivre les mêmes principes. La différence va se situer au niveau de l'implémentation car il faudra alors manipuler des listes ou des tableaux d'enfants.

Notons qu'on a déjà vu un tel problème quand on a résolu des problèmes par backtracking. En effet, avec le backtracking, on a un arbre implicite des positions partielles dont les enfants sont les mouvements possibles vers de nouvelles positions.

IV Arbres binaires de recherche

- IV.1 Objectif
- IV.2 Définition
- IV.3 Opérations
- IV.4 Équilibrage
- IV.4.i Arbres 2-3
- IV.4.ii Arbres rouges et noirs
- IV.5 Implémentation d'un dictionnaire
- V Tas
- V.1 Présentation
- V.2 Implémentation
- V.3 Application aux files de priorité
- VI TP - Arbres en OCaml
- VI.1 Premières fonctions

On va considérer le type des arbres binaires 'a arbre défini par :

```
OCaml | type 'a arbre = Nil | Noeud of 'a arbre * 'a * 'a arbre
```

Question VI.1 Écrire des fonctions :

```
OCaml | (* Calcule le nombre de noeuds de a *)
      | let taille (a : 'a arbre) : int
      | (* Calcule la hauteur de a *)
      | let hauteur (a : 'a arbre) : int
      | (* Indique si a est réduit à une feuille *)
      | let feuille (a : 'a arbre) : bool
```

Démonstration.

```
OCaml | let rec taille a = match a with
      | Nil -> 0
      | Noeud(g,x,d) -> 1 + taille g + taille d

      let rec hauteur a = match a with
      | Nil -> -1
      | Noeud(g,x,d) ->
          1 + max (hauteur g) (hauteur d)

      let feuille a = match a with
      | Nil -> false
      | Noeud(g, x, d) -> g = Nil && d = Nil
```

Question VI.2 Écrire une fonction `sous_arbres` qui renvoie la liste des sous-arbres non vides d'un arbre.

En déduire des fonctions `noeuds`, `feuilles` et `noeuds_internes` qui renvoient la liste des étiquettes des noeuds correspondants.

Démonstration.

```
OCaml | let rec sous_arbres a = match a with
      | Nil -> []
      | Noeud(g, x, d) ->
          a :: (sous_arbres g @ sous_arbres d)

      let rec noeuds a = match a with
      | Nil -> []
      | Noeud(g, x, d) ->
          x :: (noeuds g @ noeuds d)

      let rec feuilles a = match a with
      | Nil -> []
      | Noeud(g, x, d) ->
          if feuille a then [x]
```

```

else feuilles g @ feuilles d

let rec noeuds_internes a = match a with
| Nil -> []
| Noeud(Nil, _, Nil) -> []
| Noeud(g, x, d) ->
  x :: (noeuds_internes g @ noeuds_internes d)

```

Pour accéder à un nœud de l'arbre, on descend en partant de la racine et en allant à gauche ou à droite. On peut donc représenter un tel chemin par une liste de déplacements :

```

OCaml type deplacement = Gauche | Droite
type chemin = deplacement list

```

Question VI.3 Écrire une fonction `chemin_noeud : 'a arbre -> chemin -> 'a option` qui renvoie l'étiquette d'un nœud donné par son chemin. On utilise un type `option` en cas de chemin invalide.

Démonstration.

```

type deplacement = Gauche | Droite
type chemin = deplacement list

let rec chemin_noeud a l =
  match a, l with
  | Nil, _ -> None
  | Noeud(g,x,d), Gauche::q -> chemin_noeud g q
  | Noeud(g,x,d), Droite::q -> chemin_noeud d q
  | Noeud(g,x,d), [] -> Some x

```

VI.2 Parcours

Sur le même modèle que l'exploration par *backtracking*, on va réaliser un parcours en profondeur d'un arbre en explorant à gauche puis à droite ses sous-arbres de manière récursives. Chaque nœud est donc vu trois fois :

- une première fois quand on le découvre avant d'explorer son sous-arbre gauche
- entre les deux explorations
- enfin quand on a fini d'explorer son sous-arbre droit.

Question VI.4 Écrire des fonctions `affiche_avant`, `affiche_milieu` et `affiche_apres` qui parcourt et affiche les étiquettes d'un `string arbre` selon les trois cas précédents. Note : il s'agit essentiellement du même code à une ligne près.

Démonstration.

```

let rec affiche_avant a = match a with
| Nil -> ()
| Noeud(g,x,d) ->
    print_string x;
    affiche_avant g;
    affiche_avant d

let rec affiche_milieu a = match a with
| Nil -> ()
| Noeud(g,x,d) ->
    affiche_milieu g;
    print_string x;
    affiche_milieu d

let rec affiche_apres a = match a with
| Nil -> ()
| Noeud(g,x,d) ->
    affiche_apres g;
    affiche_apres d;
    print_string x

```

OCaml

Question VI.5 On peut représenter une expression arithmétique comme $(2 + 3) \times 4$ en tant qu'arbre avec des opérations pour les nœuds internes et des valeurs pour les feuilles. Quitte à utiliser des `string` dans les deux cas, qu'obtient-on sur une telle expression avec les trois opérations précédentes ?

Démonstration.

```

let rec evalue a = match a with
| Nil -> failwith "Vide"
| Noeud(Nil,x,Nil) -> int_of_string x
| Noeud(g, x, d) ->
    let eg = evalue g in
    let ed = evalue d in
    match x with
    | "+" -> eg + ed
    | "*" -> eg * ed
    | _ -> failwith "Ope inconnue"

```

OCaml

L'appel à `affiche_avant` sur l'expression $(2 + 3) \times 4$ va afficher `*+234`.
L'appel à `affiche_milieu` sur l'expression $(2 + 3) \times 4$ va afficher `2+3*4`.
L'appel à `affiche_apres` sur l'expression $(2 + 3) \times 4$ va afficher `23+4*`.
On retrouve ainsi les notions préfixes, infixes et postfixes d'une expression arithmétique.

On redonne ici l'implémentation d'une pile et d'une file en OCaml :

```

let pile_creer () = ref []
let pile_empile p x = p := x :: !p
let pile_depile p =
  match !p with
  | [] -> failwith "Pile vide"
  | x::q -> p := q; x
let pile_est_vide p = !p = []

```

OCaml

```

let file_creer () = (pile_creer (), pile_creer ())
let file_bascule (pin, pout) = pout := List.rev !pin; pin := []
let file_enfile (pin, pout) x = pile_empile pin x
let file_defile (pin, pout) =
  if pile_est_vide pout
  then file_bascule (pin, pout);
  pile_depile pout
let file_est_vide (pin, pout) = pile_est_vide pin && pile_est_vide pout

```

Ces deux structures de données ont la même interface mais deux comportements différents. On va utiliser un unique type pour les représenter afin de permettre à une fonction d'utiliser soit une pile soit une file.

```

type ('a, 'b) taches = {
  creation : unit -> 'a;
  ajouter : 'a -> 'b -> unit;
  retirer : 'a -> 'b;
  est_vide : 'a -> bool
}

let taches_pile = {
  creation = pile_creer;
  ajouter = pile_empile;
  retirer = pile_depile;
  est_vide = pile_est_vide
}

let taches_file = {
  creation = file_creer;
  ajouter = file_enfile;
  retirer = file_defile;
  est_vide = file_est_vide
}

```

OCaml

■ **Remarque 10.7** Ici, on a une limitation du système de types. On aimeraient paramétriser `taches` par `('a, 'b)`, où `'b` est un type paramètré, ainsi on aurait soit `('a pile, 'a)` où `('a file, 'a)` comme pour les deux cas. Cependant, ce n'est pas possible, les types génériques ne sont pas paramétriques. C'est pour cela qu'on a un `('a, 'b)` sans avoir de lien apparent entre `'a` et `'b`.

On pourra alors écrire une fonction prenant un gestionnaire de tâches en paramètre :

```
OCaml let f t a =
  let a_traiter = t.creation () in
  for i = 0 to Array.length a - 1 do
    t.ajouter a_traiter a.(i)
  done;
  while not (t.est_vide a_traiter) do
    print_int (t.retirer a_traiter)
  done
```

Ainsi `f taches_pile [|1;2;3|]` va afficher 321 et `f taches_file [|1;2;3|]` va afficher 123.

Question VI.6 En déduire une fonction

```
OCaml parcours : ('a, 'b arbre) taches -> 'b arbre -> unit
```

qui effectue un parcours de l'arbre en affichant les étiquettes des nœuds visités dans l'ordre induit par le gestionnaire de tâches passé en paramètre.

Démonstration.

```
OCaml let parcours t a =
  let avisiter = t.creation () in
  t.ajouter avisiter a;
  while not (t.est_vide avisiter) do
    match t.retirer avisiter with
    | Nil -> ()
    | Noeud(g,x,d) ->
        print_int x;
        t.ajouter avisiter g;
        t.ajouter avisiter d
  done
```

VI.3 Arbres binaires stricts

Pour représenter des arbres dont les nœuds ont tous deux fils non vides, on va utiliser le type

```
OCaml type ('a, 'b) arbre_bin = Feuille of 'a
          | NoeudI of ('a, 'b) arbre_bin * 'b * ('a, 'b) arbre_bin
```

Ce type permet de représenter naturellement des expressions arithmétiques comme :

```
OCaml NoeudI(NoeudI( Feuille 2, '+', Feuille 3), '*', Feuille 5)
```

Question VI.7 Écrire une fonction `eval : (int, char) arbre_bin -> int` qui évalue une telle expression.

Démonstration.

```
Ocaml let rec evalue a = match a with
| Feuille n -> n
| NoeudI(g, x, d) ->
    let eg = evalue g in
    let ed = evalue d in
    match x with
    | '+' -> eg + ed
    | '*' -> eg * ed
    | _ -> failwith "Ope inconnue"
```



Si on considère le type

```
Ocaml type ('a, 'b) etiquette = F of 'a | N of 'b
```

On peut passer d'un ('a, 'b) arbre_bin à un ('a, 'b) etiquette arbre et, dans certains cas, d'un ('a, 'b) etiquette arbre à un ('a, 'b) arbre_bin.

Question VI.8 Écrire ainsi deux fonctions de conversion :

```
Ocaml arbre_bin_vers_arbre : ('a, 'b) arbre_bin -> ('a, 'b) etiquette arbre
arbre_vers_arbre_bin : ('a, 'b) etiquette arbre -> ('a, 'b) arbre_bin option
```



Démonstration.

```
Ocaml let rec arbre_bin_vers_arbre a =
  match a with
  | Feuille n -> Noeud(Nil, F n, Nil)
  | NoeudI(g, x, d) -> Noeud(arbre_bin_vers_arbre g,
                                 N x,
                                 arbre_bin_vers_arbre d)

let rec arbre_vers_arbre_bin a =
  match a with
  | Noeud(Nil, F f, Nil) -> Feuille f
  | Noeud(g, N x, d) -> begin
      match arbre_vers_arbre_bin g, arbre_vers_arbre_bin d with
      | Some g', Some d' -> NoeudI(g', x, d')
      | _ -> None
    end
  | _ -> None
```



VI.4 Dessin d'arbres

On va réaliser dans cette partie une fonction de dessin d'arbres avec `graphics`. L'idée est de placer la racine et de dessiner les sous-arbres gauche et droit en dessous. Pour cela, il va falloir connaître la taille de ces sous-arbres en pixels.

On pourra consulter la documentation de `graphics` ici : [Graphics](#)

Question VI.9 Écrire une fonction `pixels : int arbre -> int * int` qui renvoie un couple (`largeur, racine`) où `largeur` est la largeur en pixels d'un arbre dans son affichage et `racine` l'abscisse de la racine dans cet affichage.

OCaml

```
let rnoeud = 5 (* Le rayon du noeud *)
let marge = 2 (* la marge autour du noeud *)

let rec pixels a = match a with
| Nil -> 0, 0
| Noeud(g, _, d) ->
    let lg, _ = pixels g in
    let ld, _ = pixels d in
    lg + ld + 2*(marge + rnoeud), lg + marge + rnoeud
```



Démonstration.

Question VI.10 En déduire une fonction `dessine : int arbre -> int -> int -> unit` tel que `dessine a x y` dessine l'arbre `a` en plaçant la racine en (x, y) .



Démonstration.

OCaml

```
let rec dessine a x y =
  match a with
  | Nil -> ()
  | Noeud(g, e, d) ->
      (* On précalcule les tailles des sous-arbres *)
      let lg, rg = pixels g in
      let _, rd = pixels d in
      (* position de la racine gauche relativement à (x,y) *)
      let v_rg = x - lg - marge - rnoeud + rg in
      (* position de la racine droite relative (x, y) *)
      let v_rd = x + marge + rnoeud + rd in
      let dec_y = y - 2 * rnoeud - marge in

      moveto x y; lineto v_rg dec_y;
      moveto x y; lineto v_rd dec_y;
      fill_circle x y rnoeud;

      moveto (x-tw/2) (y-th/2);
      set_color white;
      draw_string e;
      set_color black;

      dessine g v_rg dec_y;
      dessine d v_rd dec_y
```



VI.5 Génération aléatoire d'arbres

Dans cette partie, ce qui nous intéresse est de générer aléatoirement des arbres pour observer la structure. Les étiquettes ne sont pas pertinentes, on pourra donc au choix, soit considérer des `unit arbre`, soit redéfinir un type d'arbre non étiquetés.

On va réaliser ici deux modèles de génération aléatoire d'arbres. Le premier modèle consiste, pour générer un arbre de n nœuds, à choisir aléatoirement k dans $\llbracket 0, n \rrbracket$, à générer aléatoirement un arbre g à k nœuds et un arbre d à $n - k$ nœuds puis à renvoyer l'arbre `Noeud(g, (), d)`.

Question VI.11 Implémenter ce modèle avec une fonction `genere_arbre_1 : int -> unit arbre`.

Tester votre fonction, notamment avec l'affichage de la partie précédente.

Démonstration.

```
OCaml | let rec genere_arbre_1 n =
        if n = 0
        then Nil
        else if n = 1 then Noeud(Nil, (), Nil)
        else let k = Random.int (n-1) in
              Noeud(genere_arbre_1 k, (),
                    genere_arbre_1 (n-1-k))
```

Pour le deuxième modèle, on va choisir un sous-arbre vide uniformément et le remplacer par un nœud.

Question VI.12 Écrire une fonction `chemins_vides : 'a arbre -> chemin list` qui étant donné un arbre renvoie la liste des chemins permettant d'aboutir à un sous-arbre vide.

Démonstration.

```
OCaml | let chemins_vide a =
        let rec aux a l =
            match a with
            | Nil -> [ List.rev l ]
            | Noeud(g, _, d) ->
                aux g (Gauche::l)
                @ aux d (Droite::l)
        in aux a []
```

Question VI.13 Écrire une fonction `rempli : 'a arbre -> chemin -> 'a arbre` qui remplace un sous-arbre vide donnée par son chemin par un nœud.

Démonstration.

OCaml

```
let rec remplit a c =
  match a, c with
  | Nil, [] -> Noeud(Nil, (), Nil)
  | Noeud(g,x,d), Gauche::q ->
    Noeud(remplit g q, x, d)
  | Noeud(g,x,d), Droite::q ->
    Noeud(g, x, remplit d q)
  | _ -> failwith "Error"
```



Question VI.14 En déduire une fonction `genere_arbre_2 : int -> unit arbre` qui prend un entier n et construit un arbre à n nœuds en partant de l'arbre vide et en réalisant n remplacement d'un arbre vide par un nœuds, le choix de l'arbre vide se faisant uniformément.

Note : on pourra utiliser `List.nth` et `Random.int`. Voir par exemple `Random`



Démonstration.

OCaml

```
let rec genere_arbre_2 n =
  if n = 0 then Nil
  else
    let a = genere_arbre_2 (n-1) in
    let l = chemins_vide a in
    let k = Random.int (List.length l) in
    let ch = List.nth l k in
    remplit a ch
```



11. Graphes


Graphes

IV

Algorithmique

12	Introduction à l'analyse des algorithmes	115
I	État d'un programme	
II	Terminaison	
III	Correction	
IV	Complexité	
V	Exercices	
13	Complexité amortie	137
I	Introduction	
II	Techniques de calcul	
14	Recherche par Force brute	147
I	Principe	
II	Recherche par retour sur trace (backtracking)	
III	Stratégies d'énumération	
IV	Droite de balayage	
15	Algorithmes gloutons	169
I	Principe	
II	Construction de l'arbre de Huffman	
III	Preuve d'optimalité	
IV	Sélection d'activités	
V	Ordonnancement de tâches	
16	Diviser pour regner	183
I	Diviser pour régner	
17	Algorithmique des textes	189
I	Recherche dans un texte	
II	Compression	
III	Problèmes supplémentaires	

ALGORITHMS BY COMPLEXITY



12. Introduction à l'analyse des algorithmes

Source de l'image d'en-tête XKCD #1667

■ Note 12.1 Roadmap :

- reprendre les exemples dans les trois langages.
- rajouter plus exercices.

■ **Remarque 12.1** Ce chapitre présente les trois grands principes qui nous serviront de guide pour analyser les algorithmes et les programmes :

- La **terminaison** : l'algorithme termine-t-il au bout d'un nombre fini d'étapes quelle que soit l'entrée ?
- La **correction** : le résultat rendu est-il celui qui était attendu ?
- La **complexité** : combien de temps prend le programme selon la taille de l'entrée ? Combien d'espace mémoire occupe-t-il ?

Savoir répondre à ces questions, c'est pouvoir prédire, avant d'avoir écrit la moindre ligne de code, ce qui va se passer.

■ État d'un programme

Avant de commencer à raisonner sur les algorithmes, il est nécessaire de préciser la notion d'état qui correspond à un instantané de l'environnement d'exécution d'un programme lorsque son exécution est interrompue. Bien entendu, la description complète d'un tel état ne serait pas forcément pertinent, car cela prendrait en compte l'ensemble de la mémoire. Le plus souvent, on considère uniquement ce qui est important pour ce qu'on étudie.

Ainsi, si on considère le programme suivant :

```

1 int a = 3;
2 int b = 2;
3
4 a = b;

```

L'état du programme à l'entrée de la ligne 4 est

variable	valeur
a	3
b	2

et l'état à la sortie de la ligne 4 est

a	2
b	2

Parfois, on aura besoin de plus d'information dans l'état comme la position en mémoire de certaines données. Mais assez souvent, pour les algorithmes qui nous intéressent, on pourra adopter un point de vue assez abstrait de l'état d'un algorithme comme étant une fonction partielle des noms vers les valeurs.

Pour la terminaison et la correction, on va considérer des propriétés logiques dépendant de l'état. Par exemple $a \geq 0 \wedge b \geq a$.

II Terminaison

Définition II.1 On dit qu'un algorithme **termine** quand il n'exécute qu'un nombre fini d'étapes sur toute entrée.

■ **Remarque 12.2** Cela n'empêche pas que ce nombre d'étapes puisse être arbitrairement grand en fonction des entrées. ■

Un algorithme qui n'utilise ni boucles inconditionnelles ni récursivité termine toujours. Ainsi, la question de la terminaison n'est à considérer que dans ces deux cas.

Considérons par exemple l'algorithme suivant qui, étant donné un entier naturel n strictement positif, inférieur à 2^{30} , détermine le plus petit entier k tel que $n \leq 2^k$:

```

OCaml
let plus_grande_puissance2 n =
  let k = ref 0 in
  let p = ref 1 in
  while !p < n do
    k := !k + 1;
    p := !p * 2
  done;
  !k

```

On remarque que p prend successivement pour valeurs toutes les puissances de 2 jusqu'à une éventuelle sortie de boucle. Or, il existe une puissance de 2 supérieure ou égale à n , donc, une fois atteinte, la condition de la boucle `while` n'est plus remplie et l'algorithme termine.

■ **Remarque 12.3** Prouver la terminaison n'est pas une question facile, elle peut-même être insoluble. Par exemple, si on considère le programme suivant :

Python

```
def temps_de_vol(a):
    u = a
    n = 0
    while u != 1:
        if u % 2 == 0:
            u = u // 2
        else:
            u = 3*u + 1
        n = n+1
    return n
```

être capable de prouver sa terminaison revient à prouver la conjecture de Collatz (encore dite de Syracuse).

On peut aussi considérer le tri suivant :

Python

```
def bogo(t):
    while not est_trie(t):
        melange(t)
```

Il semble très improbable que cet algorithme ne termine pas, d'ailleurs on peut prouver qu'il termine avec probabilité 1, mais on ne peut pas exclure le cas où il mélange indéfiniment.

■

II.1 Variant de boucle

Pour prouver la terminaison d'une boucle conditionnelle, on utilise un **variant** de boucle.

Définition II.2 Un **variant de boucle** est une quantité entière **positive** à l'entrée de chaque itération de la boucle et qui diminue **strictement** à chaque itération.

Dans l'exemple précédent, la quantité $n - p$ est un variant de boucle :

- Au départ, $n > 0$ et $p = 1$ donc $n - p \geq 0$
- Comme il s'agit d'une différence de deux entiers, c'est un entier. Et tant que la condition de boucle est vérifiée $p < n$ donc $n - p > 0$.
- Lorsqu'on passe d'une itération à la suivante, la quantité passe de $n - p$ à $n - 2p$ or $2p - p > 0$ car $p \geq 1$. Il y a bien une stricte diminution.

■ **Remarque 12.4** Ici, en sortie de boucle, $n - p \leq 0$. On fait donc bien attention de préciser que la quantité est positive tant que la condition de boucle est vérifiée.

■

Si on a un variant de boucle qui vaut initialement n avant d'entrer dans la boucle, celle-ci effectue au plus n itérations car le variant diminue au moins de 1 à chaque étape.

Théorème II.1 Si une boucle admet un variant de boucle, elle termine.

II.2 Exemple de la recherche dichotomique

On considère ici la recherche dichotomique dans un tableau trié d'entiers. Étant donné un tableau t de taille $n > 0$ et un entier x dont on cherche à déterminer sa présence dans le tableau entre les indices i et j , on considère l'algorithme suivant :

- Si $i > j$, alors il n'y a pas de sous-tableau et on renvoie `false`.
- Sinon, soit m l'élément d'indice $p = \left\lfloor \frac{i+j}{2} \right\rfloor$.
 - * Si $x = m$, on renvoie `true`
 - * Si $x < m$, on continue la recherche dans le sous-tableau des indices i à $p - 1$.
 - * Si $x > m$, on continue la recherche dans le sous-tableau des indices $p + 1$ à j .

Le programme suivant présente une implémentation de cet algorithme en C.

```
exception Trouve of int

let rech_dicho t x =
  let i = ref 0 in
  let j = ref (Array.length t) - 1 in

  try
    while !i <= !j do
      let p = (!i + !j)/2 in
      let m = t.(p) in

      if m = x
      then raise (Trouve p)
      else if x < m
      then j := p-1
      else i := p+1
    done;
    None
  with Trouve i -> Some i
```

■ **Remarque 12.5** On aurait pu écrire $i+(j-i)/2$ et non $(i+j)/2$ afin d'éviter des erreurs de dépassement dans le calcul de $i+j$. ■

Ici, la terminaison n'est pas immédiate, on va la prouver à l'aide d'un variant de boucle. On considère ainsi la quantité $d(i, j) = j - i$.

- Comme le tableau est non vide, $d(0, n - 1) \geq 0$. Ensuite, la condition de boucle est équivalente à $d(i, j) \geq 0$, donc cette quantité est bien entière et positive à l'entrée de chaque itération.
- Quand on passe à l'itération suivante, on passe
 - * soit de $d(i, j)$ à $d(i, p - 1)$. Or $d(i, p - 1) = p - 1 - i = \left\lfloor \frac{i+j}{2} \right\rfloor - 1 - i < \frac{i+j}{2} - i \leq j - i = d(i, j)$.
 - * soit de $d(i, j)$ à $d(p + 1, j)$. Or $d(p + 1, j) = j - p - 1 = j - \left\lfloor \frac{i+j}{2} \right\rfloor - 1 < j - \frac{i+j}{2} \leq j - i = d(i, j)$.

Dans tous les cas, $d(i, j)$ diminue strictement.

Ainsi, il s'agit d'un variant de boucle et l'algorithme termine.

■ **Remarque 12.6** On remarque que le programme récursif suivant réalise également cet algorithme. ■

OCaml

```
(* rech_dicho : int array -> int -> int -> int -> int option *)
let rec rech_dicho t i j x =
  if i <= j
  then let p = (i+j)/2 in
    let m = t.(p) in
      if x = m
      then Some p
      else if x < m
      then rech_dicho t i (p-1) x
      else rech_dicho t (p+1) j x
  else None
```

Il suffit alors d'appeler `rech_dicho t 0 (Array.length t - 1) x` pour faire une recherche sur tout le tableau.

Ici, il n'y a pas explicitement de boucle, mais le même principe peut être mis en place pour prouver que le nombre d'appels récursifs est majoré, et donc que toute exécution termine. En effet, la quantité $d(i, j) = j - i$ diminue pour les mêmes raisons à chaque appel récursif et reste entière positive.

II.3 Exemple du tri à bulle

On considère le tri à bulles dans une implémentation naïve. On effectue ainsi une série de balayages d'un tableau : on parcourt le tableau de gauche à droite et si deux éléments consécutifs sont dans le désordre, on les permute. À l'issu d'un tel balayage, si on a effectué au moins un échange, on recommence, sinon on s'arrête, car c'est le signe que le tableau est trié qu'on le prouvera à la fin de ce paragraphe.

On obtient alors le code suivant :

C

```
void swap(int t[], int i, int j)
{
    int temp = t[i];
    t[i] = t[j];
    t[j] = temp;
}

void tri_bulles(int t[], int nb)
{
    bool echange = true;
    while(echange)
    {
        echange = false;
        for (int i = 0; i < nb-1; i++)
        {
            if (t[i] > t[i+1])
            {
                echange = true;
                swap(t, i, i+1);
            }
        }
    }
}
```

Si la question de la terminaison de la boucle `for` ne se pose pas, celle de la boucle `while` mérite de s'y attarder pour deux raisons :

- premièrement pour la terminaison elle-même
- deuxième pour savoir si on peut majorer le nombre d'itérations, une question qu'on verra avec la question de la complexité.

On va prouver la terminaison pour un type d'algorithme de tri qui généralise le tri à bulle. Pour cela, on commence par définir la notion d'inversion pour un tableau t de $|t|$ éléments :

Définition II.3 On dit qu'un couple $(i, j) \in \llbracket 0, |t| - 1 \rrbracket^2$ est une **inversion** pour t si $i < j$ et $t[i] > t[j]$.

On note $Inv(t)$ l'ensemble des inversions de t et $inv(t) = |Inv(t)|$ le nombre d'inversions.

On dira qu'une inversion de la forme $(i, i + 1)$ est une **inversion directe**.

On considère donc un algorithme qui résout une inversion directe dès qu'il y en a au moins une.

```
Python def tri(t):
    while existe_inversion_directe(t):
        i = debut_d_une_inversion_directe(t)
        echange(t, i, i+1)
```

Le tri à bulles est alors une manière de réaliser l'algorithme précédent en effectuant des inversions alors qu'on avance dans le tableau.

Théorème II.2 Pour un tableau t les propositions suivantes sont équivalentes :

1. t est trié dans l'ordre croissant
2. t n'a pas d'inversions
3. t n'a pas d'inversions directes

Démonstration.

- 1) \rightarrow 3) naturellement si t es trié dans l'ordre croissant, $i < i + 1$ entraîne $t[i] \leq t[i + 1]$, donc il ne peut il y avoir d'inversions directes.
- 2) \rightarrow 1) si $i < j$, comme t n'a pas d'inversions, on a $t[i] \not> t[j]$, c'est-à-dire $t[i] \leq t[j]$. Ainsi, le tableau est bien trié dans l'ordre croissant.
- 3) \rightarrow 2) pour tout $i < |t| - 1$ on a $t[i] \leq t[i + 1]$. Soit $i < j$, on va raisonner par récurrence sur $j - i$ pour montrer que $t[i] \leq t[j]$.
 - ★ si $j - i = 1$, on n'a pas d'inversion directe donc $t[i] \leq t[j]$.
 - ★ si $j - i > 1$ et que $t[i] \leq t[j - 1]$, car $i < j - 1$ avec $j - 1 - i = (j - i) - 1$, alors $t[i] \leq t[j - 1] \leq t[j]$ car $(j - 1, j)$ n'est pas une inversion.

Ainsi, dans tous les cas on a bien $t[i] \leq t[j]$. Donc, t est trié par ordre croissant. ■

II.4 Lien avec la récursivité

II.5 Boucles imbriquées

III Correction

Pour parler de correction d'un algorithme, il est nécessaire d'identifier précisément ce qui doit être calculé par l'algorithme. Pour cela, on considère ici informellement des spécifications dépendant des entrées et du résultat de l'algorithme. On verra dans le chapitre sur la logique qu'il s'agit ici de prédictats logiques.

Voici des exemples de spécifications :

- le tableau t en sortie est trié dans l'ordre croissant

- la valeur renvoyée est le plus petit indice de x dans le tableau ou -1 s'il ne le contient pas.

Définition III.1 Un algorithme est **correct** vis-à-vis d'une spécification lorsque quelle que soit l'entrée

- il **termine**
- le résultat renvoyé vérifie la spécification.

On considère également la correction **partielle** en l'absence de terminaison :

Définition III.2 Un algorithme est **partiellement correct** vis-à-vis d'une spécification lorsque quelle que soit l'entrée le résultat renvoyé vérifie la spécification.

III.1 Invariant de boucle

Définition III.3 On considère ici une boucle (conditionnelle ou non).

Un prédicat est appelé un **invariant de boucle** lorsque

- il est vérifié avant d'entrer dans la boucle
- s'il est vérifié en entrée d'une itération, il est vérifié en sortie de celle-ci.

Quand la boucle termine, on déduit alors que l'invariant est vérifié en sortie de boucle. On cherche donc un invariant qui permette de garantir la spécification en sortie de boucle.

■ **Remarque 12.7** Pour les boucles inconditionnelles, il y a une gestion implicite de l'indice de boucle qui va se retrouver dans l'invariant. On peut alors considérer que la sortie de boucle s'effectue après être passé à l'indice suivant.

Dans le cas d'une boucle conditionnelle portant sur la condition P et ayant un invariant de boucle I , en sortie le prédicat $\neg P \wedge I$ (non P et I) sera vérifié.

On peut illustrer cela en reprenant la fonction `plus_grande_puissance2` vue à la partie Terminaison. On considère ici le prédicat $I(k, p) := 2^{k-1} < n$ et $p = 2^k$.

- En entrée de boucle, on a bien $2^{-1} < n$.
- Si le prédicat est vérifié en entrée d'itération. On a alors $2^{k-1} < n$ et comme on est entrée dans cette itération $p = 2^k < n$. Donc en sortie d'itération on aura bien $I(k + 1, 2p)$, car $2p = 2^{k+1}$.

Ainsi, ce prédicat est bien un invariant et en sortie de boucle (ce qui arrive nécessairement, car l'algorithme termine), le prédicat $I(k, p)$ signifie que $2^{k-1} < n$ et la condition de sortie de boucle qu'on a $n \leq 2^k$.

La valeur renvoyée est bien k tel que $2^{k-1} < n \leq 2^k$ ce qui était la spécification annoncée du programme.

III.2 Exemple du tri par sélection

Le programme suivant présente un algorithme de tri, appelé le *tri par sélection* dont on va analyser la complexité. Il s'agit d'un tri qui repose sur un principe simple, on va chercher le plus petit élément du tableau à trier et le placer à la position courante. On définit ainsi trois fonctions :

- `echange` réalise l'échange de valeurs entre deux cases du tableau
- `indice_minimum` renvoie l'indice de la plus petite valeur entre deux indices donnés
- `tri_par_selection` réalise le tri en parcourant le tableau du premier au dernier indice et en plaçant à la position courante le minimum restant.

```
C void echange(int *tableau, int i, int j)
{
```

```

        int temp = tableau[i];
        tableau[i] = tableau[j];
        tableau[j] = temp;
    }

void indice_minimum(int *tableau, int min_indice, int max_indice)
{
    int i = min_indice;

    for (int j = min_indice + 1; j <= max_indice; j++)
    {
        if (tableau[j] < tableau[i])
            i = j;
    }

    return i;
}

void tri_par_selection(int *tableau, int taille)
{
    for (int i = 0; i < taille; i++)
    {
        echange(tableau, i, indice_minimum(tableau, i, taille-1));
    }
}

```

Il n'y a pas de problèmes de terminaison ici, car toutes les boucles sont inconditionnelles. Pour prouver sa correction, on va considérer séparément les deux boucles.

- Boucle dans `indice_minimum`: on va valider l'invariant $I(i, j) := \forall k \in [i, j-1], \text{tableau}[i] \leq \text{tableau}[k]$.
 - ★ En entrée de boucle, on a $I(\min_indice, \min_indice + 1)$ vérifié directement.
 - ★ Si en entrée d'itération, $I(i, j)$ est vérifié, ce qui signifie que $\text{tableau}[i]$ est plus petit que les valeurs compris entre les indices i et $j - 1$. Alors, on distingue deux cas :
 - soit $\text{tableau}[j] < \text{tableau}[i]$ et alors en sortie i devient $i' = j$. On a alors $\text{tableau}[i'] = \text{tableau}[j] < \text{tableau}[i] \leq \text{tableau}[k]$ pour $k \in [1, j - 1]$. Donc $I(i', j + 1)$ est vérifié.
 - soit $\text{tableau}[i] \leq \text{tableau}[j]$ et ainsi on a pu prolonger le prédictat à $I(i, j + 1)$.

Ce prédictat est bien un invariant. Ainsi, en sortie de boucle, et donc avant de renvoyer sa valeur, on a bien $I(i, \text{taille})$ donc $\text{tableau}[i]$ est la plus petite valeur du tableau.
- Boucle dans `tri_par_selection`: on va valider l'invariant $T(i) :=$ le sous-tableau $\text{tableau}[0..i-1]$ des indices 0 à $i - 1$ est trié et ne contient que des valeurs plus petites que celles du sous-tableau $\text{tableau}[i..taille-1]$.
 - ★ En entrée de boucle, le sous-tableau est vide donc trié.
 - ★ Si en entrée d'itération, le prédictat est vérifié. On récupère l'indice j du minimum du sous-tableau $\text{tableau}[i..taille-1]$ à l'aide la fonction `indice_minimum`, par hypothèse $\text{tableau}[j]$ est alors supérieur ou égal à chaque élément de $\text{tableau}[0..i-1]$, en le plaçant à l'indice i , on a bien $\text{tableau}[0..i]$ qui est trié et par construction la valeur de $\text{tableau}[i]$ est inférieure à toutes celles de $\text{tableau}[i+1..taille-1]$. On a ainsi $T(i + 1)$ vérifié en sortie d'itération.

Ce prédictat est bien un invariant. Ainsi, en sortie de boucle, $T(\text{taille})$ est vérifié : le tableau est trié.

IV Complexité

IV.1 Complexité dans le pire des cas

Considérons un algorithme pour lequel on peut associer à chaque entrée une notion de taille (par exemple le nombre d'éléments d'un tableau). Pour $n \in \mathbb{N}$, on note ainsi I_n l'ensemble des entrées de taille n pour cet algorithme. Pour une entrée e , on note $t(e)$ le temps pris, par exemple en seconde, par l'algorithme sur l'entrée e . De même, on note $s(e)$ l'espace mémoire maximal, par exemple en octets, occupé par l'algorithme au cours de cette exécution **sans compter la taille des entrées**.

Définition IV.1 On appelle :

- **complexité temporelle dans le pire des cas**, la suite $(C_n^t)_{n \in \mathbb{N}}$ telle que pour tout $n \in \mathbb{N}$, $C_n^t = \max_{e \in I_n} t(e)$.
- **complexité spatiale dans le pire des cas**, la suite $(C_n^s)_{n \in \mathbb{N}}$ telle que pour tout $n \in \mathbb{N}$, $C_n^s = \max_{e \in I_n} s(e)$.

Comme on va le voir, calculer explicitement ces suites n'a pas beaucoup d'intérêt tant elles sont dépendantes de la manière dont on mesure le temps et l'espace. Ce qui compte ici, c'est de connaître l'*ordre de grandeur* de ces complexités en fonction de n .

Pour un tableau de taille n , ce programme va effectuer n itérations et sa complexité est ainsi de l'ordre de n . Il est possible d'être très précis en considérant les temps pris

- pour mettre en place l'appel de fonction et le passage des arguments
- par la gestion de l'indice de la boucle `for`
- pour la comparaison, puis pour l'affectation éventuelle
- pour mettre en place la valeur de retour afin que le résultat soit lu

On peut remarquer que la notion de pire cas dépend de la précision à laquelle on se place. Ici, si on ne s'intéresse qu'à l'ordre de grandeur, tous les tableaux de taille n sont équivalents. Par contre, si on cherche avec précision le pire cas, il est atteint avec un tableau trié par ordre croissant, car c'est le cas qui effectue une affectation à chaque itération.

```
int maximum(int *tableau, int taille)
{
    int M = INT_MIN;

    for(int i=0; i<taille; i++)
    {
        if (M > tableau[i])
            M = tableau[i];
    }

    return M;
}
```

IV.2 Comparer des complexités

Avant de pouvoir comparer les complexités des algorithmes ou des programmes, il est nécessaire de mettre en place des outils pour en parler à la fois avec précision mais également sans rentrer dans des détails d'implémentation non pertinents.

En effet, comparons les deux fonctions suivantes permettant de chercher un élément dans un tableau.

```

int recherche(int *tab, int nb,
              int elem)
{
    for(int i=0; i<nb; i++)
    {
        if (elem == tab[i])
            return i;
    }
    return -1;
}

```

```

int recherche(int *tab, int nb,
              int elem)
{
    int ind = -1;

    for(int i=0; i<nb; i++)
    {
        if (elem == tab[i])
            ind = i;
    }
    return ind;
}

```

La fonction de droite semble moins efficace que celle de gauche, car la seconde sort tout de suite de la fonction dès qu'on a trouvé l'élément alors que la première continue à parcourir t .

Mais on doit se poser la question de la pertinence de cette optimisation selon le pire des cas. Ici, le pire des cas correspond à ne pas avoir `elem` dans le tableau, et à ce moment-là les deux fonctions fonctionnent de la même manière.

■ **Remarque 12.8** En fait, la fonction de droite sera souvent à privilégier, car il est souvent plus facile d'interrompre le flot que de faire en sorte de préserver l'état à la place du `return` pour pouvoir renvoyer la bonne valeur à la fin de la fonction.

De la même manière, il faut déterminer ce que l'on souhaite compter précisément :

- si on s'intéresse au temps mis, certaines opérations prennent moins de temps que d'autre (par exemple une addition par rapport à une multiplication) mais est-ce vraiment important à l'échelle considérée ?
- si on s'intéresse à l'espace mémoire, doit-on considérer la taille précise en octets ou se contenter d'une estimation plus grossière ?

Mis à part dans certains cadres assez spécifiques, on se contente le plus souvent d'un ordre de grandeur pour ces complexités. Pour cela, on utilise des relations de comparaisons de suites et une échelle de grandeur usuelle pour les comparer.

IV.2.i La notation grand O

Définition IV.2 Soit $(u_n)_{n \in \mathbb{N}}$ et $(v_n)_{n \in \mathbb{N}}$ deux suites de nombres réels non nuls, on dit que la suite $(u_n)_n$ est dominée par $(v_n)_n$ lorsque la suite quotient $\left(\frac{u_n}{v_n}\right)_n$ est bornée.

On note alors $u_n = O(v_n)$.

Cette dernière notation se lit u_n est un grand O de v_n .


■ **Remarque 12.9** C'est bien cette locution qu'il faut avoir en tête quand on pense aux grands O et il faut faire attention de ne pas considérer l'égalité en tant que telle sans s'assurer que ce l'on fait est licite. Quand on écrira par la suite $O(v_n)$ on signifiera *n'importe quelle suite qui soit un O(v_n)*.

Si $u_n = O(v_n)$, cela signifie qu'il existe un facteur $M > 0$ tel que pour tout entier n , on ait $-M|v_n| \leq u_n \leq M|v_n|$. Les variations de la suite $(u_n)_n$ sont ainsi entièrement contrôlées par

les variations de $(v_n)_n$.

En informatique, on ne considère pour la complexité que des suites positives, ce qui permet de simplifier la relation : si $(u_n)_n, (v_n)_n$ sont des suites de réels strictement positifs, alors $u_n = O(v_n) \iff \exists M > 0, \forall n \in \mathbb{N}, u_n \leq M v_n$. C'est le cadre dans lequel on se place implicitement dans la suite de ce document.


On peut visualiser graphiquement cette relation :




On a $u_n = O(v_n)$ si et seulement s'il est possible de multiplier les ordonnées de chaque point (n, v_n) par une constante afin que ces nouveaux points soient tous au-dessus des points (n, u_n) . On peut voir que la courbe déduite des v_n enveloppe, à un facteur près, celle des u_n .

Remarque : On a relié ici les valeurs des suites pour mieux mettre en valeur cette notion d'enveloppe.

Cette relation est une notion **asymptotique** : elle n'a d'intérêt que lorsqu'on considère des rangs au voisinage de l'infini. En effet, pour un nombre fini de termes, il est toujours possible de trouver un tel M , mais pour un nombre infini, ce n'est pas le cas.



Ici, on compare asymptotiquement les suites $(u_n)_n$ et $(v_n)_n$ où pour $n \in \mathbb{N}$, $u_n = n + n \log_2 n$ et $v_n = n \log_2 n$. Pour simplifier la visualisation, on a tracé les fonctions correspondantes. On remarque qu'on a bien $n + n \log_2 n = O(n \log_2 n)$.



Par contre, si on compare les suites $(u_n)_n$ et $(v_n)_n$ où pour $n \in \mathbb{N}$, $u_n = n^2$ et $v_n = n \log_2 n$, on remarque que quelle que soit la valeur choisie pour M , il y aura un rang à partir duquel $u_n > Mv_n$.

Ici, $n^2 \neq O(n \log_2 n)$.

■ **Remarque 12.10** On a ici utilisé le logarithme en base 2, noté \log_2 , qui est essentiel informatique : si $x = \log_2(n)$ alors $n = 2^x$ où x est un réel. On considère aussi $p = \lceil \log_2(n) \rceil$ qui est le plus petit entier égal ou supérieur à $\log_2(n)$. On parle de **partie entière supérieure** et on a alors $2^{p-1} < n \leq 2^p$. Cet entier p correspond alors au plus petit nombre de chiffre nécessaire pour pouvoir écrire n en binaire. On a $\lceil \log_2(n) \rceil = O(\log_2(n))$ et ainsi, le plus souvent, on ne considère pas la partie entière explicitement. De la même manière, $\log_2(n) = \frac{\ln n}{\ln 2} = O(\ln n)$.

Un cas important de grand O est celui des $O(1)$. Si $u_n = O(1)$, cela signifie que $(u_n)_{n \in \mathbb{N}}$ est une suite bornée.

IV.2.ii Échelle de comparaison

On rappelle les limites obtenues en mathématiques que l'on nomme **croissances comparées** :

$$\forall \alpha, \beta > 0, \lim_{n \rightarrow +\infty} \frac{(\ln n)^\alpha}{n^\beta} = 0$$

$$\forall \alpha \in \mathbb{R}, \forall \beta > 1, \lim_{n \rightarrow +\infty} \frac{n^\alpha}{\beta^n} = 0$$

Or, si $\frac{u_n}{v_n} \xrightarrow[n \rightarrow +\infty]{} 0$ a fortiori le quotient est borné et $u_n = O(v_n)$. Ainsi, on a les relations suivantes :

$$\forall \alpha, \beta > 0, (\log_2 n)^\alpha = O(n^\beta)$$

$$\forall \alpha \in \mathbb{R}, \forall \beta > 1, n^\alpha = O(\beta^n)$$

De plus, si $\alpha \geq \beta > 0$, $n^\beta = O(n^\alpha)$, $(\log_2 n)^\beta = O((\log_2 n)^\alpha)$ et $\beta^n = O(\alpha^n)$.

On se ramène souvent à des complexités qui sont des grand O de produits de ces suites.

IV.2.iii Ordre de grandeur et relation Θ

On vient de voir que $\log_2 n = O(n)$, mais on a également $\log_2 = O(n^2)$. Quand on cherche à caractériser la complexité par un grand O , on va souvent chercher le grand O le plus proche de la suite.

Il est possible de définir cela précisément en considérant des suites qui sont chacune des grand O l'une de l'autre.


Par exemple, on a vu que $n \log_2 n + n = O(n \log_2 n)$, mais on a également $n \log_2 n = O(n + n \log_2 n)$.

Quand $u_n = O(v_n)$ et $v_n = O(u_n)$, on note $u_n = \Theta(v_n)$ qui est une relation symétrique qui correspond à la notion *avoir le même ordre de grandeur*. Très souvent, lorsque l'on parle de complexité, on utilise des grand O quand, en fait, on exprime des Θ . Par exemple, l'accès à un élément dans un tableau est en $O(1)$ et il ne serait pas précis de dire que c'est en $O(n)$ **même si c'est parfaitement correct**.

On peut visualiser cette relation Θ en considérant qu'il existe ainsi $M, M' > 0$ tels que $u_n \leq Mv_n$ et $v_n \leq M'u_n$. Mais on a alors

$$1/M'v_n \leq u_n \leq Mv_n$$

Ainsi, $u_n = \Theta(v_n)$ signifie qu'on peut encadrer $(u_n)_n$ entre deux multiples de $(v_n)_n$.



En reprenant la figure précédente, on observe visuellement

$$n \log_2 n \leq n \log_2 n + n \leq 2n \log_2 n$$

Avoir $u_n = \Theta(v_n)$ signifie donc que u_n évolue entre deux guides suivant les variations de v_n .

IV.2.iv Opérations sur les grands O

Si $u_n = O(w_n)$ et $v_n = O(w_n)$ alors $u_n + v_n = O(w_n)$. Ainsi, des grand O de même ordre s'ajoutent.

■ **Remarque 12.11** Comme on l'a vu précédemment, un grand O n'est pas très précis, et il est possible que par ajout on puisse obtenir un meilleur grand O. Par exemple : $n = O(n)$ et $\log_2 n - n = O(n)$ mais $n + \log_2 n - n = \log_2 n = O(n)$. Comme on ne considère ici que des suites strictement positifs, ce phénomène de compensation n'aura pas lieu. ■

Si $u_n = O(v_n)$ et w_n est une autre suite de réels strictement positifs, alors $u_n w_n = O(v_n w_n)$. On en déduit ainsi un principe qui nous sera utile par la suite $nO(1) = O(n)$.

IV.3 Complexités en temps classiques

On parle ici de complexité par raccourci pour parler de complexité dans le pire des cas en temps.

IV.3.i Complexité constante

On dit qu'un algorithme a une complexité constante quand $C_n^t = O(1)$. Il existe ainsi une constante M telle que le temps pris par l'algorithme **sur une entrée quelconque** soit inférieur à M .

De nombreuses opérations sont en temps constant sur les structures de données usuelles. Parmi celles-ci, citons-en deux essentielles :

- accéder à une case d'indice quelconque dans un tableau
- accéder à la tête ou à la queue d'une liste chaînée

Les algorithmes ou opérations en temps constant jouent un rôle primordial dans l'analyse de la complexité d'algorithmes, comme on le verra dans la partie suivante, car elles permettent de se concentrer sur les répétitions de ces opérations pour déterminer la complexité : une boucle qui se répète n fois et n'effectue que des opérations en temps constant dans son corps sera de complexité $nO(1) = O(n)$.

IV.3.ii Complexité linéaire

On dit qu'un algorithme a une complexité linéaire quand $C_n^t = O(n)$.

Cette complexité correspond à un traitement de temps constant sur chaque élément d'une entrée de taille n . C'est le cas de la recherche d'un élément dans un tableau ou de la recherche de son maximum.

Pour la recherche linéaire d'un élément, correspondant par exemple au programme ci-dessous, le pire cas correspond à ne pas avoir x dans tableau ce qui oblige à effectuer toutes les itérations. On a bien une complexité temporelle en pire cas de $O(n)$.

```
int recherche(int *tableau, int taille, int x)
{
    /* renvoie le plus petit indice i tel que tableau[i] = x
       ou -1 si x n'est pas dans le tableau */
    for(int i = 0; i < taille; i++)
    {
        if (tableau[i] == x)
            return i;
    }

    return -1;
}
```

IV.3.iii Complexité quadratique, polynomiale

On dit qu'un algorithme a une complexité quadratique quand $C_n^t = O(n^2)$. Par extension, on dit qu'il a une complexité polynomiale quand il existe $k \in \mathbb{N}$ tel que $C_n^t = O(n^k)$. Par extension, on parle parfois de complexité polynomiale pour des complexité plus précise en $O(n^\alpha)$ où α est un réel strictement positif.

L'exemple classique d'un algorithme quadratique est celui dû à un double parcours d'un tableau. On reprend ici l'algorithme de tri par sélection vu dans la partie Exemple du tri par sélection.

Afin d'analyser sa complexité, on procède fonction par fonction pour un tableau de taille n :

- `echange` est en temps constant. $O(1)$
- `indice_minimum` réalise un parcours du tableau et effectue des opérations en temps constant à chaque étape. La complexité est donc linéaire. $O(n)$
- `tri_par_selection` réalise également un parcours du tableau mais à chaque étape, on appelle `indice_minimum` qui est en $O(n)$, la complexité est donc en $nO(n) = O(n^2)$: elle est quadratique.

IV.3.iv Complexité logarithmique

On dit qu'un algorithme a une complexité logarithmique quand $C_n^t = O(\log_2 n)$.

Pour illustrer cette complexité, on reprend l'algorithme de recherche dichotomique vu dans la partie Exemple de la recherche dichotomique.

Chaque opération effectuée étant en temps constant, la complexité de cet algorithme correspond au nombre d'itérations, soit ici au nombre d'appels récursifs.

Si on considère un sous-tableau de $n = j - i + 1$ éléments lors de l'appel, un appel récursif se fera nécessairement sur un sous-tableau de $\lfloor n/2 \rfloor$ éléments. Ainsi, si $2^{k-1} < n \leq 2^k$, l'algorithme effectue moins de k itérations. En passant au logarithme, on a donc $k - 1 < \log_2 n \leq k$. Donc, le nombre d'itérations est en $O(\log_2 n)$ et c'est ainsi la complexité de l'algorithme.

■ **Note 12.2** Esquisser dès maintenant le lien entre longueur d'une branche dans un arbre de décision et complexité logarithmique ? ■

IV.3.v Complexité quasi-linéaire

On dit qu'un algorithme a une complexité quasi-linéaire quand $C_n^t = O(n \log_2 n)$. C'est le cas de la plupart des algorithmes efficaces de tri de n éléments. On peut même montrer qu'il s'agit de la complexité optimale.

Comme de nombreux algorithmes commencent par effectuer un tri avant d'effectuer un traitement linéaire, on retrouve des algorithmes quasi-linéaires par simple utilisation de ce tri.

IV.3.vi Complexité exponentielle

On dit qu'un algorithme a une complexité exponentielle quand $C_n^t = O(a^n)$ pour $a > 0$.

Un exemple fondamental d'un tel algorithme est celui de l'énumération de données, par exemple pour chercher une solution par force brute. En effet, il y a 2^n entrées codées sur n bits et un algorithme cherchant une solution ainsi parmi ces entrées aura une complexité en $O(2^n)$.

IV.3.vii Estimation de l'impact des complexités sur le temps

Afin de mesurer l'impact d'une complexité, on va considérer un algorithme qui s'exécute en 1 seconde sur un entrée de taille n , et on va calculer combien de temps prendrait ce même algorithme sur une entrée de taille $10n$.

Pour simplifier, on considère à chaque fois que C_n^t correspond exactement à l'ordre du grand O.

Complexité	Temps pour 10n	Temps pour 100n
1	1s	1s
$\log_2 n$	1,003s	1,007s
n	10s	1m40s
$n \log_2 n$	14,7s	3m13s
n^2	1m40s	2h46m40s
2^n	10^{19} années	10^{289} années.

■ **Remarque 12.12** Pour déterminer ces valeurs, on a considéré une unité de mesure de 1000ms afin d'en déduire une valeur de n .

Ainsi, si $\log_2 n = 1000$ on a $n = 2^{1000}$. Bien sûr, ici, ce nombre 2^{1000} n'est pas réaliste. Dans un contexte de mémoire finie, une complexité logarithmique est identifiable à une complexité constante. Cela justifie la terminologie quasi-linéaire.

Si $n \log_2 n = 1000$ alors $n \approx 140,2$. Or, $1402 \log_2 1402 \approx 14700ms$.

Si $2^n = 1000$, alors $n \approx 10$. Or $2^{100} \approx 10^{30}$.

IV.4 Calculer des complexités

Deux principes fondamentaux pour calculer des complexités :

- Si on effectue deux passes successives chacune en $O(u_n)$ alors la complexité globale est en $O(u_n)$. Il ne s'agit que de reformuler l'addition des grandeurs. Quand on a deux passes de complexité différente, il suffit d'utiliser la plus grande complexité. Par exemple, un algorithme qui commence par un tri en $O(n \log_2 n)$ et qui effectue ensuite un traitement en $O(n)$ sera de complexité globale $O(n \log_2 n)$ car le traitement est également en $O(n \log_2 n)$.
- Si on effectue u_n itérations et que chaque itération est en $O(v_n)$ alors l'algorithme a une complexité de $O(u_n v_n)$. Cela permet de compter le nombre de boucles imbriquées et de se contenter de regarder ce qui se passe dans le corps des boucles.

IV.5 Complexité à plusieurs paramètres

Jusqu'ici on a considéré des entrées dépendant d'un unique paramètre n , mais il est possible d'avoir des données dépendant de plusieurs paramètres.

On adapte directement la notation des grandeurs O : si $(u_{n,p})$ et $(v_{n,p})$ sont deux suites de réels non nuls dépendant de deux paramètres, on note toujours $u_{n,p} = O(v_{n,p})$ quand le quotient est borné.

IV.5.i Données multidimensionnelles

Le cas le plus usuel de complexité dépendant de plusieurs paramètres est celui des données multidimensionnelles comme une image.

Si on considère une opération effectuant un traitement en temps constant sur chaque pixel d'une image de $w \times h$ pixels, cette opération aura une complexité en $O(wh)$. On ne peut plus parler de complexité linéaire ou quadratique ici car cela dépend d'une éventuelle relation entre w et h : si on ne travaille que sur des images de taille $1 \times h$ alors la complexité est $O(h)$, mais on ne travaille que sur des images carrées, donc pour lesquelles $w = h$, la complexité est $O(h^2)$.

Plus généralement, si on considère des données organisées dans des tableaux imbriqués, on effectuera un traitement sur chaque donnée à l'aide de boucles imbriquées non conditionnelles. La complexité sera alors celle du corps de boucles multipliée par le produit du nombre d'itérations de chaque boucle.

IV.5.ii Compromis entre paramètres

Dans certains cas, en particulier pour les graphes, on peut effectuer des traitements successifs dont la complexité ne s'exprime pas en fonction du même paramètre. Imaginons par exemple un programme ayant la structure suivante :

```
for (int i = 0; i<n; i++)
{
    /* corps de boucle en O(1) */
}

for (int j = 0; j<p; j++)
{
    /* corps de boucle en O(1) */
}
```

La complexité de la première boucle est en $O(n)$ et celle de la deuxième en $O(p)$. La complexité globale est en $O(n + p)$ car $n \leq n + p$ et $p \leq n + p$.

IV.6 Complexité en moyenne

On reprend ici les notations de la partie Complexité dans le pire des cas.

Définition IV.3 Lorsque pour tout $n \in \mathbb{N}$, I_n est fini, on appelle :

- **complexité temporelle en moyenne** la suite $(C_n^{t,m}) = \frac{1}{|I_n|} \sum_{e \in I_n} t(e)$.
- **complexité spatiale en moyenne** la suite $(C_n^{s,m}) = \frac{1}{|I_n|} \sum_{e \in I_n} s(e)$.

On peut étendre cette définition à un cadre infini en considérant une distribution de probabilité sur I_n et T_n la variable aléatoire associée à t sur I_n . Si T_n est d'espérance finie, on pourra parler de complexité en moyenne pour la suite des $E(T_n)$. Concrètement, on considère alors une fonction $p_n : I_n \rightarrow [0, 1]$ telle que $\sum_{e \in I_n} p(e) = 1$ et, lorsque la somme est définie, on note ainsi


$$C_n^{t,m} = \sum_{e \in I_n} p(e)t(e)$$

$$C_n^{s,m} = \sum_{e \in I_n} p(e)s(e)$$

Un exemple usuel de calcul de complexité en moyenne est celui des tris. En effet, même si les entrées de taille n sont infinies, on peut considérer qu'un tableau de valeurs deux à deux distinctes est l'image par une permutation du tableau triée. Si le tableau est de taille n , on aura ainsi $n!$ permutations ce qui permet, du moment que l'algorithme de tri considéré ne dépend que cette permutation, de calculer la complexité en moyenne sur l'ensemble des permutations.

■ **Remarque 12.13** Les permutations d'un ensemble sont les applications bijectives de cet ensemble dans lui-même. Si l'ensemble contient n éléments, il y a $n!$ permutations.

Par exemple, les six permutations sur l'ensemble $\{1, 2, 3\}$ correspondent aux diagrammes sagittaires suivants :



Ces six permutations correspondant elles-mêmes, de gauche à droite et de haut en bas, aux tableaux $\{1, 2, 3\}$, $\{1, 3, 2\}$, $\{3, 2, 1\}$, $\{2, 1, 3\}$, $\{2, 3, 1\}$ et $\{3, 1, 2\}$.

IV.6.i Exemple de calcul de complexité temporelle en moyenne

On considère la recherche linéaire vue dans la partie Complexité linéaire. L'ensemble des entrées est ici infini, on va donc supposer pour faire le calcul qu'on ne considère que des tableaux de valeurs deux à deux distinctes et qu'on recherche un élément présent dans le tableau, chaque élément étant équiprobable.

Si on recherche le i -ème élément du tableau, l'algorithme effectue i itérations avant d'y accéder et de renvoyer son indice. Ainsi, le temps pour cet entrée est de iC où C est le coût d'une itération.

La complexité temporelle en moyenne est alors $C_n^{t,m} = \sum_{i=1}^n \frac{1}{n} iC = \frac{(n+1)C}{2} = O(n)$. On retrouve ici la même complexité que la complexité dans le pire des cas. La sortie prématurée de la boucle n'a donc aucune influence sur la complexité.

IV.7 Complexité amortie

Dans le cadre de l'étude des structures de données, il est fréquent de considérer non pas la complexité dans le pire des cas d'une opération mais celle d'une succession d'opérations divisée par le nombre d'opérations effectuées. Ainsi, on peut très bien avoir une opération ponctuellement plus coûteuse que les autres, mais en procédant ainsi on lisse le surcoût sur l'ensemble des opérations. On parle alors de **complexité amortie**.

L'étude de la complexité amortie est traitée dans le chapitre TODO.

IV.8 Pertinence de la complexité spatiale

Même si la complexité temporelle est le plus souvent celle qui est importante à calculer, certains algorithmes ont une complexité temporelle faible mais en contrepartie une complexité spatiale élevée. On parle alors de compromis temps-mémoire.

Un exemple classique d'un tel compromis est celui de la programmation dynamique où on passe d'une complexité temporelle exponentielle à une complexité temporelle polynomiale en stockant des valeurs intermédiaires pour ne pas les recalculer. En procédant ainsi, on passe d'une complexité spatiale constante à polynomiale.

Cela est illustré dans le programme suivant qui permet de déterminer le n -ième terme de la suite de Fibonacci, ce qui n'a pas d'intérêt informatique mais est caractéristique de récurrence que l'on résoudra par la programmation dynamique.

```
(* Fibonacci exponentiel *)
let rec fibo n =
  if n = 0
  then 0
  else if n = 1
  then 1
  else fibo (n-1) + fibo (n-2)

(* Fibonacci linéaire *)
let fibo n =
  let prec = Array.make (n+1) 0 in
  prec.(0) <- 0;
  prec.(1) <- 1;
  for i = 2 to n do
    prec.(i) <- prec.(i-1) + prec.(i-2)
  done;
  prec.(n)
```

OCaml

V Exercices

Exercice 12.1 On considère le programme suivant :

OCaml

On suppose que $c \geq 2$.

1. Montrer que cet algorithme termine .
2. Montrer que pour $x, y \in \mathbb{N}$, il renvoie le produit xy .
3. Réécrire ce programme en récursif. Peut-on déduire des preuves précédentes que l'algorithme termine et qu'il est correct.

Démonstration.

1. Comme $c \geq 2$, on a $y/c < y$ ainsi y est un variant de boucle.
2. On va commencer par noter x_0 et y_0 les valeurs initiales respectives de x et de y . On va également tenir compte du nombre d'itérations, ce qui revient à rajouter un compteur i au programme. On va également noter $y_0 = \sum_{j=0}^n a_j c^j$.
 - $y = \lfloor \frac{y_0}{c^i} \rfloor = \sum_{j=i}^n a_j c^{j-i}$ et $x = x_0 c^i$ sont des invariants directement validés.
 - On va maintenant prouver l'invariant $I(i, m) = "m = x_0 \sum_{j=0}^{i-1} a_j c^j"$.
 - * **Initialisation** avant la première itération, on a $I(0, 0, x_0, y_0)$ qui est vérifié car $0 = 0$.
 - * **Hérité** si l'invariant est vérifié au début de la i ème itération on a $m + x(y \% c) = m + x_0 a_i c^i = m + x_0 \sum_{j=0}^i a_j c^j$ donc $I(i+1, m + x(y \% c))$ est vérifié.
- Ainsi, en sortie de boucle, on a $m = x_0 \sum_{j=0}^n a_j c^j = x_0 y_0$.
3. En récursif, cela ne change pas la validité des preuves précédentes mais il faudrait présenter l'invariant différemment.

```
C int multiplication(int x, int y, int c)
{
  if (y == 0) return 0;
  return x * (y % c) + multiplication(x * c, y / c, c);
}
```

Exercice 12.2 On considère un polynôme $P = \sum_{i=0}^n c_i X^i$ représenté comme un tableau de $n+1$ coefficients tel que pour tout $i \in \llbracket 0, n \rrbracket$, $P[i] = c_i$.

On veut calculer $P(a)$ pour une valeur a . Pour simplifier, on va considérer ici que les valeurs sont toutes entières.

OCaml

1. Montrer que ce programme est correct.
2. Combien effectue-t-il de multiplications et d'additions ?
3. Comparer avec l'algorithme obtenu en ajoutant chaque $c_i a^i$ pour i croissant et en maintenant une variable pour a^i .

Démonstration.

1. On considère l'invariant $I(v, i) = "v = c_{i+1} + c_{i+2}a + \dots + c_n a^{n-i-1}"$
 - **Initialisation** avant la première itération on a $I(0, n)$ vérifié car $v = 0 = c_{n+1}$.
 - **Hérité** si l'invariant est vérifié en début d'itération, on passe à $I(av + c_i, i - 1)$ en fin d'itération or, si $v = c_{i+1} + \dots + c_n a^{n-i-1}$ on a bien $av + c_i = c_i + c_{i+1}a + \dots + c_n a^{n-i}$ et donc l'invariant est vérifié en fin d'itération.

En sortie de boucle, on a alors $I(v, -1)$ donc $v = c_0 + c_1a + \dots + c_n a^n = P(a)$.
2. On effectue $n + 1$ itérations et à chaque itérations une multiplication et une addition, donc $n + 1$ multiplications et $n + 1$ additions.
3. Pour cet algorithme, on devrait faire une multiplication de plus à chaque itération pour maintenir a^i . ■

Exercice 12.3 On considère le problème du drapeau hollandais : étant donné un tableau t et un indice i , on note $p=t[i]$, on cherche à permuter les éléments de t de sorte qu'il y ait trois zones dans le tableau : les éléments $< p$, les éléments $= p$ puis les éléments $> p$.

Ainsi, si on considère $t = [5, 2, 3, 5, 1, 4]$ et $p=t[2] = 3$ on pourra obtenir $[2, 1, 3, 5, 5, 4]$ à l'issue de cet algorithme.

1. Écrire un programme résolvant ce problème en temps linéaire.
2. Prouver sa correction. ■

Démonstration.

Le programme :

```
void echange(int *t, int i, int j)
{
    int temp = t[i];
    t[i] = t[j];
    t[j] = temp;
}

void drapeau(int *t, int nb, int i)
{
    int v = t[i];
    int l = 0;
    int c = nb-1;
    int r = nb-1;

    while (l <= c)
    {
        int w = t[l];
        if (w < v)
        {
            l = l+1;
        }
        else if (w == v)
        {
            echange(t, l, c);
            c = c-1;
        }
        else
        {
```

```

        echange(t, l, c);
        echange(t, c, r);
        c = c-1;
        r = r-1;
    }
}

```

L'idée de cet algorithme est d'avoir trois indices l, c et r (pour *left*, *center* et *right*) qui délimitent trois zones :

- celle des indices 0 à $l - 1$ qui contient des valeurs $< v$
- celle des indices $c + 1$ à r qui contient des valeurs égales à v
- celle des indices $r + 1$ à $nb - 1$ qui contient des valeurs $> v$.

Au départ, ces trois zones sont triviales et au fur à mesure de l'algorithme, elles augmentent jusqu'à couvrir l'ensemble du tableau. Comme soit l croît soit c décroît à chaque itération, on a la distance $c - l$ qui est un variant de boucle et on effectue exactement $|t|$ itérations.

On va montrer que le découpage des zones est effectivement un invariant :

- **Initialisation** au départ, comme on l'a vu, ces trois zones sont vides donc l'invariant est trivialement vérifié
- **Héritéité** si l'invariant est vrai au début d'une itération, on va faire trois cas selon la position de w par rapport à v :

- ★ Si $w < v$ alors la zone des indices de 0 à l contient toujours des valeurs $< v$ et les autres zones n'ont pas bougé, l'invariant est encore vérifié.
- ★ Si $w = v$ alors on place cette valeur w au début de la zone centrale en faisant l'échange puis en décalant c vers la gauche. Les autres zones ne sont pas touchées, donc l'invariant est encore vérifié.
- ★ Si $w > v$ alors on veut le placer en tête de la zone de droite, mais l'élément qui s'y trouve est peut-être une valeur de la zone centrale si celle-ci est non triviale. On place alors cette valeur là en début de la zone centrale ce qui revient à la décaler d'un cran vers la gauche. La valeur w peut alors être échangée. La première zone n'a pas bougé et les autres zones vérifient encore les conditions voulues, l'invariant est donc vérifié. !TODO(On devrait être plus précis ici)

On a donc validé l'invariant. En sortie de boucle, on a $x = y + 1 > y$ et donc les trois zones couvrent l'intégralité du tableau.



ALGORITHMS BY COMPLEXITY

MORE COMPLEX →

LETPAD QUICKSORT GIT MERGE SELF-DRIVING CAR GOOGLE SEARCH BACKEND

SPRAWLING EXCEL SPREADSHEET
BUILT UP OVER 20 YEARS BY A
CHURCH GROUP IN NEBRASKA TO
COORDINATE THEIR SCHEDULING

13. Complexité amortie

Source de l'image d'en-tête XKCD #1667

Introduction

Dans le cadre de l'étude des structures de données, il est fréquent de considérer non pas la complexité dans le pire des cas d'une opération mais celle d'une succession d'opérations divisée par le nombre d'opérations effectuées. Ainsi, on peut très bien avoir une opération ponctuellement plus coûteuse que les autres, mais en procédant ainsi on lisse le surcoût sur l'ensemble des opérations. On parle alors de **complexité amortie**.

■ **Remarque 13.1** Cette notion ne masque pas le fait qu'une opération puisse prendre ponctuellement plus de temps. Dans des contextes temps réel où il est important de maîtriser pleinement les complexités, il est peu judicieux d'utiliser de telles complexités. Par exemple, dans une visualisation en 3D, pour maintenir un débit constant d'images par secondes, chaque image doit prendre un temps similaire. Se reposer sur une structure de donnée ayant une faible complexité amortie mais une complexité dans le pire des cas importante, c'est risquer d'avoir des saccades avec une image qui prendrait plus de temps pour être calculée.

On va reprendre ici deux exemples simples déjà traité par ailleurs.

1.1 Implémentation d'une file avec deux piles

On considère une file réalisée avec deux piles `in` et `out` (voir le chapitre Piles et files).

Comme on l'a vu, on enfile en $O(1)$ en empilant sur la pile `in` et on défile :

- soit en $O(1)$ en défilant sur `out` si elle est non vide
- soit en $O(n)$ en déversant `in` dans `out` puis en se ramenant au cas précédent.

Ainsi, en pire cas, on est en $O(n)$ pour l'opération *défiler* mais la bascule permettra de faire ensuite cette même opération en $O(1)$.

1.2 Les tableaux dynamiques

Les tableaux dynamiques sont une structure de données de haut niveau pour implémenter le type abstrait des listes. La différence principale entre cette structure de données et celle des tableaux de C est qu'on peut ajouter et supprimer des éléments.

Un tableau dynamique d'entiers est un triplet (t, c, l) où t est un tableau de taille c , appelée la capacité du tableau dynamique, et l est un autre entier représentant la longueur logique du tableau. A tout moment $c \geq l$. Dans t il y a ainsi $c - l$ cases déjà allouées qui permettent de rajouter un élément en temps constant. Quand $c = l$, on alloue une nouvelle zone mémoire, souvent de taille $2c$, on déplace le tableau t dans cette zone et on a donc pour cet ajout prévu un certain nombre de cases d'avance.

La figure suivante présente une succession d'ajouts :

$c = 0$	$l = 0$									
$c = 1$	$l = 1$	<table border="1"><tr><td>1</td></tr></table>	1							
1										
$c = 2$	$l = 2$	<table border="1"><tr><td>1</td><td>2</td></tr></table>	1	2						
1	2									
$c = 4$	$l = 3$	<table border="1"><tr><td>1</td><td>2</td><td>3</td><td></td></tr></table>	1	2	3					
1	2	3								
$c = 4$	$l = 4$	<table border="1"><tr><td>1</td><td>2</td><td>3</td><td>4</td></tr></table>	1	2	3	4				
1	2	3	4							
$c = 8$	$l = 5$	<table border="1"><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td></td><td></td><td></td></tr></table>	1	2	3	4	5			
1	2	3	4	5						

■ **Remarque 13.2** Une implémentation de ces opérations est proposée dans le programme suivant :


```
#include <stdio.h>
#include <stdlib.h>

typedef struct {
    int *t;
    size_t c;
    size_t l;
} tableau_dynamique ;

tableau_dynamique tableau_dynamique_creer()
{
    tableau_dynamique d;

    d.t = NULL;
    d.c = 0;
    d.l = 0;

    return d;
}

void tableau_dynamique_ajout(tableau_dynamique *d, int x)
{
    if (d->c == d->l) {
        if (d->c == 0)
        {
            d->c = 1;
            d->t = malloc(sizeof(int));
        }
        else
        {
            d->c = 2 * d->c;
            d->t = realloc(d->t, d->c * sizeof(int));
        }
    }
    d->t[d->l] = x;
    d->l++;
}

void tableau_dynamique_print(tableau_dynamique d)
{
    printf("c=%d\ tl=%d\ t|", d.c, d.l);
    for (size_t i = 0; i < d.l; i++) {
        printf("%d|", d.t[i]);
    }
    for (size_t i = d.l; i < d.c; i++) {
        printf(" |");
    }
    printf("\n");
}

int main(void) {
    tableau_dynamique d = tableau_dynamique_creer();
    tableau_dynamique_print(d);
    for (int i = 1; i < 6; i++) {
        tableau_dynamique_ajout(&d,i);
        tableau_dynamique_print(d);
    }
}
```

Ce programme, une fois exécuté produit la sortie suivante qui permet de retrouver exactement le comportement attendu :

```
c=0 l=0 |
c=1 l=1 |1|
c=2 l=2 |1|2|
c=4 l=3 |1|2|3|
c=4 l=4 |1|2|3|4|
c=8 l=5 |1|2|3|4|5| | | |
```

■

Avec une analyse en pire cas, l'ajout d'un élément peut entraîner un doublement de taille et une recopie, donc coûter $O(c)$ opérations où c est la capacité avant doublement. Cependant, on constate que ce doublement permettra plusieurs ajouts ensuite en temps constant, ainsi, le pire cas ne semble pas le plus pertinent.

II Techniques de calcul

II.1 Cadre

On considère une structure de données, pour simplifier initialement vide, et une successions o_1, \dots, o_n d'opérations **valides** sur cette structure de donnée. En reprenant l'exemple précédent, cela peut être une succession d'ajouts ou de suppressions dans une file mais sans jamais essayer de retirer des éléments à une file vide.

On considère de plus que pour chaque opération o_i , on connaît le coût temporel c_i en terme d'opérations élémentaires. La question que l'on se pose est d'estimer $\frac{1}{n} \sum_{i=1}^n c_i$, c'est-à-dire le coût moyen de chaque opération. L'objectif est de montrer que ce coût moyen est $O(f(n))$, avec assez souvent $O(1)$, c'est-à-dire que $\sum_{i=1}^n c_i = O(nf(n))$.

II.2 Calcul naïf

Une approche naïve consiste à calculer directement la somme des coûts. Tout le problème ici est qu'on ne connaît pas les opérations et l'ordre dans lequel elles ont été effectuées.

II.2.i Exemple de la file avec deux piles

On va commencer par calculer c_i pour les différentes opérations :

- S'il s'agit d'un ajout sur **in** ou d'un dépilement sur **out**, on a $c_i = 1$
- Si l'opération est un dépilement nécessitant un renversement, on a $c_i = 2p + 1$ où p est la taille de **in**.

Le problème du calcul naïf ici est de connaître l'ordre des opérations. On peut regrouper les opérations o_1, \dots, o_n par paquet : ajouts, suppression avec renversement, ajouts ou suppressions sans renversement, suppression avec renversement... On va noter p_i la taille de **in** avant le i ème renversement. On a donc p_{i+1} ajouts entre le i ème et le $(i+1)$ ème renversement. Ainsi, on a effectué $p_i - 1$ suppressions sans renversements entre les deux.

Comme cela correspond au pire cas, on peut supposer que o_n est une suppression avec renversement.

On obtient alors

$$\begin{aligned} \sum_{i=1}^n c_i &= p_1 + (2p_1 + 1) + p_2 + (p_1 - 1) + (2p_2 + 1) \\ &\quad + \cdots + p_r + (p_{r-1} - 1) + (2p_r + 1) \\ &\leq 4(p_1 + p_2 + \cdots + p_r) \end{aligned}$$

Pour conclure, il est nécessaire de relier le nombre d'opérations aux p_i . Or, on a

$$\begin{aligned} n &= p_1 + 1 + p_2 + p_1 - 1 + \cdots + p_r + p_{r-1} - 1 + 1 \\ &= 2p_1 + 2p_2 + \cdots + 2p_{r-1} + p_r \geq p_1 + \cdots + p_r \end{aligned}$$

Ainsi $\frac{1}{n} \sum_{i=1}^n c_i \leq 4$.

■ **Remarque 13.3** Cette analyse est assez pénible à mettre en oeuvre car elle demande de compter avec précision ce qui se passe.

II.2.ii Exemple du tableau dynamique

Ici, les opérations sont toutes des ajouts d'éléments, mais certains provoquent une recopie tandis que d'autres sont en temps constant. Cependant, on a la même distribution des coûts, la suite des c_i est toujours 1, 2, 3, 1, 5, 1, 1, 1, 9, 1, 1, 1,

Plus précisément, $c_i = \begin{cases} 2^p + 1 & \text{si } i = 2^p + 1 \\ 1 & \text{sinon} \end{cases}$.

Donc si $2^{p-1} < n \leq 2^p$ on a $\sum_{i=1}^n c_i = n + \sum_{k=1}^{p-1} 2^k = n + 2^p \leq 3n$.

On en déduit que $\frac{1}{n} \sum_{i=1}^n c_i \leq 3$ c'est-à-dire que c'est un $O(1)$.

II.2.iii Améliorer la méthode naïve

Une amélioration de la méthode naïve va consister à considérer non pas le coût réel c_i de l'opération o_i mais un coût amorti c'_i tel qu'à la fin des opérations on ait $\sum_{i=1}^n c_i \leq \sum_{i=1}^n c'_i$ où cette dernière somme est facile à majorer.

On fera souvent en sorte que la majoration soit valide tout au long des opérations, c'est-à-dire que

$$\forall k \in \llbracket 1, n \rrbracket, \sum_{i=1}^k c_i \leq \sum_{i=1}^k c'_i$$

II.3 Méthode du banquier

On va imaginer maintenant que les opérations coûtent un certain nombre de crédits, comme si l'ordinateur marchait avec des pièces de monnaie.

Des opérations vont alors accumuler des crédits dans une réserve et d'autres opérations vont consommer ces crédits. L'idée est de payer un peu plus pour chaque opération peu coûteuse afin de couvrir les coûts des opérations coûteuses.

Précisément, on considère pour chaque opération o_i :

- une quantité a_i de crédits qui seront accumulés dans la réserve
- et une quantité d_i de crédits qu'il faudra dépenser.

On pose alors $c'_i = c_i + a_i - d_i$. On s'arrange pour faire en sorte que $c'_i \leq Af(n)$ où A est une constante. Dans le cas d'une complexité constante amortie, on s'assurera que $c'_i \leq A$.

On va maintenir un invariant sur les crédits qui est que

$$\forall k \in \llbracket 1, n \rrbracket, \sum_{i=1}^k a_i \geq \sum_{i=1}^k d_i$$

Cela signifie qu'à tout moment la réserve de crédit est positive ou nulle : on ne dépense pas de crédits n'ayant pas été accumulés.

On a alors directement la majoration voulu de $\sum_i c_i$: soit $k \in \llbracket 1, n \rrbracket$,

$$\sum_{i=1}^k c'_i = \sum_{i=1}^k c_i + \left(\sum_{i=1}^k a_i - \sum_{i=1}^k d_i \right) \geq \sum_{i=1}^k c_i$$

II.3.i Exemple de la file avec deux piles

Pour chaque élément enfilé on va allouer deux crédits correspondant au futur défilement de `in` puis empilement sur `out` qui auront lieu lors du renversement.

On pose donc pour chaque opération o_i , $c'_i = c_i + a_i - d_i$ où :

- $a_i = 2$ et $d_i = 0$ si l'opération est un ajout
- $a_i = d_i = 0$ si l'opération est un défilement ne nécessitant pas de renversement
- $a_i = 0$ et $d_i = 2p$ où p est la taille de `in` dans le cas d'un défilement provoquant un renversement.

On a donc $\sum_{i=1}^k a_i = 2A$ où A est le nombre d'ajouts effectués par les k premières opérations. Si on a effectué des renversements successifs de p_1, p_2, \dots, p_r éléments dans `in`, on a

$$\begin{aligned} \sum_{i=1}^k d_i &= 2p_1 + \cdots + 2p_r \\ &= 2(p_1 + \cdots + p_r) \\ &\leq 2A \\ &\leq \sum_{i=1}^k a_i \end{aligned}$$

La majoration venant du fait qu'un élément n'est ajouté qu'une seule fois dans `in` et donc que la somme $p_1 + \cdots + p_r$ des longueurs de `in` au cours des opérations ne peut dépasser le nombre A d'éléments empilés.

On a ainsi vérifié l'invariant sur les crédits et on a donc la majoration $\sum_{i=1}^k c_i \leq \sum_{i=1}^k c'_i$.

Pour conclure, il suffit de calculer c'_i selon les cas :

- Si l'opération est un ajout, on a $c'_i = 1 + 2 - 0 = 3$.
- Si l'opération est une suppression sans renversement, on a $c'_i = 1$
- Si l'opération est une suppression avec renversement, on a $c'_i = 2p + 1 + 0 - 2p = 1$


Dans tous les cas, on a donc $c'_i \leq 3$.

On en déduit la majoration $\sum_{i=1}^n c_i \leq \sum_{i=1}^n c'_i \leq 3n$ qui est plus fine que la majoration obtenue précédemment.


II.3.ii Exemple du tableau dynamique

On va considérer qu'on alloue 2 crédits pour chaque opération d'ajout d'un élément :

- Un crédit pour la première recopie de cet élément
- Un crédit pour copier l'élément qui lui est symétrique par rapport à la demi-capacité :



Ainsi, juste avant un doublement de capacité, on dispose d'un crédit pour chaque recopie :



Plus précisément, on définit pour chaque opération $o_i : c'_i = c_i + a_i - d_i$ où $a_i = \begin{cases} 1 & \text{si } i = 1 \\ 2 & \text{sinon} \end{cases}$
et $d_i = \begin{cases} 2^p & \text{si } i = 2^p + 1 \\ 0 & \text{sinon} \end{cases}$.
On a donc $c'_i = 3$ dans tous les cas.

Théorème II.1 $\forall n \in \mathbb{N}^*, \sum_{i=1}^n a_i \geq \sum_{i=1}^n d_i$.

Démonstration.

On a $\sum_{i=1}^n a_i = 2n - 1$ et si $2^p < n \leq 2^{p+1}$,

$$\begin{aligned} \sum_{i=1}^n d_i &= d_2 + d_3 + d_5 + \cdots + d_{2^p+1} \\ &= 1 + 2 + 2^2 + \cdots + 2^p \\ &= 2^{p+1} - 1 \leq 2n - 1 \end{aligned}$$

L'inégalité est bien vérifiée. ■

Ainsi,

$$3n = \sum_{i=1}^n c'_i = \sum_{i=1}^n c_i + \left(\sum_{i=1}^n a_i - \sum_{i=1}^n d_i \right) \geq \sum_{i=1}^n c_i$$



On retombe sur une complexité amortie en $O(1)$.

II.3.iii Présentation de la méthode

La présentation qui vient d'être faite de cette méthode est assez lourde bien que précise. En général, on se contente de présenter informellement la distribution de crédits en s'assurant qu'on a couvert les opérations coûteuses.


Une manière de bien s'en assurer est de *décorer* les structures de données en rendant les crédits apparents.

Si on reprend les tableaux dynamiques, on va rajouter sous une case le nombre de crédits dont elle dispose. Si on reprend la séquence d'ajouts précédente on pourra la représenter ainsi :



II.4 Méthode du potentiel

L'idée de la méthode du potentiel est de définir une fonction sur Φ qui associe à chaque valeur de la structure de données un nombre réel. Ce réel correspond à la notion physique de potentiel : si on considère un pendule simple dans sa trajectoire son énergie potentielle est maximale au sommet quand sa vitesse, et donc son énergie cinétique est nulle. À l'inverse son énergie potentielle est nulle au point le plus bas et sa vitesse maximale.



L'idée ici est que le potentiel va correspondre aux gains de temps obtenus par des opérations peu coûteuses. Chaque opération va ainsi faire évoluer le potentiel. On peut prendre l'image d'un empilement de tuiles de bois, comme des Kapla, chaque ajout d'une tuile de bois augmente le potentiel jusqu'à un éventuel effondrement. On retrouve ici la dualité entre les opérations rapides et les opérations coûteuses liées à un basculement.

Précisement, on va noter t_i la structure obtenue à l'issue de l'opération o_i . On considère que t_0 est la structure vide et $\Phi(t_0) = 0$. On pose $c'_i = c_i + \Phi(t_i) - \Phi(t_{i-1})$ ce qui correspond à considérer la différence de potentiel.


On a donc

$$\sum_{i=1}^k c'_i = \sum_{i=1}^k c_i + \sum_{i=1}^k \Phi(t_i) - \Phi(t_{i-1}) = \sum_{i=1}^k c_i + \Phi(t_k)$$

Pour conclure par une majoration de $\sum_{i=1}^k c_i$, il suffit de s'assurer que le potentiel ne soit jamais négatif.

II.4.i Exemple de la file avec deux piles

On va poser $\Phi(t) = 2|\text{in}|$ où $|\text{in}|$ est la taille de la pile d'entrée. Pour reprendre le parallèle physique, on peut s'imaginer que la pile **in** est au dessus de la pile **out** et que les éléments menacent de s'y déverser. Ce qui permet d'avoir l'image du potentiel comme pour le pendule au sommet de sa trajectoire.



On a directement la majoration car $\Phi(t) \geq 0$.

Pour conclure, il faut calculer c'_i dans chaque cas :

- Si l'opération est un ajout, in augmente d'un élément et donc $c'_i = c_i + 2 = 3$
- Si l'opération est une suppression sans renversement, le potentiel ne change pas et $c'_i = 1$
- Si l'opération est une suppression avec renversement et que in contient p éléments, on a $c'_i = 2p + 1 + 0 - 2p = 1$.

On retombe exactement sur le calcul précédent avec la méthode du banquier.

II.4.ii Exemple du tableau dynamique

On pose ici $\Phi(t) = 2l(t) - c(t)$ où $l(t)$ est la longueur de t et $c(t)$ est sa capacité.

Ici, ce potentiel se comprend mieux en écrivant $2(l(t) - c(t)/2)$ car $l(t) - c(t)/2$ correspond aux éléments ajoutés après doublement.

Comme $c(t) \geq l(t) \geq \frac{c(t)}{2}$ on a $\Phi(t) \geq 0$ ce qui valide la majoration.

On calcule c'_i dans les deux cas d'ajout :

- Si c'est un ajout sans doublement, alors $l(t_i) = 1 + l(t_{i-1})$, $c(t_i) = c(t_{i-1})$ et ainsi

$$\begin{aligned} c'_i &= c_i + \Phi(t_i) - \Phi(t_{i-1}) \\ &= 1 + 2l(t_{i-1}) - c(t_{i-1}) - 2l(t_{i-1}) + c(t_{i-1}) = 1 \end{aligned}$$

- Si c'est un ajout avec doublement de capacité, alors $l(t_{i-1}) = c(t_{i-1}) = A$, $l(t_i) = 1 + l(t_{i-1}) = 1 + A$, $c(t_i) = 2c(t_{i-1}) = 2A$ et $c_i = A + 1$. On a donc :


$$\begin{aligned} c'_i &= c_i + \Phi(t_i) - \Phi(t_{i-1}) \\ &= A + 1 + 2(A + 1) - 2A - 2A + A \\ &= 3 \end{aligned}$$

Ainsi, $3n \geq \sum_{i=1}^n c'_i \geq \sum_{i=1}^n c_i$. On retombe sur la majoration voulue.

II.4.iii Comparatif des méthodes

On remarque que la méthode du potentiel et la méthode du banquier sont très proches. En fait, on peut montrer qu'elles sont équivalentes. La différence entre les deux est que la méthode du banquier demande de regarder avec précision les opérations pour lesquelles il va falloir louer des crédits alors que pour la méthode du potentiel il suffit de trouver son expression. Cependant, trouver l'expression du potentiel est parfois plus complexe que de définir les crédits.

On cherchera donc la méthode la mieux adaptée aux problèmes considérés. Dans l'exemple de la file, le potentiel est très facilement défini, dans le cas du tableau dynamique, la méthode du banquier peut paraître plus naturelle.



14. Recherche par Force brute

Source image : <https://www.flickr.com/photos/x6e38/3440634940/>

I Principe

I.1 Problème de décision et exploration exhaustive

Considérons un problème du type trouver un $x \in V$ vérifiant une propriété $P(x)$.

■ **Exemple 14.1** • V est l'ensemble des chaînes de caractères et P vérifié si

si une chaîne est un mot de passe qu'on cherche.

- V est l'ensemble des indices possibles dans un tableau t et P vérifie si la valeur à l'indice i est une valeur x que l'on cherche.
- V est l'ensemble des grilles complétées d'un problème de Sudoku et P vérifie si la grille est valide.
- V est l'ensemble d'assemblages de pièces d'un puzzle et P vérifie si le puzzle est correcte, c'est-à-dire si deux pièces côtés à côtés ont des côtés compatibles.

■

Dans certains problèmes, un tel x n'est pas unique et on cherche à tous les énumérer.

Une recherche par force brute ou recherche exhaustive, consiste à énumérer l'ensemble V jusqu'à obtenir une solution en testant P pour chaque valeur rencontrée.

Des problèmes précédents, la recherche linéaire est le plus simple et le programme suivant est caractéristique d'une recherche exhaustive :

```
exception Trouve of int

let recherche t x =
  try
    for i = 0 to Array.length t - 1 do
      if t.(i) = x
      then raise (Trouve i)
```

Ocaml

```

done;
raise Not_found
with Trouve i -> i

```

La forme usuelle sera alors

```

pour chaque v dans V
  si P(v) est vérifié
    s'arrêter avec la solution v

```

On rappelle que pour pouvoir s'arrêter au cours de l'énumération en OCaml, si on programme en impératif, on utilise en général des exceptions comme dans le chapitre Exceptions en OCaml.

Cela pose naturellement la question de l'énumération des éléments de V . Si c'est immédiat dans l'exemple peu pertinent de la recherche dans un tableau, c'est beaucoup plus complexe pour l'énumération des assemblages de pièces d'un puzzle, par exemple.

Pour la recherche du mot de passe, on pourrait commencer par énumérer les chaînes de longueur 1, puis de longueur 2, et ainsi de suite.

Le plus souvent, l'ensemble V est fini (pour les mots de passe, cela peut consister à limiter la longueur maximale du mot de passe). Ainsi, une recherche par force brute effectue $O(|V|)$ itérations.

I.2 Problème d'optimisation et exploration exhaustive

On retrouve la notion d'exploration exhaustive ou force brute pour des problèmes d'optimisation. Il s'agit de problèmes de la forme : déterminer $x \in V$ tel que $f(x)$ soit minimale ou maximale.

L'exploration exhaustive consiste alors à calculer toutes les images par f des éléments de V afin de déterminer un extremum.

II Recherche par retour sur trace (backtracking)


II.1 Construction itérative de candidats

Dans de nombreux cas, l'ensemble V peut se décrire une processus itératifs de construction de ses éléments. Une manière de voir cela est de parler de positions et de mouvements, ou coups.

Par exemple, considérons un puzzle comme le puzzle Eternity II constitué de 256 pièces carrées. Une configuration finale du puzzle consiste à avoir placé les 256 pièces. Parmi celles-ci, les configurations valides sont celles satisfaisant les contraintes de chaque côté.

Comme pour tous les puzzles, la position initiale est un plateau vide et chaque mouvement consiste à placer une pièce disponible dans un emplacement disponible. Cela correspond à la manière dont on procéderait à la main :

Ainsi, on peut représenter la construction de V sous la forme d'un arbre dont les nœuds sont les positions et les arêtes les mouvements. Les positions complètes sont les feuilles de l'arbre, elles correspondent aux éléments de V et ce sont donc celles-ci qu'on va explorer pour y trouver une solution.



L'avantage de cette représentation arborescente est qu'elle découle naturellement d'un parcours récursif des positions.

Tout d'abord, il va falloir définir un type de positions partielles comme on a pu le voir dans le chapitre Options en OCaml.

Comme indiqué dans ce chapitre, si le type d'une grille de Sudoku remplie est `int array array`, pour pouvoir représenter des grilles en cours de remplissage, on va utiliser le type `int option array array`. On rappelle que l'utilisation de la valeur `None` permettra de représenter une partie non construite comme une case vide.

On considère ainsi un type position des positions partielles, un type mouvement et des fonctions

```

(* les mouvements accessibles depuis une position.
   [] si la position est complète *)
val mouvements : position -> mouvement list
(* applique un mouvement *)
val applique : position -> mouvement -> position
(* vérifie si une position est complète *)
val complete : position -> bool
(* vérifie si une position complète est valide *)
val valide : position -> bool

```

OCaml

Schématiquement, un algorithme d'énumération aura la structure suivante en OCaml :

```

exception Solution of position

let rec enumere pos =
  if complete pos
  then begin
    if valide pos
    then raise (Solution pos)
  end else
    List.iter (fun mouv -> enumere (applique pos mouv))
      (mouvements pos)

```

OCaml

■ **Remarque 14.1** Ici, l'usage de `List.iter` permet de faire l'équivalent d'une boucle `for` mais sur une liste. Pour s'en passer, on peut écrire une fonction auxiliaire récursive ou, quand les mouvements sont en petit nombre, une conversion en `array` suivie d'une boucle `for`.

Si la position initiale est `pos0`, on pourra résoudre le problème ainsi :

```
Ocaml let resout () =
  try
    enumere pos0;
    raise Not_found
  with Solution pos -> pos
```

Cet algorithme de parcours des solutions est appelé le *retour sur trace*, ou *backtracking* en anglais. Il tire partie de la récursivité pour remonter les positions après avoir essayé en vain une construction.

- **Remarque 14.2** Il est possible de reprendre la construction précédente avec des données mutables et une manière de *défaire* les mouvements :

```
Ocaml val applique : position -> mouvement -> unit
val defaire : position -> mouvement -> unit

let rec enumere pos =
  if complete pos
  then begin
    if valide pos
    then raise (Solution pos)
  end else
    List.iter (fun mouv ->
      applique pos mouv;
      enumere pos;
      defaire pos mouv)
    (mouvements pos)
```


II.2 Évaluation partielle et raccourcis

Si on reprend la construction itérative précédente, on se rend compte qu'elle n'est pas très intelligente : faut-il remplir l'intégralité d'un puzzle avant de se rendre compte qu'il est invalide en raison des deux premières pièces ?

On peut donc raffiner l'approche précédente en introduisant une notion de mouvements valides qui sont les mouvements qui préservent la correction partielle.

En pratique, il suffit de remplacer la fonction `mouvements` par une fonction `mouvements_valides`.

C'est un changement réduit qui peut avoir un grand impact sur l'arbre des positions. En reprenant l'illustration précédente, on peut imaginer que cela reviendrait à ne pas parcourir les mouvements rouges et les sous-arbres associés :



II.2.i Problème : résolution de Sudoku

La recherche par retour sur trace se prête très bien à la résolution de problèmes comme le Sudoku. On va ici tout simplement tenter de remplir chaque case du haut vers le bas tant qu'on satisfait les contraintes du Sudoku. Le programme sera ainsi très proche de la résolution des huit reines.

Commençons par rappeler le principe du Sudoku :

- On part d'une grille de 81 cases réparties en une grille de 3x3 sous-grilles de 3x3 cases et comportant des chiffres de 1 à 9 dans certaines cases.

1								6
		6		2		7		
7	8	9	4	5		1		3
			8		7			4
				3				
		9			4	2		1
3	1	2	9	7			4	
	4			1	2		7	8
9		8						

- L'objectif est de remplir chaque case avec un chiffre de 1 à 9 de sorte que chaque ligne, chaque colonne et chaque sous-grille 3x3 comporte une et une seule fois chaque chiffre.
- Un sudoku admet une unique solution.

Pour représenter une grille de Sudoku en OCaml on utilise un (`int option`) array array, la valeur `None` signifiant que la case est vide et la valeur `Some x` qu'elle est remplie avec la valeur `x`.

OCaml

```
type grille = (int option) array array
```

On fait le choix de représenter la grille par un tableau de lignes, ce qui signifie que pour accéder à la case de coordonnée (x, y) dans `g` il faut écrire `g.(y).(x)`.

Le problème donné précédemment est alors représenté par la valeur suivante :

```
let probleme = [
  [| Some 1; None; None;    None; None; None;    None; None; Some 6 |];
  [| None; None; Some 6;    None; Some 2; None;    Some 7; None; None |];
  [| Some 7; Some 8; Some 9;    Some 4; Some 5; None;    Some 1; None; Some 3 |];

  [| None; None; None;    Some 8; None; Some 7;    None; None; Some 4 |];
  [| None; None; None;    None; Some 3; None;    None; None; None |];
  [| None; Some 9; None;    None; None; Some 4;    Some 2; None; Some 1 |];

  [| Some 3; Some 1; Some 2;    Some 9; Some 7; None;    None; Some 4; None |];
  [| None; Some 4; None;    None; Some 1; Some 2;    None; Some 7; Some 8 |];
  [| Some 9; None; Some 8;    None; None; None;    None; None; None |];
]
```

Afin de définir la fonction de résolution, on définit une première fonction suivant de signature :

```
OCaml | val suivant : grille -> (int * int) -> (int * int) option
```

telle que l'appel à `suivant g (x,y)` renvoie `Some (xi,yi)` quand (x_i, y_i) sont les coordonnées de la prochaine case libre, dans l'ordre gauche à droite puis haut vers bas, après (x, y) ou `None` quand il n'existe pas de telle case libre. Cela signifie alors que la grille est entièrement remplie.

```
OCaml | let rec suivant g (x,y) =
|   if y > 8
|   then None
|   else if g.(y).(x) = None
|   then Some (x,y)
|   else if x < 8 then suivant g (x+1, y)
|   else suivant g (0, y+1)
```

On définit également une fonction valide de signature

```
OCaml | val valide : grille -> int -> int -> bool
```

telle que l'appel à `valide g x y` renvoie `true` si et seulement si la valeur placée en coordonnée (x, y) n'invalidise pas la grille. Ne pas prendre cette valeur en paramètre permettant d'écrire un peu plus simplement cette fonction. La fonction est assez directe, étant donné (x, y) on va parcourir sa ligne, sa colonne et sa sous-grille pour vérifier qu'un nombre n'a pas été placé deux fois à l'aide d'un tableau de drapeaux :

```
OCaml | let valide g x y =
|   let v = ref true in
|   let vus_colonne = Array.make 9 false in
|   for y0 = 0 to 8 do
|     match g.(y0).(x) with
|     | None -> ()
|     | Some k ->
|       if vus_colonne.(k-1)
|       then v := false;
|       vus_colonne.(k-1) <- true
|   done;
|   let vus_ligne = Array.make 9 false in
|   for x0 = 0 to 8 do
|     match g.(y).(x0) with
|     | None -> ()
|     | Some k ->
|       if vus_ligne.(k-1)
|       then v := false;
|       vus_ligne.(k-1) <- true
|   done;
|   let vus_grille = Array.make 9 false in
|   let xb = (x / 3) * 3 in
|   let yb = (y / 3) * 3 in
|   for xd = 0 to 2 do
|     for yd = 0 to 2 do
```

```

    match g.(yb+yd).(xb+xd) with
    | None -> ()
    | Some k ->
        if vus_grille.(k-1)
        then v := false;
        vus_grille.(k-1) <- true
    done
done;
!v

```

On peut alors définir la fonction `resout` qui va résoudre le Sudoku en effectuant tous les remplissages tant qu'on a une grille valide. Dès qu'une solution est trouvée, on s'arrête. Pour cela, on utilise le mécanisme des exceptions pour permettre une sortie prématuée. On a fait le choix de travailler en place dans la grille, ainsi à la fin de l'exécution de la fonction, la grille correspond à la solution.

```

exception Solution

let resout g =
  let rec aux xi yi = match suivant g (xi, yi) with
    | None -> raise Solution
    | Some (x,y) ->
        for i = 1 to 9 do
          g.(y).(x) <- Some i;
          if valide g x y
          then begin
            aux x y
          end
        done;
        g.(y).(x) <- None
  in
  try
    aux 0 0
  with Solution -> ()

```

II.3 Énumération de toutes les solutions

Le problème précédent du Sudoku n'avait par définition qu'une unique solution. Cependant, il existe des problèmes pour lesquels plusieurs solutions existent et pour lesquels on souhaite les énumérer.

La fonction précédente pourra alors devenir :

```

let rec enumere pos =
  if complete pos
  then begin
    if valide pos
    then [ pos ]
    else []
  end else
  List.concat
    (List.map (fun mouv -> enumere (applique pos mouv))
      (mouvements_valides pos))

```


■ **Remarque 14.3** La fonction `List.concat` permet de concaténer une '`a list list`' d'un coup comme dans :

```
Ocaml # List.concat [ [1;2]; [3]; []; [4;5;6] ];;
- : int list = [1; 2; 3; 4; 5; 6]
```

II.3.i Problèmes des huit reines

L'exemple classique de ce problème est celui des huit reines : étant donné un échiquier, peut-on placer huit reines de sorte qu'aucune reine ne puisse prendre une autre reine ? Plus précisément : sur un plateau de 8x8 cases, peut-on placer huit pions tels que deux pions quelconques ne soient jamais sur la même ligne ou la même diagonale ?

Exemple de solution :



Ce problème admet effectivement des solutions partielles en ne considérant que k reines à placer. Pour énumérer les solutions, on peut même se contenter de solutions partielles où les k reines sont placées sur les k premières rangées.

Voici ainsi un algorithme pour énumérer les solutions :

- Supposons que k reines aient été placées et qu'on dispose d'une solution partielle.
 - ★ Si $k = 8$ alors toutes les reines sont placées et la solution est complète, on la stabilise
 - ★ Sinon, on continue la recherche pour chaque position de la $k + 1$ reine sur la $k + 1$ rangée qui préserve le fait d'être une solution partielle.

Ici, quand on dit qu'on continue la recherche, ce qu'on signifie, c'est qu'on effectue un appel récursif.

Pour programmer cette méthode, on va définir une fonction récursive de signature :

```
Ocaml val resout_reines : (int * int) list -> (int * int) list list
```

Un appel à `resout_reines part` va ainsi renvoyer la liste des solutions complètes construites à partir de la solution partielle `part`. Les solutions sont représentées par des listes de couples de coordonnées sur l'échiquier, donc dans $[[0; 7]]^2$

Voici une implémentation où on explore les solutions à l'aide d'une boucle impérative dans l'appel récursif. La fonction `valide` permet de tester si le placement d'une reine est possible avant d'effectuer un appel.

```

let rec valide (x1,y1) l =
  match l with
  | [] -> true
  | (x2,y2)::q ->
    x1 <> x2 && abs (x2-x1) <> abs(y2-y1) && valide (x1,y1) q

let rec resout_reines part =
  let k = List.length part in
  if k = 8
  then [ part ]
  else begin
    let resultats = ref [] in
    for x = 0 to 7 do
      let essai = (x,k) :: part in
      if valide (x,k) part
      then begin
        resultats := (resout_reines essai) @ !resultats;
      end
    done;
    !resultats
  end

```

OCaml

et, ici, une autre implémentation purement récursive à l'aide d'une fonction récursive.

```

let rec resout_reines part =
  let k = List.length part in
  if k = 8
  then [ part ]
  else
    let rec aux x acc =
      if x < 0
      then acc
      else let essai = (x,k) :: part in
            let nacc = if valide (x,k) part
                       then (resout_reines essai) @ acc
                       else acc in
            aux (x-1) nacc
    in
    aux 7 []

```

OCaml

Une partie de l'arbre de recherche est présenté sur l'image suivante :


Arbre de recherche pour les huit reines

L'arbre complet comporte 2057 noeuds dont 92 feuilles correspondant aux solutions du problème. À titre de comparaison, l'arbre exhaustif correspondant à faire tous les choix de placement à raison d'une reine par ligne compterait $8^8 = 16777216$ noeuds. On voit bien que le backtracking est plus économique en exploration.

II.4 TP : tours du cavalier

II.5 TP : jeu du solitaire

On considère ici le jeu du solitaire. On a un plateau comportant 33 emplacements et initialement 32 pions, représenté par des ronds blancs, et un emplacement vide au centre :



Les différents mouvements possibles consiste à passer d'une configuration `●●○` à `○○●` et ainsi à diminuer d'un pion le nombre total de pions. Ces configurations peuvent être rencontrées dans les directions horizontales ou verticales.

On considère que la partie est gagnée quand il n'y a plus qu'un pion sur le plateau.

II.5.i Première implémentation naïve

On va représenter un plateau par le type OCaml :

```

OCaml | type case = Vide | Pion | Invalidé
      | type plateau = case array array
      | let n = 7
      | (* Un plateau est une matrice 7x7 avec des cases invalides aux coins *)
  
```

Question II.1 Définir une fonction `print_plateau` qui affiche un plateau sous un format textuel lisible.

Démonstration.

```

OCaml | let print_plateau p =
      |   for j = 0 to n-1 do
      |     for i = 0 to n-1 do
      |       let c = match p.(i).(j) with
      |         | Invalidé -> ' '
      |         | Vide -> '.'
      |         | Pion -> '#'
      |         in Printf.printf "%c" c
      |     done;
      |     print_newline ()
      |   done;
      |   print_newline ()
  
```

Question II.2 Écrire une fonction `plateau_initial : unit -> plateau` qui renvoie un plateau correspondant à la configuration de départ.

Démonstration.

```
let plateau_initial () =
[]|
  [| Invalide; Invalide; Pion; Pion; Pion; Invalide; Invalide |];
  [| Invalide; Invalide; Pion; Pion; Pion; Invalide; Invalide |];
  [| Pion; Pion; Pion; Pion; Pion; Pion; Pion |];
  [| Pion; Pion; Pion; Vide; Pion; Pion; Pion |];
  [| Pion; Pion; Pion; Pion; Pion; Pion; Pion |];
  [| Invalide; Invalide; Pion; Pion; Pion; Invalide; Invalide |];
  [| Invalide; Invalide; Pion; Pion; Pion; Invalide; Invalide |]
```

Ocaml

Un mouvement peut être assimilé à un triplet de coordonnées décrivant, dans l'ordre ● ● ○ les trois cases concernées. Il se trouve que la case centrale est toujours le milieu des deux autres, on peut donc se contenter de donner un couple de coordonnées pour décrire un mouvement.

```
type mouvement = (int * int) * (int * int)
```

Question II.3 Écrire une fonction `mouvements : plateau -> mouvement list` qui renvoie la liste des mouvements possibles sur le plateau passé en paramètre.

Démonstration.

```
let possible p (i1,j1) (i3,j3) =
  let i2, j2 = (i1+i3)/2, (j1+j3)/2 in
  p.(i1).(j1) = Pion && p.(i2).(j2) = Pion && p.(i3).(j3) = Vide

let mouvements p =
  (* on utilise une pile *)
  let l = ref [] in
  for i = 0 to n-1 do
    for j = 0 to n-3 do
      if possible p (i,j) (i,j+2)
      then l := ( (i,j), (i,j+2) ) :: !l;
      if possible p (i,j+2) (i,j)
      then l := ( (i,j+2), (i,j) ) :: !l;
      if possible p (j+2,i) (j,i)
      then l := ( (j+2,i), (j,i) ) :: !l;
      if possible p (j,i) (j+2,i)
      then l := ( (j,i), (j+2,i) ) :: !l
    done
  done;
  !l
```

Question II.4 Écrire une fonction `compte_pions : plateau -> int` qui renvoie le nombre de pions sur un plateau.

En déduire une fonction valide : plateau \rightarrow bool qui indique si un plateau correspond à une partie gagnante.

Démonstration.

```
OCaml
let compte_pions p =
  let c = ref 0 in
  for i = 0 to n-1 do
    for j = 0 to n-1 do
      if p.(i).(j) = Pion
      then incr c
    done
  done;
  !c

let valide p = compte_pions p = 1
```

Question II.5 Écrire deux fonctions faire et defaire de type plateau \rightarrow mouvement \rightarrow unit permettant de faire et défaire un mouvement.

Démonstration.

```
OCaml
let applique p mouv =
  let (i1,j1), (i3,j3) = mouv in
  let i2, j2 = (i1+i3)/2, (j1+j3)/2 in
  p.(i1).(j1) <- Vide;
  p.(i2).(j2) <- Vide;
  p.(i3).(j3) <- Pion

let defaire p mouv =
  let (i1,j1), (i3,j3) = mouv in
  let i2, j2 = (i1+i3)/2, (j1+j3)/2 in
  p.(i1).(j1) <- Pion;
  p.(i2).(j2) <- Pion;
  p.(i3).(j3) <- Vide
```

Question II.6 Écrire une fonction enumere : plateau \rightarrow mouvement list \rightarrow unit telle que enumere pos chemin énumère les plateaux accessibles depuis pos jusqu'à obtenir une solution et sachant que chemin est la liste de mouvements, du plus récent au plus ancien, qui ont conduit jusqu'à pos.

En cas de succès, on produira une exception Solution of mouvement list renvoyant la liste des mouvements ayant conduits à une solution.

En déduire une fonction resout : unit \rightarrow mouvement list qui renvoie une liste de mouvement permettant de résoudre le solitaire. On prendra garde à renverser le chemin obtenu pour que le premier mouvement de la liste soit le premier mouvement effectué.

Démonstration.

Ocaml

```
exception Solution of mouvement list

let rec enumere pos chemin =
  if valide pos
  then raise (Solution chemin)
  else let l = mouvements pos in
    List.iter (fun mouv ->
      applique pos mouv;
      enumere pos (mouv :: chemin);
      defaire pos mouv) l

let resout () =
  let pos = plateau_initial () in
  try
    enumere pos [];
    raise Not_found
  with Solution l -> List.rev l
```

■

Ce code ne permet pas de calculer la solution car il prend beaucoup trop de temps en raison du nombre de positions étudiées.

II.5.ii Cache des mauvaises positions

On se rend compte que de nombreuses positions sont réétudiées alors qu'on sait déjà qu'elles ne peuvent permettre d'aboutir à une solution. En effet, il y a souvent des coups indépendants pouvant être joués au même moment, ce qui fait qu'on peut aboutir à une même position de beaucoup de manière différente, ce qui augmente exceptionnellement le nombre d'appels récursifs.

Une stratégie consiste à maintenir un ensemble de configurations mauvaises. Pour réaliser un tel ensemble, on va utiliser une table de hâchage dont les clés sont les positions et les valeurs `unit`. Si une position a une valeur associée dans la table, c'est qu'elle sera mauvaise.

Cela pose la question de la représentation persistante et immuable des positions. Une première stratégie peut consister à transformer le plateau en `case list list`. Cette stratégie est beaucoup trop coûteuse et elle ne permet pas de répondre instantanément. On va profiter du fait qu'il n'y est que 49 cases dans le plateau pour le représenter par un entier sur 49 bits : $a_{00} + a_{10}2 + a_{20}2^2 + \dots + a_{60}2^6 + a_{01}2^7 + \dots + a_{66}2^{48}$ où a_{ij} vaut 1 lorsqu'il y a un pion sur la j ème ligne et la i ème colonne, c'est-à-dire quand $p.(i).(j) = \text{Pion}$.

Indication l'entier 1 `lsl n` est 2^n . `lsl` signifie qu'on décale le chiffre 1 de n bits vers la droite dans son écriture binaire.

Question II.7 Écrire une fonction `code : plateau -> int` qui renvoie le numéro associé à un plateau.

■

Démonstration.

Ocaml

```
let code p =
  let c = ref 0 in
  for j = 0 to 6 do
    for i = 0 to 6 do
```

```

    if p.(i).(j) = Pion
    then c := !c + 1 lsl (7*j+i)
done
done;
!c

```



Pour manipuler un ensemble, on va définir

```

OCaml let mauvaises = Hashtbl.create 42
let ajoute x = Hashtbl.add mauvaises x ()
let contient x = Hashtbl.mem mauvaises x

```

L'appel à `ajoute x` rajoute `x` dans l'ensemble des mauvaises positions et `contient x` vérifie si `x` est dans cet ensemble.

Question II.8 Reprendre la fonction `enumere` avec un ensemble de mauvais codes.



Démonstration.

```

let rec enumere pos chemin =
  if valide pos
  then raise (Solution chemin)
  else
    let c = code pos in
    if not (contient c)
    then begin
      let l = mouvements pos in
      List.iter (fun mouv ->
                    applique pos mouv;
                    enumere pos (mouv :: chemin);
                    defaire pos mouv) l;
      (* Si on est ici c'est que le noeud ne permet pas de trouver
         une solution *)
      ajoute c
    end

```

OCaml



Normalement, le code doit pouvoir permettre de réaliser la résolution instantanément.

■ **Remarque 14.4** Possibles extensions :

- rajouter un affichage de la résolution
- déterminer la proportion de recalculs évités
- gérer les symétries des plateaux



III Stratégies d'énumération

III.1 Combinatoire élémentaire

produits, combinaisons, permutations

III.2 Enumération d'arbres

Imaginons que l'on souhaite énumérer des arbres binaires non étiquetés pour trouver le premier arbre binaire à n noeuds vérifiant une certaine propriété. On suppose ainsi défini un type

```
OCaml | type arbre = Nil | Noeud of arbre * arbre
```

et une fonction pour tester le prédictat :

```
OCaml | val : valide : arbre -> bool
```

Une première possibilité est d'effectuer un simple parcours récursif :

```
OCaml | let rec recherche n =
  if n = 0
  then
```

normale, par passage de continuation

IV Droite de balayage

IV.1 Principe

Il est parfois possible d'ordonner V pour tirer pour permettre de trouver une solution plus vite, voir d'ordonner des données basique pour ne pas énumérer V mais énumérer un $V' \subset V$ plus petit.

C'est un procédé classique dans le contexte de la géométrie algorithmique dans le plan : étant donné un ensemble V de candidats qu'on déduit d'un ensemble de points du plan, par exemple l'ensemble des paires de points, on va énumérer V à l'aide d'un parcours des points de gauche à droite (ou tout autre direction géométrique) pour ne pas énumérer tout V mais seulement une partie plus petite. Tout se passe comme si on balayait avec un droite l'ensemble des points, d'où le nom de droite de balayage.

Du point de vue de la complexité temporelle, on obtient le plus souvent un algorithme en $O(n \log n)$ où n est le nombre de points. Cela signifie que l'étape la plus coûteuse en temps est le tri initial.

On va présenter ici deux exemples d'utilisation d'une droite de balayage. Il est assez clair qu'il sera nécessaire dans ces cas de réfléchir géométriquement. Les exemples présentés sont donc assez simples d'un point de vue informatique, mais plutôt complexes d'un point de vue mathématiques.

IV.2 Plus proche paire


On considère le problème

Problème - PLUSPROCHEPAIRE

- Entrées :
 - Un ensemble P de n points.
- Sortie : Une paire $\{p, p'\}$ de points telle que $dist(p, p') = ||\vec{pp'}||$ soit minimale.

IV.2.i Recherche exhaustive

Considérons le problème *PlusProchePaire* qui, étant donné un ensemble de n points ($n \geq 2$), détermine la paire constituée des deux points les plus proches.



Une implémentation naïve de la recherche par force brute consiste à énumérer les $\frac{n(n-1)}{2}$ paires et donc à effectuer $O(n^2)$ itérations.

```
let plus_proche_paire points =
  let n = Array.length points in
  let min_paire = ref (distance points.(0) points.(1), (0, 1)) in
  for i = 0 to n - 1 do
    for j = i+1 to n - 1 do
      let d = distance points.(i) points.(j) in
      if d < fst !min_paire
      then min_paire := (d, (i, j))
    done
  done;
  snd !min_paire
```

Ocaml

IV.2.ii Raffinement : droite de balayage


Il est parfois possible d'accélérer la recherche par force brute en ordonnant le parcours des candidats pour pouvoir éviter de tester certains d'entre eux.

En géométrie algorithmique, une approche classique consiste à ordonner les objets selon leur abscisse et à parcourir les objets par abscisse croissante. On parle alors de **droite de balayage** (en anglais, *sweep line*) car cela revient à balayer le plan par une droite verticale en ne traitant que les objets avant cette ligne.


Reprenons le problème précédent, on considère que les points sont triés par abscisse croissante : $(x_0, y_0), \dots, (x_{n-1}, y_{n-1})$. On va parcourir les points dans cet ordre en maintenant un ensemble de points à gauche du point courant, appelés *points actifs*, et en ne calculant que les intersections avec les points actifs.

Si on a parcouru les N premiers points et qu'on a obtenu que la plus petite distance était d , lorsqu'on considère le point (x_N, y_N) , il est inutile de tester les points qui sont forcément à distance $> d$ de celui-ci. C'est-à-dire qu'on peut éliminer les points qui ne sont pas dans le rectangle $[x_N - d, x_N] \times [y_N - d, y_N + d]$ du test. Les points dont l'abscisse est $< x_N - d$ peuvent être éliminés définitivement vu que l'on raisonne par abscisse croissante, par contre, les points d'ordonnées invalides doivent être conservés pour les points ultérieurs.


Ce rectangle est représenté sur le schéma suivant ainsi qu'une ligne imaginaire qui correspond à l'abscisse du point courant et qu'on peut imaginer parcourant le plan de gauche à droite pour traiter les points au fur et à mesure.



Afin de déterminer la complexité de cet algorithme, il est nécessaire de connaitre le nombre maximal de points dans le rectangle. Comme ces points ont été pris en compte précédemment, ils sont forcément à distance au moins d les uns des autres. Il s'agit donc de déterminer le nombre maximum de points qu'on peut placer dans ce rectangle à distance au moins d . On remarque tout d'abord qu'on peut placer six points ainsi :



Si jamais on avait au moins sept points, on peut voir qu'il y a forcément un des six sous-rectangles suivants qui contiendrait au moins deux points :



Or, ces sous-rectangles sont de longueur $\frac{1}{2}d$ et de hauteur $\frac{2}{3}d$, donc la distance maximale entre deux de leurs points correspond à la longueur des diagonales : $\sqrt{\frac{1}{4} + \frac{4}{9}}d = \frac{5}{6}d < d$.

Comme un de ces six points est le point courant, il y a toujours au plus 5 points dans l'ensemble des points actifs.

Voici le principe de l'algorithme que l'on va implémenter :

- On trie le tableau `points` par ordre croissant. **Complexité** : $O(n \log n)$
- On initialise la plus petite distance d courante à la distance entre les deux premiers points
- On crée un ensemble `actifs`, ordonné par les ordonnées, de points contenant initialement les deux premiers points
- Pour chaque point (x, y) en partant du deuxième :
 - ★ On supprime les points (x', y') tels que $x' < x - d$ de `actifs`. **Complexité** : sur l'ensemble des itérations on ne pourra jamais supprimer deux fois un point, donc on effectue au maximum n suppressions chacune en $O(\log n)$ donc $O(n \log n)$.
 - ★ On parcourt les points de `actifs` dont les ordonnées sont comprises entre $y - d$ et $y + d$. **Complexité** : pour récupérer le premier point de l'ensemble, il faut $O(\log n)$ en pire cas (tous les points actifs) et ensuite on effectue au plus 5 itérations comme on vient de le prouver.

On remarque ainsi que la complexité en temps et en pire cas de cet algorithme est de $O(n \log n)$. Ici, le fait d'avoir la structure `actifs` ordonnée par les ordonnées est crucial pour garantir la complexité. Pour la réalisation d'une structure d'ensemble ordonnée ayant ces complexités, voir le chapitre FIXME.

Ici, on utilise le module Set d'OCaml pour réaliser la structure d'ensemble, pour cela on commence par créer le module PointSet pour les ensembles de points :

```
OCaml
module Point = struct
  type t = float * float
  let compare (x1,y1) (x2,y2) = Stdlib.compare y1 y2
end

module PointSet = Set.Make(Point)
```

Puis on définit une fonction permettant de parcourir les points entre deux ordonnées :

```
OCaml
let set_iter_entre f set bas haut =
  try
    let e = PointSet.find_first (fun p -> snd p >= bas) set in
    let seq = PointSet.to_seq_from e set in
    let rec aux seq =
      match seq () with
      | Seq.Nil -> ()
      | Seq.Cons (p, seq_suite) ->
        if snd p <= haut
        then begin
          f p;
          aux seq_suite
        end
    in aux seq
  with Not_found -> ()
```

On implémente alors assez directement l'algorithme décrit précédemment :

```
OCaml
let plus_proche_paire_balayage points =
  let compare (x1,y1) (x2,y2) =
    if x1 = x2
    then if y1 < y2 then -1 else 1
    else if x1 < x2 then -1 else 1
  in
  Array.sort compare points;
  let n = Array.length points in
  let d = ref (distance points.(0) points.(1)) in
  let couple = ref (points.(0), points.(1)) in
  let actifs = ref (PointSet.empty
    |> PointSet.add points.(0) |> PointSet.add points.(1)) in

  let gauche = ref 0 in

  for i = 2 to n-1 do
    let xi, yi = points.(i) in

    while fst points.(!gauche) < xi -. !d do
      actifs := PointSet.remove points.(!gauche) !actifs;
      incr gauche
    done;

    set_iter_entre (fun pj ->
      let dip = distance points.(i) pj in
```

```

if dip < !d
then begin
    couple := (points.(i), pj);
    d := dip
end) !actifs (yi -. !d) (yi +. !d);

actifs := PointSet.add points.(i) !actifs
done;
!d

```

IV.2.iii Problème : test d'intersection pour un ensemble de segments

Considérons le problème suivant *IntersectionEnsemble* : étant donné n segments dans le plan, il s'agit de déterminer si au moins deux des segments s'intersectent.

■ **Remarque 14.5** On peut considérer ici que l'on dispose d'une fonction

Ocaml `intersecte : (float * float) * (float * float)
-> (float * float) * (float * float) -> bool`

qui teste l'intersection entre deux segments.

Cependant, il est possible d'écrire une telle fonction avec un peu de géométrie élémentaire.

Si on considère que les deux segments sont $[A_1B_1]$ et $[A_2B_2]$, avec $A_1 \neq B_1$ et $A_2 \neq B_2$, alors chaque point du segment $[A_1B_1]$ est de la forme $A_1 + t\overrightarrow{A_1B_1}$ où $t \in [0, 1]$. De même les points du segment $[A_2B_2]$ sont de la forme $A_2 + u\overrightarrow{A_2B_2}$ où $u \in [0, 1]$.

S'il y a une intersection, c'est qu'il existe $(t, u) \in [0, 1]^2$ tel que

$$A_1 + t\overrightarrow{A_1B_1} = A_2 + u\overrightarrow{A_2B_2} \iff \overrightarrow{A_2A_1} + t\overrightarrow{A_1B_1} = u\overrightarrow{A_2B_2}$$

L'idée est alors d'utiliser une opération appelée **produit vectoriel** sur les vecteurs. Comme ici, tout est plan, le produit vectoriel est uniquement déterminé par sa troisième coordonnée, celle qui sort du plan, et on peut se contenter de calculer celle-ci. On note ainsi $(x, y) \times (x', y') = xy' - yx'$ cette coordonnée. On a donc $u \times u = 0$.

On peut alors composer l'égalité par $\times \overrightarrow{A_2B_2}$:

$$\overrightarrow{A_2A_1} \times \overrightarrow{A_2B_2} + t \left(\overrightarrow{A_1B_1} \times \overrightarrow{A_2B_2} \right) = 0$$

Notons $\Delta = \overrightarrow{A_1B_1} \times \overrightarrow{A_2B_2}$, si $\Delta \neq 0$, alors

$$t = -\frac{\overrightarrow{A_2A_1} \times \overrightarrow{A_2B_2}}{\Delta} = \frac{\overrightarrow{A_1A_2} \times \overrightarrow{A_2B_2}}{\Delta}$$

On procède de même avec $\times \overrightarrow{A_1B_1}$ pour obtenir une expression de u : $\overrightarrow{A_2A_1} \times \overrightarrow{A_1B_1} = u \left(\overrightarrow{A_2B_2} \times \overrightarrow{A_1B_1} \right) = -u\Delta$ et donc

$$u = -\frac{\overrightarrow{A_2A_1} \times \overrightarrow{A_1B_1}}{\Delta} = \frac{\overrightarrow{A_1A_2} \times \overrightarrow{A_1B_1}}{\Delta}$$

Si $\Delta \neq 0$, on peut donc alors exprimer u et t et vérifier qu'ils sont dans $[0, 1]$.

Si $\Delta = 0$ c'est que les deux segments sont de directions parallèles ou confondues.

- Si $\overrightarrow{A_1A_2} \times \overrightarrow{A_1B_1} \neq 0$ alors $\overrightarrow{A_1A_2}$ et $\overrightarrow{A_1B_1}$ sont non colinéaires donc les deux segments sont sur des droites parallèles distinctes et ne peuvent s'intersecter.
- Sinon, les segments reposent sur une même droite et il s'agit de vérifier leurs positions sur la droite. Pour cela, on exprime $A_2 = A_1 + t_A \overrightarrow{A_1B_1}$ de même pour $B_2 = A_1 + t_B \overrightarrow{A_1B_1}$. Plus précisément, on calcule $\overrightarrow{A_1A_2} \cdot \overrightarrow{A_1B_1} = t_A \|\overrightarrow{A_1B_1}\|^2$ à l'aide du produit scalaire et on a $t_A = \frac{\overrightarrow{A_1A_2} \cdot \overrightarrow{A_1B_1}}{\|\overrightarrow{A_1B_1}\|^2}$. De même, $t_B = \frac{\overrightarrow{A_1B_2} \cdot \overrightarrow{A_1B_1}}{\|\overrightarrow{A_1B_1}\|^2}$. On doit alors vérifier si l'intervalle $[t_A, t_B]$ (ou $[t_B, t_A]$ selon leur position) intersecte $[0, 1]$.

Voici une fonction OCaml qui correspond à ce raisonnement

```
let intersecte (a1,b1) (a2,b2) =
  let vec (x1,y1) (x2,y2) = (x2-.x1,y2-.y1) in
  let cross (x1,y1) (x2,y2) = x1 *. y2 -. y1 *. x2 in
  let dot (x1,y1) (x2,y2) = x1 *. x2 +. y1 *. y2 in
  let proche0 x = let eps = 1e-20 in
    if x < 0. then -x < eps else x < eps in
  let a1b1 = vec a1 b1 in let a2b2 = vec a2 b2 in
  let a1a2 = vec a1 a2 in let a1b2 = vec a1 b2 in

  let delta = cross a1b1 a2b2 in

  if proche0 delta
  then
    if proche0 (cross a1a2 a1b1)
    then let na1b1 = dot a1b1 a1b1 in (* colinéaires *)
        let tA = (dot a1a2 a1b1) /. na1b1 in
        let tB = (dot a1b2 a1b1) /. na1b1 in
        if tA < tB
        then not (tB < 0. || tA > 1.)
        else not (tA < 0. || tB > 1.)
    else false (* parallèles *)
  else let t = (cross a1a2 a2b2) /. delta in (* se croisent *)
        let u = (cross a1a2 a1b1) /. delta in
        t >= 0. && t <= 1. && u >= 0. && u <= 1.
```

OCaml

■ **Note 14.1** réécrire cela avec le déterminant de deux vecteurs du plan qui est au programme de mathématiques de seconde.

La recherche par force brute va alors énumérer l'ensemble des paires de segments distincts et tester deux à deux les intersections. On peut ainsi écrire le programme suivant qui est assez simple et effectuera effectivement $O(|v|^2)$ itérations dans le pire cas, i.e. lorsqu'il n'y a pas d'intersections.


```
exception Trouve

let intersection_ensemble (v: ((float * float) * (float * float)) array) : bool =
  let n = Array.length v in
  try
    for i = 0 to n - 1 do
      for j = i+1 to n-1 do
```

OCaml

```
    if intersecte v.(i) v.(j)
    then raise Trouve
done
done;
false
with Trouve -> true
```

TODO approche par droite de balayage : algorithme de Shamos et Hoey (1976)



15. Algorithmes gloutons

Principe

On considère ici un problème d'énumération comme dans la section précédente muni d'une fonction d'objectifs qui attribue une valeur numérique aux solutions et aux solutions partielles.


Soit $f : P \rightarrow \mathbb{R}$ une telle fonction, où $S \cup P$ est l'ensemble des solutions du problème d'énumération et P l'ensemble des solutions partielles, on se pose maintenant le problème de l'optimalité vis-à-vis de f : déterminer $x \in S$ tel que $f(x) = \max_{y \in S} f(y)$ on note souvent $x = \operatorname{argmax}_{y \in S} f(y)$. On parle alors de problème d'optimisation combinatoire.

- **Remarque 15.1**
- En considérant $g : y \mapsto -f(y)$, on transforme un problème de maximisation en un problème de minimisation.
 - Il y a une ambiguïté sur $\operatorname{argmax}_{y \in S} f(y)$ quand plusieurs éléments de S réalisent ce maximum. Dans la plupart des algorithmes gloutons qu'on va considérer, on commence par donner un ordre sur S et on considère le plus petit y pour cet ordre réalisant le maximum. L'ordre choisi est alors crucial dans la preuve de correction. C'est aussi une des raisons pour lesquelles les algorithmes gloutons sont souvent de complexité temporelle $O(n \log_2 n)$.

■


Une première stratégie très élémentaire consiste alors à énumérer S , de manière exhaustive ou avec une stratégie plus fine comme le retour sur trace, puis à déterminer un élément maximal de manière directe.

Cela revient donc à déterminer l'arbre des solutions puis à trouver une feuille maximisant l'objectif :




Un algorithme glouton va suivre une approche beaucoup plus efficace : à chaque étape de construction de la solution, on choisit la branche qui maximise la fonction d'objectif. C'est-à-dire que si en partant d'une solution partielle $x \in P$ il est possible de l'étendre en d'autres solutions partielles $p_x = \{y_1, \dots, y_n\}$, on va choisir $y = \operatorname{argmax}_{t \in p_x} f(t)$ la solution qui maximise localement f .

Sur l'arbre précédent, cela reviendrait à n'emprunter qu'une seule branche :



Cela a l'air très efficace mais il y a un problème majeur : il n'y a aucune garantie qu'on aboutisse ainsi à une solution, encore moins à une solution optimale. En effet, on aurait très bien pu faire les choix suivants :



et ne pas aboutir à une solution.

Considérons par exemple le problème du **rendu de monnaie** : étant donné, une liste de valeurs faciales de pièces $P = (v_1, \dots, v_p) \in (\mathbb{N}^*)^p$ avec $1 = v_1 < \dots < v_p$ et une somme $n \in \mathbb{N}^*$, on cherche la manière d'exprimer cette somme avec le plus petit nombre de pièces possible.

Plus précisément, l'ensemble des solutions $S = \{(k_1, \dots, k_p) \in \mathbb{N}^p \mid k_1 v_1 + \dots + k_p v_p = n\}$ et la fonction d'objectif est $f : (k_1, \dots, k_p) \mapsto k_1 + \dots + k_p$. Les solutions partielles ici sont les réalisations de valeur $< n$. On cherche alors $x = \operatorname{argmin}_{y \in S} f(y)$.

Comme $1 = v_1$, $S \neq \emptyset$ car $(n, 0, \dots, 0) \in S$ et ainsi $f(x) \leq n$.

L'algorithme glouton va utiliser la plus grande pièce possible à chaque étape puis on applique l'algorithme glouton sur la somme restante sauf si elle est nulle, ce qui constitue la condition d'arrêt.

Exemple 1

- $P = (1, 2, 5, 10)$
- $n = 14$
- On utilise la plus grande pièce possible $10 \leq 14$ puis on exprime $4 = 14 - 10$
- Ici, la plus grande pièce est 2 et on continue avec $2 = 4 - 2$
- La plus grande pièce est encore 2 et on s'arrête car $0 = 2 - 2$.
- En conclusion, on a obtenu $x = (0, 2, 0, 1)$.
- Une exploration exhaustive permet de s'assurer qu'on a effectivement obtenu une décomposition minimale. En effet, ici l'ensemble des décompositions est : { $(14,0,0,0), (12,1,0,0), (8,3,0,0), (6,4,0,0), (4,5,0,0), (2,6,0,0), (0,7,0,0), (9,0,1,0), (7,1,1,0), (5,2,1,0), (3,3,1,0), (1,4,1,0), (4,0,2,0), (2,1,2,0), (0,2,2,0), (4,0,0,1), (2,1,0,1), (0,2,0,1)$ }.

Exemple 2

- $P = (1, 2, 7, 10)$
- $n = 14$
- L'algorithme glouton va ici procéder comme dans l'exemple 1 et on va obtenir $x = (0, 2, 0, 1)$.
- Mais on remarque que ce n'est pas un minimum car $x' = (0, 0, 2, 0)$ convient avec $f(x') = 2 < 3 = f(x)$.

Conclusion l'algorithme glouton n'a effectivement pas de raisons d'être optimal.

On peut se poser la question des algorithmes pour lesquels l'algorithme glouton aboutit nécessairement à une solution optimale.

■ **Note 15.1** TODO - Ajouter un paragraphe simple sur les matroïdes qui puisse se décliner sous la forme d'un problème.

II Construction de l'arbre de Huffman

■ **Remarque 15.2** Ce paragraphe décrit l'étape cruciale du principe de compression de Huffman. Celui-ci sera présenté complètement dans le chapitre Algorithmique des textes.

On va étudier ici un principe de compression parfaite (sans perte d'information à la décompression) de données appelé l'algorithme de Huffman et qui repose sur ce principe simple : coder sur moins de bits les caractères les plus fréquents.

Par exemple si on considère le mot abaabc, en le codant avec un nombre de bits fixes, par exemple 2 avec le code $a=00, b=01, c=10$, on aurait besoin de 12 bits pour représenter le mot. Mais si on choisit le code suivant : $a=0, b=10, c=11$, il suffit de 9 bits. On a donc gagné 3 bits soit un facteur de compression de 75%.

On remarque que pour pouvoir décompresser, il n'aurait pas été possible de faire commencer le code de b ou c par un 0, sinon on aurait eu une ambiguïté avec la lecture d'un a. On parle alors

de code préfixe :

Définition II.1 Soit $X \subset \{0, 1\}^*$, on dit que X est un code préfixe lorsque pour tous $x, y \in X$, x n'est pas un préfixe de y et y n'est pas un préfixe de x .


On se pose alors la question du code préfixe optimal pour un texte donné.

Plus précisément, étant donné un alphabet fini Σ et une application $f : \Sigma \rightarrow [0, 1]$ associant à chaque lettre son nombre d'occurrences dans le texte considéré. Ainsi $\sum_{x \in \Sigma} f(x)$ est la longueur du texte. On cherche un code préfixe X et une application $c : \Sigma \rightarrow X$ telle que $\sum_{x \in \Sigma} f(x)|c(x)|$ soit minimale car cela correspond au nombre de bits après codage.

■ **Remarque 15.3** On utilise aussi la notion de fréquence du lettre qui est son nombre d'occurrence rapporté à la longueur du texte. Un des avantages de la notion de fréquence est qu'il est possible de considérer une table de fréquence déjà construite comme celle de la langue française.

L'application de codage c peut être représenté par un arbre binaire où les arêtes gauches correspondent à 0, les arêtes droites à 1 et les feuilles aux éléments de Σ dont les étiquettes des chemins y menant depuis la racine de l'arbre correspondent à leur image par c .

Par exemple, pour le code $a = 0, b = 10, c = 11$ on aurait l'arbre :



Avec un tel arbre, il est très simple de décoder le texte codé car il suffit de suivre un chemin dans l'arbre jusqu'à tomber sur une feuille, produire la lettre correspondante, puis repartir de la racine de l'arbre. La longueur du code associé à une lettre est alors égale à la profondeur de la feuille correspondante. L'optimalité du codage préfixe est ainsi équivalente à la minimalité de l'arbre vis-à-vis de la fonction d'objectif $\varphi(t) = \sum_{x \in \Sigma} f(x)p(t, x)$ où $p(t, x)$ est la profondeur de la feuille d'étiquette x dans l'arbre t ou 0 si x n'est pas une des étiquettes, cet extension permettant d'étendre la fonction d'objectif aux solutions partielles.

L'algorithme d'Huffman va construire un arbre correspondant à un codage optimal à l'aide d'une file de priorité d'arbres. On étend pour cela l'application f à de tels arbres en définissant que si t est un arbre de feuilles x_1, \dots, x_n alors $f(t) = f(x_1) + \dots + f(x_n)$.

- Au départ, on place dans la file des arbres réduits à une feuille pour chaque élément $x \in \Sigma$ et dont la priorité est $f(x)$.
- Tant que la file contient au moins deux éléments
 - ★ on retire les deux plus petits éléments x et y de la file de priorité $f(x)$ et $f(y)$
 - ★ on ajoute un arbre $z = \text{Noeud}(x, y)$ de priorité $f(z) = f(x) + f(y)$.
- On renvoie l'unique élément restant dans la file.

L'implémentation de cet algorithme est alors assez directe avec une file de priorité. On réutilise ici la structure de tas implementée en FIXME. Comme il s'agit d'un tas max, on insère avec $-f(x)$ comme valeur.

```
OCaml | let construit_arbre occ =
        let arbres = Tas.cree 2000 (0, Feuille 0) in
        for i = 0 to 255 do
```

```

let f = occ.(i) in
  if f > 0 (* on ignore les occurrences nulles *)
    then Tas.insere (-f, Feuille i) arbres
done;
while Tas.taille arbres > 1 do
  let fx, x = Tas.supprime_racine arbres in
  let fy, y = Tas.supprime_racine arbres in
  Tas.insere (fx+fy, Noeud(x,y)) arbres
done;
snd (Tas.supprime_racine arbres)

```

L'algorithme de Huffman est un algorithme glouton car si on considère pour solution partielle la fôret présente dans la file et pour objectif la fonction φ étendue aux fôrets en sommant la valeur de φ sur chaque arbre, alors fusionner dans la fôret F deux arbres x et y en la transformant en une fôret F' va avoir l'impact suivant sur la fonction d'objectif :

$$\varphi(F') = \varphi(F) + f(x) + f(y)$$

car, en effet, on va rajouter 1 à la profondeur de chaque feuille et donc on passe pour la contribution de x de $\varphi(x) = \sum_{c \in \Sigma} f(c)p(x, c)$ à $\sum_{c \in \Sigma} f(c)(p(x, c) + 1) = \varphi(x) + \sum_{c \in \Sigma} f(c) = \varphi(x) + f(x)$.

On remarque ainsi que la fusion qui minimise localement φ est celle qui fusionne les deux arbres de plus petite valeur pour f .

Pour montrer que l'algorithme glouton produit ici un codage minimal, on va utiliser une technique classique qui consiste à montrer qu'étant donné une solution optimale, on peut toujours la transformer sans augmenter sa valeur pour obtenir, de proche en proche, la solution renvoyée par le glouton.

Théorème II.1 Supposons que les lettres les moins fréquentes soient a et b , il existe un arbre optimal dont les deux feuilles étiquetées par a et b descendent du même noeud et sont de profondeur maximale.

Démonstration.

Considérons un arbre optimal t et soient c l'étiquette d'une feuille de profondeur maximale. On remarque qu'elle a forcément une feuille sœur car sinon, on pourrait omettre le noeud et l'arbre obtenu serait de plus petite valeur par φ .

FIXME : dessin

Soit d l'étiquette de cette feuille sœur. Sans perte de généralités, on suppose que $f(c) \leq f(d)$ et $f(a) \leq f(b)$. Comme a a le plus petit nombre d'occurrences, a $f(a) \leq f(c)$ et comme b est la deuxième, on a $f(b) \leq f(d)$. De plus, $p(t, a) \geq p(t, c)$ et $p(t, b) \geq p(t, d)$.

Si on échange les étiquettes a et c , seules les termes associés à ces lettres changent dans l'évaluation de φ . Si on note t' le nouvel arbre obtenu après cet échange, on a

$$\varphi(t') = \varphi(t) - f(a)p(t, a) - f(c)p(t, c) + f(a)p(t, c) + f(c)p(t, a)$$

Or, $f(c) \geq f(a)$ et $p(t, a) \geq p(t, c)$ donc


$$\varphi(t') = \varphi(t) + (f(c) - f(a))(p(t, a) - p(t, c)) \leq \varphi(t)$$

L'échange préserve le caractère optimal. En fait, ici, on a nécessairement une égalité pour ne pas aboutir à une contradiction, donc soit les feuilles étaient à même profondeur, soit les lettres avaient le même nombre d'occurrences.

Comme on a les mêmes relations entre b et d , on peut effectuer le même argument et échanger les étiquettes en préservant le caractère optimal.

Le théorème suivant permet de raisonner par récurrence en diminuant le nombre de lettres.

Théorème II.2 Soit t un arbre ayant x et y comme feuilles soeurs et t' l'arbre obtenu en remplaçant le noeud liant x et y par une feuille étiquetée par z où z est une nouvelle lettre telle que $f(z) = f(x) + f(y)$.



On a alors $\varphi(t) = \varphi(t') + f(z)$.

Démonstration.

Seule les termes portant sur x , y et z sont influencés par le changement et on a :

$$\begin{aligned}\varphi(t) &= \varphi(t') + f(x)p(t,x) + f(y)p(t,y) - f(z)p(t',z) \\ &= \varphi(t') + f(z)(p(t',z) + 1) - f(z)p(t',z) \\ &= \varphi(t') + f(z)\end{aligned}$$

Théorème II.3 L'algorithme de Huffman renvoie un arbre optimal.

Démonstration.

Par récurrence sur $|\Sigma|$.

Initialisation : si Σ ne contient qu'une lettre, il n'y a qu'un arbre qui est nécessairement optimal.

Héritéité : si la propriété est vraie pour un alphabet de $n-1 \geq 1$ lettres, alors soit Σ contenant n lettres et x et y les deux lettres les moins fréquentes.

On pose Σ' obtenue en remplaçant x et y par une nouvelle lettre z et on suppose que $f(z) = f(x) + f(y)$. L'hypothèse de récurrence assure qu'on obtient un arbre optimal t' en appliquant l'algorithme d'Huffman sur Σ' . Comme la première étape d'Huffman va fusionner les feuilles x et y , on sait que l'arbre t obtenu en partant de Σ se déduit de t' en remplaçant z par $Noeud(x, y)$. Le théorème précédent assure alors que $\varphi(t) = \varphi(t') + f(z)$.

Soit t_o un arbre optimal pour Σ dans lequel x et y sont soeurs, possible en vertu du premier théorème, et soit t'_o l'arbre obtenu en remplaçant dans t_o le noeud liant x et y par une feuille étiquetée par z . On a ici encore $\varphi(t_o) = \varphi(t'_o) + f(z) \geq \varphi(t') + f(z) \geq \varphi(t)$ car t' est optimal.

Ainsi, on a bien l'égalité $\varphi(t_o) = \varphi(t)$ et t est optimal.

III Preuve d'optimalité

Dans le paragraphe précédent, on retrouve un schéma de preuve classique pour les preuves d'optimalité des algorithmes gloutons :


- Montrer qu'à partir d'une solution optimale, il est possible de déterminer une solution optimale ayant fait le même choix que l'algorithme glouton. Pour Huffman c'était le fait d'avoir un arbre optimal ayant les deux lettres les moins fréquentes comme sœurs à profondeur maximale.
- Montrer qu'une solution optimale se comportant comme le résultat de l'algorithme glouton à une étape ne peut être meilleure que le résultat de l'algorithme glouton.

IV Sélection d'activités

IV.1 Description

Étant donné un ensemble d'activités données par leur temps de début et leur temps de fin (on considère les temps comme des entiers pour simplifier), on se pose la question du nombre maximal d'activité que l'on puisse sélectionner sans que deux activités soient en conflits. Cela correspond par exemple à l'organisation du planning d'un employé.

On dit que deux activités (d_1, f_1) et (d_2, f_2) sont en conflits quand $[d_1, f_1] \cap [d_2, f_2] \neq \emptyset$.



Ici, t_1 et t_2 sont en conflits avec t_3 . Mais t_1 et t_2 ne sont pas en conflit. On considère que deux activités peuvent se succéder directement : $f_1 = d_2$.

On considère donc en entrée de ce problème une suite finie $((d_1, f_1), \dots, (d_n, f_n))$ et on cherche un sous-ensemble $I \subset \llbracket 1, n \rrbracket$ de plus grand cardinal tel que pour tous $i, j \in I$, si $i \neq j$ alors (d_i, f_i) et (d_j, f_j) ne sont pas en conflits. On dit que I est un **ensemble indépendant**.

IV.2 Algorithme glouton et implémentation

Pour résoudre ce problème, on considère l'algorithme glouton associé à la fonction d'objectif cardinal et **en triant les activités** ordre croissant de temps de fin.

Cet algorithme est implémenté dans le programme suivant :

```
#include <stdio.h>
#include <stdlib.h>

typedef struct {
    unsigned int id;
    unsigned int debut;
    unsigned int fin;
    unsigned char selectionnee;
} activite;

int compare_activites(const void *t1, const void *t2)
{
```

```

        return ((activite *)t1)->fin - ((activite *)t2)->fin;
    }

void selectionne(activite *activites, size_t nb_activites)
{
    size_t derniere_activite = 0;
    /* on commence par trier en O(n log2 n) les activites
     * selon le temps de fin */
    qsort(activites, nb_activites,
          sizeof(activite), compare_activites);
    activites[0].selectionnee = 1;
    for (size_t i = 1; i < nb_activites; i++)
    {
        if (activites[i].debut >= activites[derniere_activite].fin)
        {
            activites[i].selectionnee = 1;
            derniere_activite = i;
        }
    }
}

int main()
{
    activite activites[] = {
        { 0, 1, 3, 0 }, { 1, 3, 4, 0 }, { 2, 2, 5, 0 },
        { 3, 5, 9, 0 }, { 4, 11, 12, 0 }, { 5, 8, 10, 0 },
        { 6, 0, 7, 0 }
    };
    size_t nb_activites = sizeof(activites) / sizeof(activite);

    selectionne(activites, nb_activites);

    for (size_t i = 0; i < nb_activites; i++)
    {
        printf("Activité %d (%d,%d) : %d\n",
               activites[i].id, activites[i].debut,
               activites[i].fin, activites[i].selectionnee);
    }

    return 0;
}

```

Ce programme produit alors la sortie :

Activité 0 (1,3) : 1
 Activité 1 (3,4) : 1
 Activité 2 (2,5) : 0
 Activité 6 (0,7) : 0
 Activité 3 (5,9) : 1
 Activité 5 (8,10) : 0
 Activité 4 (11,12) : 1

■ **Remarque 15.4** Comme l'algorithme commence par effectuer un tri, on a rajouté dans la structure activite un champ permettant d'identifier une activité autrement que par son indice.

IV.3 Preuve d'optimalité

On va prouver que l'algorithme glouton renvoie un ensemble indépendant optimal. Le fait que l'ensemble soit indépendant étant direct, on se concentre sur la preuve d'optimalité en présentant un schéma de preuve qui correspond à celui identifié dans le paragraphe précédent.

Théorème IV.1 Si a_1, \dots, a_n sont des activités énumérées dans l'ordre croissant de leur temps de fin, alors il existe un ensemble indépendant optimal contenant a_1 .

■ **Remarque 15.5** Cela signifie qu'il fait le même choix que l'algorithme glouton à la première étape.

Démonstration.

Soit I un ensemble indépendant optimal ne contenant pas $a_1 = (d_1, f_1)$ (sinon c'est direct). Si $a_k = (d_k, f_k)$ est l'activité de plus petit indice dans I , alors $f_k \geq f_1$ donc pour tout $a_i = (d_i, f_i)$ dans $I' = I \setminus \{a_k\}$ on a $d_i \geq f_k \geq f_1$ et ainsi a_1 et a_i ne sont pas en conflit. Ainsi $I' \cup \{a_1\}$ est un ensemble indépendant contenant a_1 de même cardinal que I donc optimal.

Théorème IV.2 Soit $A = \{a_1, \dots, a_n\}$ des activités ordonnées par ordre croissant de temps de fin et I un ensemble indépendant optimal contenant $a_1 = (d_1, f_1)$ (ce qui est possible selon le théorème précédent).

$I' = I \setminus \{a_1\}$ est optimal pour $A' = \{(d, f) \in A \mid d \geq f_1\}$.

Démonstration.

Si, par l'absurde, I' est pas optimal pour A' alors $J \subset A'$ est un ensemble indépendant de cardinal strictement plus grand que celui de I' . Or, $A' \cup \{a_1\}$ est indépendant pour l'ensemble des activités et est de cardinal strictement plus grand que I . Contradiction.

Théorème IV.3 L'algorithme glouton renvoie un ensemble indépendant optimal.

Démonstration.

Par récurrence forte sur le nombre d'activités.

- Initialisation : Pour une activité a_1 , le glouton renvoie $\{a_1\}$ qui est directement optimal.
- Héritérité : Si la propriété est vérifiée pour $k \leq n$ activités, soit $A = \{a_1, \dots, a_n\}$ des activités ordonnées par temps de fin. Soit I un ensemble indépendant optimal contenant a_1 et $I' = I \cap \{a_1\}$. Le théorème précédent assure que I' est optimal sur $A' = \{(d, f) \in A \mid d \geq f_1\}$.

Par hypothèse de récurrence, l'algorithme glouton sur A' produit un ensemble indépendant optimal G' , donc tel que $|G'| = |I'|$. Par construction l'algorithme glouton sur A renvoie $G = G' \cup \{a_1\}$ de même cardinal que I , donc optimal.



V Ordonnancement de tâches

V.1 Description

On considère ici un problème voisin du problème précédent. On considère n tâches $T = \{t_1, \dots, t_n\}$ prenant une unité de temps pour être traitées sur une unité de calcul.

Chaque tâche t dispose d'une date limite $f(t) \in \llbracket 1, n \rrbracket$ (**deadline**) à laquelle elle doit être traitée sans quoi on écope d'une pénalité $p(t) \in \mathbb{N}$.

On appelle stratégie d'ordonnancement une application $d : T \rightarrow \llbracket 0, n - 1 \rrbracket$ qui associe à chaque tâche un unique temps de début $d(t)$. Selon cette stratégie, on déduit une séparation de T en deux ensembles disjoints :

- $T^+(d)$ l'ensemble des tâches traitées dans les délais : $t \in T^+(d) \iff d(t) < f(t)$.
- $T^-(d)$ l'ensemble des tâches traitées en retard : $t \in T^-(d) \iff d(t) \geq f(t)$.

On note alors $P(d) = \sum_{t \in T^-(d)} p(t)$ la somme des pénalités des tâches en retard.

■ **Exemple 15.1** On considère l'ensemble de tâches :

t_i	1	2	3	4	5	6	7
$f(t_i)$	1	2	3	4	4	4	6
$p(t_i)$	3	6	4	2	5	7	1

Une stratégie d'ordonnancement (les tâches en retard sont en gras) est donnée dans le tableau suivant :

t_i	1	2	3	4	5	6	7
$d(t_i)$	6	0	1	4	3	2	5

On a alors $P(d) = 5$.



On cherche à obtenir une stratégie d'ordonnancement de valeur $P(d)$ minimale.

On remarque que l'ordonnancement des tâches en retard n'a aucune importance, et on peut donc se contenter de déterminer une stratégie d'ordonnancement pour les tâches traitées dans les délais et la compléter par n'importe quel ordonnancement des autres tâches. On peut ainsi reformuler le problème : déterminer un sous-ensemble $T^+ \subset T$ de tâches **pouvant** être traitées dans les délais tel que $\sum_{t \in T^+} p(t)$ soit **maximale**.

V.2 Algorithme glouton et implémentation

On résout maintenant ce problème de maximisation des pénalités T^+ par un algorithme glouton :

- On commence avec $T^+ = \emptyset$ et tous les temps de $\llbracket 0, n - 1 \rrbracket$ sont marqués comme étant disponibles.
- On parcourt les tâches dans l'ordre décroissant des pénalités.
 - * Quand on considère la tâche t s'il existe un temps i disponible tel que $i < d(t)$ alors on marque comme indisponible le temps $i_0 = \max \{ i \in \llbracket 0, n - 1 \rrbracket \mid i < d(t) \text{ et } i \text{ disponible} \}$ et on rajoute alors t à T^+ en commençant t au temps i_0 .
- On place les tâches restantes aux temps disponibles.

Pour les structures de données, on utilise une représentation en tableaux de booléens (des `unsigned char` à 0 ou 1 en C) pour la disponibilités des temps. L'ensemble T^+ est alors implicite car il correspond aux tâches ordonnancé dans la première étape. Utiliser un tableau implique qu'une recherche linéaire soit faite pour chercher un plus grand temps disponible, et donc, la complexité temporelle globale sera en $O(n^2)$.

■ **Remarque 15.6** Il est possible d'améliorer cela pour passer en $O(n \log_2 n)$ (*exercice*). ■

Le programme C suivant implémente cet algorithme.

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

typedef struct {
    unsigned int id;
    unsigned int date_limite;
    unsigned int penalite;
    int debut; /* -1 tant que la tâche n'est pas ordonnancée */
} tache;

int compare_taches(const void *t1, const void *t2)
{
    return ((tache *)t2)->penalite - ((tache *)t1)->penalite;
}

void *ordonnancement(tache *taches, size_t nb_taches)
{
    unsigned char *temps_occupe = malloc(sizeof(unsigned char) * nb_taches);
    memset(temps_occupe, 0, nb_taches);

    /* tri des activités par ordre décroissant des pénalités */
    qsort(taches, nb_taches, sizeof(tache), compare_taches);

    /* T+ par algorithme glouton */
    for (size_t k = 0; k < nb_taches; k++)
    {
        int i0 = -1;
        for (size_t i = 0; i < nb_taches; i++)
        {
            if (temps_occupe[i] == 0 && i < taches[k].date_limite)
                i0 = i;
        }
        if (i0 >= 0)
        {
            taches[k].debut = i0;
            temps_occupe[i0] = 1;
        }
    }

    /* Complétion par les tâches en retard */
    int i = 0; // indice du dernier temps disponible utilisé
```

```

    for (size_t k = 0; k < nb_taches; k++)
    {
        if (taches[k].debut == -1)
        {
            while (temps_occupe[i] == 1)
                i++;
            taches[k].debut = i;
            temps_occupe[i] = 1;
        }
    }

    free(temps_occupe);
}

int main()
{
    tache taches[] = {
        { 1, 1, 3, -1 }, { 2, 2, 6, -1 }, { 3, 3, 4, -1 },
        { 4, 4, 2, -1 }, { 5, 4, 5, -1 }, { 6, 4, 7, -1 },
        { 7, 6, 1, -1 }
    };

    size_t nb_taches = sizeof(taches) / sizeof(tache);

    ordonnancement(taches, nb_taches);

    for (size_t i = 0; i < nb_taches; i++)
    {
        printf("T%d (f:%d,p:%d) @ %d\n", taches[i].id, taches[i].date_limite,
               taches[i].penalite, taches[i].debut);
    }

    return 0;
}

```

Il produit la sortie :

```

T6 (f:4,p:7) @ 3
T2 (f:2,p:6) @ 1
T5 (f:4,p:5) @ 2
T3 (f:3,p:4) @ 0
T1 (f:1,p:3) @ 4
T4 (f:4,p:2) @ 6
T7 (f:6,p:1) @ 5

```

Ce qui correspond à l'ordonnancement $t_3, t_2, t_5, t_6, t_1, t_7, t_4$. Les tâches t_1 et t_4 sont en retard, donc la pénalité totale est de 5.

V.3 Preuve d'optimalité

On va montrer que cet algorithme glouton renvoie un ensemble T^+ optimal. Pour cela, on procède comme précédemment. Tout d'abord, on montre qu'il existe une solution optimale qui effectue le premier choix de l'algorithme glouton.

Théorème V.1 Soit T un ensemble de tâches et $t \in T$ une tâche de pénalité maximale. Il existe un ensemble T^+ de tâches pouvant être traitées dans les délais, maximal pour les pénalités et tel que $t \in T^+$.

Démonstration.

Soit $T^+ \subset T$ un ensemble maximal. S'il contient t , il convient directement. Sinon, il existe une tâche t' de T^+ qui est traitée à un moment où on pourrait traiter t à temps (sinon $T^+ \cup \{t\}$ conviendrait et T^+ ne pourrait être maximal). On a $p(t') \leq p(t)$ par maximalité de t . L'ensemble T' déduit de T^+ en remplaçant t' par t convient car on a forcément $P(T') = P(T^+)$ (en fait \geq mais = par optimalité de T^+) et par construction toutes ses tâches peuvent être traitées à temps. ■

On montre maintenant qu'en enlevant le choix glouton, on obtient une solution optimale du sous-problème.

Théorème V.2 Soit $T^+ \subset T$ ensemble de tâches pouvant être traitées, maximal pour les pénalités et contenant une tâche t de plus grande pénalité. Soit i l'instant auquel la tâche t commence dans un ordonnancement de T^+ .

On pose $T' = T \setminus \{t\}$ avec des dates limites modifiées :

$$\forall t' \in T', d_{T'}(t') = \begin{cases} d_T(t') & \text{si } d_T(t') \leq i \\ d_T(t') - 1 & \text{sinon} \end{cases}$$

$T^+ \setminus \{t\}$ est alors maximal pour T' .

Démonstration.


Dans T' , on a à la fois enlevé t et supprimé l'instant i . Tout ordonnancement de T' peut alors être relevé en un ordonnancement de T en décalant d'un instant les tâches commençant à partir de l'instant i et en ordonnant là la tâche t . Réciproquement d'un ordonnancement dans T , on déduit directement un ordonnancement de T'

Ainsi, s'il existait T'^+ maximal pour T' tel que $P(T'^+) > P(T^+ \setminus \{t\}) = P(T^+) - p(t)$ alors $T'^+ \cup \{t\}$ serait de somme de pénalités strictement plus grande que celle de T^+ supposé maximal.

Donc, $T^+ \setminus \{t\}$ est maximal. ■

On conclut alors directement par récurrence sur le nombre de tâches comme on l'a fait précédemment pour la sélection d'activités :

Théorème V.3 L'algorithme glouton renvoie un ordonnancement optimal.



16. Diviser pour régner

I Diviser pour régner

1.1 Principe

Le principe des algorithmes dits *Diviser pour régner* est de décomposer un problème en plusieurs sous-problèmes disjoints et de déduire des solutions de ces sous-problème une solution au problème de départ.

Le point clé pour ce principe est de pouvoir **fusionner** les solutions de sous-problèmes pour en faire une solution, et de pouvoir le faire dans un temps/espace raisonnable. On procède alors par récursivité en appliquant ce principe pour résoudre les sous-problèmes eux-mêmes jusqu'à tomber sur des sous-problèmes très simples.

1.2 Tri fusion

L'algorithme du tri fusion est un des exemples les plus importants d'algorithmes *Diviser pour régner* :

- Étant donnée une liste l de taille $n \geq 2$, on va considérer les sous-listes l_p des valeurs d'indice pair et l_i des valeurs d'indice impair.
- On trie ensuite l_1 et l_2 pour obtenir l'_1 et l'_2 .
- On fusionne ces deux listes pour obtenir $l' = \text{fusion}(l'_1, l'_2)$ liste triée déduite de l .

Comme expliqué dans le paragraphe précédent, les tris de l_1 et l_2 s'effectuent eux-aussi à l'aide d'un tri fusion.

■ **Note 16.1** TODO : dessin

Voici une implémentation en OCaml de cet algorithme :

```
OCaml
let rec separe_en_deux l =
  match l with
  | [] -> ([], [])
  | [x] -> ([x], [])
```

```

| x::y::q -> let l1, l2 = separe_en_deux q in
  (x::l1, y::l2)

let rec fusionne l1 l2 =
  match l1, l2 with
  | [], _ -> l2
  | _, [] -> l1
  | x::q1, y::q2 ->
    if x < y
    then x :: (fusionne q1 l2)
    else y :: (fusionne l1 q2)

let rec tri_fusion l =
  match l with
  | [] -> []
  | [x] -> [x]
  | _ ->
    let l1, l2 = separe_en_deux l in
    let l1p = tri_fusion l1 in
    let l2p = tri_fusion l2 in
    fusionne l1p l2p

```

La correction et la terminaison de cet algorithme ne posant aucune difficulté, on va se concentrer sur le calcul de la complexité temporelle :

- `separe_en_deux` consiste en un parcours linéaire de la liste l donc $O(|l|)$.
- `fusionne` supprime un élément d'une des deux listes à chaque appel récursif, donc une complexité en $O(|l_1| + |l_2|)$.
- Pour `tri_fusion` la situation est plus complexe en raison du double appel récursif. On va d'abord traiter le cas des listes contenant 2^k éléments.

Notons t_n la complexité temporelle pour $|l| = n$.

Lemme I.1 $t_{2^n} = O(2^n \log_2 2^n)$

Démonstration.

Par l'analyse de complexité des deux fonctions auxiliaires, on a pour $n \in \mathbb{N}$

$$t_{2^{n+1}} = 2t_{2^n} + O(2^n) \leq 2t_{2^n} + M2^n$$

où on peut supposer que $M \geq 1$.

On va montrer par récurrence sur $n \in \mathbb{N}^*$ que $t_{2^n} \leq 2Mn2^n$.

- Initialisation : $t_{2^1} = 2t_1 + M2 = 2M + 2 \leq 4M = 2 \times 1 \times 2^1 M$.
- Hérédité : si $n \in \mathbb{N}^*$ et l'hypothèse est vérifiée pour t_{2^n} , alors $t_{2^{n+1}} \leq 4n2^nM + M2^n = (4n + 1)M2^n \leq 4(n + 1)M2^n \leq 2M(n + 1)2^{n+1}$.
Ainsi $t_{2^n} = O(n2^n)$. ■

Théorème I.2 $t_n = O(n \log_2 n)$

Démonstration.

Le lemme assure qu'il existe M' tel que $\forall p \in \mathbb{N}^*, t_{2^p} \leq M'p2^p$.

Soit $n \in \mathbb{N}^*$ et p minimum tel que $n \leq 2^p$. On a $\log_2 n \leq p$ par croissance de \log_2 et ainsi $t_n \leq t_{2^p} \leq M'p2^p = M'n \log_2 n$.

Ainsi, $t_n = O(n \log_2 n)$. ■

■ **Remarque 16.1** On a utilisé implicitement la croissance de t_n ici : plus la liste est longue, plus on effectue d'opérations. ■

Le programme suivant présente une implémentation du tri fusion reposant sur des tableaux. Les sous-tableaux sont manipulés à l'aide de leurs indices de début et de fin comme pour la recherche dichotomique.

```
let rec separe_en_deux l =
  match l with
  | [] -> ([], [])
  | [x] -> ([x], [])
  | x::y::q -> let l1, l2 = separe_en_deux q in
    (x::l1, y::l2)

let rec fusionne l1 l2 =
  match l1, l2 with
  | [], _ -> l2
  | _, [] -> l1
  | x::q1, y::q2 ->
    if x < y
    then x :: (fusionne q1 l2)
    else y :: (fusionne l1 q2)

let rec tri_fusion l =
  match l with
  | [] -> []
  | [x] -> [x]
  | _ ->
    let l1, l2 = separe_en_deux l in
    let l1p = tri_fusion l1 in
    let l2p = tri_fusion l2 in
    fusionne l1p l2p
```

OCaml

■ **Note 16.2** TODO : exercice tri avec un tableau et tri **en place** ■

I.3 Nombre d'inversions

Définition I.1 Soit t une structure séquentielle (tableau, liste,) contenant des valeurs comparables a_0, \dots, a_{n-1} et énumérées dans cet ordre au sein de t .

Une paire $(i, j) \in \llbracket 0, n-1 \rrbracket^2$ où $i < j$ est appelée une *inversion* de t lorsque $a_i > a_j$.

On note $I(t)$ le nombre d'inversion de t .

■ **Remarque 16.2** • Le nombre d'inversions permet de mesurer à quel point t est non triée dans l'ordre croissant.
 • Ce concept d'inversion est exactement celui utilisé pour les permutations en mathématiques : si $\sigma \in \mathfrak{S}_n$, il suffit de considérer $(\sigma(1), \dots, \sigma(n))$.

On cherche dans ce paragraphe à calculer $I(t)$ efficacement. Remarquons tout d'abord qu'un algorithme naïf est en $O(n^2)$ où $|t| = n$ en explorant toutes les paires :

```
size_t inversions(int *t, size_t taille)
{
    size_t inv = 0;
    for (size_t i = 0; i < taille; i++)
    {
        for (size_t j = i+1; j < taille; j++)
        {
            if (t[i] > t[j]) inv++;
        }
    }
    return inv;
}
```

On va maintenant donner un algorithme type *Diviser pour régner* :

- On sépare t en deux moitiés t_1 et t_2 .
- On calcule $I(t_1)$ et $I(t_2)$ par des appels récursifs.
- On compte les inversions entre des éléments de t_1 et des éléments de t_2
 - ★ Cela ne dépend pas de leur position dans t_1 ou dans t_2 .
 - ★ On peut donc trier t_1 en t'_1 et t_2 en t'_2 .
 - ★ On compte $N(t_1, t_2) = N(t'_1, t'_2)$ le nombre d'inversions entre t'_1 et t'_2 .
- On en déduit que $I(t) = I(t_1) + I(t_2) + N(t_1, t_2)$.

Pour calculer le nombre d'inversions entre deux tableaux triés t'_1 et t'_2 on peut utiliser l'algorithme en $O(|t'_1| + |t'_2|)$ suivant : pour j parcourant les indices de t'_2 , on cherche le plus petit i tel que $t'_1[i]$.

I.4 Points les plus proches

I.5 Sous-ensemble de somme donnée

I.6 Recherche dichotomique

I.7 Couverture par des segments égaux

On considère ici n points sur la droite réelle. Le i -ème point est identifié par sa coordonnée x_i . On se pose alors, dans un premier temps, la question de savoir si on peut trouver k segments de longueur l tels que chaque point appartienne à au moins un de ces segments. Dans un second temps, on se posera la question de la longueur l minimale de ces segments.

I.7.i Couverture par des segments de longueur donnée

On va ici résoudre le premier problème :

Problème - EXISTENCECOUVERTURESEGMENT

- Entrées :
 - ★ n points sur la droite réelle x_1, \dots, x_n
 - ★ un entier $k \geq 1$
 - ★ un réel l
- Sortie : existe-t-il k segments S_1, \dots, S_k de longueur l tels que
 $\forall i \in \llbracket 1, n \rrbracket, \exists j \in \llbracket 1, k \rrbracket, x_i \in S_j$?

On remarque qu'un segment de longueur l est uniquement caractérisé par son extrémité gauche. Pour chaque x_i , il doit ainsi exister une extrémité gauche dans le segment $S_i = [x_i - l, x_i]$. On peut ainsi renverser le problème et en faire un problème de couverture de segments par des points : on cherche k points tel que chaque segment S_i contienne au moins un de ces points.

Problème - ENSEMBLEINTERSECTANTLIGNE

- Entrées :
 - ★ n segments $S_i = [l_i, r_i]$
 - ★ un entier $k \geq 1$.
- Sortie : Un ensemble P de k points tels que $\forall p \in P, \exists i \in \llbracket 1, n \rrbracket, p \in S_i$ en cas de succès

Ce problème peut se résoudre par un algorithme glouton :

- on commence avec $P = \emptyset$
- on trie les segments par r_i croissant
- pour chaque segment $S_i = [l_i, r_i]$, s'il ne contient aucun élément de P , on rajoute r_i à P .
- on répond avec un succès si $|P| \leq k$ (on peut alors compléter avec des points quelconques pour avoir exactement k points).

Cet algorithme est en $O(n \log n)$ en raison du tri initial.

I.7.ii Longueur minimale

On considère maintenant le problème suivant :

Problème - COUVERTURESEGMENTSMINIMALE

- Entrées :
 - ★ n points à coordonnées entières sur la droite réelle x_1, \dots, x_n
 - ★ un entier $k \geq 1$
- Sortie : la longueur l minimale pour laquelle il existe une couverture des points par k segments de longueur l .

On peut résoudre ce problème par dichotomie à l'aide de l'algorithme précédent

- on considère $L = \frac{\max_{1 \leq i < j \leq n} |x_j - x_i|}{k} = \frac{D}{k}$ où le diamètre D se calcule en $O(n)$ et correspond à répartir de manière uniforme les segments pour couvrir les points. Une telle couverture existe toujours.
- on peut considérer, sans avoir besoin de le calculer au préalable, le tableau V de booléen de longueur $L + 1$ tel que $V[l]$ indique s'il est possible de couvrir les points par k segments de longueur l . Pour obtenir la valeur $V[l]$ il suffit d'appliquer l'algorithme précédent.
- on effectue alors une recherche dichotomique du plus petit indice l tel que $V[l]$ soit vrai. On obtient ainsi un algorithme en $O(n \log n \log \frac{D}{k})$ qu'on peut considérer comme étant en $O(n \log n)$ en supposant que D est une constante.

Cette dichotomie est en fait une instance d'un principe fondamental permettant de transformer un problème de décision (existe-t-il ?) en un problème d'optimisation (quelle est ... minimal/maximal ?).

I.7.iii Implémentation



17. Algorithmique des textes

Source image : justgrims, <https://www.flickr.com/photos/notbrucelee/8016192302>

■ Note 17.1 Roadmap :

- Des exercices.
- Les extensions à la fin.

Sources

- *Algorithms* Robert Sedgewick, Kevin Wayne
- *Éléments d'algorithmique* D. Beauquier, J. Berstel, Ph. Chrétienne
- *125 Problems in Text Algorithms with Solutions* Maxime Crochemore, Thierry Lecroq, Wojciech Rytter

I Recherche dans un texte

I.1 Principe de la recherche

On s'intéresse ici au problème suivant :

Problème - RECHERCHETEXTE

- Entrées :
 - ★ une chaîne de caractère s sur l'alphabet Σ
 - ★ un autre chaîne de caractère m sur ce même alphabet appelé *motif* et de longueur plus petite que s
- Sortie : un résultat partiel correspondant à l'indice de la première occurrence du motif dans la chaîne s'il est présent.

La différence fondamentale entre ce problème et celui de la recherche d'un sous-tableau dans un tableau est le fait qu'on considère un alphabet fini et dont le nombre d'éléments est le plus souvent négligeable par rapport à la taille des chaînes de caractères. Cela permet d'effectuer des optimisations qui ne sont pas sans rappeler les tris linéaires comme le tri par comptage.

On parle alors d'algorithmique du texte pour désigner des algorithmes tirant partie de cette contrainte sur les données. La plupart des algorithmes que l'on présente peuvent ainsi s'adapter aisément au cas de tableaux dont les éléments sont pris dans un ensemble fini de petit cardinal.

Avant d'entamer ce chapitre, remarquons qu'il existe, outre l'alphabet usuel, trois alphabets très importants :

- celui des caractères ASCII usuels
- celui contenant les deux éléments 0 et 1, ce qui permet de travailler sur des recherche en binaire.
- et enfin, très important pour la biologie, l'alphabet à quatre lettres A, T, G et C correspondant aux bases d'un brin d'ADN et qui ouvre la porte à beaucoup d'applications en bio-informatique.

■ **Note 17.2** Il y aura sûrement des applications bio-info dans la partie programmation dynamique, faire le lien ici.

1.2 Algorithme naïf en force brute

Une solution naïve consiste à parcourir chaque position de s afin de tester si le motif est présent à partir de cette position.

indices	0	1	2	3	4	5	6	7	8
s	t	o	t	a	t	o	t	o	u
recherche à l'indice 0	t	o	t	o					
à l'indice 1		t	o	t	o				
à l'indice 2			t	o	t	o			
à l'indice 3				t	o	t	o		
à l'indice 4					t	o	t	o	
									motif trouvé à l'indice 4

Cela donne l'implémentation assez directe suivante :

```
exception Trouve of int
exception PasDeMotif

(* renvoie un booléen indiquant si m est présent
 * dans s à l'indice i *)
let cherche_motif (m:string) (s:string) (i:int) : bool =
  let p = String.length m in
  try
    for j = 0 to p-1 do
      if s.[i+j] <> m.[j]
      then raise PasDeMotif
    done;
    true
  with PasDeMotif -> false

let recherche_naive m s =
  let n = String.length s in
  let p = String.length m in
  try
    for i = 0 to n-p do
      if cherche_motif m s i
```

OCaml

```

    then raise (Trouve i)
done;
None
with Trouve i -> Some i

```

La complexité temporelle en pire cas de cet algorithme correspond au maximum de comparaisons. On peut naturellement en déduire par majoration une borne en $O(np)$ mais on peut remarquer qu'il est assez difficile d'obtenir un exemple concret, ce qui fait penser que ce pire cas est *rare*.

■ **Remarque 17.1** Considérons la chaîne $s = aa\dots a = a^n$ qui contient n fois la lettre a et le motif $m = a^{p-1}b$ qui contient $p-1$ a et finit par un b . Dans l'algorithme, on va donc à chaque étape de la première boucle effectuer p itérations dans la seconde avant de se rendre compte que le motif n'est pas présent en comparant b et a . On a donc exactement $(n-p+1)p = \Theta(np)$ comparaisons et on retombe ainsi sur la complexité $O(np)$ pour ces exemples.

Ce qui va se passer dans une application usuelle de cet algorithme, c'est qu'au bout d'une ou deux comparaisons, on pourra invalider la position et passer à la suivante. On va alors avoir une complexité en $O(n+p)$ en considérant en plus la validation du motif dans le cas où il est présent. Ici $p \leq n$ donc $O(n+p) = O(n)$ mais c'est important de garder en tête cette complexité en $O(n+p)$ qu'on retrouvera car elle s'appliquera à des algorithmes où on effectue un prétraitement sur le motif pour l'appliquer ensuite sur plusieurs chaînes.

1.3 Algorithme de Boyer-Moore

Dans un premier temps, on va présenter la variante usuelle de cet algorithme appelée algorithme de Boyer-Moore-Horspool. On présentera ensuite l'algorithme de Boyer-Moore en tant que tel.


1.3.i Principe de Boyer-Moore-Horspool

Le principe de l'algorithme de Boyer-Moore-Horspool est d'effectuer une recherche du motif comme précédemment mais en partant de la fin. On va alors tenter de trouver des suffixes de plus en plus grand du motif. Si on trouve ainsi le motif, on renvoie la position. Sinon, c'est qu'on a lu dans s un mot de la forme xm' où m' est un suffixe strict de m mais xm' n'en est pas un. Si x n'est pas présent dans m , alors on peut relancer la recherche juste après x dans s . Si x est présent dans m , on peut relancer la recherche en alignant ce caractère avec sa position la plus à droite dans m .

■ **Remarque 17.2** Il faut tenir compte différemment du dernier caractère du motif, car il n'est pas utile de le réaligner. On considère alors, quand elle existe, l'occurrence précédente de ce caractère.

On obtient ainsi une stratégie de saut qui en cas d'échec relance la recherche plus loin.

Voici un premier exemple où on effectue une recherche de $abaa$ dans le mot $aabababbaa$. Cette stratégie a permis d'éviter une recherche inutile à partir de l'indice 1.



I.3.ii Implémentation par table de saut

Pour réaliser ces sauts, on construit une table `droite` indexée par Σ et telle que $\text{droite}[c]$ indique l'indice de l'occurrence la plus à droite dans le motif m du caractère c , en ignorant le dernier caractère du motif.

Ainsi, dans l'exemple précédent du motif `abaa`, on obtient la table suivante :

c	'a'	'b'	'c'	...
<code>droite[c]</code>	2	1	\emptyset	...

On a indiqué ici \emptyset quand un caractère de Σ n'est pas présent dans le motif, car il peut être présent dans s .

Cette table contient donc de l'ordre de $|\Sigma|$ éléments. On peut la réaliser par un tableau direct de taille $|\Sigma|$ étant donné un ordre d'énumération. On peut aussi la réaliser par un dictionnaire, ce qui est plus économique en espace si le motif contient peu de lettres différentes. On a choisi, pour des raisons pédagogiques, de considérer la numérotation ASCII naturelle associées au caractère de cette table.

```
let taille_alphabet = 256

let calcule_droite (motif:string) : int option array =
  (* Calcule le tableau droite associé au motif *)
  let droite = Array.make taille_alphabet None in
  let p = String.length motif in
  for i = 0 to p-2 do
    let j = p-2-i in
    let c = motif.[j] in
    if droite.(Char.code c) = None
    then droite.(Char.code c) <- Some j
  done;
  droite
```

Afin d'implémenter l'algorithme lui-même, il est nécessaire de faire des calculs élémentaires mais précis pour déterminer le saut à effectuer. Si à la position $i + j$ on a un échec après avoir lu le caractère c où $\text{droite}[c]$ contient la valeur k .

- Si $k = \emptyset$, c'est que le motif ne pourra jamais être trouvé tant que ce caractère c sera présent. On relance donc la recherche juste après à l'indice $i + j + 1$.

0	1	2	3	4	5	6	7	8
a	b	b	a	a	d	a	c	a
d	a	c	d	a	c			

- Si $k \geq j$, cela signifie que c est présent plus à droite dans le motif, donc aligner cette occurrence ne permettrait pas d'avancer la recherche. Rien ne nous permet de savoir si c est présent ou non ailleurs dans le motif, on relance alors prudemment la recherche en $i + 1$.

0	1	2	3	4	5	6	7	8
a	c	a	c	a	d	a	c	a
c	a	c						
	c	a	c					

- Sinon, on veut aligner ce c avec le caractère correspondant du motif, si on relance à l'indice i' , on souhaite ainsi avoir $i' + k = i + j$ donc $i' = i + j - k$.

```

exception Difference
exception Trouve of int

let recherche_BMH (motif:string) (droite:int option array)
  (chaine:string) : int option =
  let n = String.length chaine in
  let p = String.length motif in
  let i = ref 0 in
  try
    while !i <= n-p do
      try
        for j = p-1 downto 0 do
          if chaine.[!i+j] <> motif.[j]
          then begin
            let dec = match droite.(Char.code chaine.[!i+j]) with
              | None -> j+1
              | Some k when k < j -> j-k
              | _ -> 1 in
            i := !i + dec;
            raise Difference
          end
        done;
        raise (Trouve !i)
      with Difference -> ()
    done;
    None
  with Trouve k -> Some k

```

Ocaml

I.3.ii.a Correction

Tout d'abord, remarquons que la terminaison ne pose pas de questions dans la mesure où on le nouvel indice auquel on relance la recherche est toujours strictement plus grand que le précédent.

Au sujet de la correction, il suffit de s'assurer que les indices écartés correspondent nécessairement à des recherches infructueuses. Sans perte de généralité, on peut supposer que la recherche s'effectue depuis le premier indice de s . Comme seul les sauts d'au moins deux indices sont ceux pour lesquels il est nécessaire de faire une preuve, cela correspond au cas où $m = m_1cm_2dm_3x$ et $s = s_1cm_3s'$ avec c, d et x des caractères, $d \neq c$ et c non présent dans m_2dm_3 .

Ainsi, toute recherche démarrant à des indices inférieurs échouera systématiquement, au plus tard, en comparant le caractère c de cm_3 avec un caractère du motif dans m_2dm_3 donc

différent de c .

1.3.ii.b Complexité

Tout d'abord, on remarque que la table de saut se construit en $O(\max(|m|, |\Sigma|))$ pour un motif m sur un alphabet Σ .

Sans chercher à rentrer dans les détails, on peut raisonnablement penser **si l'alphabet contient assez de caractères** que les motifs auront peu de répétitions et qu'ainsi, les sauts seront presque toujours maximaux, ce qui permet d'obtenir de l'ordre de $\frac{n}{p}$ comparaisons où n est la longueur de la chaîne et p la longueur du motif.

Cependant, en pire cas, cet algorithme n'est pas meilleur que le précédent. Pour s'en convaincre, on va considérer un exemple proche de celui introduit par l'algorithme naïf. Si on cherche ba^{p-1} dans a^n à l'indice i , il est nécessaire d'attendre de comparer au caractère b pour constater un échec et devoir relancer l'algorithme à l'indice $i + 1$. On va donc faire ici aussi $(n - p + 1)p = \Theta(np)$ comparaisons.

La complexité temporelle en pire cas de Boyer-Moore-Horspool est donc de $O(np)$, même si, en pratique, elle est sous-linéaire.

■ **Remarque 17.3** Si l'alphabet contient peu de caractères, ce qui est le cas en particulier du binaire, il y a de grandes chances qu'on soit dans ce cas pire cas. Ainsi, Boyer-Moore-Horspool n'est pas adapté pour ce type de texte. ■

1.3.iii Principe de Boyer-Moore

Considérons le cas suivant de l'algorithme précédent : on cherche abbcabc dans cbacbbcab.

0	1	2	3	4	5	6	7	8	9
c	b	a	c	b	b	c	a	b	c
a	b	b	c	a	b	c			
a	b	b	c	a	b	c			
	a	b	b	c	a	b	c		

On remarque qu'en raison du fonctionnement de cet algorithme, on est forcé de faire de tous petits sauts et on est ramené à l'algorithme naïf. Cependant, après la première étape, on sait qu'on a lu un suffixe du motif bc qui est précédé d'un caractère a en sorte que bbc ne soit pas un suffixe du motif.

Il y a un autre endroit dans le motif où on peut trouver *bc avec * un autre caractère que a. On pourrait donc relancer la recherche en alignant cette occurrence de bc avec celle qu'on vient de lire. Cela revient à sauter directement à la dernière étape dans cet exemple :

0	1	2	3	4	5	6	7	8	9
c	b	a	c	b	b	c	a	b	c
a	b	b	c	a	b	c			
	a	b	b	c	a	b	c		
		a	b	b	c	a	b	c	

Pour pouvoir réaliser ce décalage, il est nécessaire de calculer une nouvelle table en parcourant le motif pour identifier de telles apparitions de suffixes.

On peut aller plus loin en considérant également le plus long préfixe du motif qui soit un suffixe du suffixe considéré. Par exemple, pour le motif bcabc on remarque que bc étant un préfixe, on peut effectuer un saut comme dans l'exemple suivant :

0	1	2	3	4	5	6	7	8
c	a	a	b	c	c	b	b	c
b	c	a	b	c				
		b	c	a	b	c		

I.3.iii.a Table des bons suffixes

■ **Note 17.3** Tout cela sera redéfini proprement plus tard dans le chapitre sur les langages. Je laisse cette partie en attendant pour que la présentation soit complète.

Il est nécessaire d'introduire des définitions précises pour formaliser la stratégie qu'on vient de présenter. Dans le contexte des langages, on parle plus souvent de mot que de chaîne de caractères, qui sont un type de données permettant de les représenter. Un mot sur l'alphabet Σ est donc une suite finie $a_1 \dots a_n$ de lettres dans l'alphabet. On note μ l'unique mot vide, c'est-à-dire ne contenant aucune lettre. L'ensemble des mots sur Σ est noté Σ^* . Si u et v sont des mots, uv est le mot obtenu par concaténation.

■ **Remarque 17.4** Σ^* muni de cette loi de composition a une structure proche de l'ensemble des entiers naturels \mathbb{N} muni de l'addition :

- on a : $\forall u, v, w \in \Sigma^*, u(vw) = (uv)w = uvw$, on dit que la loi est associative;
- elle possède un élément neutre $\mu : \forall u \in \Sigma^*, \mu u = u\mu = u$.

On dit alors que Σ^* est un **monoïde**. Cette structure très simple est cruciale en informatique.

Définition I.1 Soit $u, v \in \Sigma^*$, on dit que v est :

- un **suffixe** de u s'il existe $w \in \Sigma^*$ tel que $u = wv$
- un **préfixe** de u s'il existe $w \in \Sigma^*$ tel que $u = vw$

Lorsque $w \neq \mu$, on parle de suffixe ou de préfixe **propre**.

On dit que v est un **bord** de u lorsque v est suffixe et préfixe propre de u .

■ **Exemple 17.1** Soit $u = abacaba$. $abac$ est un préfixe de u , $caba$ un suffixe et aba un bord.

Définition I.2 Soit $x = x_1 \dots x_n$ et u, v deux suffixes **distincts** de x . On dit que u et v sont des suffixes **disjoints** quand on est dans l'un des cas suivants :

- $u = x$
- $v = x$
- $u \neq x, v \neq x$ et $x_{|x|-|u|} \neq x_{|x|-|v|}$.

Des suffixes disjoints sont donc des suffixes précédés par des lettres différentes dans x . On définit de même la notion de préfixes disjoints.

On considère un motif $x = x_0 \dots x_{n-1}$ et on va reprendre, en la précisant, la description précédente. Se faisant, on va construire une table **bonsuffixe** appelée la **table des bons suffixes** du motif x et telle que, pour $i \in \llbracket 0, n-1 \rrbracket$, $\text{bonsuffixe}[i]$ donne le nombre de positions dont on doit décaler le motif vers la droite pour relancer la recherche après la lecture du suffixe $x_{i+1} \dots x_{n-1}$.

Supposons qu'on vient de lire avec succès un suffixe propre u . Ainsi $x = x_0 \dots x_i u$ et on vient de lire dans la chaîne où on effectue la recherche au avec $a \neq x_i$.

- Soit il existe un autre suffixe buv de x où $b \neq x_i$ et alors on appelle bon suffixe pour u un tel suffixe de longueur minimale et on pose alors $\text{bonsuffixe}[i] = |v|$

- Sinon, on cherche v de longueur minimale tel que x soit un suffixe de uv et on pose également $\text{bonsuffixe}[i] = |v|$.

On remarque que si x est suffixe de uv et qu'on a également buv' suffixe de x , alors $|uv| = |u| + |v| \geq |x| \geq |buv'| \geq |u| + |v'|$ donc $|v| \geq |v'|$ ce qui permet de considérer le plus petit v sur l'ensemble des cas.

I.3.iii.b Table des suffixes

Afin de calculer efficacement `bonsuffixe` on va commencer par calculer la table des suffixes du motif, il s'agit de la table `suffixe` où $\text{suffixe}[i]$ contient la longueur du plus long suffixe de x de la forme $x_j \dots x_i$. Ainsi, si on note S_i les suffixes de cette forme, on a :

$$\text{suffixe}[i] = \begin{cases} 0 & \text{si } S_i = \emptyset \\ \max \{ |s| \mid s \in S_i \} & \text{sinon} \end{cases}$$

Nécessairement, $\text{suffixe}[n-1] = n$ car x convient.

■ **Exemple 17.2** Pour $x = bcabc$ on a :


i	0	1	2	3	4
<code>suffixe[i]</code>	0	2	0	0	5

et pour $x = abbabba$:

i	0	1	2	3	4	5	6
<code>suffixe[i]</code>	1	0	0	4	0	0	7

Il est possible de construire `suffixe` avec un simple parcours linéaire en tirant partie de l'information déjà calculée. Pour cela, on va remplir `suffixe` de droite à gauche.

A tout moment, on va conserver le meilleur suffixe rencontré, c'est-à-dire celui pour lequel on est allé le plus loin à gauche avant d'avoir un échec de comparaison. On note s la position la plus à droite de ce suffixe et k sa longueur, il s'agit donc de $u = x_{s-k+1} \dots x_s$ et il y a eu un échec de comparaison en x_{s-k} . Par définition de `suffixe` on a $\text{suffixe}[s] = k$. Le mot x s'écrit alors :




Ce qu'on peut représenter schématiquement ainsi :

	$s - k$	s	$n - k - 1$	$n - 1$
	a	u	b	u

Maintenant, on considère la position $s - i$ où $s > s - i > s - k$, cela signifie qu'on cherche un suffixe depuis une position interne au mot u de gauche. Le point clé permettant d'obtenir un algorithme linéaire est de remarquer que la situation est la même que dans le mot u de droite. Or, comme on procède de gauche à droite, on a déjà calculé la valeur correspondante $\text{suffixe}[n-1-i]$. Là, on a deux cas :

- soit quand on a cherché le plus grand suffixe à partir de $n - i$, on s'est heurté à une erreur de comparaison à la position $n - k$. Dans ce cas, on a $\text{suffixe}[n-1-i] = k - i$ et on peut regarder, en partant de la position $s - k$, si on peut prolonger le suffixe finissant à la position $s - i$.



Pour effectuer ce prolongement, il suffit de comparer, caractère par caractère, vers la gauche en partant de la position $s - k$. On aboutira alors à une nouvelle position du suffixe finissant le plus à gauche qui finira en $s - i$.



Remarquons qu'il n'est pas nécessaire que $s - i - l \neq s - k$. C'est-à-dire que même si a ne permet pas de prolonger le suffixe déduit de la position $n - i$, on considère tout de même que la nouvelle position de référence est $s - i$. On en déduit également la valeur $\text{suffixe}[s-i] = l$.

- soit $\text{suffixe}[n-1-i] = p \neq k - i$ et alors
 - soit $p < k - i$, on a alors pour ce suffixe un échec dans u , ce qui limite de la même manière la valeur en $s - i$: $\text{suffixe}[s-i] = p$.
 - soit $p > k - i$, donc on doit avoir un b après avoir le suffixe dans u depuis $s - i$ pour le prolonger, or, c'est impossible car il y a un $a \neq b$. Ainsi, le suffixe est limité par u : $\text{suffixe}[s-i] = k - i$.

Il reste à traiter le cas où $s - i \leq s - k$, ce qui revient à considérer qu'on a dépassé le précédent suffixe pouvant apporter une information. On procède donc naïvement pour trouver le plus grand suffixe depuis cette position.

On en déduit l'implémentation suivante :

```
let calcule_suffixe (x:string) : int array =
  (* Prend en entrée un mot non vide x et renvoie son tableau de suffixe *)
  let n = String.length x in
  let suffixe = Array.make n (-1) in
  suffixe.(n-1) <- n;
  let plus_a_gauche = ref (n-1) in
  let depart = ref (-1) in

  for j = n-2 downto 0 do
    if !plus_a_gauche < j
      && suffixe.(n-1-!depart+j) <> j - !plus_a_gauche
    then suffixe.(j) <- min suffixe.(n-1-!depart+j) (j - !plus_a_gauche)
    else begin
      plus_a_gauche := min j !plus_a_gauche;
      depart := j;
      while !plus_a_gauche >= 0
        && x.[!plus_a_gauche] = x.[n-1-j + !plus_a_gauche] do
          plus_a_gauche := !plus_a_gauche - 1
      done;
      suffixe.(j) <- !depart - !plus_a_gauche
    end
```

```
done;
suffixe
```

■ **Remarque 17.5** Cette implémentation est optimisée par rapport à la description précédente en calculant directement sans introduire i ou k , et en fusionnant deux cas qui reviennent à dupliquer du code.

On donne ici le code maladroit qui correspond à la traduction exacte de la description précédente :

```
let calcule_suffixe_rep (x:string) : int array =
(* Prend en entrée un mot non vide x et renvoie son tableau de suffixe *)
let n = String.length x in
let suffixe = Array.make n 0 in
suffixe.(n-1) <- n;
let plus_a_gauche = ref (n-1) in
let depart = ref (-1) in

for j = n-2 downto 0 do
  if !plus_a_gauche < j
  then begin
    (* on a j = depart - i avec *)
    let i = !depart - j in
    (* et plus_a_gauche = depart - k avec *)
    let k = !depart - !plus_a_gauche in
    if suffixe.(n-1-i) <> k-i
    then suffixe.(j) <- min suffixe.(n-1-i) (k-i)
    else begin
      depart := j;
      while !plus_a_gauche >= 0
        && x.[!plus_a_gauche] = x.[n-1-j + !plus_a_gauche] do
        plus_a_gauche := !plus_a_gauche - 1
      done;
      suffixe.(j) <- !depart - !plus_a_gauche
    end
  end else begin
    plus_a_gauche := j;
    depart := j;
    while !plus_a_gauche >= 0
      && x.[!plus_a_gauche] = x.[n-1-j + !plus_a_gauche] do
      plus_a_gauche := !plus_a_gauche - 1
    done;
    suffixe.(j) <- !depart - !plus_a_gauche
  end
done;
suffixe
```

Ocaml

On remarque que dans ce code, `plus_a_gauche` ne peut que diminuer, on effectue donc au plus n itérations dans la boucle `while` pour tout l'algorithme. Donc, en considérant la boucle `for`, on effectue au plus $2n$ comparaisons de caractères : au plus une pour chaque itération de la boucle `for` pour voir si on entre dans le `while`, puis en tout au plus n avant de sortir du `while`.

L'algorithme qu'on a obtenue est bien linéaire en $|x|$.

1.3.iii.c Obtention de bonsuffixe à partir de suffixe

On reprend maintenant le calcul de `bonsuffixe[i]` dans le mot $x = x_0 \dots x_{n-1}$.

On cherche à obtenir des suffixe de la forme buv de x où $b \neq x_i$ et $u = x_{i+1} \dots x_{n-1}$ est un suffixe de x . Mais si $\text{suffixe}[k] = n - 1 - i$ cela signifie que ce suffixe est exactement u et qu'il est soit préfixe, soit précédé d'une lettre différente de x_i , sinon $n - 1 - i$ ne serait pas maximal.

On a donc

$$\begin{aligned}\text{bonsuffixe}[n - 1 - i] &= \min \{ n - 1 - k \mid \text{suffixe}[k] = n - 1 - i \} \\ &= n - 1 - \max \{ k \mid \text{suffixe}[k] = n - 1 - i \}\end{aligned}$$

On remarque qu'on peut ainsi faire croître k et poser :

$$\text{bonsuffixe}[n - 1 - \text{suffixe}[k]] = n - 1 - k$$

On a aura alors naturellement, à la fin de la boucle, la valeur minimale placée en dernier.

Reste à considérer les valeurs non remplies ainsi dans le tableau `bonsuffixe`. Elles correspondent aux positions i telles qu'il n'existe pas de suffixe de la forme buv . On doit donc chercher un mot uv de longueur minimale dont x est suffixe. Mais u étant un suffixe de x , cela revient à considérer les bords de x . La table `suffixe` permet également de détecter les bords : si $x_0 \dots x_k$ est un bord c'est que $\text{suffixe}[k] = k + 1$.

Soit $k < n - 1$ maximal vérifiant cette condition. Pour tout $u = x_{i+1} \dots x_n$ suffixe de x , pour qu'il ait $x_0 \dots x_k$ comme suffixe, il faut qu'il soit strictement plus long (sinon on est dans le cas précédent), donc que $n - i > k + 1 \iff i < n - 1 - k$. Dans ce cas, x est alors suffixe de uv où $v = x_{k+1} \dots x_{n-1}$ donc $|v| = n - 1 - k$. Les k plus petits ne pourront alors que faire augmenter $|v|$, on peut ainsi poser `bonsuffixe[i] = n - 1 - k`.

On en déduit un remplissage en parcourant les k dans l'ordre décroissant de $n - 2$ à 0, tout en maintenant l'indice i de la prochaine valeur à remplir dans `bonsuffixe`. Dès qu'on détecte un bord, on place $n - 1 - k$ jusqu'à ce que $i \geq n - 1 - k$.

En sortie de boucle, il est possible que $i < n$ donc qu'il reste des valeurs à remplir. On remarque dans ce cas là que pour que x soit un suffixe de uv il faut que $v = x$. On a donc pour ces valeurs restantes `bonsuffixe[i] = n`.

Comme ce second cas est toujours plus long que le premier quand les deux se produisent en i , on implémente successivement les remplissages de sorte à obtenir la valeur minimum. On en déduit le programme suivant :

```
let calcule_bonsuffixe (x:string) : int array =
  (* Prend en entrée un mot non vide x et renvoie son tableau de suffixe *)
  let n = String.length x in
  let suffixe = calcule_suffixe x in
  let bonsuffixe = Array.make n n in

  let suivant = ref 0 in
  for k = n-2 downto 0 do
    if suffixe.(k) = k+1 (* c'est un bord *)
    then begin
      for i = !suivant to n-2-k do
        bonsuffixe.(i) <- n-1-k
      done;
      suivant := n-1-k
    end
  done;

  for k = 0 to n-2 do
```

```

bonsuffixe.(n-1-suffixe.(k)) <- n-1-k
done;

bonsuffixe

```

Il est facile de constater que cet algorithme est de complexité temporelle linéaire en $|x|$.

I.3.iii.d Algorithme de Boyer-Moore

On incorpore naturellement la table précédente à l'algorithme de Boyer-Moore en choisissant le meilleur décalage entre cette table et la stratégie précédente.

```

let recherche_BM (motif:string)
  (droite:int option array) (bonsuffixe:int array)
  (chaine:string) : int option =
  let n = String.length chaine in
  let p = String.length motif in
  let i = ref 0 in
  try
    while !i <= n-p do
      try
        for j = p-1 downto 0 do
          if chaine.[!i+j] <> motif.[j]
          then begin
            let dec = match droite.(Char.code chaine.[!i+j]) with
              | None -> j+1
              | Some k when k < j -> j-k
              | _ -> 1 in
            i := !i + max dec bonsuffixe.(j);
            raise Difference
          end
        done;
        raise (Trouve !i)
      with Difference -> ()
    done;
    None
  with Trouve k -> Some k

```

Supposons que le motif est de longueur p , que la chaîne dans laquelle on recherche est de longueur n et que la taille de l'alphabet est une constante indépendante des entrées. La première partie de l'algorithme consiste à construire les tables de sauts, comme on l'a vu, elle est en complexité en temps et en espace en pire cas en $O(p)$.

On admet que l'algorithme Boyer-Moore complet, étant donné les deux tables de saut et d'autres modifications mineures non présentées ici, est en complexité temporelle en pire cas en $O(n)$.

Il est assez raisonnable de penser que soit $p \leq n$ quand on effectue une recherche, soit on compte chercher un même motif dans plusieurs textes et on réutilise ainsi les tables de sauts. Il n'est donc pas forcément très pertinent de parler de la complexité globale de l'algorithme, mais lorsqu'on le fait, on dit qu'elle est en $O(p + n)$. On rappelle ici le rôle de l'addition dans les complexités qui fait référence à la succession de deux traitements, un en $O(p)$ suivi d'un en $O(n)$.

I.4 Algorithme de Rabin-Karp


I.4.i Principe

L'algorithme de Rabin-Karp est un algorithme de recherche d'un motif dans un texte qui utilise une notion d'empreinte pour déterminer, en temps constant, si il est probable que la position actuelle corresponde à une occurrence du motif.

Pour cela, si on cherche un motif de longueur p sur l'alphabet Σ , on considère une **fonction de hachage** $h : \Sigma^p \rightarrow X$. Les éléments de l'ensemble X sont appelés des empreintes et on suppose que l'égalité entre deux empreintes se vérifie en temps constant contrairement à l'égalité dans Σ^p qui se vérifie en $O(p)$ dans le pire des cas. Le plus souvent, on choisit pour X un type entier machine.

■ **Note 17.4** Sûrement mettre ici des renvois vers la partie portant le plus sur la notion de fonction de hachage pour la définition la plus complète. ■

Bien qu'il soit normalement aussi coûteux de calculer l'image par h d'une sous-chaîne de longueur p que de tester l'égalité entre cette sous-chaîne et le motif, le point essentiel de l'algorithme de Rabin-Karp est d'utiliser une fonction de hachage permettant un calcul incrémental en temps constant :



Ici, on considère donc, pour $a, b \in \Sigma$, une fonction de mise à jour $\delta_{a,b} : X \rightarrow X$ telle que pour tout $c_2, \dots, c_p \in \Sigma$ on ait $\delta_{a,b}(h(ac_2 \dots c_p)) = h(c_2 \dots c_p b)$.

L'algorithme de Rabin-Karp procède alors ainsi pour chercher m de longueur p dans la chaîne $s = c_0 \dots c_{n-1}$ où $n \geq p$:

- calcul de $e_m = h(m)$ et $e = h(c_0 \dots c_{p-1})$.
- Pour i allant de 0 à $n - p$:
 - ★ Si $e_m = e$, on renvoie un succès pour la recherche à la position i si $m = c_i \dots c_{i+p-1}$
 - ★ si $i < n - p$ on met à jour l'empreinte $e \leftarrow \delta_{c_i, c_{i+p}}(e)$.

La complexité temporelle liée à la gestion des empreintes est donc en $O(n + p) = O(n)$ car $n \geq p$. Par contre, pour calculer la complexité liée à la recherche $m = c_i \dots c_{i+p-1}$, il est nécessaire d'estimer la proportion de faux positifs, c'est-à-dire de positions i telles que $e_m = e$ mais $m \neq c_i \dots c_{i+p-1}$. On va voir dans la partie suivante qu'on peut supposer qu'elle est négligeable, ce qui permet de considérer que l'algorithme de Rabin-Karp est linéaire.

I.4.ii Choix d'une fonction de hachage

Réaliser une bonne fonction de hachage est une question très complexe qui dépasse le cadre du cours d'informatique de MPI. Cependant, il est possible de réaliser ici une fonction de hachage répondant aux contraintes de Rabin-Karp assez facilement.

Pour cela, on considère que les caractères sont des entiers compris entre 0 et 255, ce qui correspond au type des caractères non signés sur un octet. On peut alors identifier une chaîne de longueur p avec un nombre entre 0 et $r^p - 1$ où $r = 2^8$, on note ainsi

$$P(c_0 \dots c_{p-1}) = \sum_{i=0}^{p-1} c_i r^{p-1-i} = c_0 r^{p-1} + c_1 r^{p-2} + \dots + c_{p-1}$$

On considère de plus un entier premier q et on pose $h(s) = P(s) \bmod q$ c'est-à-dire le reste de $P(s)$ dans la division euclidienne par q . On peut ainsi définir $\delta_{a,b}(e) = (r(e - ar^{p-1}) + b) \bmod q$.

Si on précalcule $r^{p-1} \bmod q$ il suffit d'un nombre d'opération constant, et indépendant de p , pour calculer la nouvelle empreinte à l'aide de $\delta_{a,b}$.

Le point essentiel est alors de déterminer un nombre premier q tel qu'il soit peu probable d'obtenir des faux positifs. Une analyse mathématique permet d'affirmer que chaque élément de $[|0; q - 1|]$ a de l'ordre de $\frac{r^p}{q}$ antécédents par h . Ainsi, si on choisit deux chaînes aléatoirement dans Σ^p , il y aura collision avec probabilité proche de $\frac{1}{q}$. En considérant q proche de la taille maximale pour le type entier considéré, on minimise donc cette probabilité.

■ Remarque 17.6 On peut également s'intéresser à des nombres q pour lesquels le modulo soit rapide à calculer. Un exemple classique est $q = 2^{31} - 1$ car on peut déduire la division euclidienne de a par q de l'écriture de a en base 2^{31} . En effet, si $a = \sum_{k=0}^n a_k 2^{31k}$ comme $2^{31} - 1 | 2^{31k} - 1$ pour $k \geq 1$, on a $2^{31k} \equiv 1 \pmod{q}$ et ainsi $a \equiv \sum_{k=0}^n a_k \pmod{q}$. On remarque que $a_k = (a >> 31k) \& 2^{31}$, on a alors soit $a_k < q$ et alors $a_k \bmod q = a_k$, soit $a_k = q$ et $a_k \bmod q = 0$. Il suffit donc de faire un masquage pour obtenir directement $a_k \bmod q = (a >> 31k) \& q$.

On obtient alors le programme suivant :

```
OCaml
let rec fastmod a =
  let s = ref 0 in
  let x = ref a in
  let q = 0x7fffffff in
  while !x > 0 do
    s := !s + (!x land q);
    x := !x lsr 31
  done;
  if !s > q
  then fastmod !s
  else if !s = q
  then 0
  else !s
```

Le programme suivant implémente naïvement les calculs de h et de $\delta_{a,b}$:

```
OCaml
let hash r q s =
  let p = ref 1 in
  let e = ref 0 in
  for i = String.length s - 1 downto 0 do
    e := (!p * (Char.code s.[i]) + !e) mod q;
    p := (r * !p) mod q
  done;
  !e

let delta r q rp a b e = (* rp est  $r^{(p-1)} \bmod q$  *)
  (r * (e - rp * (Char.code a)) + Char.code b) mod q
```

1.4.iii Implémentation

Une implémentation directe de l'algorithme de Rabin-Karp est donnée dans le programme qui suit. On se sert ici du caractère paresseux du `&&` pour n'effectuer le test coûteux d'égalité des

chaînes qu'en cas d'égalité des empreintes.

```
exception Trouve of int

let rabin_karp m s =
  let n = String.length s in
  let p = String.length m in
  let r = 256 in
  let q = 0x7fffffff in (* 2^(31)-1 *)
  let rp = pow r (p-1) q in
  let me = hash r q m in
  let e = ref (hash r q (String.sub s 0 p)) in
  try
    for i = 0 to n-p+1 do
      if me = !e && m = String.sub s i p
      then raise (Trouve i);
      if i+p < n then e := delta r q rp s.[i] s.[i+p] !e
    done; None
  with Trouve k -> Some k
```

OCaml

Si on suppose qu'il est improbable d'obtenir un faux positif, il est possible de renvoyer un succès dès que les empreintes sont égales. L'avantage d'une telle version est alors d'être un algorithme sans retour sur les données. C'est-à-dire qu'il n'est pas nécessaire de garder en mémoire ou de réaccéder à un caractère.

1.4.iv L'algorithme originel de Rabin et Karp

Si on regarde l'article originel de Rabin et Karp décrivant cette méthode, on peut être étonné du fait que la méthode précédemment décrite était considérée comme déjà connue dans la littérature par les auteurs. En fait, ce qu'ils décrivent et annoncent comme étant novateur est l'utilisation d'un algorithme probabiliste en choisissant aléatoirement une fonction de hachage à chaque lancement de l'algorithme. En pratique, il s'agit de choisir aléatoirement un nombre premier q parmi un ensemble précalculé de nombres premiers.

L'algorithme que l'on vient de décrire a un pire cas qui est très improbable car on considère que la probabilité d'un faux positif est à peu près de $1/q$, donc moins de $5 \cdot 10^{-10}$ pour $q = 2^{31} - 1$. Le problème ici est la notion de probabilité sur les entrées : est-on certain que l'algorithme recevra une entrée choisie uniformément ? Rabin et Karp parlent d'un *adversaire intelligent* qui aurait connaissance de la fonction de hachage choisie pour produire des entrées en pire cas. On pourrait ainsi imaginer une *attaque* sur serveur effectuant une recherche avec Rabin-Karp suite à l'entrée d'un utilisateur. Un adversaire pourrait construire une entrée en pire cas et tenter de surcharger le serveur en l'effectuant de manière répétée.

Pour bien mettre en lumière ce phénomène, nous allons ici construire, dans un cas très simple de fonction de hachage, une telle chaîne problématique. Pour cela, considérons la fonction de hachage précédemment décrite dans le cas de motif de taille 2, avec Σ contenant les lettres de a à z , $r = 26$ et $q = 17$. On considère une recherche du motif aa dont l'empreinte est 0, la même que celle des chaînes ar et ra . On peut donc considérer la chaîne $arar\dots ar$ qui produira un faux positif à chaque étape.

■ **Remarque 17.7** Détail des calculs. Ici on associe à a la valeur 0, ..., à z la valeur 25. On a donc

$$h(aa) = (0 \times 26 + 0) \mod 17 = 0$$

$$h(ar) = (0 \times 26 + 17) \mod 17 = 0$$

$$h(ra) = (17 \times 26 + 0) \mod 17 = 0$$

L'empreinte reste ainsi nulle tout au long de l'algorithme de Rabin-Karp et on a un faux positif à chaque itération.

II Compression

II.1 Principe

On s'intéresse ici à la compression parfaite d'un texte, c'est-à-dire, étant donné un alphabet fixé Σ , qu'on cherche à réaliser un couple de fonctions $comp, dec : \Sigma^* \rightarrow \Sigma^*$ telles que :

- pour tout mot $m \in \Sigma^*$, $dec(comp(m)) = m$
- pour la plupart des mots m qui correspondent aux données qu'on cherche à compresser, $|comp(m)| < |m|$.

■ **Remarque 17.8** Le fait que $dec \circ comp = id_{\Sigma^*}$ implique, comme on a pu le voir dans le cours de mathématique, que $comp$ est injective : deux mots différents ont nécessairement des images distinctes.

Si A et B sont deux ensembles finis tels que $|A| < |B|$, il n'existe pas de fonction injective de A dans B . Ainsi, si on note L_n les mots de Σ^* de longueur au plus n , il ne peut exister de fonction injective de L_n dans L_m où $n < m$.

Autrement dit : il est impossible d'espérer pouvoir compresser toutes les données de L_n . Si certains mots vont diminuer de longueur après compression, d'autres vont nécessairement augmenter.

Tout l'enjeu des algorithmes de compression parfaites est alors de diminuer les longueurs des mots qui nous intéressent. Par exemple, si on s'intéresse à des mots issus de textes en français, il est plus important d'arriver à compresser une phrase comme "ceci est un texte" plutôt qu'une suite de caractères non signifiante comme "c2#\$%1ajdn //@#3d!fn".

II.2 Algorithme d'Huffman

La définition et la construction de l'arbre de Huffman ont été présentées au paragraphe Algorithme d'Huffman - Compression. On va s'intéresser ici au processus complet permettant de compresser et décompresser des fichiers avec cet algorithme.

II.2.i Calcul de la table d'occurrences

Par souci d'efficacité, on calcule une table d'occurrences pour l'ensemble des valeurs d'octets entre 0 et 255. Il suffit alors de parcourir le fichier pour incrémenter les valeurs correspondant aux octets lus.

```
OCaml
let table_occurrences nomdefichier =
  let fichier = open_in_bin nomdefichier in
  let occurrences = Array.make 256 0 in
  begin
    try
      while true do
        let c = input_byte fichier in
        occurrences.(c) ← occurrences.(c) + 1;
    done
```

```

with End_of_file -> ()
end;
close_in fichier;
occurrences

```

II.2.ii Sérialisation de l'arbre de Huffman

Afin de décompresser, il est nécessaire de connaître l'arbre de Huffman donnant le code préfixe. Pour cela, il faut stocker cet arbre dans le fichier comme une série d'octet, on parle de *sérialisation*. Cette notion sera prolongée dans le chapitre FIXME.

On choisit ici la représentation récursive `repr(a)` de l'arbre `a` définie ainsi :

- Si `a = Noeud(g,d)`, `repr(a) = 0 repr(g) repr(d)`
- Si `a = Feuille(c)`, `repr(a) = 1 c.`

■ **Exemple 17.3** Si `a = Noeud(Feuille 42, Noeud(Feuille 16, Feuille 64))`, on obtient la suite d'octets : `0 1 42 0 1 16 1 64.`

La lecture et l'écriture de la sérialisation s'effectue alors simplement par récurrence :

```

let rec output_arbre f a =
  match a with
  | Noeud (x, y) -> begin
    output_byte f 0;
    output_arbre f x;
    output_arbre f y
  end
  | Feuille c -> begin
    output_byte f 1;
    output_byte f c
  end

let rec input_arbre f =
  let code = input_byte f in
  match code with
  | 0 -> let g = input_arbre f in
    let d = input_arbre f in
    Noeud(g,d)
  | _ -> Feuille (input_byte f)

```

Ocaml

II.2.iii Écriture dans un fichier un bit à la fois

■ **Note 17.5** À déplacer éventuellement dans une partie spécifique sur la gestion de fichiers.

Le propre de l'algorithme de Huffman est d'associer à chaque caractère un codage binaire de longueur variable. Afin de pouvoir écrire ce codage dans un fichier, il est nécessaire de grouper les bits par paquet de huit (octet en français, byte en anglais).

Ainsi, par exemple, si on a le codage suivant :

c	'a'	'b'	'c'
code(c)	0	100	101

et qu'on doit encoder "abbaca", on obtient le mot binaire `010010001010` qu'on complète avec des 0 à la fin et qu'on sépare en octets : `01001000 10100000`. On obtient donc les deux octets, convertis en décimal, 72 et 160. Ce sont eux qu'on va écrire dans un fichier.

Une technique usuelle pour cela est de garder un accumulateur qui correspond à l'octet en train d'être construit ainsi que le nombre de bits qui ont été accumulé. Dès qu'on accumulé 8 bits, on peut construire l'octet, l'écrire dans le fichier, puis reinitialiser ces variables.

Quand on rajoute un bit b à l'accumulateur, on veut passer de $acc = b_1 \dots b_k$ à $b_1 \dots b_k b = 2acc + b$.

On en déduit l'implémentation assez directe suivante :

```
type out_channel_bits = {
  o_fichier : out_channel;
  mutable o_accumulateur : int;
  mutable o_bits_accumules : int
}

let open_out_bits fn =
  { o_fichier = open_out_bin fn; o_accumulateur = 0; o_bits_accumules = 0 }

let output_bit f b =
  if f.o_bits_accumules = 8
  then begin
    output_byte f.o_fichier f.o_accumulateur;
    f.o_accumulateur <- 0;
    f.o_bits_accumules <- 0
  end;
  if b
  then f.o_accumulateur <- f.o_accumulateur + 1 lsl f.o_bits_accumules;
  f.o_bits_accumules <- 1 + f.o_bits_accumules
```

Il reste à traiter la question des zéros finaux, si l'accumulateur contient k bits au moment de la fermeture du fichier, où $0 < k < 8$, il faut ajouter $8 - k$ zéros. On appelle cela du *padding* de l'anglais pour rembourrage. Ici, cela correspond à faire un décalage binaire vers la gauche d'autant (*shift left* en anglais). Comme il sera nécessaire de se souvenir que ces zéros ne sont pas significants à la lecture, on rajoute un octet final contenant cette valeur k .

On obtient alors la fonction de fermeture de fichier suivante :

```
let close_out_bits f =
  if f.o_bits_accumules = 0
  then output_byte f.o_fichier 0
  else begin
    let padding = 8 - f.o_bits_accumules in
    output_byte f.o_fichier (Int.shift_left f.o_accumulateur padding);
    output_byte f.o_fichier padding
  end;
  close_out f.o_fichier
```

■ **Remarque 17.9** Une autre possibilité consiste à ajouter un entier décrivant la taille des données non compressées. C'est d'ailleurs parfois un problème avec les formats car si la taille est stockée sur 4 octets cela limite la taille d'un fichier pouvant être compressé.

Pour la lecture, on procède de même en faisant attention à deux points :

- on va lire les bits dans l'octet de la gauche vers la droite, c'est-à-dire du bit de poids le plus fort au bit de poids le plus faible. Ainsi, si l'accumulateur contient $acc = b_1 \dots b_8$, il suffit de faire un *et bit à bit* avec $b10000000=0x80=128$ pour obtenir $acc \& 0x80 = b_1 0 \dots 0$

donc un nombre qui vaut 0 si et seulement si $b_1 = 0$. Après avoir effectué cette lecture, il suffit de décaler vers la gauche en multipliant l'accumulateur par 2 : $2acc = b_2 \dots b_8 0$.

- on doit tenir compte des zéros finaux, pour ça, on a besoin de savoir qu'on est en train de lire le dernier caractère du fichier. On calcule donc la taille du fichier à son ouverture et on test si l'octet lu est l'avant-dernier, auquel cas on lit le dernier octet et on diminue d'autant le nombre de bits significants dans l'accumulateur.

On obtient alors le programme suivant pour la lecture :

```
type in_channel_bits = {
  i_fichier : in_channel;
  mutable i_accumulateur : int;
  mutable i_bits_accumules : int;
  i_taille : int
}

let open_in_bits fn =
  let fichier = open_in_bin fn in
  { i_fichier = fichier;
    i_accumulateur = 0; i_bits_accumules = 0; i_taille = in_channel_length fichier }

let input_bit f =
  if f.i_bits_accumules = 0
  then begin
    f.i_accumulateur <- input_byte f.i_fichier;
    f.i_bits_accumules <- 8;
    if pos_in f.i_fichier = f.i_taille - 1
    then begin
      let pad = input_byte f.i_fichier in
      f.i_bits_accumules <- f.i_bits_accumules - pad
    end
  end;
  let bit = f.i_accumulateur mod 2 = 1 in
  f.i_accumulateur <- f.i_accumulateur / 2;
  f.i_bits_accumules <- f.i_bits_accumules - 1;
  bit

let close_in_bits f = close_in f.i_fichier
```

Ocaml

II.2.iv Compression d'un octet

Pour pouvoir compresser un octet, il est nécessaire d'obtenir le chemin qui mène jusqu'à la feuille dont il est l'étiquette dans l'arbre de Huffman. Pour cela, on commence par calculer l'ensemble des chemins de l'arbre de Huffman sous forme d'une table à 256 entrées qui contient le chemin associé à un octet s'il est présent dans l'arbre ou un chemin vide sinon. On parlera de représentation plate de l'arbre de Huffman.

Il suffit de faire un parcours exhaustif de l'arbre (FIXME référence aux parcours d'arbres) pour réaliser cette table :

```
let chemins a =
  let a_plat = Array.make 256 [] in
  let rec parcours a chemin =
    match a with
    | Noeud (g, d) ->
      parcours g (false::chemin);
```

Ocaml

```

parcours d (true)::chemin)
| Feuille c -> a_plat.(c) <- List.rev chemin
in parcours a []; a_plat

```

Afin de compresser un octet, on va donc aller lire le chemin dans cette table puis écrire le mot binaire correspondant grâce aux fonctions d'écriture bit à bit :

```

OCaml let compresse_byte f a_plat c =
let rec output_bool_list l =
  match l with
  | t::q -> Bitpacking.output_bit f t; output_bool_list q
  | [] -> ()
in output_bool_list a_plat.(c)

```

■ **Remarque 17.10** A chaque fois qu'on va compresser un octet, on va parcourir la liste correspondant à son chemin. Comme les chemins les plus longs sont les moins fréquents, cela ne pose pas vraiment de problèmes.

Cependant, il est possible d'optimiser cela en ne stockant pas le chemin mais la fonction d'écriture elle-même. Ainsi, on ne va plus stocker des listes de booléens mais des fonctions du type `Bitpacking.out_channel_bit -> unit` qui vont réaliser l'écriture compressé de l'octet correspondant.

Au cours du parcours de l'arbre, on maintient une fonction correspondant à l'écriture du préfixe du chemin `chemin`. Si on l'appel est effectué sur un noeud, on remplace `chemin` par la fonction qui appelle `chemin` puis écrit le bit correspondant au côté gauche ou droit.

Cela correspond au programme suivant :

```

OCaml let chemins_continuation a =
let a_plat = Array.make 256 (fun _ -> ()) in
let rec parcours a chemin =
  match a with
  | Noeud (g, d) ->
    parcours g (fun f -> chemin f; Bitpacking.output_bit f false);
    parcours d (fun f -> chemin f; Bitpacking.output_bit f true)
  | Feuille c -> a_plat.(c) <- chemin
in parcours a (fun _ -> ()); a_plat

let compresse_byte_continuation f a_plat c =
  a_plat.(c) f

```

Cette représentation des chemins partiels par des fonctions est très classique dans le style de programmation fonctionnelle par passage de continuations.

II.2.v Décompression d'un octet

Pour décompresser un octet, il suffit de parcourir l'arbre de Hufmann en lisant bit à bit le fichier compressé en descendant à gauche ou à droite selon que le bit lu soit 0 ou non. Dès qu'on arrive sur une feuille, on écrit dans le nouveau fichier le caractère correspondant.

```

OCaml let rec decomprese_byte f a =
  match a with
  | Feuille c -> c
  | Noeud(g,d) ->

```

```
decompresse_byte f (if Bitpacking.input_bit f then d else g)
```

II.2.vi Compression et décompression de fichiers

En mettant bout à bout l'ensemble des fonctions, on obtient la fonction suivante qui réalise la compression complète d'un fichier :

```
let compresse_fichier nom_in nom_out =
  let occ = table_occurrences nom_in in
  let a = construit_arbre occ in
  let f_out = Bitpacking.open_out_bits nom_out in
  output_arbre f_out.o_fichier a;
  let a_plat = chemins a in
  let f_in = open_in_bin nom_in in
  begin
    try
      while true do
        let c = input_byte f_in in
        compresse_byte f_out a_plat c
      done
    with End_of_file -> ()
  end;
  close_in f_in;
  Bitpacking.close_out_bits f_out
```

OCaml

On obtient de même la fonction de décompression suivante :

```
let decompresse_fichier nom_in nom_out =
  let f_in = Bitpacking.open_in_bits nom_in in
  let a = input_arbre f_in.i_fichier in
  let f_out = open_out_bin nom_out in
  begin
    try
      while true do
        let c = decompresse_byte f_in a in
        output_byte f_out c
      done
    with End_of_file -> ()
  end;
  Bitpacking.close_in_bits f_in;
  close_out f_out
```

■ **Exemple 17.4** En compressant ainsi l'intégrale de Proust, on passe de 7543767 octets à 4249758 octets. A titre de comparaison, l'outil unix `zip` permet d'obtenir un fichier de 2724213 octets.

■ **Remarque 17.11** Le format de fichier présenté ici est rudimentaire. Les formats usuels sont en général plus complexes pour gérer

- l'identification : c'est-à-dire pouvoir déterminer qu'un fichier est un fichier compressé par un certain programme. Les fichiers `zip` commencent ainsi par les deux lettres PK.
- l'extensibilité : il est possible qu'on souhaite changer le format de sérialisation de l'arbre, ou même l'algorithme. En rajoutant un système de version sur les différentes parties, on peut permettre de faire évoluer un type de fichier en préservant la compatibilité avec les versions précédentes.

II.3 Algorithme de Lempel-Ziv-Welch

L'algorithme d'Huffman est efficace, mais il présente un désavantage majeur : il nécessite de lire le contenu d'un fichier dans son intégralité pour pouvoir déterminer un code préfixe optimal. Il est toutefois possible de modifier l'algorithme pour lever cette limitation. Dans ce paragraphe, nous allons plutôt étudier une autre technique de compression qui, bien que moins efficace en pratique que Huffman, se programme assez facilement et permet de compresser des flux plutôt que des fichiers. C'est-à-dire qu'on peut compresser et décompresser des données au fur et à mesure qu'elles sont transmises.

Il s'agit de l'algorithme de Lempel-Ziv-Welch, appelé communément compression LZW, et qui est une modification faite en 1984 par Welch de l'algorithme de LZ78 de Lempel et Ziv.

II.3.i Principe de la compression


L'idée de l'algorithme LZW est de faire avancer une fenêtre sur le texte en maintenant une table des motifs déjà rencontrés. Quand on rencontre un motif déjà vu, on le code avec une référence vers la table et quand on rencontre un nouveau motif, on le code tel quel en rajoutant une entrée dans la table.






Pour la table, on peut utiliser un tableau dynamique de motifs (ref FIXME) dont la taille ne pourra pas dépasser 2^d éléments ou directement un tableau de 2^d valeurs optionnelles, dans la mesure où d est en général petit. Ainsi, on pourra référencer chaque motif avec un mot de d bits. Afin de pouvoir retrouver efficacement l'indice associé à un motif, on utilise une table de hachage (ref FIXME) réalisant l'inverse de la table.

L'algorithme procède alors ainsi pour compresser :

- on initialise la table avec une entrée pour chaque caractère, donc chaque octet, en considérant des caractères 8bit.
- on maintient une variable contenant le plus long suffixe m du texte lu qui soit présent dans la table, il est initialisé avec la première lettre du texte.
- on lit alors chaque caractère x :
 - * Soit mx est dans la table, et alors on remplace le motif courant par $m \leftarrow mx$
 - * Soit mx n'est pas dans la table, par construction m y est nécessairement on produit alors le code correspondant à m , on rajoute une entrée dans la table pour mx si elle contient moins de 2^d éléments et on repart de $m \leftarrow x$.
- quand tous les caractères ont été lus, on produit le code correspondant à m .

Voici les différentes étapes pour la compression de la chaîne AABABAAAB qui produit la suite d'entiers 65, 256, 66, 65, 258, 257 qui seront alors codés dans un fichier sur d bits. Les 256 premières entrées de la table ont été volontairement ignorées. On remarque juste que A correspond à l'index 65 et B à l'index 66.









II.3.ii Principe de la décompression



Pour décompresser, on effectue la procédure précédente en sens inverse. Cependant, il faut reconstruire la table en même temps qu'on lit le fichier compressé. Dans la majorité des cas, c'est assez immédiat. Pour le premier code lu, il s'agit forcément d'un référence à un des 256 caractères, donc on le reproduit. A partir du second code lu :

- on lit un code n où $n < |\text{table}|$ et $\text{table}[n] = xm'$, x est un caractère et m' un mot.
- on écrit xm' dans le fichier de sortie.
- on rajoute ensuite mx dans la table où c est le précédent code lu et $\text{table}[c] = m$

En faisant ainsi, on reproduit le processus de compression mais en remplaçant la table avec un temps de retard. En effet, si on reprend le principe exposé plus haut, une entrée pour mx est ajoutée dans la table quand on lit le caractère x et que le motif lu précédemment est m , on repart alors avec x pour motif lu. C'est exactement ce qu'on fait ici en tenant compte du premier caractère de $\text{table}[n]$. Contrairement à la compression, il est inutile ici de retrouver l'indice associé à un motif. On peut donc ignorer la table de hachage utilisée par la compression.

Voici les étapes de décompression de l'exemple précédent :






Il reste toutefois un cas à traiter, celui où $n = |\text{table}|$, c'est-à-dire quand on lit un code qui n'est pas encore présent dans la table. Pour comprendre ce cas, il est important d'identifier précisément quand il se produit dans le processus de compression. Comme on vient de le voir, on rajoute une entrée pour mx après avoir produit le code c correspondant à m . Pour que le code n ne soit pas présent dans la table, il faut donc que n corresponde à cette entrée mx . Or, quand on a compressé, on est reparti du motif x à ce moment là, donc nécessairement m commence par x . Cela signifie qu'on peut reconstruire $\text{table}[n]$ en décompressant avec mx où x est la première lettre de $\text{table}[c] = m$.

On en déduit alors la procédure complète suivante :

- on initialise la table avec une entrée pour chaque caractère, donc chaque octet, en considérant des caractères 8bit.
- on maintient une variable c contenant le dernier code lu qu'on initialise avec le premier code en produisant le caractère correspondant.
- pour chaque code n :
 - ★ Soit $n < |\text{table}|$ et $\text{table}[n] = xm'$ où x est un caractère, alors on écrit xm' en sortie
 - ★ Soit $n = |\text{table}|$ et alors on écrit en sortie $\text{table}[c]x$ où x est le premier caractère de $\text{table}[c]$
 - ★ Dans tous les cas, on remplace $c \leftarrow n$ et on ajoute $\text{table}[c]x$ à la table.

Il y a un exemple classique où on a besoin de traiter ce cas : celui où le même caractère est présent plusieurs fois en début de fichier. Comme LZW est utilisé pour compresser des formats d'images où les pixels sont des indices dans une palette de 256 couleurs avec une couleur pour la transparence, le cas où la même couleur est présente au début du fichier est fréquent. Voici ici un exemple de compression et de décompression pour AAA :



■ **Remarque 17.12** On peut pousser un peu plus l'analyse précédente afin d'identifier précisément les situations menant à ces cas problématiques. Comme on vient de le voir, il est nécessaire que le texte à compresser contienne un motif de la forme $xwxwx$ où w est un mot et x une lettre. Mais pour que le motif xw lui-même soit dans la table, ce qui signifie que chaque préfixe de xw est également dans la table au moment où on commence à le lire, mais que si le motif précédent est w' alors $w'x$ n'était pas dans la table.

On considère un mot $w = a_1 \dots a_n a$ où toutes les lettres sont distinctes, et on va essayer de construire un mot p tel que la compression de p permettra avoir $a_1, a_1a_2, a_1a_2a_3, \dots, a_1 \dots a_n$ dans la table.

Si on lit a_1a_2 , on va ajouter a_1 puis a_1a_2 dans la table. On continue alors en partant de a_2 comme motif, pour pouvoir ajouter $a_1a_2a_3$ à la table, il faut lire $a_1a_2a_3$ ensuite car à la lecture de a_1 , comme a_2a_1 n'est pas dans la table on l'ajoute et m devient a_1 , puis a_1a_2 . Ainsi $a_1a_2a_1a_2a_3$ va ajouter $a_1, a_1a_2, a_1a_2a_3$ dans la table. En continuant ainsi avec $a_1a_2a_3a_4$, comme a_3a_1 n'est pas dans la table, on va procéder de même.

Le mot $p = a_1a_2a_1a_2a_3a_1a_2a_3a_4 \dots a_1a_2 \dots a_n$ va donc permettre d'ajouter tous les préfixes de m dans la table.

Maintenant, pour obtenir le cas précédent, il suffit de lire le texte $pwwa_1x = pa_1w_0a_1w_0a_1x$ où $w_0 = a_2 \dots a_n$ et x n'est pas l'un des a_i . En effet, on lit d'abord p ce qui permet d'ajouter tous les préfixes. Comme $a_n a_1$ n'est pas dans la table, on continue avec a_1 comme motif, on l'augmente jusqu'à lire $a_1 w_0$ puis on ajoute une entrée pour $a_1 m_0 a_1$ en ayant a_1 comme motif, et là on va lire $a_1 w_0 a_1 x$ et à la lecture de x , produire le code de $a_1 w_0 a_1$ qui est le dernier saisi dans la table.

Remarquons qu'on peut aussi ne considérer que $pwwa_1$ dans la mesure où la fin du fichier provoquera aussi l'écriture du code.

Si on considère $w = ABCD$, on a $p = ABABCABCD$ et on pourra ainsi compresser le texte

$$pwwA = pAw_0Aw_0A = ABABCABCDABCDABCDA$$

Après lecture de p on est dans la configuration suivante :

entrée																	
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
A	B	A	B	C	A	B	C	D	A	B	C	D	A	B	C	D	A
<i>m table</i>																	
...	256	257	258	259	260												
...	AB	BA	ABC	CA	ABCD												


Puis après lecture de $wA = Aw_0A$:

entrée																	
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
A	B	A	B	C	A	B	C	D	A	B	C	D	A	B	C	D	A
<i>m table</i>																	
...	256	257	258	259	260	261											
...	AB	BA	ABC	CA	ABCD	DA											

Enfin, la lecture du reste du texte va déclencher l'ajout de ABCDA dans la table et l'écriture de son code.

entrée																	
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
A	B	A	B	C	A	B	C	D	A	B	C	D	A	B	C	D	A
<i>m</i>																	
...	256	257	258	259	260	261	262										
...	AB	BA	ABC	CA	ABCD	DA	ABCDA										

A la décompression, on produira bien le texte correspondant avec le principe présenté plus haut :



II.3.iii Implémentation

Avant de commencer à implémenter l'algorithme, il est nécessaire de définir des fonctions de manipulation des entiers sur d bits et de lecture/écriture dans un fichier.

Tout d'abord, on définit des fonctions d'écriture d'entiers sous forme codée sur d bits à l'aide des fonctions vues précédemment :

```
let input_code f longueur_code =
  let acc = ref 0 in
  for i = 0 to longueur_code - 1 do
    let b = input_bit f in
    if b
    then acc := !acc + (1 lsl i)
  done;
  !acc

let output_code f code longueur_code =
  assert (code < 1 lsl longueur_code);

  let acc = ref code in
  for i = 0 to longueur_code - 1 do
    output_bit f (!acc mod 2 = 1);
    acc := !acc / 2
  done
```

On implémente alors assez directement la compression :

```
type table_bidir = {
  elements : string array;
  indices : (string, int) Hashtbl.t;
  mutable n_elements : int
}

let string_of_byte b = String.make 1 (Char.chr b)

let cree_table longueur_code =
  let taille_table = 1 lsl longueur_code in
  let elements = Array.make taille_table "" in
  let indices = Hashtbl.create taille_table in
  for i = 0 to 255 do
    let s = string_of_byte i in
    elements.(i) <- s;
    Hashtbl.add indices s i
```

Ocaml

Ocaml

```

done;
{ elements = elements; indices =  indices; n_elements = 256 }

let ajoute_entree table s =
  table.elements.(table.n_elements) <- s;
  Hashtbl.add table.indices s table.n_elements;
  table.n_elements <- table.n_elements + 1

let compresse_fichier nom_in nom_out longueur_code =
  let table = cree_table longueur_code in
  let taille_table = 1 lsl longueur_code in
  let f_out = Bitpacking.open_out_bits nom_out in
  let f_in = open_in_bin nom_in in
  let m = ref (string_of_byte (input_byte f_in)) in
  begin
    try
      while true do
        let c = string_of_byte (input_byte f_in) in
        let mc = !m ^ c in
        match Hashtbl.find_opt table.indices mc with
        | Some _ -> m := mc
        | None -> begin
            let i = Hashtbl.find table.indices !m in
            Bitpacking.output_code f_out i longueur_code;
            if table.n_elements < taille_table
            then ajoute_entree table mc;
            m := c
          end
      done
    with End_of_file -> ()
  end;
  (* code final *)
  let i = Hashtbl.find table.indices !m in
  Printf.printf "%d " table.n_elements;
  Bitpacking.output_code f_out i longueur_code;
  close_in f_in;
  Bitpacking.close_out_bits f_out

```

Et on procède de même pour la décompression :

```

let decomprime_fichier nom_in nom_out longueur_code =
  let table = cree_table longueur_code in
  let taille_table = 1 lsl longueur_code in
  let f_in = Bitpacking.open_in_bits nom_in in
  let f_out = open_out_bin nom_out in
  let code = ref (Bitpacking.input_code f_in longueur_code) in
  output_string f_out table.elements.(!code);

begin
  try
    while true do
      let nouveau = Bitpacking.input_code f_in longueur_code in
      let s_code = table.elements.(!code) in
      let s =
        if nouveau = table.n_elements

```

```

        then let x = String.sub s_code 0 1
              in s_code ^ x
        else table.elements.(nouveau) in
      let x = String.sub s 0 1 in
      output_string f_out s;
      if table.n_elements < taille_table
      then ajoute_entree table (s_code ^ x);
      code := nouveau
    done
  with End_of_file -> ()
end;
Bitpacking.close_in_bits f_in;
close_out f_out

```

II.3.iv Impact de la longueur du code

Afin d'étudier l'impact de la longueur du code sur la taille des fichiers compressés, on considère deux fichiers :

- `proust.txt` contenant, en 7543768 octets, l'intégrale de *à la recherche du temps perdu* de Marcel Proust
- `code.py` contenant 8566 octets de code source Python

On note np la taille en nombre d'octets après compression du fichier `proust.txt` et tp le nombre d'entrées dans la table à la fin du processus. De même, on note nc et tc les valeurs respectives pour le fichier `code.py`.

On obtient alors les valeurs suivantes en fonction du nombre d de bits du code :

d	np	nc	tp	tc
8	7543768	8566	256	256
9	5056398	5709	512	512
10	4195124	4431	1024	1024
11	3864174	3948	2048	2048
12	3612505	4039	4096	2947
13	3434424	4376	8192	2947
14	3262145	4712	16384	2947
15	3131790	5049	32768	2947
16	2998639	5385	65536	2947
17	2682264	5722	131072	2947
18	2554323	6058	262144	2947
19	2500314	6395	524288	2947
20	2557656	6731	1023317	2947

On constate qu'il est nécessaire d'avoir un texte riche pour bénéficier d'une grande longueur de code. Le fichier `code.py` ne contenant pas plus que 2947 motifs. Même si le fichier `proust.txt` en contient plus que les tailles considérées ici, il y a un compromis qui s'établit entre la richesse de la table et la taille du code. Ainsi, il semble que le fichier `proust.txt` soit compressé de manière optimale avec un code de longueur 19.

III **Problèmes supplémentaires**

- III.1** Transformation de Burrows-Wheeler
- III.2** Move to front
- III.3** La structure de données corde
- III.4** L'algorithme de Knuth-Morris-Pratt
- III.5** Extensions à l'analyse d'images

V

Systèmes

18	Gestion de la mémoire dans un programme compilé	223
I	Organisation de la mémoire	
II	Pointeurs	
III	Portée d'un identificateur	
IV	Piles d'exécution, variables locales et paramètres	
V	Allocation dynamique	



18. Gestion de la mémoire dans un programme compilé

■ Note 18.1 Roadmap :

- reprendre les exemples en C en utilisant des `int` suite au changement dans le programme.
- rajouter la présentation des pointeurs ici

■ **Remarque 18.1** Ce chapitre se concentre sur la manière dont un programme compilé gère la mémoire. Il est question, en particulier, de la notion de variable. Le modèle dans lequel on se place est celui du langage C où une variable est un emplacement mémoire.

I Organisation de la mémoire

■ **Note 18.2** Ici, je fais le choix d'une présentation assez informelle pour ne pas qu'elle soit trop liée à la réalité d'un compilateur en particulier.


Un programme compilé gère la mémoire d'un ordinateur de deux manières très différentes

- statiquement : c'est le cas des variables locales ou globales définies dans le programme. Au moment de la compilation, le compilateur dispose de l'information suffisante pour prévoir de la place en mémoire pour stocker ces données.
- dynamiquement : c'est le cas des objets dont la taille n'est connue qu'à l'exécution et peut varier selon l'état du programme. C'est alors au moment de l'exécution que le programme va faire une demande d'allocation pour obtenir une place mémoire.

En terme d'allocation statique, on peut distinguer plusieurs types de mémoire :

- les variables globales initialisées qui seront stockées dans le binaire et placées en mémoire dans une zone spécifique chargée avec le binaire
- les variables globales non initialisées dont seule la déclaration sera dans le binaire et qui seront allouées, placées en mémoire et initialisées à 0 au moment du chargement du binaire
- les variables locales et les paramètres qui sont placés dans une pile afin de les allouer uniquement au moment de l'exécution du bloc ou de la fonction

L'allocation dynamique utilise une zone mémoire appelée tas dont une possible organisation est développée dans la partie sec. V.4.



Structure de la mémoire associée à un programme

Considérons le programme c suivant.

```

const int a = 42;
int b[] = { 1, 2, 3 };
int c;

int f(int x, int y)
{
    int z = x;
    z = z * y;
    return z;
}

int main(int argc, char **argv)
{
    const int d = 1664;

    c = f(a, d);

    return 0;
}
  
```

Il est possible d'observer la manière dont sa mémoire sera répartie en utilisant la commande objdump :

```

$ gcc -c memoire.c
$ objdump -x memoire.o

memoire.o:      file format elf64-x86-64
memoire.o
architecture: i386:x86-64, flags 0x00000011:
HAS_RELOC, HAS_SYMS
start address 0x0000000000000000

Sections:
Idx Name          Size   VMA           LMA           File off  Algn
  0 .text         00000053  0000000000000000  0000000000000000  00000040  2**0
  
```

```

CONTENTS, ALLOC, LOAD, RELOC, READONLY, CODE
1 .data      00000000 0000000000000000 0000000000000000 00000093 2**0
CONTENTS, ALLOC, LOAD, DATA
2 .bss       00000004 0000000000000000 0000000000000000 00000094 2**2
ALLOC
3 .rodata    00000014 0000000000000000 0000000000000000 00000098 2**3
CONTENTS, ALLOC, LOAD, READONLY, DATA
4 .comment   00000013 0000000000000000 0000000000000000 000000ac 2**0
CONTENTS, READONLY
5 .note.GNU-stack 00000000 0000000000000000 0000000000000000 000000bf 2**0
CONTENTS, READONLY
6 .eh_frame  00000058 0000000000000000 0000000000000000 000000c0 2**3
CONTENTS, ALLOC, LOAD, RELOC, READONLY, DATA

SYMBOL TABLE:
0000000000000000 l  df *ABS* 0000000000000000 orga.c
0000000000000000 l  d  .text 0000000000000000 .text
0000000000000000 l  d  .data 0000000000000000 .data
0000000000000000 l  d  .bss 0000000000000000 .bss
0000000000000000 l  d  .rodata 0000000000000000 .rodata
0000000000000000 l  d  .note.GNU-stack 0000000000000000 .note.GNU-stack
0000000000000000 l  d  .eh_frame 0000000000000000 .eh_frame
0000000000000000 l  d  .comment 0000000000000000 .comment
0000000000000000 g  O  .rodata 0000000000000004 a
0000000000000000 g  O  .data 000000000000000c b
0000000000000000 g  O  .bss 0000000000000004 c
0000000000000000 g  F  .text 000000000000001f f
0000000000000001f g  F  .text 0000000000000034 main

```

RELOCATION RECORDS FOR [.text]:

OFFSET	TYPE	VALUE
0000000000000042	R_X86_64_PLT32	f-0x0000000000000004
0000000000000048	R_X86_64_PC32	c-0x0000000000000004

RELOCATION RECORDS FOR [.eh_frame]:

OFFSET	TYPE	VALUE
0000000000000020	R_X86_64_PC32	.text
0000000000000040	R_X86_64_PC32	.text+0x000000000000001f

On retrouve dans les sections mémoire :

- .text contenant le programme binaire
- .data contenant les variables globales initialisées et non constantes
- .bss contenant les variables non initialisées
- .rodata contenant les variables globales initialisées mais constantes.

Ici, le schéma mémoire est un peu plus compliqué car une zone mémoire distincte est prévue pour les variables constantes initialisées pour des raisons de sécurité.

La pile et le tas sont automatiques et n'ont pas besoin de figurer dans le binaire, c'est pour cela qu'on ne les trouve pas dans la liste.

Dans cette description mémoire, on trouve la table des symboles qui décrit où vont se trouver

en mémoire certaines variables.

Nom de variable	Sorte de déclaration	Section mémoire
a	constante globale initialisée	rodata
b	globale initialisée	data
c	globale non init.	bss

La section suivante permettra de compléter le tableau en étudiant comment les paramètres et variables locales sont gérés. On remarque cependant qu'il n'y a pas de symboles pour ceux-ci. En effet, le nom des variables locales est a priori perdu après la compilation contrairement aux variables globales.

II Pointeurs

III Portée d'un identificateur

En ce qui concerne une variable dans un programme, on peut définir deux notions d'apparence assez similaire.

D'une part la portée d'un identificateur qui correspond au texte du programme :

Définition III.1 La portée d'un identificateur est définie par la zone du texte d'un programme dans laquelle il est possible d'y faire référence sans erreurs.

■ **Remarque 18.2** Dans le langage C, un identificateur peut être utilisé dès sa déclaration mais tant que la variable n'est pas initialisée, le comportement n'est pas spécifié et il faut considérer cela comme une erreur. Le compilateur produit ainsi un avertissement quand on utilise le paramètre `-Wall`.

Dans le cas d'une définition, il est ainsi possible de faire référence à l'identificateur dans l'expression de son initialisation : `int x = x`. Ce cas est pathologique et le fait qu'on compte la ligne de déclaration dans la portée ne devrait pas inciter à écrire ce genre de code qui produira, de toutes façons, une erreur avec les options `-Wall -Werror`.

Dans le programme :

```

1 int a = 1;
2
3 int f (int x)
4 {
5     int y = x + a;
6     return y;
7 }
8
9 int g()
10 {
11     int z = 3;
12     return z + f(z);
13 }
```

La portée des identificateurs est :

Identificateur	Portée
a	1-13
x	3-7
y	5-7
f	4-13
g	10-13
z	11-13

Pour une fonction, afin de pouvoir écrire des fonctions récursives, l'identificateur est utilisable dans le corps de la fonction.

Comme la portée est une notion associée aux identificateurs, elle est indépendante de la notion de variables. Si on considère le programme suivant :

```

1 int f()
2 {
3     int i = 3;
4
5     return i;
6 }
7
8 int g()
9 {
10    int i = 5;
11
12    return i+1;
13 }
```

L'identificateur *i* a pour portée les lignes 3-6 et 10-13.

Un autre phénomène plus complexe peut se produire quand on redéfinit un identificateur dans sa portée.

Considérons le programme suivant

```

1 int f()
2 {
3     int i = 3;
4
5     for (int j = 0; j < 3; j++)
6     {
7         int i = 4;
8
9         i += j;
10    }
11
12    return i;
13 }
```

Ici, l'identificateur *i* a pour portée les lignes 3-13 mais dans les lignes 7-10 il y a un phénomène dit de masquage où la première définition est cachée par la seconde.

L'identificateur associé à une variable globale a pour portée l'ensemble des lignes suivant sa déclaration.

■ **Remarque 18.3** En C, la portée d'un identificateur est **statique** : elle dépend uniquement du texte du programme au moment de la compilation.

En Python, la portée d'un identificateur est **dynamique** : elle peut dépendre de l'exécution d'un programme. Par exemple si on considère le programme Python

```
Python | if condition:
          x = 3
```

La portée de l'identificateur `x` dépend ici du fait que la `condition` soit réalisée ou non. ■

IV Piles d'exécution, variables locales et paramètres

On a vu qu'en raison de leur durée de vie, les variables globales étaient allouées dès le chargement du programme. Pour les variables locales ainsi que la mécanique des appels, on utilise une **pile**.

Cette pile d'exécution est représentée en mémoire par un tableau et un indicateur de fond de pile.

Le remplissage de ce tableau s'effectue souvent des adresses hautes vers les adresses faibles : on empile en faisant diminuer les adresses.

■ **Remarque 18.4** En fait, il existe des architectures où les adresses sont croissantes. Ce qui importe est que le tas et la pile aient des comportements opposés pour qu'ils puissent grandir dans la même zone mémoire. ■

Un compilateur peut faire le choix d'utiliser directement des registres processeurs pour les variables locales ou pour passer des paramètres à une fonction. Ici, pour simplifier, on va supposer que ce n'est pas le cas et que tout passe par la pile d'exécution.

■ **Remarque 18.5** Afin de pouvoir appeler une fonction dans une bibliothèque potentiellement compilée avec un autre compilateur, il est nécessaire d'avoir une convention d'appels de fonctions. Une telle convention est appelée une *interface applicative binaire* (Application Binary Interface).


La convention System V AMD64 ABI qui est celle de Linux et macOS sur des architectures 64bits consiste à utiliser des registres entiers pour les six premiers arguments entiers ou pointeurs et des registres flottants pour les huit premiers arguments flottants. Les arguments suivants sont alors passés sur la pile (donc dès le septième entier/pointeur ou neuvième flottant).

La convention cdecl qui est assez répandue sur les architectures 32bits consiste à utiliser la pile. Par contre la valeur de retour est présente dans des registres comme pour la convention System V AMD64 ABI. ■

Lors d'un appel d'une fonction passant par la pile, on commence par empiler les paramètres (souvent de la droite vers la gauche) puis on empile l'adresse à laquelle doit revenir l'exécution une fois que la fonction aura terminé son exécution.

Au début de l'exécution de cette fonction, on place sur la pile l'adresse du fond de pile et on déplace celui-ci pour résERVER de la place pour les variables locales.

L'empreinte sur la pile d'un appel de fonction est appelée une structure pile (**stack frame** en anglais). La pile est alors organisée, depuis l'appel au point d'entrée du programme, par empilement et dépilement de structures piles.



Structure pile associée à un appel de fonction

Voici un exemple possible de l'état de la pile d'exécution lors de l'exécution d'un programme compilé avec la norme `cdecl` (Il suffit d'ajouter l'argument `-m32` pour compiler en 32bits).

```

1 int f(int a, int b)
2 {
3     int c = 3;
4     /* pile ici après l'appel en l13 */
5     c = c + b;
6     c = c * a;
7     return c;
8 }
9
10 int main()
11 {
12     int x = f(10,12);
13 }
14

```



:

A chaque appel de fonction, on va donc empiler une structure de pile complète, puis la dépiler à la sortie. Ce mécanisme est essentiel pour permettre la récurrence car il permet d'effectuer plusieurs appels d'une même fonction sans risquer que la mémoire utilisée lors d'un des appels interfère avec un autre. On comprend également les limites de la récursivité ici car cet empilement successif de structures de piles peut dépasser la taille maximale de la pile d'exécution : on parle alors de *dépassement de pile* ou **stack overflow** en anglais.

■ **Remarque 18.6** Il est possible de définir des variables locales qui soient situées au même emplacement mémoire pour tous les appels d'une fonction, c'est ce qu'on appelle des variables *statiques* dans le paragraphe précédent.

Ce mécanisme est essentiellement géré comme les variables globales et il ne sera pas développé dans la suite.

■ **Note 18.3** Je me demande s'il faudrait parler plus précisément de la manière dont la pile est gérée avec les registres `ebp/esp`. Mais ça ne me semble pas apporter grand chose ici.

V Allocation dynamique

Comme cela a été vu dans la section sec. I, il est possible d'allouer dynamiquement de la mémoire. Pour gérer cette allocation dynamique, on passe par une zone mémoire appelé le *tas* ainsi que par un mécanisme d'allocation et de libération de mémoire au niveau du système.

Pour l'utilisateur, cette gestion interne est transparente et on peut se contenter de considérer qu'il y a deux mécanismes :

- **l'allocation** mémoire où on demande à ce qu'une zone mémoire d'une certaine taille soit allouée
- **la libération** mémoire où on signale que la zone mémoire peut être récupérée par le système.

Naturellement, la mémoire d'un ordinateur étant finie, il est très important de libérer au plus tôt la mémoire non utilisée pour éviter d'épuiser la mémoire. Quand un programme ne libère pas toute la mémoire qu'il alloue, on parle de **fuite mémoire**. L'empreinte mémoire d'un tel programme peut alors croître jusqu'à rendre le programme ou le système inutilisable.

V.1 Allocation

Pour allouer une zone mémoire, on utilise la fonction `malloc` dans `stdlib.h` de signature :

```
void *malloc(size_t size)
```

Ici `size` indique le nombre d'**octets** à allouer et la fonction renvoie un pointeur vers le premier octet alloué. Comme la fonction ne connaît pas le type d'objets alloués, on utilise ainsi le type `void *`.

Ce type joue un rôle spécial et on peut changer directement le type de la valeur de retour sans rien avoir à écrire d'autre l'appel à `malloc` :

```
char *t = malloc(n);
```

■ Remarque 18.7 Dans le langage C++ qui peut être vu comme un successeur de C, il est obligatoire de préciser ici le nouveau type à l'aide d'un `transtypepage`. Pour convertir la valeur `x` vers le type `char *` on écrit alors `(char *)x`. Ainsi, pour allouer un tableau de `n` caractères, on utilisera :

```
char *t = (char *) malloc(n);
```

Bien que ce ne soit pas nécessaire en C, il est fréquent de rencontrer des programmes présentant de tels transtypages qui sont superflus mais corrects syntaxiquement en C.

Pour obtenir la taille à allouer, il peut être utile d'utiliser l'opérateur `sizeof` qui prend en entrée un type ou une valeur et renvoie sa taille. Ainsi si on peut allouer un tableau de `n` entiers non signés ainsi :

```
unsigned int *t = malloc( sizeof(unsigned int) * n );
```

et cet appel ne dépend de la taille prise par un `unsigned int` sur l'architecture.

Une autre raison de l'utilisation de `sizeof` est l'extensibilité. Par exemple, si on a un `struct point` représentant des points en 2D :

```
C | struct point {
C |     float x;
C |     float y;
C | };
```

on peut allouer un tableau de n points ainsi :

```
C | struct point *t = malloc( sizeof(struct point) * n );
```

Si jamais on change la structure pour représenter des points en 3D ainsi :

```
C | struct point {
C |     float x;
C |     float y;
C |     float z;
C | };
```

il sera inutile de changer le code d'allocation du tableau car `sizeof(point)` tiendra compte automatiquement du changement.

Si jamais une erreur empêche d'allouer la mémoire - ce qui peut être le cas s'il n'y a plus de mémoire disponible - le pointeur renvoyé par `malloc` a la valeur spéciale `NULL`.

■ Remarque 18.8 La zone mémoire renvoyée par `malloc` n'est pas initialisée. On ne peut pas supposer qu'elle soit remplie de la valeur 0. Il faut donc manuellement initialiser la mémoire après le retour de `malloc`.

V.2 Libération

Pour libérer la mémoire, on utilise la fonction `free` également présente dans `stdlib.h` et dont la signature est :

```
C | void free(void *ptr);
```

■ Remarque 18.9 Il est très important d'utiliser uniquement un pointeur obtenu précédemment par un appel à `malloc` et de ne pas l'utiliser plus d'une fois.

Le programme suivant provoque une erreur `free(): invalid pointer` à l'exécution mais est détecté par un avertissement du compilateur : `warning: attempt to free a non-heap object 'a'`.

```
#include <stdlib.h>

int main()
{
    int a;
    free(&a);
    return 0;
}
```

Le programme suivant alloue un tableau de deux `char` et appelle `free` sur l'adresse de la seconde case. En faisant cela, il n'y a pas d'avertissement car on appelle `free` sur un objet

qui est effectivement sur le tas. On obtient alors à nouveau une erreur à l'exécution `free(): invalid pointer`.

```
#include <stdlib.h>

int main()
{
    char *a = malloc(2);
    free(&(a[1]));
    return 0;
}
```

Le programme suivant libère deux fois la mémoire et provoque l'erreur `free(): double free detected in tcache 2` à l'exécution.

```
#include <stdlib.h>

int main()
{
    char *a = malloc(2);
    free(a);
    free(a);
    return 0;
}
```

V.3 Protection mémoire

Comme on l'a vu dans la première partie, quand un programme s'exécute il a un environnement mémoire constitué de plusieurs zones, parfois appelées **segments**, avec le droit d'écriture dans certaines d'entre elles.

Le système d'exploitation protège ainsi la mémoire et, au niveau matériel, l'unité de gestion de la mémoire connaît les adresses accessibles à un programme. En cas d'accès anormal, le matériel provoque une erreur qui remonte au système d'exploitation qui termine l'exécution du programme avec une erreur souvent intitulée `Segmentation fault`.

Voici quelques exemples commentés produisant des erreurs de type `segmentation fault` à l'exécution.

Lecture à l'adresse 0, ce qui provoque toujours une erreur.

Même problème avec une adresse inaccessible ou invalide.

```
int main()
{
    int *a = 0;
    return a[0];
}
```

Écriture dans une zone en lecture seule comme le segment du code.

```
int main()
{
    int *a = (int*) (&main);
    // a pointe sur le corps de la fonction main

    *a = 0;

    return 0;
}
```


V.4 Réalisation d'un système d'allocation de mémoire

- Note 18.4 Prérequis : listes chaînées

Afin de comprendre comment fonctionne le tas, et en particulier malloc et free, on va simuler ici ce comportement en allouant une grande plage de mémoire avec malloc et en gérant le découpage et l'allocation de celle-ci.


Pour gérer les blocs mémoires libres, on utilise une liste circulaire. Une liste circulaire est une liste chaînée avec un lien supplémentaire entre le premier et le dernier maillon, ce qui fait qu'on peut considérer n'importe quel maillon comme étant la *tête* de la liste.

Une liste chaînée :



Ici le dernier maillon comprend un pointeur qui ne pointe sur rien indiqué par \times , en pratique il a la valeur NULL

Une liste circulaire :



Le seul changement est donc de faire pointer le dernier maillon sur le premier. Le fait d'avoir préserver les valeurs dans les maillons permet ici de voir ce qu'est devenu le premier maillon, mais on peut accéder à cette liste par n'importe lequel de ces maillons.

Les noeuds de la liste circulaire de blocs libres auront pour valeur un triplet (`adresse`, `taille`, `libre`) qui indique qu'à l'adresse `adresse` il y a un bloc de `taille` octets et le booléen `libre` indique si ce bloc a été alloué ou non.

Pour cela on commence par définir une structure `bloc` et une fonction de création d'un bloc :

```
struct bloc {
    void *adresse;
    uint32_t taille;
    bool libre;
    struct bloc *suivant;
};
```

```

struct bloc *cree_bloc(void *adresse, uint32_t taille, bool libre)
{
    struct bloc *b = malloc(sizeof(struct bloc));
    b->adresse = adresse;
    b->taille = taille;
    b->libre = libre;
    return b;
}

```

On définit ensuite deux variables globales :

- `bloc_libres` qui va pointer sur un maillon de la liste circulaire des blocs
- `plage_memoire` qui pointe sur l'adresse de la plage mémoire que l'on va gérer et servira à la libérer en sortie de programme.

```

struct bloc *blocs_libres;
void *plage_memoire;

```

La fonction `creation_blocs_libres` permet de créer la liste circulaire avec un premier bloc qui pointe sur lui-même et qui correspond à l'adresse que l'on va placer dans `plage_memoire`.

```

void creation_blocs_libres(uint32_t taille_bloc_initial)
{
    plage_memoire = malloc(taille_bloc_initial);
    blocs_libres = cree_bloc(plage_memoire, taille_bloc_initial, true);
    blocs_libres->suivant = blocs_libres; // boucle initiale
}

```

Pour libérer la liste à la sortie du programme, on définit la fonction `destruction_blocs_libres` qui présente ainsi le parcours usuel d'une liste circulaire : on procède comme pour une liste chaînée classique mais, au lieu d'utiliser un test `bloc_courant->suivant == NULL` pour l'arrêt, il faut se souvenir du premier bloc et tester pour voir si on est revenu au point de départ. On n'oublie pas de libérer l'espace `plage_memoire` à la fin.

```

void destruction_blocs_libres()
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;

    // on boucle pour libérer chaque maillon
    while (true) {
        struct bloc *bloc_suivant = bloc_courant->suivant;
        free(bloc_courant);
        if (bloc_suivant == premier_bloc) return;
        bloc_courant = bloc_suivant;
    }

    // on libère la plage mémoire initiale
    free(plage_memoire);
}

```

Pour allouer t octets, on parcourt la liste des blocs jusqu'à trouver un bloc b libre de taille $b.t$ telle que $b.t \geq t$. Si un tel bloc n'existe pas, on renvoie le pointeur `NULL` signe d'un échec d'allocation. Sinon, on indique que le bloc est occupé, on va renvoyer l'adresse du bloc obtenu

mais, si $b.t > t$ on insère après b un nouveau bloc libre de taille $b.t - t$. Dans tous les cas, on fait pointer la liste des blocs libres vers le bloc qui suit b , qui est peut-être le bloc nouvellement créé et a de grandes chances d'être libre.

Ce mécanisme est implementé dans la fonction allocation :

```
void *allocation(uint32_t taille)
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;

    while (!bloc_courant->libre || bloc_courant->taille < taille)
    {
        bloc_courant = bloc_courant->suivant;
        if (bloc_courant == premier_bloc)
        {
            // Retour au point de départ : échec d'allocation
            return NULL;
        }
    }

    // bloc_courant pointe sur un bloc libre de bonne taille

    void *adresse = bloc_courant->adresse;
    bloc_courant->libre = false;
    if (bloc_courant->taille > taille) {
        // on le sépare en deux pour récupérer la place
        struct bloc *bloc_libre = cree_bloc(adresse+taille,
                                             bloc_courant->taille-taille, true);
        bloc_courant->taille = taille;
        bloc_libre->suivant = bloc_courant->suivant;
        bloc_courant->suivant = bloc_libre;
    }

    // On pointe sur le bloc suivant qui est sûrement libre
    blocs_libres = bloc_courant->suivant;

    return adresse;
}
```

Pour libérer un bloc, on parcourt la liste jusqu'à trouver le bloc correspondant à l'adresse à libérer et on indique que le bloc est libre. Ici, il y a deux assert permettant de s'assurer que l'adresse est bien celle d'un bloc et que le bloc n'a pas déjà été libéré.

```
void liberation(void *adresse)
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;

    while (bloc_courant->adresse != adresse)
    {
        bloc_courant = bloc_courant->suivant;
        // adresse invalide
        assert(bloc_courant != premier_bloc);
    }
```

```
// pas de double libération
assert(!bloc_courant->libre);

// on libère l'adresse
bloc_courant->libre = true;
}
```

Voici un premier programme de test de ces fonctions qui alloue 10 octets puis effectue plusieurs allocations. L'allocation de c échoue car il n'y a plus de place libre.

```
1 int main(void)
2 {
3     creation_blocs_libres(10);
4
5     uint8_t *a = allocation(5);
6     uint8_t *b = allocation(3);
7     uint8_t *c = allocation(3);
8     liberation(b);
9     uint8_t *d = allocation(2);
10
11    printf("Allocation a:%p b:%p c:%p d:%p\n",
12          (void *)a, (void *)b, (void *)c, (void *)d);
13
14    destruction_blocs_libres();
15
16    return 0;
17 }
```

Ce programme affiche alors


Allocation a:0x55c6c0c922a0 b:0x55c6c0c922a5 c:(nil) d:0x55c6c0c922a5

Voici l'évolution de la liste circulaire en présentant les maillons sous la forme :


adresse
taille
libre
suivant

L'évolution de la liste des blocs entre les lignes 3 et 9 est alors :


- Ligne 3




- Ligne 5




- Ligne 6



- Ligne 8



- Ligne 9



Cette méthode d'allocation a un défaut majeur : elle fragmente l'espace libre. Dans le programme suivant, il sera impossible d'allouer b car la liste circulaire contient deux blocs libres de 5 octets et non une bloc libre de 10 octets.

```
creation_blocs_libres(10);
c uint8_t *a = allocation(5)
liberation(a);
uint8_t *b = allocation(10);
```

■ **Remarque 18.10** On peut observer ce phénomène sur le diagramme précédent à la ligne 8 où deux blocs contigus sont libres et pourraient être fusionnés en un unique bloc de 5 octets. ■

On peut éviter cela en effectuant une phase de coalescence des blocs libres à la libération. En vertu de la nature de la liste circulaire, il est nécessaire de fusionner un bloc libre avec les blocs suivants. En utilisant une liste circulaire doublement chaînée, on pourrait également fusionner avec les blocs précédents.

Pour cela on change la fonction liberation ainsi :

```
void liberation(void *adresse)
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;
```

```
while (bloc_courant->adresse != adresse)
{
    bloc_courant = bloc_courant->suivant;
    // adresse invalide
    assert(bloc_courant != premier_bloc);
}

// pas de double libération
assert(!bloc_courant->libre);

// on libère l'adresse
bloc_courant->libre = true;

premier_bloc = bloc_courant;
bloc_courant = bloc_courant->suivant;

while (bloc_courant != premier_bloc && bloc_courant->libre)
{
    struct bloc* actuel = bloc_courant;
    premier_bloc->taille += bloc_courant->taille;
    bloc_courant = bloc_courant->suivant;
    free(actuel); // on libere le bloc inutile
}

premier_bloc->suivant = bloc_courant;
}
```