

Copyright © 2020 Marc de Falco Licensed under the Creative Commons Attribution-NonCommercial 3.0 Unported License (the "License"). You may not use this file except in compliance with the License. You may obtain a copy of the License at http://creativecommons.org/licenses/by-nc/3.0. Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.



- 1	Introduction			
1	Introduction	11		
I	Feuille de route	11		
2	Introduction à l'informatique	13		
I	Données, Problème, Algorithme	13		
l.1	Données	13		
1.2	Problèmes	14		
1.3	Algorithme	14		
П	Modèle de calcul, Machines, Programmes	14		
II.1	Exemple : ordinateur	15		
11.2	Exemple : les machines à deux compteurs	15		
11.3	Exemple: le noyau fonctionnel pur d'OCaml	16		
11.4	Exemple : Jeu de la vie			
11.5	Exemple: FRACTRAN			
11.6	Modèle Turing complets	20		
Ш	Langages, Compilateur, Interprète	21		
III.1	Langages	21		
III.2	Compilateur	21		
111.3	Interprète	21		
111.4	Unité de compilation, modules	21		
IV	Paradigmes	22		
IV.1	Impératif structuré	22		
IV.2	Fonctionnel déclaratif	22		
IV.3	Programmation logique	22		

Ш	Programmation

3	Introduction à la programmation (impérative)	25
I	Introduction	25
l.1	Les quatre étages de la programmation	. 26
1.2	Exemple	
1.3	Se remettre sans cesse à l'ouvrage	. 27
II	Représenter	28
II.1	Les données simples	. 28
11.2	Les données composées ou structurées	. 28
Ш	Manipuler	30
III.1	Variables	. 30
III.2	État d'exécution	. 30
III.3	Instructions et blocs	. 31
111.4	Portée	. 32
111.5	Manipuler des données composées mutables	
III.6	Instruction conditionnelle	
111.7	Entrées et sorties	. 37
IV	Répéter	37
IV.1	Répéter n fois	
IV.2	Répéter pour chaque élément	
IV.3	Répéter tant qu'une condition est vérifiée	
IV.4	Choisir la structure de boucle adaptée	
IV.5	Boucles imbriquées et dimensionnalité	. 38
V	Abstraire	38
V.1	Définir et appeler des fonctions	
V.2	Action d'une fonction et valeur de retour	
V.3	Fonctions et portée	
V.4	Structurer des programmes avec des fonctions	
V.5	Les fonctions comme valeurs	. 38
4	Récursivité	39
ı	La récursivité	39
l.1	Principe et exemples	. 39
1.2	Implémentation pratique	. 40
1.3	Programmer en récursif	. 41
1.4	Récursivité croisée	. 41
II	L'arbre d'appels	41
11.1	Définition	. 41
11.2	Complexité en nombre d'appels	. 41
11.3	Terminaison	. 41
Ш	Récursivité terminale	41
III.1	Présentation	. 41
III.2	Optimisation	. 41
III.3	Techniques	. 41
IV	Types inductifs et induction structurelle	41
IV.1	Définition naïve des types inductifs	. 41

Ш	Structures de données	
5	Structures de données abstraites et implémentations 49	5
ı	Introduction 4	5
П	Structure de données abstraite 45	5
6	Séquences et ses implémentations : tableaux, listes chaînées 4	7
I	Structure abstraite séquence ou liste 4	7
11	Implémentations 4	7
Ш	Implémentations concrètes des Listes chaînées 4	7
III.1	En C	
III.2 III.3	En OCaml	
7	Piles et files : structures abstraites et implémentations 5	7
8	Séquences et ses implémentations : tableaux, listes chaînées 59	9
ı	Implémentation des Listes chaînées 59	9
I.1	En C	9
1.2	En OCaml	9
9	Séquences et ses implémentations : tableaux, listes chaînées 6	1
I	Implémentation des Listes chaînées 6:	1
I.1 I.2	En C En OCaml 6	
IV	Algorithmique	
10	Introduction à l'analyse des algorithmes	5
ı	État d'un programme 69	
П	Terminaison 60	
II.1	Variant de boucle	7
11.2	Exemple de la recherche dichotomique	
11.3	Exemple du tri à bulle	
II.4 II.5	Lien avec la récursivité	
III	Correction	
III.1	Invariant de boucle	_
111.2	Exemple du tri par sélection	
IV	Complexité 72	2
IV.1	Complexité dans le pire des cas	
IV.2	Comparer des complexités	
IV.3 IV.4	Complexités en temps classiques	
IV.4 IV.5	Complexité à plusieurs paramètres	

IV.6	Complexité en moyenne	81
IV.7	Complexité amortie	
IV.8	Pertinence de la complexité spatiale	84
V	Exercices	85
11	Algorithmique exacte	. 89
I	Recherche par force brute	89
l.1	Principe	90
1.2	Raffinement : droite de balayage	90
1.3	Recherche par retour sur trace (backtracking)	95
П	Algorithmes gloutons	99
II.1	Principe	99
11.2	Construction de l'arbre de Huffman	
11.3	Preuve d'optimalité	
11.4	Sélection d'activités	
11.5	Ordonnancement de tâches	. 107
Ш	Diviser pour régner	111
III.1	Principe	
111.2	Tri fusion	
111.3	Nombre d'inversions	
111.4	Points les plus proches	
III.5 III.6	Sous-ensemble de somme donnée	
III.7	Recherche dichotomique	
IV	Programmation dynamique	116
IV.1	Principe	. 116
IV.2	Somme de sous-ensembles	. 116
IV.3	Ordonnancement de tâches	. 116
IV.4	Plus longue sous-suite commune	
IV.5	Distance d'édition	. 116
12	Algorithmique des textes	117
I	Recherche dans un texte	117
l.1	Principe de la recherche	. 117
1.2	Algorithme naïf en force brute	
1.3	Algorithme de Boyer-Moore	
1.4	Algorithme de Rabin-Karp	
II	Compression	132
II.1	Principe	
11.2	Algorithme d'Huffman	
II.3	Algorithme de Lempel-Ziv-Welch	
Ш	Problèmes supplémentaires	145
III.1	Transformation de Burrows-Wheeler	
111.2	Move to front	
III.3 III.4	L'algorithme de Knuth Marris Pratt	
III.4 III.5	L'algorithme de Knuth-Morris-Pratt	
111.J	Entensions a Fanalyse a images	. т+Э

V	Systèmes	
13	Gestion de la mémoire dans un programme compilé	149
I	Organisation de la mémoire	149
П	Pointeurs	152
Ш	Portée d'un identificateur	152
IV	Piles d'exécution, variables locales et paramètres	154
V	Allocation dynamique	156
V.1	Allocation	. 156
V.2	Libération	. 157
V.3	Protection mémoire	. 158
V.4	Réalisation d'un système d'allocation de mémoire	. 159

Introduction

1	Introduction	11
l	Feuille de route	
_		
2	Introduction à l'informatique	13
I	Données, Problème, Algorithme	
II	Modèle de calcul, Machines, Programmes	
Ш	Langages, Compilateur, Interprète	
IV	Paradigmes	



Ce site présente des documents personnels autour du programme de MP2I/MPI, et donc également du programme d'option informatique de MPSI/MP et du tronc commun.

Il s'agit pour le moment d'un premier jet, et il est amené à beaucoup évoluer. Il correspond à mon interprétation personnelle de certaines notions.

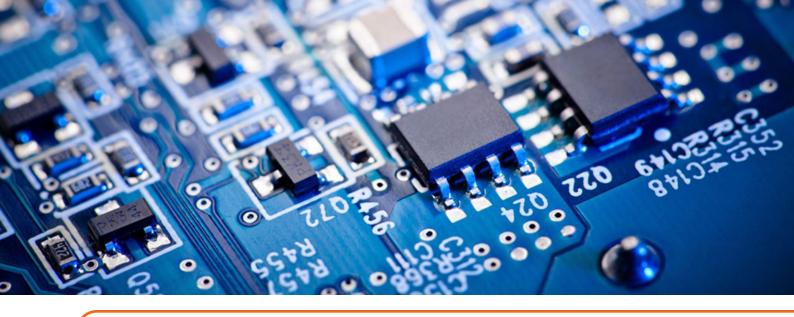
Des problèmes sont présentés au cours des documents, ils peuvent donner lieu à des développements en classe, des séances de travaux pratiques ou des problèmes. Plutôt que de donner un découpage figé en questions, ils sont souvent présentés tels quels.

Mon idée principale avec ces ressources est de proposer un contenu assez riche, plutôt à destination des enseignants. Certains points un peu pointus ne sont pas forcément essentiels pour tous les étudiants.

Le but ici n'est pas de surpasser des références sur chaque domaine, je n'ai pas cette prétention, mais de présenter un livre *tout-en-un* ce qui implique des compromis dans les notions traités et la présentation.

Feuille de route

- Faire une présentation uniforme pour les problèmes avec un index.
- Rajouter des macros pour compiler/exécuter et inclure la sortie des bouts de code.
- Rajouter les TP.
- Des roadmaps sont données dans chaque chapitre.



2. Introduction à l'informatique

■ Note 2.1 Roadmap:

• tout reprendre. Je suis peu satisfait du résultat.

Dans ce chapitre, on présente de manière très survolée l'informatique. On aura l'occasion de revenir en détail sur certaines notions. L'objectif est avant totu d'avoir une vision claire même si elle est naïve de

- ce qu'est un problème informatique
- ce qu'est un programme
- ce qu'est une machine
- ce que signifie de résoudre informatiquement un problème

Cela permet de répondre à des questions comm :

- qu'est-ce qui permet de dire qu'on programme en OCaml alors qu'on a l'impression de ne faire que des suites de définitions?
- peut-on se contenter de programmer sans chercher à comprendre?

Précisons ici qu'on parle d'informatique mais que le terme le plus proche de ce que l'on étudie en anglais est computer science par complémentarité avec des notions comme celles de computer engineering plus proches de considérations matérielles. Il n'y a pas une unique vision de l'informatique mais plutôt une grande richesse de point de vue.

I Données, Problème, Algorithme

I.1 Données

Définition I.1 Une donnée informatique est un élément d'information fini qu'on peut stocker ou transmettre.

Selon le niveau d'abstraction auquel on se place, on peut considérer une donnée comme étant une succession de bits, c'est-à-dire de valeur valant 0 ou 1, ou comme une donnée plus structurées, comme un texte, une image, un graphe, ...

En informatique, on adapte souvent son point vue sur les notions de base comme celle-ci. Si on fait de la transmission ou de la compression de données, c'est important d'en avoir une représentation la plus primitive possible comme des mots binaires. Mais si s'intéresse à des notions de chemins dans un graphe, il est plus adéquat de considérer un graphe comme un élément de données même si la question de sa représentation n'est pas immédiate.

I.2 Problèmes

Définition 1.2 Un problème informatique est un ensemble de questions parametrées par des données (les *entrées*) et dont les réponses peuvent être

- soit Oui ou Non, auquel cas on parle de problème de décision
- ou d'autres données dépendant des entrées : les sorties, on parle alors de problème de recherche ou de construction.
- Exemple 2.1 Étant donné un entier, déterminer s'il est premier ou non.
 - Étant donnés deux entiers, calculer leur PGCD.
 - Étant donné un graphe pondéré et deux sommets, déterminer un chemin de longueur minimale permettant d'aller de l'un à l'autre.
 - Étant un programme informatique et une entrée, déterminer si le programme va s'arrêter ou non.
 - Étant donné une image et une base de donnée de visages, déterminer les personnes présentes sur l'image.

On voit que certains de ces problèmes n'ont pas eu besoin d'attendre l'informatique, comme les problèmes d'arithmétique.

On peut prouver qu'un problème comme le problème de l'arrêt ne pourra jamais être résolu par un ordinateur (on dira qu'il est *indécidable*).

I.3 Algorithme

Définition 1.3 Un *algorithme* est un procédé systématique et mécanisable permettant de résoudre un problème informatique.

Ce qu'on signifie ici par le mot systématique est que le procédé de calcul est précis et non ambigu et par *mécanisable* qu'il s'agit d'un calcul qui puisse être fait par une *machine* dans un sens à venir.

Une autre manière de voir les problèmes est de dire que ce sont des fonctions mathématiques des entrées vers les sorties. Un algorithme est alors une description de la réalisation d'une telle fonction.

II Modèle de calcul, Machines, Programmes

On donne ici des définitions volontairement naïves et imprécises. Elles pourraient être précisées en fixant un cadre théorique plus conséquent, ce qui est prématuré à ce stade.

Définition II.1 Un modèle de calcul est un cadre permettant de décrire comment calculer la solution de problèmes en fonction des entrées.

Définition II.2 Une *machine* est un modèle de calcul défini par un ensemble de *configurations* et des opérations élémentaires, aussi appelées *instructions*, permettant de passer d'une configuration à une autre.

Ces instructions sont regroupées sous la forme d'une suite finie appelée un programme.

Pour éxecuter un programme, il y a dans la configuration un entier qui s'appelle le *pointeur d'instruction* et qui donne le numéro dans le programme de l'instruction courante. Généralement, on part de la première instruction en passant ensuite, sauf contre-ordre, à l'instruction suivante, jusqu'à la fin du programme.

II.1 Exemple : ordinateur

Un ordinateur est naturellement un exemple de machine. Une configuration est la donnée de l'état des registres du processeur, de la mémoire et aussi des périphériques d'entrée-sortie. Un programme est une suite d'instructions exécutées par le processeur.

II.2 Exemple : les machines à deux compteurs

Les configurations d'une machine à deux compteurs sont des triplets (A,B,PC) où A et B sont deux compteurs entiers naturels, en général initialisés avec les entrées et dans lesquels on pourra lire les sorties, et PC est le pointeur d'intruction, initialisé à la première instruction.

Un programme est une suite finie et numérotée d'instructions élémentaires parmi les suivantes :

- INCA: incrémenter A, c'est-à-dire ajouter 1 à la valeur qu'il contient
- DECA: décrementer A, c'est-à-dire soustraire 1 à la valeur qu'il contient
- IFA i j sauter à l'instruction numéro i si A est nul, sinon sauter à l'instruction numéro j.
- ullet les instructions INCB, DECB et IFB i j respectives vis-à-vis du compteur B.

Ainsi, on peut considérer le programme suivant

- 1: IFA 6 2
- 2: DECA
- 3: INCB
- 4: INCB
- 5: IFA 1 1
- 6: INCA
- 7: DECA

Si on initialise les compteurs (A,B) à (n,0) et qu'on exécute le programme, on obtient alors (0,2n) dans les compteurs. Ce programme réalise ainsi un doublement du compteur A et place le résultat dans le compteur B.

- Exercice 2.1 1. Écrire un programme permettant de passer de la configuration (a,b) à (0,a+b).
 - 2. Écrire un programme permettant de passer de la configuration (n,0) à (0,0) si n est pair ou (0,1) sinon.

	2.
1.	1. TEA 7.2
	1: IFA 7 2
1: IFA 5 2	2: DECA
2: DECA	3: IFA 6 4
3: INCB	4: DECA
4: IFA 1 1	5: IFA 1 1
5: INCA	6: INCA
6: DECA	7: INCA
	8: DECA

II.3 Exemple: le noyau fonctionnel pur d'OCaml

On considère ici le noyau OCaml avec les entiers, leurs opérations élémentaires, les fonctions, les définitions (récursives ou non) et ce qui correspond à l'évaluation.

Ainsi le terme OCaml suivant fun $n \rightarrow 2 * n$ peut être vu simplement comme prenant en entrée un entier n et renvoyant son double.

Ce qui est important ici, sans qu'on s'attarde sur la définition précise de l'évaluation, c'est de comprendre qu'il s'agit d'un modèle de calcul sans avoir de notion de machine, d'instructions ou de programme.

Bien entendu, quand on interprète ou qu'on compile un programme OCaml, cela se passe sur un ordinateur, donc une machine.

On considère que les termes sont les programmes dans un tel langage de programmation. La différence principale entre un programme vu ainsi et un dans le sens usuel, comme un programme Python, c'est que l'on n'a pas conscience de la réalité la machine quand on programme : il n'y a pas de notion d'instructions. Bien sûr, on verra qu'il est possible de retrouver cela dans OCaml et ainsi de se ramener en terrain connu, mais c'est important de comprendre que ce noyau existe indépendamment d'une notion de machine.

■ Remarque 2.1 C'est Alonzo Church qui a défini ce noyau, qu'on appelle le λ -calcul, en 1933 alors qu'il souhaitait présenter un cadre pour exprimer les fonctions calculables.

II.4 Exemple : Jeu de la vie

Le jeu de la vie défini en 1970 par John Conway dans le but d'être une récréation mathématique s'est révélé être un modèle de calcul très important.

Il s'agit d'un cas particulier d'une plus grande classe de modèles de calcul appelés les **automates cellulaires**.

Une configuration du jeu de la vie est une grille bidimensionnelle de valeur booléenne. On appelle chaque case une *cellule* et on dirait que le booléen permet de déterminer si elle *vivante* ou *morte*.

L'évaluation de ce modèle consiste à définir une nouvelle configuration en appliquant la règle suivante pour chaque cellule :

- si la cellule est vivante et a deux ou trois voisines vivantes, elle reste vivante dans la nouvelle configuration, sinon elle meurt.
- si la cellule est morte, elle devient vivante si et seulement si elle a exactement trois voisines vivantes.

Quand on parle de cellules voisines, on fait référence aux huit voisines directe sur la grille (on compte ainsi les diagonales).

_

Le point essentiel dans cette procédure permettant de passer d'une configuration à une autre est qu'on ne modifie pas la configuration courante, tout se passe comme si chaque cellule était modifié simultanément.

La configuration initiale est à la fois le programme et ses entrées. Un point critique ici c'est qu'il n'existe pas de notion de fin d'évaluation. En effet, même des configurations très simples n'atteignent pas un point fixe. On devra donc choisir en fonction du problème que l'on cherche à résoudre, comment déterminer la fin du calcul.

II.5 Exemple : FRACTRAN

FRACTRAN est un modèle de calcul également inventé par John Conway en 1987. Un programme FRACTRAN est une suite finie de fractions d'entiers naturels comme :

$$P = \left(\frac{17}{91}, \frac{78}{85}, \frac{19}{51}, \frac{23}{38}, \frac{29}{33}, \frac{77}{29}, \frac{95}{23}, \frac{77}{19}, \frac{1}{17}, \frac{11}{13}, \frac{13}{11}, \frac{15}{2}, \frac{1}{7}, \frac{55}{1}\right)$$

Une entrée est un entier et pour *exécuter* un tel programme, on considère un entier courant n, initialisé à la valeur de l'entrée, et on parcourt les fractions de gauche à droite jusqu'à trouve une fraction $\frac{p}{q}$ tel que $n\frac{p}{q}$ soit un entier. Dans ce cas, c'est la nouvelle valeur de n et on recommence le processus. Sinon, le programme termine.

■ Exemple 2.2 $(\frac{3}{10}, \frac{4}{3})$ sur l'entrée 14 va s'arrêter tout de suite, sur l'entrée 15, on va avoir 20, 6 puis 8 et s'arrêter.

Exercice 2.2 Exécuter P sur l'entrée 2 suffisament longtemps pour noter les quatres premières puissances de 2 prises par l'entier courant. Attention, cela nécessite sûrement de programmer l'évaluation.

Démonstration. On remarque que les puissances de 2 qui apparaissent sont dans l'ordre : $2^2, 2^3, 2^5, 2^7, 2^{11}, 2^{13}, \dots$ Ainsi ce programme énumère les nombres premiers.

Comment fonctionne FRACTRAN? En fait, chaque fraction va être de la forme

$$\frac{p_1^{a_1} \dots p_k^{a_k}}{q_1^{b_1} \dots q_l^{b_l}}$$

où les p_i et les q_j sont des nombres premiers distincts.

Pour qu'on sélectionne cette fraction, il faut que n soit divisible par le dénominateur, donc si on écrit n en produit de facteurs premiers, il faut que les puissances correspondant à chaque q_i soit $\geq b_i$. On va alors les diminuer de b_i puis augmenter les puissances correspondant à chaque p_i de a_i .

Ainsi, si on considère qu'un nombre n s'écrit $n=\prod_{i\in\mathbb{N}}p_i^{a_i}$, avec les a_i presque tous nuls et $p_0< p_1< p_2<\dots$ une énumération des nombres premiers, on voit qu'un nombre n'est alors qu'une configuration d'une infinité de compteurs indexés par des entiers et qui sont presque tous à 0. Une fraction est alors une règle de la forme :

$$C[i_1] \geq b_1, \dots, C[i_k] \geq b_k \rightarrow C[i_1] - b_1, \dots, C[i_k] - b_k, C[j_1] + a_1, \dots, C[j_l] + a_l$$

où on a nommé $C[0], C[1], \dots$ les compteurs.

FRACTRAN est donc une sorte de machine à compteurs dont les instructions sont exécutées comme dans un filtrage OCaml en cherchant de gauche à droite la première règle qui s'applique. Le point le plus délicat c'est que la condition permettant d'appliquer une règle est destructrice : on divise, et on ne peut pas utiliser le même compteur pour la condition et pour le résultat, car sinon on simplifierait la fraction.

Remarque 2.2 Comment fonctionne le programme P?

Pour cela, on va réecrire P en suivant la syntaxe précédente, comme on a forcément des décrements de compteurs correspondant à la condition d'application, il est inutile de les répeter et on écrira juste

```
2:-2 3:-2 |> 1:+2 0:+1
```

pour la fraction $\frac{18}{1225}=\frac{2.3^2}{5^2.7^2}$ car $p_0=2,p_1=3,p_2=5$ et $p_3=7$. Par soucis de lisibilité, on peut de plus nommer les compteurs par des lettres en commençant à a et donc écrire

Comme les régles de P ne font intervenir que des +1 et des -1, on pourra encore abréger en écrivant a – plutôt que a–1 et b+ plutôt que b+1.

Ainsi, P devient la suite de règles suivantes (numérotées pour y faire référence ensuite).

```
0: d-f- |> g+
1: c-g- |> a+b+f+
2: b-g- |> h+
3: a-h- |> i+
4: b-e- |> j+
5: j- |> d+e+
6: i- |> c+h+
7: h- |> d+e+
8: g- |>
9: f- |> e+
10: e- |> f+
11: a- |> b+c+
12: d- |>
13: |> c+e+
```

On commence avec la configuration $n=2=2^1$ donc uniquement 1 dans le compteur a et 0 dans les autres. On notera

```
a:1
```

cette configuration.

On remarque donc que si on a la configuration

```
a : n - 1
```

on va appliquer la règle 11 jusqu'à obtenir la configuration

$$b: n-1, c: n-1$$

Ensuite, on applique la règle 13 puis successivement les règles 4 et 5 jusqu'à être dans la configuration

$$c: n, d: n-1, e: 1$$

La règle 10 permet de passer à

$$c: n, d: n-1, f: 1$$

On va effectuer une succession de règle afin de déterminer si n-1 divise n. En fait, cette sucession de règle va déterminer si d divise c. Imaginons donc qu'on a la configuration

on applique successivement les règles 0 et 1 pour obtenir la configuration

$$a:m,b:m,c:n-m,f:1$$

La règle 9 s'applique alors pour passer à

$$a:m,b:m,c:n-m,e:1$$

et on effectue alors la succession des règles 4 et 5 qu'on a déjà vu pour passer à

$$a:m,c:n-m,d:m,e:1$$

Comme il n'y a plus rien dans b c'est la règle 10 qui s'applique et on repasse à

$$a:m,c:n-m,d:m,f:1$$

On repasse alors dans les règles 0 et 1 jusqu'à obtenir

```
a:2m, b:m, c:n-2m, f:1
```

et ainsi de suite. Pour l'arret, deux cas peuvent alors se produire :

• Soit on a vidé c en effectuant la soustraction de m, ce qui correspond au cas où m ne divise pas n, et alors la règle 1 ne pourra plus s'appliquer car elle nécessite $c \geq 1$. Si n = qm + r avec 0 < r < n, on aboutit alors avec une dernière application de 0 en

$$a: n, b: r, d: m-r-1, g: 1$$

Comme la règle 1 ne s'applique plus, on passe alors à la règle 2 vers

$$a:n,b:r,d:m-r-1,h:1$$

on enchaine alors les règles 3 et 6 jusqu'à obtenir la configuration

$$b: r-1, c: n, d: m-r-1, h: 1$$

On ne peut alors qu'apppliquer la règle 7 qui permet de passer à

```
b: r-1, c: n, d: m-r, e: 1
```

puis l'alternance 4 et 5 transfère b dans d vers

```
c: n, d: m-1, e: 1
```

Dans ce cas, si on a m-1>0 et on va alors repasser dans la règle 10 pour tester la divisibilité de n par m-1. Mais ce qui est subtil ici, c'est que le cas m-1=0 a déjà été pris en compte car il correspond à m=1, c'est-à-dire à une divisibilité qui aboutit forcément et qui est donc traité par le cas suivant.

ullet Soit m divise n, donc n=km et on va aboutir forcément par soustraction après une règle 0 à une configuration de la forme

```
a:n,d:m-1,g:1
```

Donc, contrairement au cas précédent, la règle 2 ne s'applique pas car b=0. On passe donc à la règle 8 qui produit

```
a: n, d: m-1
```

C'est ici qu'on peut produire un nombre premier, car si m-1=0, cela veut dire que la seule divisiblité s'est produite pour 1, donc que n est premier. Or, on a alors uniquement n dans le compteur a, et ainsi ça correspond au 2^n .

On poursuit alors par une étape de nettoyage pour passer à l'entier n+1 et continuer. Pour cela, on applique la règle 11 comme précédemment. Le seul changement c'est qu'avant de passer à la règle 13, on va appliquer la règle 12 pour vider le compteur d

Ainsi, ce programme pourrait être traduit par le code Python suivant :

```
a = 1
while True:
    a = a+1
    for d in reversed(range(1,a)):
        b = a
        reste = False
        while b != 0:
            for i in range(d):
                if b == 0:
                     reste = True
                     break
                b = b-1
        if not reste:
            break
    if d == 1:
        print(a,' est premier')
```

II.6 Modèle Turing complets

Tous les exemples présentés ci-dessus sont équivalents : ils permettent de calculer les mêmes fonctions mathématiques pourvu qu'on précise la manière dont on donne l'entrée et comment

hon

on lit la sortie.

Par exemple, s'il n'est pas possible de réaliser l'incrémentation en FRACTRAN, il est possible d'écrire un programme permettant de passer de 2^a à 3^{a+1} .

On dit que ces modèles sont **Turing-complet** en référence au modèle de calcul de référence : les machines de Turing.

III Langages, Compilateur, Interprète

III.1 Langages

Un langage de programmation est une manière de représenter textuellement un programme. Cela peut être un programme en lien avec une notion de machine mais aussi une notion plus abstraite comme on va le voir.

Comme on l'a vu, un ordinateur est une machine. Un programme pour cette machine est ce qu'on appelle un binaire et l'ensemble des instructions s'appelle le langage machine. C'est le langage naturel d'un ordinateur et il dépend de son processeur. Ainsi, un binaire pour un téléphone n'est pas directement utilisable sur son ordinateur, car les premiers ont des processeurs utilisant un jeu d'instructions arm et les seconds un jeu d'instructions x86_64.

III.2 Compilateur

Un **compilateur** est un traducteur d'un langage à un autre. On considère le plus souvent des compilateurs vers un langage machine, qu'il soit lié à des processeurs réels ou une machine spécifique appelée une machine virtuelle.

III.3 Interprète

Un interprète est un programme qui va lire un programme écrit dans un langage donné et l'évaluer en interprétant les instructions. Cela diffère d'une machine virtuelle dans le fait que le programme utilise toute la richesse du langage de programmation dans lequel il a été programmé pour son interprète. De plus, le fait de ne pas passer par une machine virtuelle permet de plus facilement relier l'environnement de l'interprète et celui du langage interprété. Un autre avantage discutable et la possibilité dans le langage cible de faire référence à l'interpréte. Cela permet notamment de permettre l'évaluation dynamique de code (eval en Python).

Pour autant, les interprètes ont de nombreux défauts qui font qu'on a de plus en plus recours à des compilateurs vers des machines virtuelles. Parmi ceux-ci, citons le fait de devoir relire directement le programme à chaque fois qu'on va l'exécuter, ce qui est particulièrement critique quand on veut faire appels à des fonctions définies ailleurs, ou le fait que l'interprète lui-même est souvent très verbeux.

III.4 Unité de compilation, modules

Un programme est souvent structuré sous la forme de nomnbreux sous-programmes reliés entre eux. C'est une bonne pratique pour regrouper des fonctions selon un même thème et permettre la réutilisation du code sans duplication. On utilise pour cela la notion de modules ou de bibliothèques. Cela correspond au niveau du programme à rajouter du code existant au moment de la compilation ou de l'interprétation. Il est alors possible de réutiliser une partie de la compulation sur ce code, et ainsi, on utilise en général une version intermédiaire qui est du code pre-compilé utilisable par un autre programme, soit en copiant le résultat dans le programme ou en faisant réference à des versions définies dans le système (bibliothèque dynamique). Un programme est chargé de faire le lien entre les différentes bibliothèques et le programme, c'est l'éditeur de liens.

IV Paradigmes

Un paradigme de programmation est une manière de concevoir des programmes. On va citer ici trois paradigmes.

IV.1 Impératif structuré

Un programme impératif est un programme construit plus ou moins directement en lien avec une notion de machines comme une suite d'instructions. Afin de permettre de programmer convenablement, un tel langage fourni une notion de structure qui permet de structurer le code. D'une certaine manière, la notion de classe et la programmation objet enrichi ce paradigme en permettant de structurer le code autour d'une notion d'objets.

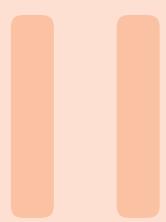
IV.2 Fonctionnel déclaratif

On a vu qu'en programmation fonctionnelle, tout n'est qu'une expression, un terme, qu'on évalue. Un programme fonctionnel déclaratif est ainsi consistué d'une succession de définitions de valeurs ou de fonctions. C'est ainsi qu'en OCaml n'est qu'une suite de let ou let rec.

Comment calcule un tel programme? En évaluant chacune des déclarations, certaines vont effectivement produire des effets de bords et permettre la lecture ou l'écriture. L'usage en OCaml est ainsi de finir un programme par une déclaration nommée main ou _ qui va se charger d'appeler les déclarations précédentes.

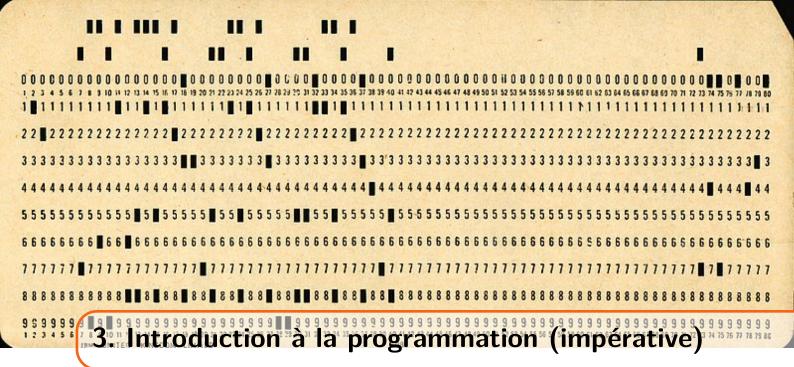
IV.3 Programmation logique

Le paradigme de la programmation logique est sûrement le plus déroutant des trois. Un programme logique est en fait une formule logique dont une solution correspond à son résultat. Sans rentrer dans les détails, on remarquera que cela correspond à ce qu'on fait en SQL pour les bases de données où une requête de recherche est définie sous une forme de formule logique qui décrit les propriétés qui doivent être vérifiés par les éléments qu'on cherche.



Programmation

3	Introduction à la programmation (impéra-
	tive) 25
1	Introduction
Ш	Représenter
III	Manipuler
IV	Répéter
V	Abstraire
4	Récursivité 39
1	La récursivité
П	L'arbre d'appels
Ш	Récursivité terminale
IV	Types inductifs et induction structurelle



Source de l'image: https://www.flickr.com/photos/binaryape/5151286161/

■ Note 3.1 Roadmap:

- finir l'écriture avec Python.
- rajouter OCaml et C.
- en profiter pour faire une introduction aux référence en OCaml quitte à rajouter une partie spécifique.
- rajouter beaucoup d'exemples et d'exercices.

Introduction

Dans ce chapitre introductif sur la programmation, on va présenter celle-ci à travers quatre notions permettant de comprendre ce que signifie programmer. Un certain soin a été porté au fait de rendre cette présentation indépendante du langage tout en permettant qu'elle serve de support pour l'apprentissage d'un langage particulier. Ainsi, les éléments propres à un langage donnée sont clairement séparé.

Comme nous l'avons vu dans le chapitre d'introduction, la programmation consiste à décrire des algorithmes et la manière dont ils sont mis en œuvre sur une machine. En cela, le modèle que l'on suit ici est celui de la programmation dite impérative structurée. Pour autant, de nombreuses notions présentées ici restent valides dans d'autres paradigmes.

La présentation faite ici est indépendante du langage sous réserve que celui-ci comporte des traits impératifs structurés. Pour autant, selon les langages certaines notions sont plus ou moins riches. Des paragraphes spécifiques complètent ainsi le texte et on encourage le lecteur à basculer d'un langage à un autre tout au long de la lecture.

Python est le langage d'abord le plus aisé sur ces notions, mais aussi celui pour lequel il est vraiment nécessaire d'avoir une discipline d'utilisation afin de ne pas faire n'importe quoi.

Ainsi, on a fait le choix de faire une présentation sans artifice qui n'utilise pas de structures ou de mécanismes propres à Python et problématiques. Ceux-ci sont esquissés en remarque en précisant en quoi ils sont effectivement à manipuler avec parcimonie.

I.1 Les quatre étages de la programmation

Programmer c'est

- représenter des données, allant du booléen valant vrai ou faux, jusqu'aux bases de données permettant de modéliser des relations complexes
- manipuler ces données en lien avec un environnement, ce qui signifie autant de pouvoir les stocker que de pouvoir les transformer
- répéter ces manipulations élémentaires, car les données sont d'une taille finie, mais non connue à l'avance
- **abstraire** les notions précédentes pour ne pas avoir à se répéter, à -ravers la notion de fonctions

I.2 Exemple

Prenons un exemple simple pour comprendre les différents étages où le but est final est de pouvoir calculer des sommes comme $1+2+\cdots+n$.

Représenter Un entier comme 3 est une donnée qu'on pourra représenter telle quelle dans la plupart des langages avec cependant des limitations à garder en tête : la mémoire étant finie, on ne peut pas représenter des entiers quelconques, car il y en a une infinité. Déjà, à ce stade, on peut se poser la question de savoir si on ne veut représenter que des entiers dans un intervalle fixe, afin de borner leur occupation mémoire, ou si on veut les représenter en arbitraire. On peut opérer sur ces entiers avec un opérateur tel que + pour l'addition, mais le choix de la représentation aura son importance sur ce qui se cache derrière cette opération. L'addition de deux très grands entiers en précision arbitraire prendra plus de temps.

A l'aide de cela, on peut ainsi écrire 1+2+3+4+5.

Manipuler On peut aussi les stocker directement en mémoire à l'aide de variable. Ainsi

```
\mathbf{x} = 3
```

permettra de définir une variable nommée x et contenant la valeur entière 3. On peut alors manipuler cette variable en changeant sa valeur à l'aide des opérations :

```
\mathbf{x} = \mathbf{x} + 2
```

Avec ces instructions de manipulation, on peut reprendre le calcul précédent de $1+2+\cdots+5$ avec une suite d'instructions :

```
workful s = 0
s = s + 1*1
s = s + 2*2
s = s + 3*3
s = s + 4*4
s = s + 5*5
```

Répeter En fait, les 5 instructions d'ajout qu'on vient d'écrire ont la même structure : il s'agit d'ajouter une valeur i^2 à la variable s avec i prenant tour à tour les valeurs 1, 2, 3, 4 et 5. Une

I Introduction 27

structure comme une boucle va permettre d'éviter cette répétition et d'écrire qu'il existe une variable i prenant ces valeurs et les instructions à réaliser pour chaque valeur de i. On pourra donc écrire :

```
s = 0

for i in range(1,5+1):

    s = s + i*i
```

C'est en fait très proche de la notation $1+2+\cdots+5=\sum_{i=1}^5 i$. En fait, on cette notation mathématique est très proche d'une boucle.

Abstraire imaginons qu'on ait besoin d'effectuer le calcul précédent $\sum_{i=1}^n i^2$ à plusieurs reprises pour différentes valeurs de n, on pourrait à chaque fois recopier ces lignes en changeant la valeur maximale prise par i. Mais c'est inefficace pour plusieurs raisons :

- en recopiant du code, on risque de propager et répéter des erreurs. Si jamais on découvre une meilleure manière de faire le calcul, il faudra ainsi changer le code à chaque endroit où on l'a copié.
- là où on a besoin de ce calcul, il est possible que ce soit pour faire d'autres choses avec et donc qu'il s'inscrive dans une logique complexe. En copiant le code, on rend le programme plus compliqué à comprendre, car la boucle pour calculer cette somme est mise sur le même plan que le code qui nous intéresse.

Pour faire un parallèle avec les mathématiques, c'est comme si on recopiait une preuve dans un cas particulier chaque fois qu'on a besoin d'appliquer un théorème.

On introduit ainsi une notion d'abstraction les fonctions qui vont nous permettre de faire un code générique de calcul en prenant n en paramètre.

```
def somme_carres(n):
    s = 0
    for i in range(1,n+1):
        s = s + i*i
    return s
```

Comme on le verra, une telle fonction est caractérisée par son nom qui nous permet d'y faire référence, comme lorsqu'on applique le théorème de Thalès, ainsi que des arguments qui seront, à l'exécution, remplacé par les valeurs qui nous intéressent, comme le fait que Thalès est démontré dans un triangle *générique* mais on l'applique sur un triangle particulier et une valeur de retour qui correspond à ce que la fonction calcule.

On peut alors, quand on a besoin de faire le calcul de $\sum_{i=1}^5 i^2$ juste écrire :

```
somme_carres(5)
```

1.3 Se remettre sans cesse à l'ouvrage

De notre présentation *étagée*, on pourrait retenir une hiérarchisation des différents étages. Il n'en est rien.

Ainsi, autant il peut être assez direct de représenter des données, comme dans le cas précédent, autant cela peut être une étape cruciale que de choisir la meilleure représentation. C'est le cas quand on s'intéresse au choix d'une structure de données la plus adaptée ou quand on conçoit un schéma de base de données.

La programmation, et plus largement l'informatique, sont ainsi à rapprocher d'un art martial comme l'Aïkido où on travaille tout au long de sa pratique les mêmes gestes simples en se

perfectionnant sans cesse. Aller au bout de ce chapitre ne sera donc pas le signe qu'on maîtrise la programmation, mais juste qu'on a fait le premier pas sur la voie du perfectionnement.

Tout au long des autres chapitres, on verra ainsi des méthodes, des notions, qui permettent de mieux comprendre et de mieux pratiquer la programmation. Mais au moment où se retrouvera à programmer, on ne sortira pas de ces quatre étages.

II Représenter

Les données sont regroupées en informatique autour de la notion de types. Un type de données peut être vu en première approximation comme un ensemble de données de même nature. On considère, par exemple, usuellement le type des entiers naturels ou celui des nombres à virgule flottante.

II.1 Les données simples

Les données les plus simples sont celles qui correspondent à des valeurs numériques. Elles dépendent assez souvent des langages de programmation, mais on retrouve toujours un type pour les booléens, un type pour les entiers et un type pour les nombres à virgule flottante, c'est-à-dire pour des représentations de certains nombres réels.

On a ainsi:

- le type int des entiers en précision arbitraire muni des opérations usuelles + *
 // % ** en prenant garde au fait que // est la division entière. Ces opérations prennent d'autant plus de temps que les nombres ont beaucoup de chiffres.
- le type float des nombres à virgule flottante comme 1.4 ou -3.14. On verra plus loin les nombres de \mathbb{R} qui sont ainsi représentables. Les opérations sont alors + * / **. On remarque qu'on a une **vraie division** avec / et ainsi 1 / 2 renvoie un float correspondant à $\frac{1}{2}$.
- le type bool des booléens qui ne comporte que deux valeurs True et False et des opérations suivantes :
 - * la négation not qui permet de passer de True à False et réciproquement.
 - ★ la conjonction and telle que b1 and b2 soit True lorsque b1 et b2 sont égaux à True et False sinon
 - ★ la disjonction or telle que b1 or b2 soit False lorsque b1 et b2 sont égaux à False et True sinon

Les booléens sont particulièrement important, car ils correspondent aux types des comparaisons. On dispose sur tous les types des opérateurs de comparaison == != > > = < = = 0 qui correspondent aux relations mathématiques $= \neq > \geq < \leq$.

• le type Nonetype assez particulier qui ne contient qu'une seule valeur None et aucune opération. Ce type permet de donner un sens à l'absence de valeur, comme pour une fonction qui ne renvoie rien.

II.2 Les données composées ou structurées

Les données simples permettent de tout représenter. En effet, l'élément de donnée le plus primitif est le bit qui correspond à un booléen. Ainsi, la mémoire d'un ordinateur est entièrement constituée de booléens. Mais en disant cela, on ne dit pas grand-chose, car il ne s'agit pas d'une soupe informe de booléens, mais d'une organisation structurée. C'est ainsi qu'on considère des données composées comme les tableaux ou les couples.

On distingue deux types de données composées :

thon

II Représenter

• les données *immuables*, c'est-à-dire celles qui ne permettent pas de changer les valeurs qu'elles regroupent ni leur structure après leur création

• les données mutables qui le permettent.

Les principaux types de données composées sont :

- (immuable) les tuples qui permettent de représenter des n-uplets de valeurs de types quelconques. On les écrit comme en mathématiques : (1, 3.2, 4). Un tuple ne contenant qu'un seul élément doit tout de même faire apparaître la virgule pour le distinguer d'une valeur. Ainsi on écrit (1,) car (1) est juste la valeur 1. Le tuple vide s'écrit ().
 - On dispose d'un opérateur de concaténation + qui permet de créer un tuple obtenu en mettant bout à bout deux autres tuples. Ainsi (1,2) + (3,4,5) est le tuple (1,2,3,4,5). En mathématiques, si b est entier naturel on a $a \times b = a + ... + a$ où on ajoute b fois a. De même, on dispose d'une opération \star telle que $(1,2) \star 3$ corresponde à (1,2) + (1,2) + (1,2), c'est-à-dire au tuple (1,2,1,2,1,2). On obtient la taille d'un tuple à l'aide de len. En effet, len (1,2,3) renvoie 3. Attention aux doubles parenthèses ici, on le verra, len est une fonction et les parenthèses sont nécessaires pour l'appliquer, mais le tuple lui-même s'écrit avec des parenthèses.
 - On accède aux différentes composantes d'un tuple avec la construction t[i] où t est un tuple et i est l'indice de la composante en commençant par numéroter à 0. Ainsi (1, 3.2, 4)[1] est la valeur 3.2. Les accès s'effectuent modulo la longueur, et ainsi on peut écrire t[-1] plutôt que t[len(t)-1] pour accéder à la dernière composante.
- (immuable) les str ou chaînes de caractère qui permettent de représenter des textes comme 'bonjour' ou "au revoir". On utilise indifférement 'ou " mais il faut que ce soit le même symbole qui ouvre et ferme une chaîne. Il n'y a pas de type spécifique pour les caractères en Python: ce sont des chaînes de longueur 1 comme 'a'.

 Les opérations sont les mêmes que pour les tuples avec + pour la concaténation, len pour la longueur ou [i] pour accéder au ième caractère. C'est quelque chose qu'on retrouvera pour la plupart des types composés qui sont des suites d'éléments, on parle de séquences.
- (mutable) les list ou tableaux qui correspondent à des tuples dont peut modifier les valeurs ou même modifier la structure, comme en ajoutant ou en supprimant des éléments. Cela correspond alors à des manipulations et non des opérations, et on les verra au paragraphe suivant.
 - Pour définir un tableau, on écrit comme un couple mais avec des crochets. Ainsi on peut écrire [1,3.2,3]. Le tableau vide est [] et comme il n'y pas d'ambiguité, un tableau contenant un unique élément se note juste [1].
 - Là encore, on dispose des opérations communes de concaténation, longueur et accès.
- (mutable) les dict ou dictionnaires, qui permettent de réaliser des associations entre des valeurs immuables et d'autres valeurs. On peut ainsi considérer une valeur comme { 'nom' : 'Michel', 'prenom' : 'Louise', 42 : True } les valeurs à gauche du : sont les clés qui permettent d'accèder aux valeurs, comme lorsqu'on cherche un mot dans un dictionnaire pour accéder à sa définition. Ici, on ne dispose plus de concaténation, car ça ne voudrait pas dire grand-chose d'ajouter deux dictionnaires (que fait-on si une même clé est associée?). On dispose toutefois de len pour le nombre d'associations et il est possible d'accéder à la valeur associée à une clé en écrivant d[cle] où d est une valeur de type dict et cle une clé

présente dans d.

Le dictionnaire vide est {} et on verra dans le paragraphe suivant comment manipuler un dictionnaire pour ajouter ou supprimer des associations.

III Manipuler

III.1 Variables

L'élément clé permettant de manipuler des valeurs est de pouvoir les placer à un endroit et de changer la valeur qui s'y trouve. C'est ce qu'on appelle une **variable**. Même si cela ne correspond pas à une réalité selon les langages, il est d'usage de considérer une variable comme une case mémoire disposant d'un nom et dans laquelle on place des valeurs.

On a alors trois éléments:

- définir une variable, souvent en la limitant à un certain type de donnée, on parle de **dé- claration**
- accéder à sa valeur
- changer sa valeur, on parle d'assignation

Les noms de variables sont le plus souvent composés de lettres, de chiffres et du symbole _, ils doivent commencer par une lettre.

Il n'existe pas de mécanisme spécifique pour déclarer une variable distinct de l'assignation. Ainsi, on écrira x = 3 à la fois pour déclarer une variable nommée x contenant la valeur 3 et pour changer la valeur de x.

Pour accéder à la valeur d'une variable, il suffit d'écrire son nom directement dans une expression. Ainsi, on pourra écrire x+2 pour la valeur obtenue en ajoutant 2 à la valeur de x. Les valeurs en Python sont typées mais pas les variables. Ainsi on pourra tout à fait écrire

```
x = 3 # déclare une variable x contenant un entier
# puis plus loin
x = 'Bonjour' # maintenant x contient une chaîne
```

III.2 État d'exécution

L'ensemble des variables et des valeurs auxquelles elles sont associées à un moment de l'exécution d'un programme est un état d'exécution. Les instructions de déclaration et d'assignation modifient ainsi l'état.

Suite aux instructions

```
a = 3
b = 2
```

l'état est alors

variable	valeur
a	3
b	2

Si on exécute ensuite l'instruction

```
b = a
```

III Manipuler 31

il devient

a	3
b	3

Dans la suite, on pourra noter a=3, b=3 un tel état. Ici, le = permet une notation intuitive.

III.3 Instructions et blocs

Les programmes qu'on va écrire vont maintenant être des suites d'instructions, comme

$$\begin{array}{lll}
x &= 3 \\
y &= x + 2 \\
x &= y
\end{array}$$

Ces instructions sont regroupées ensemble sous une notion de blocs. Suivant les langages, ces blocs sont plus ou moins explicites.

Un bloc est un groupement d'instructions à la suite qui sont toutes alignées dans le texte du programme. On dispose ainsi d'une indentation signifiante, c'est-à-dire que cet alignement a du sens et il est directement compris par Python pour savoir si une instruction appartient à un bloc ou non.

Ainsi, on ne pourra pas écrire

```
x = 3

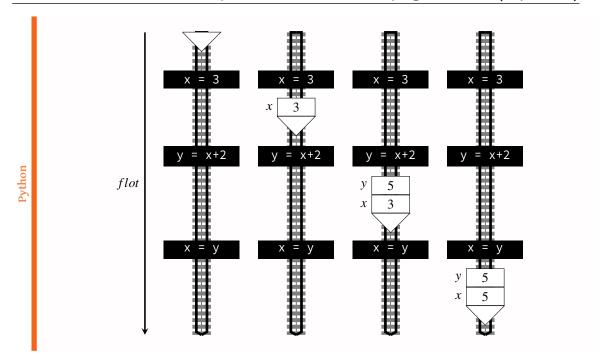
y = x + 2 \# non aligné avec le reste du bloc

<math>x = y
```

Derrière cette notion de bloc on trouve une notion implicite qui est celle de flot d'exécution et qui régit la manière dont les instructions sont exécutées. En accord avec la manière dont on écrit les programmes, les instructions sont exécutées de haut en bas. L'état d'exécution est alors modifié le long du flot.

Une analogie qui sera utile dans la suite est de voir l'état d'un programme comme un train qui circule à travers les rails du flot de contrôle, en rajoutant ou modifiant des wagons à chaque instruction présentée comme un arrêt. Cette image assez naïve permet de faire passer une idée très importante qui est celle de l'ordre d'évaluation et du contexte associé.

vthon



Un exemple important est celui de l'échange du contenu de deux variables a et b. On ne peut pas écrire

```
python p = a a = p
```

car comme on vient de le voir, la valeur de b est déjà perdue après la première assignation. Une solution consiste alors à introduire une variable temporaire qui ne va servir que de support pour pouvoir garder la valeur de b. On écrira ainsi :

```
temp = b
b = a
a = temp
```

III.4 Portée

Une variable a une durée de vie, souvent, elle n'existe que localement dans un programme. Par exemple, uniquement au sein de la fonction ou du bloc dans laquelle on l'a définie. On parle de portée d'une variable pour désigner l'ensemble des instructions dans lesquelles ont peut y accéder.

La portée des variables est assez dynamique. On peut ainsi définir une variable uniquement dans certains cas comme on le verra avec une instruction conditionnelle. Ce qui fait que selon l'état d'un programme, on définira différemment la portée d'une même variable.

III.5 Manipuler des données composées mutables

Les types de données mutables permettent de modifier leur valeur. Ce sont le plus souvent des **collections**, c'est-à-dire des arrangements structurés de valeurs, comme un tableau qui les arrange en ligne de la première à la dernière. Lorsqu'on peut faire un accès direct à une valeur, on peut alors la modifier comme si c'était une variable. Il peut également être possible de faire des modifications sur la structure de la collection elle-même, comme enlever ou rajouter des

éléments.

III.5.i Modification des valeurs des éléments

On a vu deux types mutables: les tableaux (list) et les dictionnaires (dict).

• Pour une variable t contenant un tableau de n éléments, on peut accéder à t[i] pour $i \in [\![0,n-1]\!]$ comme si c'était une variable. Ainsi, on pourra écrire t[i] = 3 pour changer la valeur à la ième case par 3. Un tableau peut ainsi être vu comme une suite finie de variables. Si jamais on accède en lecture comme en écriture à t[j] quand $j \notin [\![0,n-1]\!]$, cela va déclencher une erreur et non ajouter une association entre j et cette valeur.

Ainsi, il n'est pas possible de changer la structure d'un tableau par des assignations. Si on exécute la suite d'instructions

```
t = [1, 0, 2]
t[0] = 3
t[2] = t[1]
```

L'état va alors passer de t=[1, 0, 2] à t=[3, 0, 2] puis t=[3, 2, 2].

Tout se passe comme si on avait trois variables t0, t1, t2 avec les instructions :

• Pour une variable d contenant un dictionnaire, on peut accéder à d[c], où c est un clé présente dans d, en lecture comme en écriture. Si on assigne une valeur à d[c] alors que c n'est pas une clé présente dans le dictionnaire, elle sera alors ajoutée. Ce qui fait que, contrairement au cas des tableaux, il est possible de modifier la structure du dictionnaire à l'aide d'assignation.

Si on considère la suite d'instructions

```
d = { 'a' : 2, 'test' : 3 }
d['a'] = 4
d['b'] = d['test']

On passe de l'état d={ 'a' : 2, 'test' : 3 } à d={ 'a' : 4, 'test' : 3 } puis
d={ 'a' : 4, 'b' : 3, 'test' : 3 }.
```

III.5.ii Partages de valeurs composées entre plusieurs variables

Il y a une différence fondamentale entre écrire

```
a = 3
b = a
a = 2
```

et écrire

```
a = [ 3 ]
b = a
a[0] = 2
```

Dans le premier cas, lors de l'assignation b = a, il n'y a pas de lien entre la valeur 3 dans a

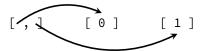
hon

et celle dans b. Dans le second cas, après b = a, on a b et a qui pointent vers le même tableau. On notera b, a = [3] cet état. Ainsi, quand on exécute l'instruction a [0] = 2 on modifie le tableau qui est également associé à b. Donc a **et** b sont associées au tableau [2].

En fait, quand on écrit a = [3], on ne **stocke** pas la valeur du tableau dans a. On crée le tableau [3] en mémoire et on place dans a une référence vers ce tableau. Quand on exécute alors b = a, on place dans b une autre référence mais vers le même tableau. Une manière simple de voir cela est de représenter les références par des flèches, ainsi l'état pourrait en fait se représenter ainsi :



Si on considère un tableau de tableau comme [[0], [1]] on aura alors dans les cases du tableau principal des références vers les deux tableaux [0] et [1]:



Ainsi, si on écrit

on aura alors les deux références qui pointent vers le même tableau, et quand on modifie t[1][0], on modifie donc forcément t[0][0] également pour aboutir à l'état :

On peut remarque que plus rien ne fait référence ici au tableau [1]. Il y a un mécanisme dans Python qui détecte cela et qui supprime de la mémoire le tableau.

Ce qui vient d'être dit pour les tableaux en Python est encore vrai avec le dictionnaires, et plus généralement avec la plupart des données.

III.5.iii Modification de la structure des données composées

Pour parler de modification de tableaux ou de dictionnaires, il est nécessaire de comprendre que Python est un langage objet. On se contentera ici de dire qu'un objet est une donnée munie d'opérations de manipulation sur cette donnée.

Ainsi, si t est un tableau, on pourra écrire t.append(x) pour ajouter la valeur x comme une nouvelle case à la fin du tableau. t.append(x) est une instruction, elle ne renvoie pas un nouveau tableau avec cette modification mais elle modifie directement t. On dit que .append est une méthode de la classe list de t. Il est tout à fait possible d'utiliser Python sans écrire de classes, mais dans la mesure où c'est un langage objet dans son cœur, on manipulera forcément des objets.

Par exemple, la suite d'instructions:

III Manipuler 35

```
t = []
t.append(2)
t.append(3)
```

```
va faire passer l'état de t = [] à t = [2] puis t = [2, 3].
```

Il existe beaucoup de méthodes pour les types list et dict. On les verra selon les besoins dans la suite. Il est toutefois possible, et souhaitable, de se référer à la documentation pour avoir une description détaillée de celles-ci.

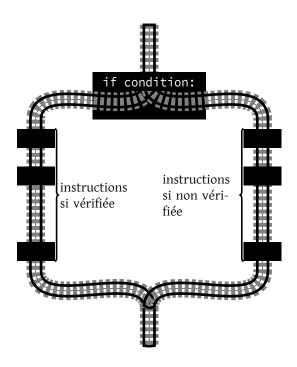
III.6 Instruction conditionnelle

L'instruction conditionnelle va permettre d'enrichir le flot de contrôle avec des branchements. Elle permet d'orienter le flot d'exécution dans un bloc ou dans un autre selon qu'une condition soit vérifiée ou non.

On écrit

```
if condition:
    # bloc si la
    # condition est vérifiée
else:
    # bloc si la
    # condition n'est pas
    # vérifiée
```

Si on reprend l'analogie des trains et des rails, une instruction conditionnelle est un échangeur qui, selon que le train vérifie ou pas la condition va le faire circuler dans une branche ou une autre. Il est important de comprendre qu'une fois une branche exécutée, les flots se rejoignent sur l'instruction qui suit l'instruction conditionnelle.



Il arrive qu'on n'ait rien à faire dans une branche, on peut alors placer un bloc vide, mais, en général, on préfère, quitte à nier la condition, ne pas écrire de else comme dans :

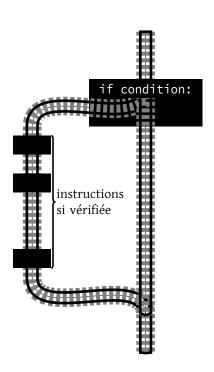
```
if condition:

# bloc si la

# condition est vérifiée

# le flot saute directement ici si

# la condition n'est pas vérifiée
```



■ Remarque 3.1 En Python, un bloc vide se note pass comme dans le programme suivant :

```
if x == 3:
    y = y + 1 # incrémente y si x vaut 3
else:
    pass # ne fait rien sinon

qu'on aurait pu écrire:

if x == 3:
    y = y + 1 # incrémente y si x vaut 3
```

On pourrait être tenter d'écrire l'instruction a priori inoffensive y = y dans le bloc du else, mais une telle assignation n'est jamais gratuite. En effet, pour certaines données, il peut se produire une duplication coûteuse pour la réaliser et c'est une bonne pratique de ne pas écrire des opérations qui, si pour nous elles ne font rien comme y = y + 0, peuvent en fait avoir un coût caché.

Une principe clé de la programmation est la compositionnalité des instructions de gestion

IV Répéter 37

de flot : on peut placer des instructions conditionnelles dans le corps d'une des branches. On pourra donc écrire

```
if condition1:
    if condition2:
        # bloc si condition 1 et condition 2 sont vérifiées
    else:
        # bloc si condition 1 est vérifiée mais condition 2 ne l'est pas
elese:
    if condition2:
        # bloc si condition 1 n'est oas vérifiée et condition 2 l'est
else:
        # bloc si condition 1 et condition 2 ne le sont pas
```

III.6.i Conditions et opérations sur les booléens

Le rôle des conditions est central dans l'usage des instructions conditionnelles et ainsi c'est très important de bien comprendre le fonctionnement des booléens et de leurs opérations.

Une condition est une formule logique constituée

- de formules atomiques portant sur l'état comme x == 3, x < 2, ...
- d'opérateurs booléens pour relier ces formules : not, and ou or

III.6.ii Inversion de point de vue par rapport aux mathématiques

En mathématiques, il est courant d'avoir des définitions de valeurs par cas. Par exemple, on pourrait écrire

$$x = \begin{cases} \frac{y}{2} & \text{si } y \text{ pair} \\ \frac{y-1}{2} & \text{sinon.} \end{cases}$$

On pourrait le traduire alors aisément ainsi :

```
if y % 2 == 0:

    x = y / 2

else:

    x = (y-1) / 2
```

Mais en faisant cela, on a inversé le point de vue en plaçant la condition avant l'affection de

III.6.iii Instructions conditionnelles en cascade

III.7 Entrées et sorties

IV Répéter

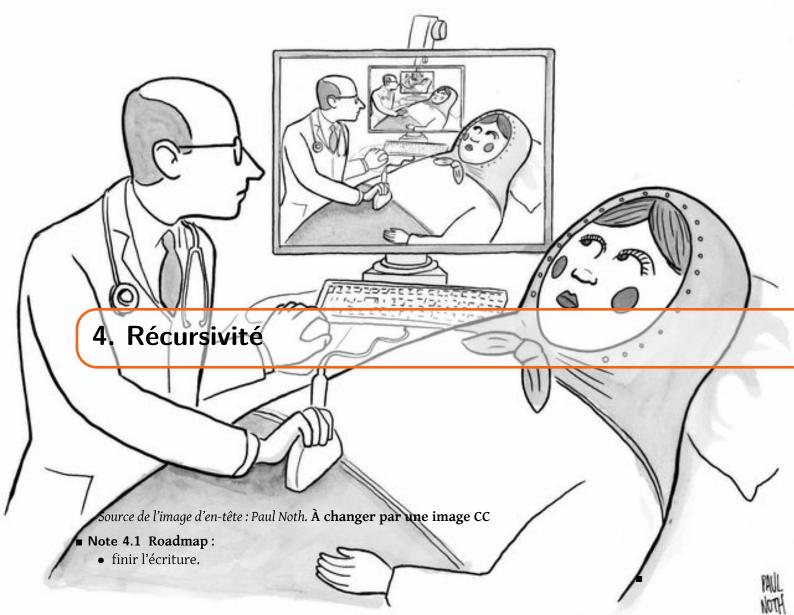
Χ.

Jusqu'ici, on a vu des instructions permettant de manipuler l'état d'exécution, éventuellement de manière différente selon sa valeur à l'aide d'instructions conditionnelles. Mais étant donné un état de départ, on connait déjà les instructions qui seront exécutées et surtout **on connait leur nombre** qui est majoré par le nombre total d'instructions. En effet, pour reprendre l'analogie des trains, ceux-ci ne font que descendre le long du flot et le nombre d'arrêts rencontrés est majoré par le nombre d'arrêts total.

Cependant, la force principale de l'informatique vient du fait qu'on peut, à l'aide d'un nombre d'instructions fini, avoir la potentialité d'exécuter un nombre arbitrairement grand d'instructions. A cette fin, nous allons introduire un élément fondamental : la notion de répétition ou de boucles.

On pourrait être étonné de la formulation précédente sur ce nombre arbitrairement grand car la mémoire, et même le temps d'exécution en pratique, étant fini, tout est borné. Si on considère un programme qui va calculer la somme des éléments d'un tableau et qu'on sait que la longueur d'un tel tableau est majorée, on pourrait imaginer une énorme boucle conditionnelle

- IV.1 Répéter n fois
- IV.2 Répéter pour chaque élément
- IV.2.i Accumulateur
- IV.2.ii Drapeau
 - IV.3 Répéter tant qu'une condition est vérifiée
 - IV.4 Choisir la structure de boucle adaptée
 - IV.5 Boucles imbriquées et dimensionnalité
 - **V** Abstraire
 - V.1 Définir et appeler des fonctions
 - V.2 Action d'une fonction et valeur de retour
 - V.3 Fonctions et portée
 - V.4 Structurer des programmes avec des fonctions
 - V.5 Les fonctions comme valeurs



La récursivité

I.1 Principe et exemples

On dit qu'une fonction est récursive lorsqu'elle va s'appeler elle-même lors de son exécution. Le plus souvent, cet appel sera directement visible depuis le corps de la fonction.

Par exemple, la fonction fact suivante permettant de calculer n! est récursive :

```
def fact(n):
    if n == 0:
        return 1
    else:
        return n * fact(n-1)
```

On utilise ici un exemple mathématique pour la simplicité des fonctions écrites. En effet, on ne voit rien d'autre dans fact que ces appels récursifs et ils correspondent directement à la définition mathématique :

$$n! = egin{cases} 1 & ext{si } n = 0 \\ n imes (n-1)! & ext{sinon.} \end{cases}$$

■ Remarque 4.1 En fait, la définition mathématique se fait plutôt en posant :

$$0! = 1$$
 $(n+1)! = (n+1) \times n!$

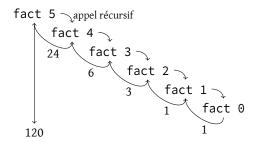
Donc, pour retraduire une telle définition en tant que fonction, il est souvent nécessaire de décaler les rangs.

On remarque tout de suite deux choses:

- il y a un valeur pour laquelle on ne fait aucun appel
- dans les autres cas, quand on fait un appel, l'argument n-1 diminue strictement.

Cela permet d'être sûr qu'on ne va pas s'arrêter indéfiniment. On verra dans la suite comment on peut s'en assurer pour des fonctions plus complexes.

Quand on évalue fact 5 on va effectuer une série d'appels :



Pour calculer la valeur il faut descendre le long des appels récursifs jusqu'à tomber sur un cas de base puis remonter.

I.2 Implémentation pratique

Comme on vient de le voir, pour calculer une valeur avec une fonction récursive, il est nécessaire de remonter. Pour cela, on a besoin d'interrompre l'évaluation d'une fonction le temps que l'appel récursif se termine, puis de revenir dans l'évaluation là où on en était. On parle alors de contexte d'évaluation ou contexte d'exécution pour l'information qu'il faut sauvegarder afin de reprendre là où on en était. En première approximation, on peut se dire qu'un contexte est la donnée de la position de l'instruction courante, ou de la sous-expression en train d'être évaluée si on raisonne en fonctionnel, ainsi que de l'ensemble des valeurs des variables locales. Il est donc nécessaire de sauvegarder la succession des contextes tout au long des appels récursifs.

On remarque que ce mécanisme est déjà présent pour n'importe quel appel de fonction. La différence principale avec la récursivité, c'est que le nombre d'appels imbriqués à tout moment du programme n'est pas borné à priori, il dépend des paramètres récursifs, et donc il ne peut être connu qu'à l'exécution. On a ainsi besoin d'un mécanisme qui permettent de stocker un nombre quelconque de contextes.

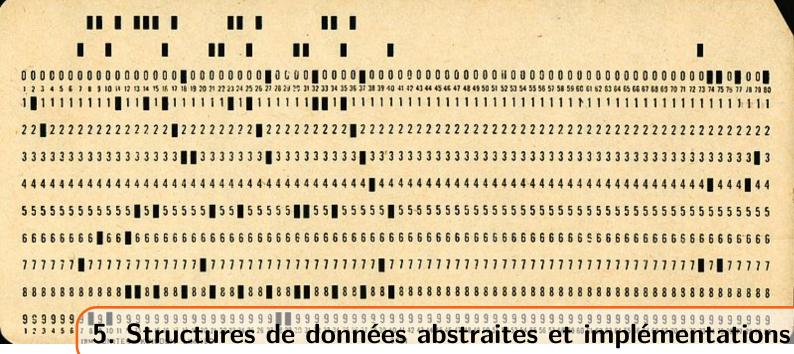
Pour cela, on passe par ce qu'on appelle la pile d'appels. On verra plus tard qu'elle peut être organisée de manière très efficace pour des programmes binaires, mais pour le moment, on se contente d'imaginer que cette pile est vide au début de l'evaluation, puis, à chaque appel, on **empile** le contexte courant, on exécute l'appel, une fois la valeur de retour obtenue, on **dépile** le contexte pour reprendre l'exécution là où on en était avant l'appel mais avec cette valeur de retour calculée.

II L'arbre d'appels 41

- **I.3** Programmer en récursif
- I.4 Récursivité croisée
- II L'arbre d'appels
- II.1 Définition
- II.2 Complexité en nombre d'appels
- II.3 Terminaison
- **III** Récursivité terminale
- III.1 Présentation
- III.2 Optimisation
- III.3 Techniques
 - IV Types inductifs et induction structurelle
- IV.1 Définition naïve des types inductifs

Structures de données

5	Structures de données abstraites et implémentations
I	Introduction
II	Structure de données abstraite
6	Séquences et ses implémentations : ta-
	bleaux, listes chaînées 47
I	Structure abstraite séquence ou liste
II	Implémentations
Ш	Implémentations concrètes des Listes chaînées
7	Piles et files : structures abstraites et implémentations
8	Séquences et ses implémentations : ta-
	bleaux, listes chaînées 59
I	Implémentation des Listes chaînées
9	Séquences et ses implémentations : ta-
	bleaux, listes chaînées
ı	Implémentation des Listes chaînées
1	implementation des Listes chamees



Introduction

On va étudier dans ce chapitre la notion de structures de données. Une structure de données est une manière de stocker des données et d'interagir avec elles. On peut regrouper de grandes classes de structures données en faisant abstraction de la manière dont les données sont stockées en se concentrant uniquement sur les interactions possibles. Cela permet de définir la notion d'une structure de données abstraites.

Dans un second temps, on s'intéresse à la notion d'implémentation d'une structure de données abstraites qui correspond à un choix concret de stockage et donc à une réalisation de l'interface attendue.

Il Structure de données abstraite

Définition II.1 On appelle structure de données abstraite la donnée d'un type t et d'une interface

- Structure abstraite séquence ou liste
- **II** Implémentations
- III Implémentations concrètes des Listes chaînées
- III.1 En C
- III.1.i Représentation et type

Il existe de nombreuses possibilités d'implémentation des listes chaînées en C. On présente ici les opérations autour d'une implémentation et on discutera ensuite des alternatives.

Dans les limites du programme, on ne présente que des listes permettant de contenir un même type, ici des entiers.

Une liste est ainsi un pointeur sur un maillon et un maillon est un couple (valeur, suivant) représenté dans une struct où suivant pointe vers le prochain maillon de la chaîne. Le pointeur nul, de valeur NULL, permet ainsi de représenter la liste vide.

```
struct maillon {
    int valeur;
    struct maillon *suivant;
};
typedef struct maillon maillon;
typedef maillon *liste;
```

On représentera graphiquement le pointeur nul par une croix et les maillons par des blocs contenant une valeur et un pointeur. Ainsi, le dernier maillon de la liste contient une croix. La liste l correspondant à la valeur qu'on pourrait noter [1,2,3] sera représentée ainsi:



III.1.ii Constructeur

On parle de constructeur pour des fonctions qui permettent d'allouer et d'initialiser une valeur d'une structure de donnée. Ici, comme les listes sont des pointeurs sur des maillons, il s'agit uniquement de créer un maillon. Pour cela, on va utiliser malloc pour allouer dynamiquement un nouveau maillon.

```
maillon *maillon_creer(int valeur, maillon *suivant)
{
    maillon *m = malloc(sizeof(maillon));
    m->valeur = valeur;
    m->suivant = suivant;
    return m;
}
```

En fait, ce constructeur pourrait être découpé en deux parties : l'allocation qui va se charger de récupérer un emplacement mémoire pour le maillon et l'initialisation qui va attribuer des valeurs.

```
maillon *maillon_allouer()
{
    return malloc(sizeof(maillon));
}

void maillon_initialiser(maillon *m, int valeur, maillon *suivant)
{
    m->valeur = valeur;
    m->suivant = suivant;
}

maillon *maillon_creer(int valeur, maillon *suivant)
{
    maillon *m = maillon_allouer();
    maillon_initialiser(m, valeur, suivant);
    return m;
}
```

On peut alors commencer à créer des listes en enchainant les maillons :

```
maillon *m1 = creer_maillon(1, NULL); // pas de suivant, c'est le dernier maillon
maillon *m2 = creer_maillon(2, m1);
maillon *m3 = creer_maillon(3, m2);
liste l = m3; // la liste pointe sur le premier maillon
```

Comme le pointeur sur le premier maillon suffit ici, on aurait pu directement écrire :

```
liste l = creer_maillon(3,
creer_maillon(2,
creer_maillon(1, NULL)));
```

III.1.iii Destructeur

Pour détruire un maillon, il suffit de libérer l'espace qu'on lui a attribué.

```
void maillon_detruire(maillon *m)
{
```

```
free(m);
}
```

Pour détruire une liste, on va par contre avoir besoin de parcourir l'ensemble des maillons qui la constitue. Comme pour les autres parcours, on a alors deux choix :

• parcours récursif on a un cas de base quand la liste est vide et dans le cas général, un éventuel appel récursif sur le pointeur suivant.

```
void liste_detruire(liste l)
{
    if (l != NULL)
    {
        liste_detruire(l->suivant);
        maillon_detruire(l); // Attention à l'ordre pour l->suivant
    }
}
```

• parcours impératif on boucle tant que la liste est non nulle. On fait ici attention à ne pas accéder à ->suivant après avoir libéré le maillon.

```
void liste_detruire(liste l)
{
    while (l != NULL)
    {
        liste suivante = l->suivant;
        maillon_detruire(l);
        l = suivante;
    }
}
```

III.1.iv Ajout et suppression en tête

Pour ajouter ou supprimer un maillon en tête de la liste, on va avoir besoin de modifier le pointeur vers le premier maillon. Pour cela, on a deux approches possibles :

• passer un pointeur vers la liste elle-même, c'est-à-dire un pointeur sur un pointeur sur un maillon, ce qui en C aura le type maillon **, qui s'écrit aussi liste *. On aura alors le prototype:

```
void liste_ajout_en_tete(liste *l, int valeur);
```

• renvoyer un pointeur vers le nouveau premier maillon. On aura alors le prototype :

```
oliste liste_ajout_en_tete(liste l, int valeur);
```

On présente ici les versions renvoyant une nouvelle liste :

```
liste liste_ajout_en_tete(liste l, int valeur)
{
    maillon *m = maillon_creer(valeur, l);
    return m;
}
liste liste_suppr_en_tete(liste l)
{
```

```
assert(l != NULL);
liste queue = l->suivant;
maillon_detruire(l); // Attention, on détruit juste le maillon, pas la liste
return queue;
}
```

III.1.v Longueur de la liste

On présente ici le calcul de la longueur comme exemple de parcours de la liste. C'est encore très proche du parcours effectué dans le destructeur.

```
int liste_longueur(liste l)
{
    int longueur = 0;
    while(l != NULL)
    {
       longueur = longueur + 1;
       l = l->suivant;
    }
    return longueur;
}
```

III.1.vi Accès au nième maillon de la liste

On effectue un parcours similaire pour accéder au nième maillon.

```
maillon *liste_nieme(liste l, int n)
{
    while(n > 0)
    {
        assert(l != NULL);
        l = l->suivant;
        n = n-1;
    }
    assert(l != NULL);
    return l;
}
```

Toujours avec un programme similaire, on peut chercher un maillon avec sa valeur:

```
maillon *liste_recherche(liste l, int x)
{
    while(l != NULL && l->valeur != x)
    {
        l = l->suivant;
    }
    return l;
}
```

Ici, pas besoin d'asserts, en cas d'échec de la recherche, on renvoie un pointeur nul.

III.1.vii Ajout/Suppression ailleurs qu'en tête

Pour ajouter ou supprimer ailleurs qu'en tête, il est nécessaire de pouvoir repérer précisément un maillon. Pour cela, on peut le faire :

- par son indice, celui utilisé dans liste_nieme;
- par sa valeur, avec une recherche;
- ou encore directement par un pointeur sur le maillon.

Une fois le maillon supprimé, on peut procéder comme pour un ajout/suppression en tête, cependant il va falloir reconnecter le pointeur suivant du maillon précédent et pour cela on garde dans la boucle du parcours un pointeur vers ce maillon.

```
void liste_ajout_non_en_tete(liste l, maillon *m, int x)
{
    liste prec = NULL;

    while(l != m)
    {
        assert(l != NULL);
        prec = l;
        l = l->suivant;
    }
    prec->suivant = liste_ajout_en_tete(m, x);
}

void liste_suppr_non_en_tete(liste l, maillon *m)
{
    liste prec = NULL;

    while(l != m)
    {
        assert(l != NULL);
        prec = l;
        l = l->suivant;
    }
    prec->suivant = liste_suppr_en_tete(m);
}
```

En fait, lorsqu'on regarde le parcours précédent, on remarque deux points :

- comme on a donné le maillon concerné, le parcours a uniquement pour but de repérer le maillon qui le précède;
- on pourrait se contenter d'utiliser uniquement un pointeur sur le maillon précédent lors du parcours car le maillon qui le suit est accessible avec ->suivant.

III.1.viii Autres implémentations

Une autre implémentation standard consiste à *cacher* le pointeur sur le premier maillon, ce qui permet de donner également un pointeur sur le dernier maillon. En effet, le pointeur sur le dernier maillon permet de réaliser un ajout en fin de liste en O(1) car il n'y a pas besoin de parcourir la liste pour faire cet ajout.

On obtient alors un type comme:

```
struct maillon {
    int valeur;
    struct maillon *suivant;
};
typedef struct maillon maillon;

struct liste {
    maillon *premier;
    maillon *dernier;
};
typedef struct liste liste;
```

III.2 En OCaml

III.2.i Cas des 'a list

Tout d'abord, il faut se rendre compte que le type par défaut

```
type 'a list = (::) of 'a * 'list | []
```

fait intervenir des maillons et des pointeurs. La différence principale avec C est qu'on ne peut pas changer la valeur des pointeurs.

III.2.ii Type des listes chaînées

Pour retrouver la richesse du type précédent, on peut définir un type comme :

```
type 'a maillon = {
    mutable valeur : 'a;
    mutable suivant : 'a liste
} and 'a liste = Vide | Lien of 'a maillon
```

Ici, le type est une traduction directe du type précédent. On remarque que les types sont mutuellement récursifs car un maillon contient une liste. Le type somme 'a liste ressemble fortement à un pointeur qui peut être nul ou pointer sur un maillon. On remarque qu'on aurait pu aussi se contenter d'écrire le type suivant :

```
type 'a maillon = {
    mutable valeur : 'a;
    mutable suivant : 'a maillon option
}

type 'a liste = 'a maillon option
```

Mais on va préférer le premier type qui a l'avantage de permettre de bien faire apparaître la structure.

III.2.iii Ajout et suppression en tête

Pour rajouter un maillon en tête, on peut écrire :

```
let cons x l = Lien { valeur = x; suivant = l}
```

On remarque que la fonction est beaucoup plus simple que celle en C car l'allocation est automatique et l'initialisation se fait naturellement dans la syntaxe. Cette fonction renvoie une nouvelle liste, on aurait pu aussi rajouter une référence pour les listes afin de permettre de les rendre modifiables, c'est la même discussion que dans la partie précédente.

La suppression en tête, cela revient à renvoyer la queue de la liste comme le fait List.tl:

```
let tl l = match l with
| Vide -> failwith "Liste vide"
| Lien { valeur = _; suivant = q} -> q
```

On remarque le filtrage imbriqué | Lien { valeur = t; suivant = q } qui correspond au filtrage | t :: q du type a list.

III.2.iv Exemple de parcours sans modification : calcul de la longueur

Vu les remarques précédentes, il n'est pas étonnant que le parcours d'une liste de manière récursive soit très proche de ce qu'on a déjà pu voir avec les listes de base.

```
let rec longueur l = match l with
| Vide -> 0
| Lien { valeur = _; suivant = q } -> 1 + longueur q
```

On en déduit de même une fonction renvoyant un maillon par son indice :

```
let rec nieme l n = match l with
| Vide -> failwith "Liste vide"
| Lien m -> if n = 0 then m else nieme m.suivant (n-1)
```

■ Remarque 6.1 Il est possible de réecrire la fonction précédente en permettant à la fois de donner un nom, ici m, au maillon et de faire un filtrage sur ce qu'il contient. Pour cela, on utilise le mot clé as en OCaml :

```
let rec nieme l n = match l with

| Vide -> failwith "Liste vide"

| Lien ({ valeur=_; suivant = q} as m) ->

if n = 0 then m else nieme q (n-1)
```

III.2.v Exemple de parcours avec modification : ajout d'une maillon en fin de liste

On va montrer un exemple de modification de liste en rajoutant un maillon en fin d'une liste non vide. Ici, on effectue un parcours jusqu'à tomber sur le dernier maillon auquel on rajoute le nouveau à la suite.

```
let rec ajout_fin l x =
    match l with
    | Vide -> failwith "Liste vide"
    | Lien m ->
        if m.suivant = Vide
        then m.suivant <- Lien { valeur = x; suivant = Vide }
        else ajout_fin m.suivant x</pre>
```

III.2.vi Raffinement pour permettre l'ajout à la fin en temps constant

Le programme précédent est à comparer au programme suivant :

```
let rec ajout_fin l x =
    match l with
    | [] -> [x]
    | t::q -> t :: ajout_fin q x
```

On n'a pas l'impression d'avoir vraiment gagné en expressivité ou en efficacité.

Cependant, on peut se dire qu'en changeant le type 'a liste on peut tirer partie des maillons pour obtenir un ajout en fin de liste en temps constant. Le programme suivant présente une interface permettant de le faire.

```
type 'a maillon = {
    mutable valeur : 'a;
    mutable suivant : 'a maillon_ptr
    }
and 'a maillon_ptr = 'a maillon option
```

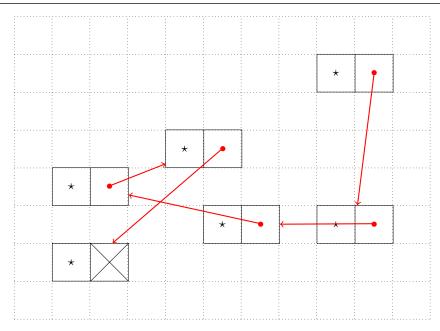
```
and 'a liste = {
      mutable premier : 'a maillon_ptr;
      mutable dernier : 'a maillon_ptr
  }
let liste_vide () = { premier = None; dernier = None }
let ajout_debut l x =
    l.premier <- Some { valeur = x; suivant = l.premier };</pre>
    if l.dernier = None
    then l.dernier <- l.premier
let suppr_debut l =
    match l.premier with
    | None -> failwith "Liste vide"
    | Some { valeur = _; suivant = l' } ->
            l.premier <- l'</pre>
let ajout_fin l x =
    let m = { valeur = x; suivant = None } in
    (match l.dernier with
     Some m' -> m'.suivant <- Some m
    | None -> () );
    l.dernier <- Some m;</pre>
    if l.premier = None
    then l.premier <- l.dernier
```

Quelques remarques sur ce programme:

- comme on change directement premier et dernier, il est nécessaire de générer une nouvelle liste vide, ce qui est assuré ici par le paramètre ();
- les pointeurs sont représentés par des options dans des champs mutables;
- afin de préserver l'intégrité des deux pointeurs, on est obligé de gérer les cas où il n'y a qu'un seul maillon;
- attention à la priorité du cas de filtrage sur ; qui oblige à mettre des parenthèses dans ajout_fin.

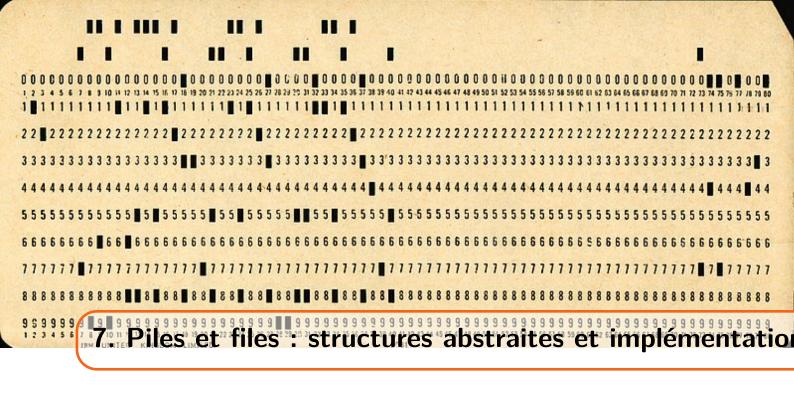
III.3 Structure de la mémoire

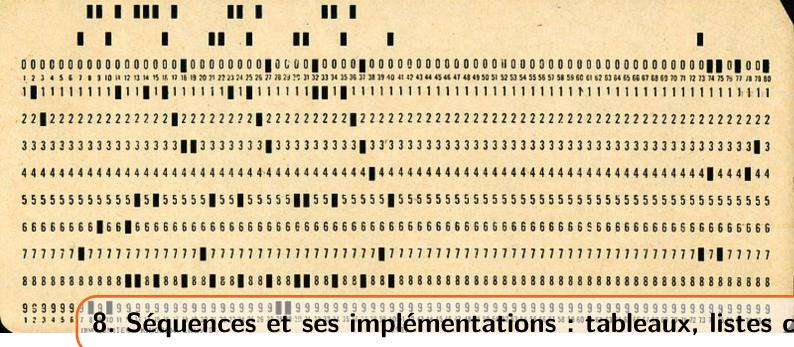
En mémoire, les maillons d'une liste chaînée, comme celle vue en C, sont sur le tas et de manière désorganisée. Cela signifie qu'il n'y a aucune raison que deux maillons proches dans une liste soient proches en mémoire.



Or, les processeurs optimisent la gestion de la mémoire à l'aide d'un cache qui, au lieu de n'accéder qu'à une seule valeur située à une adresse, va charger une zone mémoire autour de cette adresse. Ceci encourage une cohérence spatiale dans l'organisation de la mémoire afin de profiter au maximum de cette mise en cache.

Une stratégie pour réaliser des listes chaînées efficacement consiste à allouer un tableau de maillons et à gérer ensuite les allocations parmi cette réserve.





I Implémentation des Listes chaînées

I.1 En C

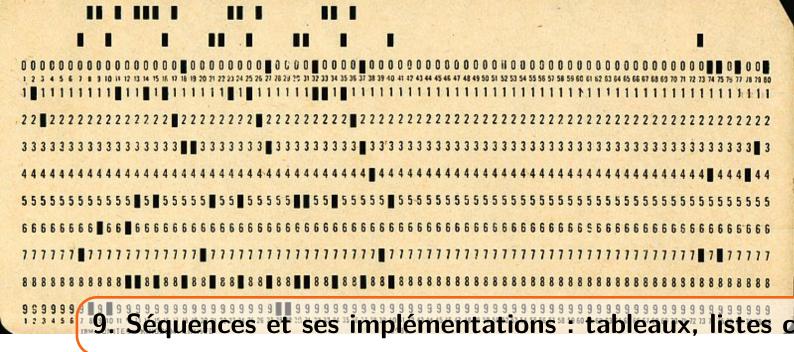
```
struct maillon {
    int valeur;
    struct maillon *suivant;
};
typedef struct maillon maillon;
typeder maillon *liste;
```

I.2 En OCaml

Tout d'abord, il faut se rendre compte que le type par défaut

```
type 'a list = (::) of 'a * 'list | []
```

fait en fait intervenir des maillons et des pointeurs.



I Implémentation des Listes chaînées

I.1 En C

```
struct maillon {
    int valeur;
    struct maillon *suivant;
};
typedef struct maillon maillon;
typeder maillon *liste;
```

I.2 En OCaml

Tout d'abord, il faut se rendre compte que le type par défaut

```
type 'a list = (::) of 'a * 'list | []
```

fait en fait intervenir des maillons et des pointeurs.

Algorithmique

10 	Introduction à l'analyse des algorithmes État d'un programme Terminaison Correction Complexité Exercices	65
11 	Algorithmique exacte Recherche par force brute Algorithmes gloutons Diviser pour régner Programmation dynamique	89
12 	Algorithmique des textes	117





10. Introduction à l'analyse des algorithmes

Source de l'image d'en-tête XKCD #1667

■ Note 10.1 Roadmap:

- reprendre les exemples dans les trois langages.
- rajouter plus exercices.
- Remarque 10.1 Ce chapitre présente les trois grands principes qui nous serviront de guide pour analyser les algorithmes et les programmes :
 - La **terminaison**: l'algorithme termine-t-il au bout d'un nombre fini d'étapes quelle que soit l'entrée?
 - La **correction** : le résultat rendu est-il celui qui était attendu?
 - La **complexité** : combien de temps prend le programme selon la taille de l'entrée ? Combien d'espace mémoire occupe-t-il ?

Savoir répondre à ces questions, c'est pouvoir prédire, avant d'avoir écrit la moindre ligne de code, ce qui va se passer.

État d'un programme

Avant de commencer à raisonner sur les algorithmes, il est nécessaire de préciser la notion d'état qui correspond à un instantané de l'environnement d'exécution d'un programme lorsque son exécution est interrompue. Bien entendu, la description complète d'un tel état ne serait pas forcément pertinent, car cela prendrait en compte l'ensemble de la mémoire. Le plus souvent, on considère uniquement ce qui est important pour ce qu'on étudie.

Ainsi, si on considère le programme suivant :

```
int a = 3;
int b = 2;
a = b;
```

L'état du programme à l'entrée de la ligne 4 est

variable	valeur
a	3
b	2

et l'état à la sortie de la ligne 4 est

a	2
b	2

Parfois, on aura besoin de plus d'information dans l'état comme la position en mémoire de certaines données. Mais assez souvent, pour les algorithmes qui nous intéressent, on pourra adopter un point de vue assez abstrait de l'état d'un algorithme comme étant une fonction partielle des noms vers les valeurs.

Pour la terminaison et la correction, on va considérer des propriétés logiques dépendant de l'état. Par exemple $a \geq 0 \land b \geq a$.

II Terminaison

Définition II.1 On dit qu'un algorithme **termine** quand il n'exécute qu'un nombre fini d'étapes sur toute entrée.

■ Remarque 10.2 Cela n'empêche pas que ce nombre d'étapes puisse être arbitrairement grand en fonction des entrées.

Un algorithme qui n'utilise ni boucles inconditionnelles ni récursivité termine toujours. Ainsi, la question de la terminaison n'est à considérer que dans ces deux cas.

Considérons par exemple l'algorithme suivant qui, étant donné un entier naturel n strictement positif, inférieur à 2^{30} , détermine le plus petit entier k tel que $n \le 2^k$:

```
def plus_grande_puissance2(n):
    k = 0
    p = 1

while p < n:
    k = k+1
    p = p*2

return k</pre>
```

On remarque que p prend successivement pour valeurs toutes les puissances de 2 jusqu'à une éventuelle sortie de boucle. Or, il existe une puissance de 2 supérieure ou égale à n, donc, une fois atteinte, la condition de la boucle while n'est plus remplie et l'algorithme termine.

II Terminaison 67

■ Remarque 10.3 Prouver la terminaison n'est pas une question facile, elle peut-même être insoluble. Par exemple, si on considère le programme suivant :

être capable de prouver sa terminaison revient à prouver la conjecture de Collatz (encore dite de Syracuse).

On peut aussi considérer le tri suivant :

```
def bogo(t):
    while not est_trie(t):
    melange(t)
```

Il semble très improbable que cet algorithme ne termine pas, d'ailleurs on peut prouver qu'il termine avec probabilité 1, mais on ne peut pas exclure le cas où il mélange indéfiniment.

II.1 Variant de boucle

Pour prouver la terminaison d'une boucle conditionnelle, on utilise un variant de boucle.

Définition II.2 Un **variant de boucle** est une quantité entière **positive** à l'entrée de chaque itération de la boucle et qui diminue **strictement** à chaque itération.

Dans l'exemple précédent, la quantité n-p est un variant de boucle :

- Au départ, n > 0 et p = 1 donc n p > 0
- Comme il s'agit d'une différence de deux entiers, c'est un entier. Et tant que la condition de boucle est vérifiée p < n donc n-p > 0.
- Lorsqu'on passe d'une itération à la suivante, la quantité passe de n-p à n-2p or 2p-p>0 car $p\geq 1$. Il y a bien une stricte diminution.
- Remarque 10.4 Ici, en sortie de boucle, $n-p \le 0$. On fait donc bien attention de préciser que la quantité est positive tant que la condition de boucle est vérifiée.

Si on a un variant de boucle qui vaut initialement n avant d'entrer dans la boucle, celle-ci effectue au plus n itérations car le variant diminue au moins de 1 à chaque étape.

Théorème II.1 Si une boucle admet un variant de boucle, elle termine.

II.2 Exemple de la recherche dichotomique

On considère ici la recherche dichotomique dans un tableau trié d'entiers. Étant donné un tableau t de taille n>0 et un entier x dont on cherche à déterminer sa présence dans le tableau entre les indices i et j, on considère l'algorithme suivant :

- Si i > j, alors il n'y a pas de sous-tableau et on renvoie false.
- Sinon, soit m l'élément d'indice $p = \left\lfloor \frac{i+j}{2} \right\rfloor$.
 - \star Si x=m, on renvoie true
 - \star Si x < m, on continue la recherche dans le sous-tableau des indices i à p-1.
 - \star Si x > m, on continue la recherche dans le sous-tableau des indices p + 1 à j.

Le programme suivant présente une implémentation de cet algorithme en C.

```
def rech_dicho(t, x):
    i = 0
    j = len(t) - 1

while i <= j:
    p = (i+j)//2
    m = t[p]
    if x == m:
        return p
    elif x < m:
        j = p-1
    else:
        i = p+1

return None</pre>
```

■ Remarque 10.5 On aurait pu écrire i+(j-i)/2 et non (i+j)/2 afin d'éviter des erreurs de dépassement dans le calcul de i+j.

Ici, la terminaison n'est pas immédiate, on va la prouver à l'aide d'un variant de boucle. On considère ainsi la quantité d(i,j)=j-i.

- Comme le tableau est non vide, $d(0, n-1) \ge 0$. Ensuite, la condition de boucle est équivalente à $d(i,j) \ge 0$, donc cette quantité est bien entière et positive à l'entrée de chaque itération.
- Quand on passe à l'itération suivante, on passe
 - \star soit de d(i,j) à d(i,p-1). Or $d(i,p-1)=p-1-i=\left\lfloor\frac{i+j}{2}\right\rfloor-1-i<\frac{i+j}{2}-i\leq j-i=d(i,j)$.
 - $\star \text{ soit de } d(i,j) \text{ à } d(p+1,j). \text{ Or } d(p+1,j) = j-p-1 = j-\left\lfloor \frac{i+j}{2} \right\rfloor -1 < j-\frac{i+j}{2} \leq j-i = d(i,j).$

Dans tous les cas, d(i, j) diminue strictement.

Ainsi, il s'agit d'un variant de boucle et l'algorithme termine.

■ Remarque 10.6 On remarque que le programme récursif suivant réalise également cet algorithme.

II Terminaison 69

```
(* rech_dicho : int array -> int -> int -> int option *)
let rec rech_dicho t i j x =
    if i <= j
    then let p = (i+j)/2 in
        let m = t.(p) in
        if x = m
        then Some p
        else if x < m
        then rech_dicho t i (p-1) x
        else rech_dicho t (p+1) j x
        else None</pre>
```

Il suffit alors d'appeler rech_dicho t 0 (Array.length t - 1) x pour faire une recherche sur tout le tableau.

Ici, il n'y a pas explicitement de boucle, mais le même principe peut être mis en place pour prouver que le nombre d'appels récursifs est majoré, et donc que toute exécution termine. En effet, la quantité d(i,j)=j-i diminue pour les mêmes raisons à chaque appel récursif et reste entière positive.

II.3 Exemple du tri à bulle

On considère le tri à bulles dans une implémentation naïve. On effectue ainsi une série de balayages d'un tableau : on parcourt le tableau de gauche à droite et si deux éléments consécutifs sont dans le désordre, on les permute. À l'issu d'un tel balayage, si on a effectué au moins un échange, on recommence, sinon on s'arrête, car c'est le signe que le tableau est trié qu'on le prouvera à la fin de ce paragraphe.

On obtient alors le code suivant :

Si la question de la terminaison de la boucle for ne se pose pas, celle de la boucle while mérite de s'y attarder pour deux raisons :

- premièrement pour la terminaison elle-même
- deuxième pour savoir si on peut majorer le nombre d'itérations, une question qu'on reverra avec la question de la complexité.

On va prouver la terminaison pour un type d'algorithme de tri qui généralise le tri à bulle. Pour cela, on commence par définir la notion d'inversion pour un tableau t de |t| éléments :

Définition II.3 On dit qu'un couple $(i, j) \in [0, |t| - 1,]$ 2 est une **inversion** pour t si i < j et t[i] > t[j].

On note Inv(t) l'ensemble des inversions de t et inv(t) = |Inv(t)| le nombre d'inversions.

On dira qu'une inversion de la forme (i, i + 1) est une **inversion directe**.

On considère donc un algorithme qui résout une inversion directe dès qu'il y en a au moins une.

```
def tri(t):
    while existe_inversion_directe(t):
        i = debut_d_une_inversion_directe(t)
        echange(t, i, i+1)
```

Le tri à bulles est alors une manière de réaliser l'algorithme précédent en effectuant des inversions alors qu'on avance dans le tableau.

Théorème II.2 Pour un tableau t les propositions suivantes sont équivalentes :

- 1. t est trié dans l'ordre croissant
- 2. t n'a pas d'inversions
- 3. t n'a pas d'inversions directes

Démonstration. • 1) \rightarrow 3) naturellement si t es trié dans l'ordre croissant, i < i + 1 entraine $t[i] \le t[i+1]$, donc il ne peut il y avoir d'inversions directes.

- 2) \rightarrow 1) si i < j, comme t n'a pas d'inversions, on a $t[i] \not> t[j]$, c'est-à-dire $t[i] \le t[j]$. Ainsi, le tableau est bien trié dans l'ordre croissant.
- 3) \rightarrow 2) pour tout i < |t| 1 on a $t[i] \le t[i+1]$. Soit i < j, on variasonner par récurrence sur j i pour montrer que $t[i] \le t[j]$.
 - \star si j-i=1, on n'a pas d'inversion directe donc $t[i] \leq t[j]$.
 - * si j i > 1 et que $t[i] \le t[j 1]$, car i < j 1 avec j 1 i = (j i) 1, alors $t[i] \le t[j 1] \le t[j]$ car (j 1, j) n'est pas une inversion.

Ainsi, dans tous les cas on a bien $t[i] \leq t[j]$. Donc, t est trié par ordre croissant.

- II.4 Lien avec la récursivité
- II.5 Boucles imbriquées
- **III** Correction

Pour parler de correction d'un algorithme, il est nécessaire d'identifier précisément ce qui doit être calculé par l'algorithme. Pour cela, on considère ici informellement des spécifications dépendant des entrées et du résultat de l'algorithme. On verra dans le chapitre sur la logique qu'il s'agit ici de prédicats logiques.

Voici des exemples de spécifications :

- le tableau t en sortie est trié dans l'ordre croissant
- la valeur renvoyée est le plus petit indice de x dans le tableau ou -1 s'il ne le contient pas.

III Correction 71

Définition III.1 Un algorithme est **correct** vis-à-vis d'une spécification lorsque quelle que soit l'entrée

- il termine
- le résultat renvoyé vérifie la spécification.

On considère également la correction partielle en l'absence de terminaison :

Définition III.2 Un algorithme est **partiellement correct** vis-à-vis d'une spécification lorsque quelle que soit l'entrée le résultat renvoyé vérifie la spécification.

III.1 Invariant de boucle

Définition III.3 On considère ici une boucle (conditionnelle ou non).

Un prédicat est appelé un invariant de boucle lorsque

- il est vérifié avant d'entrer dans la boucle
- s'il est vérifié en entrée d'une itération, il est vérifié en sortie de celle-ci.

Quand la boucle termine, on déduit alors que l'invariant est vérifié en sortie de boucle. On cherche donc un invariant qui permette de garantir la spécification en sortie de boucle.

■ Remarque 10.7 Pour les boucles inconditionnelles, il y a une gestion implicite de l'indice de boucle qui va se retrouver dans l'invariant. On peut alors considérer que la sortie de boucle s'effectue après être passé à l'indice suivant.

Dans le cas d'une boucle conditionnelle portant sur la condition P et ayant un invariant de boucle I, en sortie le prédicat $\neg P \land I$ (non P et I) sera vérifié.

On peut illustrer cela en reprenant la fonction plus_grande_puissance2 vue à la partie Terminaison. On considère ici le prédicat $I(k,p):=2^{k-1}< n$ et $p=2^k$.

- En entrée de boucle, on a bien $2^{-1} < n$.
- Si le prédicat est vérifié en entrée d'itération. On a alors $2^{k-1} < n$ et comme on est entrée dans cette itération $p=2^k < n$. Donc en sortie d'itération on aura bien I(k+1,2p), car $2p=2^{k+1}$.

Ainsi, ce prédicat est bien un invariant et en sortie de boucle (ce qui arrive nécessairement, car l'algorithme termine), le prédicat I(k,p) signifie que $2^{k-1} < n$ et la condition de sortie de boucle qu'on a $n < 2^k$.

La valeur renvoyée est bien k tel que $2^{k-1} < n \le 2^k$ ce qui était la spécification annoncée du programme.

III.2 Exemple du tri par sélection

Le programme suivant présente un algorithme de tri, appelé le *tri par sélection* dont on va analyser la complexité. Il s'agit d'un tri qui repose sur un principe simple, on va chercher le plus petit élément du tableau à trier et le placer à la position courante. On définit ainsi trois fonctions :

- echange réalise l'échange de valeurs entre deux cases du tableau
- indice_minimum renvoie l'indice de la plus petite valeur entre deux indices donnés
- tri_par_selection réalise le tri en parcourant le tableau du premier au dernier indice et en plaçant à la position courante le minimum restant.

```
void echange(int *tableau, int i, int j)
{
    int temp = tableau[i];
    tableau[i] = tableau[j];
```

Il n'y a pas de problèmes de terminaison ici, car toutes les boucles sont inconditionnelles. Pour prouver sa correction, on va considérer séparément les deux boucles.

- Boucle dans indice_minimum: on va valider l'invariant $I(i,j) := \forall k \in [\![i,j-1]\!]$, tableau $[i] \leq$ tableau[k].
 - \star En entrée de boucle, on a $I(\min_i indice, \min_i indice + 1)$ vérifié directement.
 - \star Si en entrée d'itération, I(i,j) est vérifié, ce qui signifie que tableau[i] est plus petit que les valeurs compris entre les indices i et j-1. Alors, on distingue deux cas :
 - soit tableau[j] < tableau[i] et alors en sortie i devient i'=j. On a alors tableau[i'] = tableau[j] < tableau[i] ≤ tableau[k] pour $k \in [1, j-1]$. Donc I(i', j+1) est vérifié.
 - soit tableau $[i] \le$ tableau[j] et ainsi on a pu prolonger le prédicat à I(i,j+1). Ce prédicat est bien un invariant. Ainsi, en sortie de boucle, et donc avant de renvoyer sa valeur, on a bien I(i, taille) donc tableau[i] est la plus petite valeur du tableau.
- Boucle dans tri_par_selection: on va valider l'invariant T(i) := le sous-tableau tableau [0..i-1] des indices 0 à i 1 est trié et ne contient que des valeurs plus petites que celles du sous-tableau tableau [i..taille-1].
 - * En entrée de boucle, le sous-tableau est vide donc trié.
 - \star Si en entrée d'itération, le prédicat est vérifié. On récupère l'indice j du minimum du sous-tableau [i.taille-1] à l'aide la fonction indice_minimum, par hypothèse tableau[j] est alors supérieur ou égal à chaque élément de tableau [0.i-1], en le plaçant à l'indice i, on a bien tableau [0.i] qui est trié et par construction la valeur de tableau[i] est inférieure à toutes celels de tableau[i+1.taille-1]. On a ainsi T(i+1) vérifié en sortie d'itération.

Ce prédicat est bien un invariant. Ainsi, en sortie de boucle, $T({\sf taille})$ est vérifié : le tableau est trié.

IV Complexité

IV Complexité 73

Complexité dans le pire des cas

Considérons un algorithme pour lequel on peut associer à chaque entrée une notion de taille (par exemple le nombre d'éléments d'un tableau). Pour $n \in \mathbb{N}$, on note ainsi I_n l'ensemble des entrées de taille n pour cet algorithme. Pour une entrée e, on note t(e) le temps pris, par exemple en seconde, par l'algorithme sur l'entrée e. De même, on note s(e) l'espace mémoire maximal, par exemple en octets, occupé par l'algorithme au cours de cette exécution sans compter la taille des entrées.

Définition IV.1 On appelle :

- complexité temporelle dans le pire des cas, la suite $(C_n^t)_{n\in\mathbb{N}}$ telle que pour tout $n\in$
- \mathbb{N} , $C_n^t = \max_{e \in I_n} t(e)$.

 complexité spatiale dans le pire des cas, la suite $(C_n^s)_{n \in \mathbb{N}}$ telle que pour tout $n \in \mathbb{N}$, $C_n^s = \max_{e \in I_n} s(e).$

Comme on va le voir, calculer explicitement ces suites n'a pas beaucoup d'intérêt tant elles sont dépendantes de la manière dont on mesure le temps et l'espace. Ce qui compte ici, c'est de connaître l'ordre de grandeur de ces complexités en fonction de n.

Pour un tableau de taille n, ce programme va effectuer n itérations et sa complexité est ainsi de l'ordre de n. Il est possible d'être très précis en considérant les temps pris

- pour mettre en place l'appel de fonction et le passage des arguments
- par la gestion de l'indice de la boucle
- pour la comparaison, puis pour l'affectation éventuelle
- pour mettre en place la valeur de retour afin que le résultat soit lu

On peut remarquer que la notion de pire cas dépend de la précision à laquelle on se place. Ici, si on ne s'intéresse qu'à l'ordre de grandeur, tous les tableaux de taille n sont équivalents. Par contre, si on cherche avec précision le pire cas, il est atteint avec un tableau trié par ordre croissant, car c'est le cas qui effectue une affectation à chaque itération.

```
int maximum(int *tableau, int taille)
    int M = INT_MIN;
    for(int i=0; i<taille; i++)</pre>
         if (M > tableau[i])
             M = tableau[i];
    return M;
```

Comparer des complexités

Avant de pouvoir comparer les complexités des algorithmes ou des programmes, il est nécessaire de mettre en place des outils pour en parler à la fois avec précision mais également sans rentrer dans des détails d'implémentation non pertinents.

En effet, comparons les deux fonctions suivantes permettant de chercher un élément dans un tableau.

La fonction de droite semble moins efficace que celle de gauche, car la seconde sort tout de suite de la fonction dès qu'on a trouvé l'élément alors que la première continue à parcourir t.

Mais on doit se poser la question de la pertinence de cette optimisation selon le pire des cas. Ici, le pire des cas correspond à ne pas avoir elem dans le tableau, et à ce moment-là les deux fonctions fonctionnent de la même manière.

■ Remarque 10.8 En fait, la fonction de droite sera souvent à privilégier, car il est souvent plus facile d'interrompre le flot que de faire en sorte de préserver l'état à la place du return pour pouvoir renvoyer la bonne valeur à la fin de la fonction.

De la même manière, il faut déterminer ce que l'on souhaite compter précisément :

- si on s'intéresse au temps mis, certaines opérations prennent moins de temps que d'autre (par exemple une addition par rapport à une multiplication) mais est-ce vraiment important à l'échelle considérée?
- si on s'intéresse à l'espace mémoire, doit-on considérer la taille précise en octets ou se contenter d'une estimation plus grossière?

Mis à part dans certains cadres assez spécifiques, on se contente le plus souvent d'un ordre de grandeur pour ces complexités. Pour cela, on utilise des relations de comparaisons de suites et une échelle de grandeur usuelle pour les comparer.

IV.2.i La notation grand O

Définition IV.2 Soit $(u_n)_{n\in\mathbb{N}}$ et $(v_n)_{n\in\mathbb{N}}$ deux suites de nombres réels non nuls, on dit que la suite $(u_n)_n$ est dominée par $(v_n)_n$ lorsque la suite quotient $\left(\frac{u_n}{v_n}\right)_n$ est bornée. On note alors $u_n = O(v_n)$.

Cette dernière notation se lit u_n est un grand 0 de v_n .

■ Remarque 10.9 C'est bien cette locution qu'il faut avoir en tête quand on pense aux grands O et il faut faire attention de ne pas considérer l'égalité en tant que telle sans s'assurer que ce l'on fait est licite. Quand on écrira par la suite $O(v_n)$ on signifiera n'importe quelle suite qui soit un $O(v_n)$.

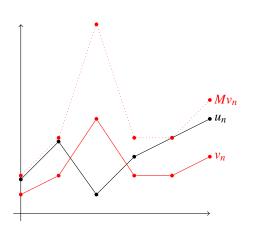
Si $u_n=O(v_n)$, cela signifie qu'il existe un facteur M>0 tel que pour tout entier n, on ait $-M|v_n|\leq u_n\leq M|v_n|$. Les variations de la suite $(u_n)_n$ sont ainsi entièrement contrôlées par

IV Complexité 75

les variations de $(v_n)_n$.

En informatique, on ne considère pour la complexité que des suites positives, ce qui permet de simplifier la relation : si $(u_n)_n, (v_n)_n$ sont des suites de réels strictement positifs, alors $u_n = O(v_n) \iff \exists M>0, \forall n\in\mathbb{N}, u_n\leq Mv_n$. C'est le cadre dans lequel on se place implicitement dans la suite de ce document.

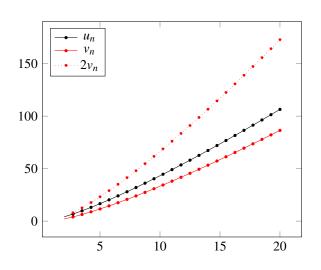
On peut visualiser graphiquement cette relation:



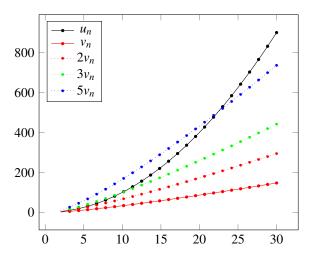
On a $u_n = O(v_n)$ si et seulement s'il est possible de multiplier les ordonnés de chaque point (n, v_n) par une constante afin que ces nouveaux points soient tous au-dessus des points (n, u_n) . On peut voir que la courbe déduite des v_n enveloppe, à un facteur près, celle des u_n .

Remarque : On a relié ici les valeurs des suites pour mieux mettre en valeur cette notion d'enveloppe.

Cette relation est une notion **asymptotique** : elle n'a d'intérêt que lorsqu'on considère des rangs au voisinage de l'infini. En effet, pour un nombre fini de termes, il est toujours possible de trouver un tel M, mais pour un nombre infini, ce n'est pas le cas.



Ici, on compare asymptotiquement les suites $(u_n)_n$ et $(v_n)_n$ où pour $n \in \mathbb{N}$, $u_n = n + n\log_2 n$ et $v_n = n\log_2 n$. Pour simplifier la visualisation, on a tracé les fonctions correspondantes. On remarque qu'on a bien $n + n\log_2 n = O(n\log_2 n)$.



Par contre, si on compare les suites $(u_n)_n$ et $(v_n)_n$ où pour $n \in \mathbb{N}$, $u_n = n^2$ et $v_n = n \log_2 n$, on remarque que quelle que soit la valeur choisie pour M, il y aura un rang à partir duquel $u_n > Mv_n$.

Ici,
$$n^2 \neq O(n \log_2 n)$$
.

■ Remarque 10.10 On a ici utilisé le logarithme en base 2, noté \log_2 , qui est essentiel informatique : si $x = \log_2(n)$ alors $n = 2^x$ où x est un réel. On considère aussi $p = \lceil \log_2(n) \rceil$ qui est le plus petit entier égal ou supérieur à $\log_2(n)$. On parle de **partie entière supérieure** et on a alors $2^{p-1} < n \le 2^p$. Cet entier p correspond alors au plus petit nombre de chiffre nécessaire pour pouvoir écrire n en binaire. On a $\lceil \log_2(n) \rceil = O(\log_2(n))$ et ainsi, le plus souvent, on ne considère pas la partie entière explicitement. De la même manière, $\log_2(n) = \frac{\ln n}{\ln 2} = O(\ln n)$.

Un cas important de grand O est celui des O(1). Si $u_n = O(1)$, cela signifie que $(u_n)_{n \in \mathbb{N}}$ est une suite bornée.

IV.2.ii Échelle de comparaison

On rappelle les limites obtenues en mathématiques que l'on nomme **croissances compa**rées :

$$\forall \alpha,\beta>0, \lim_{n\to +\infty}\frac{(\ln n)^\alpha}{n^\beta}=0$$

$$\forall \alpha \in \mathbb{R}, \forall \beta > 1, \lim_{n \to +\infty} \frac{n^{\alpha}}{\beta^n} = 0$$

Or, si $\frac{u_n}{v_n} \xrightarrow[n \to +\infty]{} 0$ a fortiori le quotient est borné et $u_n = O(v_n)$. Ainsi, on a les relations suivantes :

$$\forall \alpha, \beta > 0, (\log_2 n)^\alpha = O(n^\beta)$$

$$\forall \alpha \in \mathbb{R}, \forall \beta > 1, n^{\alpha} = O(\beta^n)$$

De plus, si $\alpha \geq \beta > 0$, $n^{\beta} = O(n^{\alpha})$, $(\log_2 n)^{\beta} = O((\log_2 n)^{\alpha})$ et $\beta^n = O(\alpha^n)$.

On se ramène souvent à des complexités qui sont des grand O de produits de ces suites.

IV.2.iii Ordre de grandeur et relation Θ

On vient de voir que $\log_2 n = O(n)$, mais on a également $\log_2 = O(n^2)$. Quand on cherche à caractériser la complexité par un grand O, on va souvent chercher le grand O le plus proche de la suite.

IV Complexité 77

Il est possible de définir cela précisément en considérant des suites qui sont chacune des grand 0 l'une de l'autre.

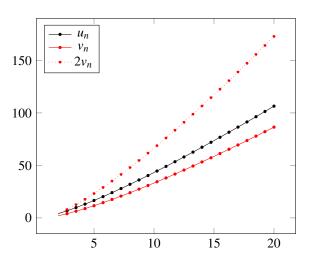
Par exemple, on a vu que $n\log_2 n + n = O(n\log_2 n)$, mais on a également $n\log_2 n = O(n+n\log_2 n)$.

Quand $u_n = O(v_n)$ et $v_n = O(u_n)$, on note $u_n = \Theta(v_n)$ qui est une relation symétrique qui correspond à la notion avoir le même ordre de grandeur. Très souvent, lorsque l'on parle de complexité, on utilise des grand O quand, en fait, on exprime des Θ . Par exemple, l'accès à un élément dans un tableau est en O(1) et il ne serait pas précis de dire que c'est en O(n) même si c'est parfaitement correct.

On peut visualiser cette relation Θ en considérant qu'il existe ainsi M, M'>0 tels que $u_n \leq M v_n$ et $v_n \leq M' u_n$. Mais on a alors

$$1/M'v_n \le u_n \le Mv_n$$

Ainsi, $u_n = \Theta(v_n)$ signifie qu'on peut encadrer $(u_n)_n$ entre deux multiples de $(v_n)_n$.



En reprenant la figure précédente, on observe visuellement

$$n\log_2 n \leq n\log_2 n + n \leq 2n\log_2 n$$

Avoir $u_n = \Theta(v_n)$ signifie donc que u_n évolue entre deux guides suivant les variations de v_n .

IV.2.iv Opérations sur les grands O

Si $u_n = O(w_n)$ et $v_n = O(w_n)$ alors $u_n + v_n = O(w_n)$. Ainsi, des grand O de même ordre s'ajoutent.

■ Remarque 10.11 Comme on l'a vu précédemment, un grand O n'est pas très précis, et il est possible que par ajout on puisse obtenir un meilleur grand O. Par exemple : n = O(n) et $\log_2 n - n = O(n)$ mais $n + \log_2 n - n = \log_2 n = O(n)$. Comme on ne considère ici que des suites strictement positifs, ce phénomène de compensation n'aura pas lieu.

Si $u_n = O(v_n)$ et w_n est une autre suite de réels strictement positifs, alors $u_n w_n = O(v_n w_n)$. On en déduit ainsi un principe qui nous sera utile par la suite nO(1) = O(n).

IV.3 Complexités en temps classiques

On parle ici de complexité par raccourci pour parler de complexité dans le pire des cas en temps.

IV.3.i Complexité constante

On dit qu'un algorithme a une complexité constante quand $C_n^t = O(1)$. Il existe ainsi une constante M telle que le temps pris par l'algorithme **sur une entrée quelconque** soit inférieur à M.

De nombreuses opérations sont en temps constant sur les structures de données usuelles. Parmi celles-ci, citons-en deux essentielles :

- accéder à une case d'indice quelconque dans un tableau
- accéder à la tête ou à la queue d'une liste chaînée

Les algorithmes ou opérations en temps constant jouent un rôle primordiale dans l'analyse de la complexité d'algorithmes, comme on le verra dans la partie suivante, car elles permettent de se concentrer sur les répétitions de ces opérations pour déterminer la complexité : une boucle qui se répète n fois et n'effectue que des opérations en temps constant dans son corps sera de complexité nO(1) = O(n).

IV.3.ii Complexité linéaire

On dit qu'un algorithme a une complexité linéaire quand $C_n^t = O(n)$.

Cette complexité correspond à un traitement de temps constant sur chaque élément d'une entrée de taille n. C'est le cas de la recherche d'un élément dans un tableau ou de la recherche de son maximum.

Pour la recherche linéaire d'un élément, correspondant par exemple au programme ci-dessous, le pire cas correspond à ne pas avoir x dans tableau ce qui oblige à effectuer toutes les itérations. On a bien une complexité temporelle en pire cas de O(n).

```
int recherche(int *tableau, int taille, int x)
{
    /* renvoie le plus petit indice i tel que tableau[i] = x
        ou -1 si x n'est pas dans le tableau */
    for(int i = 0; i < taille; i++)
    {
        if (tableau[i] == x)
            return i;
    }
    return -1;
}</pre>
```

IV.3.iii Complexité quadratique, polynomiale

On dit qu'un algorithme a une complexité quadratique quand $C_n^t=O(n^2)$. Par extension, on dit qu'il a une complexité polynomiale quand il existe $k\in\mathbb{N}$ tel que $C_n^t=O(n^k)$. Par extension, on parle parfois de complexité polynomiale pour des complexité plus précise en $O(n^\alpha)$ où α est un réel strictement positif.

L'exemple classique d'un algorithme quadratique est celui dû à un double parcours d'un tableau. On reprend ici l'algorithme de tri par sélection vu dans la partie Exemple du tri par sélection.

Afin d'analyser sa complexité, on procède fonction par fonction pour un tableau de taille n:

- echange est en temps constant. O(1)
- indice_minimum réalise un parcours du tableau et effectue des opérations en temps constant à chaque étape. La complexité est donc linéaire. O(n)
- tri_par_selection réalise également un parcours du tableau mais à chaque étape, on appelle indice_minimum qui est en O(n), la complexité est donc en $nO(n) = O(n^2)$: elle est quadratique.

IV Complexité 79

V.3.iv Complexité logarithmique

On dit qu'un algorithme a une complexité logarithmique quand $C_n^t = O(\log_2 n)$.

Pour illustrer cette complexité, on reprend l'algorithme de recherche dichotomique vu dans la partie Exemple de la recherche dichotomique.

Chaque opération effectuée étant en temps constant, la complexité de cet algorithme correspond au nombre d'itérations, soit ici au nombre d'appels récursifs.

Si on considère un sous-tableau de n=j-i+1 éléments lors de l'appel, un appel récursif se fera nécessairement sur un sous-tableau de $\lfloor n/2 \rfloor$ éléments. Ainsi, si $2^{k-1} < n \leq 2^k$, l'algorithme effectue moins de k itérations. En passant au logarithme, on a donc $k-1 < \log_2 n \leq k$. Donc, le nombre d'itérations est en $O(\log_2 n)$ et c'est ainsi la complexité de l'algorithme.

■ **Note 10.2** Esquisser dès maintenant le lien entre longueur d'une branche dans un arbre de décision et complexité logarithmique?

IV.3.v Complexité quasi-linéaire

On dit qu'un algorithme a une complexité quasi-linéaire quand $C_n^t = O(n\log_2 n)$. C'est le cas de la plupart des algorithmes efficaces de tri de n éléments. On peut même montrer qu'il s'agit de la complexité optimale.

Comme de nombreux algorithmes commencent par effectuer un tri avant d'effectuer un traitement linéaire, on retrouve des algorithmes quasi-linéaire par simple utilisation de ce tri.

IV.3.vi Complexité exponentielle

On dit qu'un algorithme a une complexité exponentielle quand $C_n^t = O(a^n)$ pour a > 0.

Un exemple fondamental d'un tel algorithme est celui de l'énumération de données, par exemple pour chercher une solution par force brute. En effet, il y a 2^n entrées codées sur n bits et un algorithme cherchant une solution ainsi parmi ces entrées aura une complexité en $O(2^n)$.

IV.3.vii Estimation de l'impact des complexités sur le temps

Afin de mesurer l'impact d'une complexité, on va considérer un algorithme qui s'exécute en 1 seconde sur un entrée de taille n, et on va calculer combien de temps prendrait ce même algorithme sur une entrée de taille 10n.

Pour simplifier, on considère à chaque fois que ${\cal C}_n^t$ correspond exactement à l'ordre du grand O.

Complexité	Temps pour 10n	Temps pour 100n
1	1s	1s
$\log_2 n$	1,003s	1,007s
n	10s	1m40s
$n \log_2 n$	14,7s	3m13s
n^2	1m40s	2h46m40s
2^n	10^{19} années	10^{289} années.

■ Remarque 10.12 Pour déterminer ces valeurs, on a considéré une unité de mesure de $1000 \, \mathrm{ms}$ afin d'en déduire une valeur de n.

Ainsi, si $\log_2 n = 1000$ on a $n = 2^{1000}$. Bien sûr, ici, ce nombre 2^{1000} n'est pas réaliste. Dans un contexte de mémoire finie, une complexité logarithmique est identifiable à une complexité constante. Cela justifie la terminologie quasi-linéaire.

Si $n\log_2 n = 1000$ alors $n \approx 140, 2$. Or, $1402\log_2 1402 \approx 14700ms$.

_

```
Si 2^n = 1000, alors n \approx 10. Or 2^{100} \approx 10^{30}.
```

IV.4 Calculer des complexités

Deux principes fondamentaux pour calculer des complexités :

- Si on effectue deux passes successives chacune en $O(u_n)$ alors la complexité globale est en $O(u_n)$. Il ne s'agit que de reformuler l'addition des grand O. Quand on a deux passes de complexité différente, il suffit d'utiliser la plus grande complexité. Par exemple, un algorithme qui commence par un tri en $O(n\log_2 n)$ et qui effectue ensuite un traitement en O(n) sera de complexité globale $O(n\log_2 n)$ car le traitement est également en $O(n\log_2 n)$.
- Si on effectue u_n itérations et que chaque itération est en $O(v_n)$ alors l'algorithme a une complexité de $O(u_nv_n)$. Cela permet de compter le nombre de boucles imbriquées et de se contenter de regarder ce qui se passe dans le corps des boucles.

IV.5 Complexité à plusieurs paramètres

Jusqu'ici on a considéré des entrées dépendant d'un unique paramètre n, mais il est possible d'avoir des données dépendant de plusieurs paramètres.

On adapte directement la notation des grands O : si $(u_{n,p})$ et $(v_{n,p})$ sont deux suites de réels non nuls dépendant de deux paramètres, on note toujours $u_{n,p} = O(v_{n,p})$ quand le quotient est borné.

IV.5.i Données multidimensionnelles

Le cas le plus usuel de complexité dépendant de plusieurs paramètres est celui des données multidimensionnelle comme une image.

Si on considère une opération effectuant un traitement en temps constant sur chaque pixel d'une image de $w \times h$ pixels, cette opération aura une complexité en O(wh). On ne peut plus parler de complexité linéaire ou quadratique ici car cela dépend d'une éventuelle relation entre w et h: si on ne travaille que sur des images de taille $1 \times h$ alors la complexité est O(h), mais on ne travaille que sur des images carrées, donc pour lesquelles w = h, la complexité est $O(h^2)$.

Plus généralement, si on considère des données organisées dans des tableaux imbriqués, on effectuera un traitement sur chaque donnée à l'aide de boucles imbriquées non conditionnelles. La complexité sera alors celle du corps de boucles multipliée par le produit du nombre d'itérations de chaque boucle.

IV.5.ii Compromis entre paramètres

Dans certains cas, en particulier pour les graphes, on peut effectuer des traitements successifs dont la complexité ne s'exprime pas en fonction du même paramètre. Imaginons par exemple un programme ayant la structure suivante :

```
for (int i = 0; i<n; i++)
{
     /* corps de boucle en O(1) */
}

for (int j = 0; j<p; j++)
{
     /* corps de boucle en O(1) */
}</pre>
```

La complexité de la première boucle est en O(n) et celle de la deuxième en O(p). La complexité globale est en O(n+p) car $n \le n+p$ et $p \le n+p$.

IV Complexité 81

Complexité en moyenne

On reprend ici les notations de la partie Complexité dans le pire des cas.

Définition IV.3 Lorsque pour tout $n \in \mathbb{N}$, I_n est fini, on appelle :

- complexité temporelle en moyenne la suite $(C_n^{t,m}) = \frac{1}{|I_n|} \sum_{e \in I_n} t(e)$. complexité spatiale en moyenne la suite $(C_n^{s,m}) = \frac{1}{|I_n|} \sum_{e \in I_n} s(e)$.

On peut étendre cette définition à un cadre infini en considérant une distribution de probabilité sur I_n et T_n la variable aléatoire associée à t sur I_n . Si T_n est d'espérance finie, on pourra parler de complexité en moyenne pour la suite des ${\cal E}(T_n)$. Concrètement, on considère alors une fonction $p_n:I_n\to[0,1]$ telle que $\sum_{e\in I_n}p(e)=1$ et, lorsque la somme est définie, on note ainsi

$$C_n^{t,m} = \sum_{e \in I_n} p(e)t(e)$$

$$C_n^{s,m} = \sum_{e \in I_n} p(e)s(e)$$

Un exemple usuel de calcul de complexité en moyenne est celui des tris. En effet, même si les entrées de taille n sont infinies, on peut considérer qu'un tableau de valeurs deux à deux distinctes est l'image par une permutation du tableau triée. Si le tableau est de taille n, on aura ainsi n! permutations ce qui permet, du moment que l'algorithme de tri considéré ne dépend que cette permutation, de calculer la complexité en moyenne sur l'ensemble des permutations.

■ Remarque 10.13 Les permutations d'un ensemble sont les applications bijectives de cet ensemble dans lui-même. Si l'ensemble contient n éléments, il y a n! permutations.

Par exemple, les six permutations sur l'ensemble $\{1, 2, 3\}$ correspondent aux diagrammes sagittaires suivants:

Ces six permutations correspondant elles-mêmes, de gauche à droite et de haut en bas, aux tableaux {1,2,3}, {1,3,2}, {3,2,1}, {2,1,3}, {2,3,1} et {3,1,2}.

IV.6.i Exemple de calcul de complexité temporelle en moyenne

On considère la recherche linéaire vue dans la partie Complexité linéaire. L'ensemble des entrées est ici infini, on va donc supposer pour faire le calcul qu'on ne considère que des tableaux de valeurs deux à deux distinctes et qu'on recherche un élément présent dans le tableau, chaque élément étant équiprobable.

Si on recherche le i-ème élément du tableau, l'algorithme effectue i itérations avant d'y accéder et de renvoyer son indice. Ainsi, le temps pour cet entrée est de iC où C est le coût d'une itération.

La complexité temporelle en moyenne est alors $C_n^{t,m} = \sum_{i=1}^n \frac{1}{n}iC = \frac{(n+1)C}{2} = O(n)$. On retrouve ici la même complexité que la complexité dans le pire des cas. La sortie prématurée de la boucle n'a donc aucune influence sur la complexité.

IV.7 Complexité amortie

Dans le cadre de l'étude des structures de données, il est fréquent de considérer non pas la complexité dans le pire des cas d'une opération mais celle d'une succession d'opérations divisée par le nombre d'opérations effectuées. Ainsi, on peut très bien avoir une opération ponctuellement plus coûteuse que les autres, mais en procédant ainsi on lisse le surcoût sur l'ensemble des opérations. On parle alors de **complexité amortie**.

■ Remarque 10.14 Cette notion ne masque pas le fait qu'une opération puisse prendre ponctuellement plus de temps. Dans des contextes temps réel où il est importat de maitriser pleinement les complexités, il est peu judicieux d'utiliser de telles complexités. Par exemple, dans une visualisation en 3D, pour maintenir un débit constant d'images par secondes, chaque image doit prendre un temps similaire. Se reposer sur une structure de donnée ayant une faible complexité amortie mais une complexité dans le pire des cas importante, c'est risquer d'avoir des sacades avec une image qui prendrait plus de temps pour être calculée.

Un exemple simple est donnée par la structure de données des tableaux dynamiques. C'est la structure de données utilisées dans de nombreux langages de haut niveau pour implémenter le type abstrait des listes. La différence principale entre cette structure de données et celle des tableaux de C est qu'on peut ajouter et supprimer des éléments.

Un tableau dynamique d'entiers est un triplet (t,c,n) où t est un tableau de taille c, appelée la capacité du tableau dynamique, et n est un autre entier représentant la taille logique du tableau. A tout moment $c \geq n$. Dans t il y a ainsi c-n cases déjà allouées qui permettent de rajouter un élément en temps constant. Quand c=n, on alloue une nouvelle zone mémoire, souvent de taille c, on déplace le tableau c dans cette zone et on a donc pour cet ajout prévu un certain nombre de cases d'avance.

La figure suivante présente une succession d'ajouts :

$$c = 2 \quad n = 0$$

$$c = 2 \quad n = 1 \quad \boxed{1}$$

$$c = 2 \quad n = 2 \quad \boxed{1} \quad \boxed{2}$$

$$c = 4 \quad n = 3 \quad \boxed{1} \quad \boxed{2} \quad \boxed{3}$$

$$c = 4 \quad n = 4 \quad \boxed{1} \quad \boxed{2} \quad \boxed{3} \quad \boxed{4}$$

$$c = 8 \quad n = 5 \quad \boxed{1} \quad \boxed{2} \quad \boxed{3} \quad \boxed{4} \quad \boxed{5}$$

Une implémentation de ces opérations est proposée dans le programme suivant :

```
#include <stdio.h>
#include <stdlib.h>

typedef struct {
   int *t;
   size_t c;
```

IV Complexité 83

```
size_t n;
} tableau_dynamique ;
tableau_dynamique tableau_dynamique_creer()
    tableau_dynamique d;
    const size_t capacite_initiale = 2;
    d.t = malloc(capacite_initiale * sizeof(int));
    d.c = capacite_initiale;
    d.n = 0;
    return d;
}
void tableau_dynamique_ajout(tableau_dynamique *d, int x)
    if (d->c == d->n) {
        d -> c = 2 * d -> c;
        d->t = realloc(d->t, d->c * sizeof(int));
    d\rightarrow t[d\rightarrow n] = x;
    d->n++;
}
void tableau_dynamique_print(tableau_dynamique d)
    printf("c=%d\tn=%d\t|", d.c, d.n);
    for (size_t i = 0; i < d.n; i++) {</pre>
        printf("%d|", d.t[i]);
    for (size_t i = d.n; i < d.c; i++) {</pre>
        printf(" |");
    printf("\n");
}
int main(void) {
    tableau_dynamique d = tableau_dynamique_creer();
    tableau_dynamique_print(d);
    for (int i = 1; i < 6; i++) {
        tableau_dynamique_ajout(&d,i);
        tableau_dynamique_print(d);
    }
```

Ce programme, une fois exécuté produit la sortie suivante qui permet de retrouver exactement le comportement attendu :

Calculons la complexité amortie de l'ajout d'un élément. Si on considère un ajout d'élément qui provoque une réallocation du tableau, celle-ci sera en O(c) et les c-1 opérations suivantes d'ajout seront en O(1). La complexité globale de ces c opérations d'ajout est alors en O(c), ce qui donne une complexité amortie en O(1). On peut ainsi considérer que l'ajout d'un élément dans un tableau dynamique est en complexité temporelle amortie constante.

■ Note 10.3 Il faut faire un choix entre reprendre ici une preuve plus précise ou la garder pour un chapitre ultérieur avec au moins un exemple de méthode du potentiel (Skew Heaps?)

IV.8 Pertinence de la complexité spatiale

Même si la complexité temporelle est le plus souvent celle qui est importante à calculer, certains algorithmes ont une complexité temporelle faible mais en contrepartie une complexité spatiale élevée. On parle alors de compromis temps-mémoire.

Un exemple classique d'un tel compromis est celui de la programmation dynamique où on passe d'une complexité temporelle exponentielle à une complexité temporelle polynomiale en stockant des valeurs intermédiaires pour ne pas les recalculer. En procédant ainsi, on passe d'une complexité spatiale constante à polynomiale.

Cela est illustré dans le programme suivant qui permet de déterminer le n-ième terme de la suite de Fibonacci, ce qui n'a pas d'intérêt informatique mais est caractéristique de récurrence que l'on résoudra par la programmation dynamique.

```
(* Fibonacci exponentiel *)
let rec fibo n =
    if n = 0
    then 0
    else if n = 1
    else fibo (n-1) + fibo (n-2)
(* Fibonacci linéaire *)
let fibo n =
    let prec = Array.make (n+1) 0 in
    prec.(0) <- 0;
    prec.(1) <- 1;
    for i = 2 to n do
        prec.(i) \leftarrow prec.(i-1) + prec.(i-2)
    done;
    prec.(n)
```

V Exercices 85

Exercices

Exercice 10.1 On considère le programme suivant :

Python

On suppose que $c \geq 2$.

- 1. Montrer que cet algorithme termine.
- 2. Montrer que pour $x, y \in \mathbb{N}$, il renvoie le produit xy.
- 3. Réecrire ce programme en récursif. Peut-on déduire des preuves précédentes que l'algorithme termine et qu'il est correct.

1. Comme $c \ge 2$, on a y/c < y ainsi y est un variant de boucle. Démonstration.

- 2. On va commencer par noter x_0 et y_0 les valeurs initiales respectives de x et de y. On va également tenir compte du nombre d'itérations, ce qui revient à rajouter un compteur i au programme. On va également noter $y_0 = \sum_{j=0}^n a_j c^j$.

 • $y = \left\lfloor \frac{y_0}{c^i} \right\rfloor = \sum_{j=i}^n a_j c^{j-i}$ et $x = x_0 c^i$ sont des invariants directement validés.

 - On va maintenant prouver l'invariant $I(i,m) = "m = x_0 \sum_{j=0}^{i-1} a_j c^j$ ".
 - * Initialisation avant la première itération, on a $I(0,0,x_0,y_0)$ qui est vérifié car 0 = 0.
 - * **Hérédité** si l'invariant est vérifié au début de la ième itération on a m+x(y%c)= $m + x_0 a_i c^i = m + x_0 \sum_{j=0}^i a_j c^j$ donc I(i+1, m+x(y%c)) est vérifié.

Ainsi, en sortie de boucle, on a $m = x_0 \sum_{j=0}^n a_j c^j = x_0 y_0$.

3. En récursif, cela ne change pas la validité des preuves précédentes mais il faudrait présenter l'invariant différemment.

```
int multiplication(int x, int y, int c)
  if (y == 0) return 0;
return x * (y % c) + multiplication(x * c, y / c, c);
```

Exercice 10.2 On considère un polynôme $P = \sum_{i=0}^n c_i X^i$ représenté comme un tableau de n+1 coefficients tel que pour tout $i \in [0, n], P[i] = c_i$.

On veut calculer P(a) pour une valeur a. Pour simplifier, on va considérer ici que les valeurs sont toutes entières.

```
int horner(P, int a)
```

- 1. Montrer que ce programme est correct.
- 2. Combien effectue-t-il de multiplications et d'additions?
- 3. Comparer avec l'algorithme obtenu en ajoutant chaque $c_i a^i$ pour i croissant et en main-

tenant une variable pour a^i .

Démonstration. 1. On considère l'invariant $I(v,i) = "v = c_{i+1} + c_{i+2}a + \cdots + c_na^{n-i-1}"$

- Initialisation avant la première itération on a I(0,n) vérifié car $v=0=c_{n+1}$.
- **Hérédité** si l'invariant est vérifié en début d'itération, on passe à $I(av+c_i,i-1)$ en fin d'itération or, si $v=c_{i+1}+\cdots+c_na^{n-i-1}$ on a bien $av+c_i=c_i+c_{i+1}a+\cdots+c_na^{n-i}$ et donc l'invariant est vérifié en fin d'itération.

En sortie de boucle, on a alors I(v,-1) donc $v=c_0+c_1a+\cdots+c_na^n=P(a)$.

- 2. On effectue n+1 itérations et à chaque itérations une multiplication et une addition, donc n+1 multiplications et n+1 additions.
- 3. Pour cet algorithme, on devrait faire une multiplication de plus à chaque itération pour maintenir a^i .

Exercice 10.3 On considère le problème du drapeau hollandais : étant donné un tableau t et un indice i, on note p=t[i], on cherche à permuter les éléments de t de sorte qu'il y ait trois zones dans le tableau : les éléments < p, les éléments = p puis les éléments > p.

Ainsi, si on considère t = [5, 2, 3, 5, 1, 4] et p=t[2] = 3 on pourra obtenir [2, 1, 3, 5, 5, 4] à l'issue de cet algorithme.

- 1. Écrire un programme résolvant ce problème en temps linéaire.
- 2. Prouver sa correction.

Démonstration. Le programme :

```
void echange(int *t, int i, int j)
    int temp = t[i];
    t[i] = t[j];
    t[j] = temp;
void drapeau(int *t, int nb, int i)
    int v = t[i];
    int l = 0;
    int c = nb-1;
    int r = nb-1;
    while (l <= c)</pre>
        int w = t[l];
        if (w < v)
            l = l+1;
        else if (w == v)
            echange(t, l, c);
            c = c-1;
        }
```

V Exercices 87

```
else
{
     echange(t, l, c);
     echange(t, c, r);
     c = c-1;
     r = r-1;
   }
}
```

L'idée de cet algorithme est d'avoir trois indices l, c et r (pour left, center et right) qui délimitent trois zones :

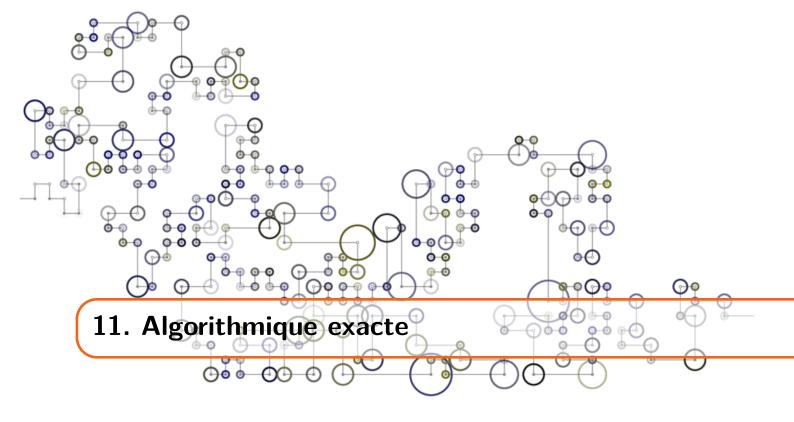
- celle des indices 0 à l-1 qui contient des valeurs < v
- celle des indices c+1 à r qui contient des valeurs égales à v
- celle des indices r + 1 à nb 1 qui contient des valeurs > v.

Au départ, ces trois zones sont triviales et au fur à mesure de l'algorithme, elles augmentent jusqu'à couvrir l'ensemble du tableau. Comme soit l croit soit c décroit a chaque itération, on a la distance c-l qui est un variant de boucle et on effectue exactement |t| itérations.

On va montrer que le découpage des zones est effectivement un invariant :

- Initialisation au départ, comme on l'a vu, ces trois zones sont vides donc l'invariant est trivialement vérifié
- **Hérédité** si l'invariant est vrai au début d'une itération, on va faire trois cas selon la position de w par rapport à v :
 - \star Si w < v alors la zone des indices de 0 à l contient toujours des valeurs < v et les autres zones n'ont pas bougé, l'invariant est encore vérifié.
 - * Si w = v alors on place cette valeur w au début de la zone centrale en faisant l'échange puis en décalant c vers la gauche. Les autres zones ne sont pas touchées, donc l'invariant est encore vérifié.
 - * Si w > v alors on veut le placer en tête de la zone de droite, mais l'élément qui s'y trouve est peut-être une valeur de la zone centrale si celle-ci est non triviale. On place alors cette valeur là en début de la zone centrale ce qui revient à la décaler d'un cran vers la gauche. La valeur w peut alors etre échangée. La première zone n'a pas bougé et les autres zones vérifient encore les conditions voulues, l'invariant est donc vérifié.!TODO(On devrait être plus précis ici)

On a donc validé l'invariant. En sortie de boucle, on a x=y+1>y et donc les trois zones couvrent l'intégralité du tableau.



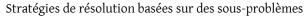
Source image: https://www.flickr.com/photos/x6e38/3440634940/

■ Note 11.1 Roadmap:

- finir l'écriture.
- rajouter les codes dans les trois langages.
- des exercices, plein d'exercices!
- et aussi des problèmes.

■ Remarque 11.1 Dans ce chapitre, on étudie des problèmes pour lesquels on va exprimer des algorithmes permettant d'obtenir des solutions exactes. C'est à contraster avec le chapitre sur l'algorithmique approchée.

Une grande partie des stratégies de résolution est basée sur la résolution de sous-problèmes. On verra ainsi trois types de stratégies résumées dans le schéma suivant :





Recherche par force brute

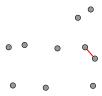
I.1 Principe

Considérons un problème du type trouver un $x \in V$ vérifiant une propriété P(x). Par exemple, V est l'ensemble des chaînes de caractère et P vérifie si une chaîne est un mot de passe qu'on cherche. Dans certains problèmes, un tel x n'est pas unique et on cherche à tous les énumérer.

Une recherche par force brute, ou recherche exhaustive, consiste à parcourir l'ensemble V jusqu'à obtenir une solution. Pour la recherche du mot de passe, on pourrait commencer par énumérer les chaînes de longueur 1, puis de longueur 2, et ainsi de suite.

Le plus souvent, l'ensemble V est fini (pour les mots de passe, cela peut consister à limiter la longueur maximale du mot de passe). Ainsi, une recherche par force brute effectue O(|V|) itérations.

Considérons le problème *PlusProchePaire* qui, étant donné un ensemble de n points $(n \ge 2)$, détermine la paire constituée des deux points les plus proches.



Une implémentation naïve de la recherche par force brute consiste à énumérer les $\frac{n(n-1)}{2}$ paires et donc à effectuer $O(n^2)$ itérations.

```
let plus_proche_paire points =
    let n = Array.length points in
    let min_paire = ref (distance points.(0) points.(1), (0, 1)) in
    for i = 0 to n - 1 do
        for j = i+1 to n - 1 do
            let d = distance points.(i) points.(j) in
            if d < fst !min_paire
            then min_paire := (d, (i, j))
        done
    done;
    snd !min_paire</pre>
```

I.2 Raffinement : droite de balayage

Il est parfois possible d'accélérer la recherche par force brute en ordonnant le parcours des candidats pour pouvoir éviter de tester certains d'entres eux.

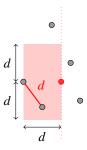
En géométrie algorithmique, une approche classique consiste à ordonner les objets selon leur abscisse et à parcourir les objets par abscisse croissante. On parle alors de **droite de balayage** (en anglais, *sweep line*) car cela revient à balayer le plan par une droite verticale en ne traitant que les objets avant cette ligne.

Reprenons le problème précédent, on considère que les points sont triés par abscisse croissante : $(x_0, y_0), \ldots, (x_{n-1}, y_{n-1})$. On va parcourir les points dans cet ordre en maintenant un ensemble de points à gauche du point courant, appelés *points actifs*, et en ne calculant que les intersections avec les points actifs.

Si on a parcouru les N premiers points et qu'on a obtenu que la plus petite distance était d, lorsqu'on considère le point (x_N,y_N) , il est inutile de tester les points qui sont forcément à distance >d de celui-ci. C'est-à-dire qu'on peut éliminer les points qui ne sont pas dans le rectangle $[x_N-d,x_N]\times[y_N-d,y_N+d]$ du test. Les points dont l'abscisse est $<x_N-d$

peuvent être éliminés définitivement vu que l'on raisonne par abscisse croissante, par contre, les points d'ordonnées invalides doivent être conservés pour les points ultérieurs.

Ce rectangle est représenté sur le schéma suivant ainsi qu'une ligne imaginaire qui correspond à l'abscisse du point courant et qu'on peut imaginer parcourant le plan de gauche à droite pour traiter les points au fur et à mesure.



Afin de déterminer la complexité de cet algorithme, il est nécessaire de connaître le nombre maximal de points dans le rectangle. Comme ces points ont été pris en compte précédemment, ils sont forcément à distance au moins d les uns des autres. Il s'agit donc de déterminer le nombre maximum de points qu'on peut placer dans ce rectangle à distance au moins d. On remarque tout d'abord qu'on peut placer six points ainsi :



Si jamais on avait au moins sept points, on peut voir qu'il y a forcément un des six sous-rectangles suivants qui contiendrait au moins deux points :



Or, ces sous-rectangles sont de longueur $\frac{1}{2}d$ et de hauteur $\frac{2}{3}d$, donc la distance maximale entre deux de leurs points correspond à la longueur des diagonales : $\sqrt{\frac{1}{4} + \frac{4}{9}}d = \frac{5}{6}d < d$.

Comme un de ces six points est le point courant, il y a toujours au plus 5 points dans l'ensemble des points actifs.

Voici le principe de l'algorithme que l'on va implémenter :

- On trie le tableau points par ordre croissant. **Complexité** : $O(n \log n)$
- On initialise la plus petite distance d courante à la distance entre les deux premiers points
- On crée un ensemble actifs, ordonné par les ordonnées, de points contenant initialement les deux premiers points
- Pour chaque point (x, y) en partant du deuxième :
 - * On supprime les points (x', y') tels que x' < x d de actifs. **Complexité**: sur l'ensemble des itérations on ne pourra jamais supprimer deux fois un point, donc on effectue au maximum n suppressions chacune en $O(\log n)$ donc $O(n \log n)$.

 \star On parcourt les points de actifs dont les ordonnées sont comprises entre y-d et y+d. Complexité: pour récupérer le premier point de l'ensemble, il faut $O(\log n)$ en pire cas (tous les points actifs) et ensuite on effectue au plus 5 itérations comme on vient de le prouver.

On remarque ainsi que la complexité en temps et en pire cas de cet algorithme est de $O(n \log n)$. Ici, le fait d'avoir la structure actifs ordonnée par les ordonnées est crucial pour garantir la complexité. Pour la réalisation d'une structure d'ensemble ordonnée ayant ces complexité, voir le chapitre FIXME.

Ici, on utilise le module Set d'OCaml pour réaliser la structure d'ensemble, pour cela on commence par créer le module PointSet pour les ensembles de points :

```
module Point = struct
    type t = float * float
    let compare (x1,y1) (x2,y2) = Stdlib.compare y1 y2
end

module PointSet = Set.Make(Point)
```

Puis on définit une fonction permettant de parcourir les points entre deux ordonnées :

On implémente alors assez directement l'algorithme décrit précédemment :

```
let xi, yi = points.(i) in

while fst points.(!gauche) < xi -. !d do
    actifs := PointSet.remove points.(!gauche) !actifs;
    incr gauche

done;

set_iter_entre (fun pj ->
    let dip = distance points.(i) pj in
    if dip < !d
    then begin
        couple := (points.(i), pj);
        d := dip
    end) !actifs (yi -. !d) (yi +. !d);

actifs := PointSet.add points.(i) !actifs

done;
!d</pre>
```

1.2.i Problème : test d'intersection pour un ensemble de segments

Considérons le problème suivant Intersection Ensemble: étant donné n segments dans le plan, il s'agit de déterminer si au moins deux des segments s'intersectent.

■ Remarque 11.2 On peut considérer ici que l'on dispose d'une fonction

```
intersecte : (float * float) * (float * float)
-> (float * float) * (float * float) -> bool
```

qui teste l'intersection entre deux segments.

Cependant, il est possible d'écrire une telle fonction avec un peu de géométrie élémentaire.

Si on considère que les deux segments sont $[A_1B_1]$ et $[A_2B_2]$, avec $A_1 \neq B_1$ et $A_2 \neq B_2$, alors chaque point du segment $[A_1B_1]$ est de la forme $A_1 + t\overline{A_1B_1}$ où $t \in [0,1]$. De même les points du segments $[A_2B_2]$ sont de la forme $A_2 + u\overline{A_2B_2}$ où $u \in [0,1]$.

S'il y a une intersection, c'est qu'il existe $(t, u) \in [0, 1]^2$ tel que

$$A_1 + t\overrightarrow{A_1B_1} = A_2 + u\overrightarrow{A_2B_2} \iff \overrightarrow{A_2A_1} + t\overrightarrow{A_1B_1} = u\overrightarrow{A_2B_2}$$

L'idée est alors d'utiliser une opération appelée **produit vectoriel** sur les vecteurs. Comme ici, tout est plan, le produit vectoriel est uniquement déterminé par sa troisième coordonnée, celle qui sort du plan, et on peut se contenter de calculer celle-ci. On note ainsi $(x,y) \times (x',y') = xy' - yx'$ cette coordonnée. On a donc $u \times u = 0$.

On peut alors composer l'égalité par $\times \overrightarrow{A_2B_2}$:

$$\overrightarrow{A_2A_1} \times \overrightarrow{A_2B_2} + t\left(\overrightarrow{A_1B_1} \times \overrightarrow{A_2B_2}\right) = 0$$

Notons
$$\Delta = \overrightarrow{A_1B_1} \times \overrightarrow{A_2B_2}$$
, si $\Delta \neq 0$, alors

$$t = -\frac{\overrightarrow{A_2A_1} \times \overrightarrow{A_2B_2}}{\Delta} = \frac{\overrightarrow{A_1A_2} \times \overrightarrow{A_2B_2}}{\Delta}$$

On procède de même avec $\times \overrightarrow{A_1B_1}$ pour obtenir une expression de $u: \overrightarrow{A_2A_1} \times \overrightarrow{A_1B_1} = u\left(\overrightarrow{A_2B_2} \times \overrightarrow{A_1B_1}\right) = -u\Delta$ et donc

$$u = -\frac{\overrightarrow{A_2 A_1} \times \overrightarrow{A_1 B_1}}{\Delta} = \frac{\overrightarrow{A_1 A_2} \times \overrightarrow{A_1 B_1}}{\Delta}$$

Si $\Delta \neq 0$, on peut donc alors exprimer u et t et vérifier qu'ils sont dans [0,1].

Si $\Delta=0$ c'est que les deux segments sont de directions parallèles ou confondues.

- Si $\overrightarrow{A_1A_2} \times \overrightarrow{A_1B_1} \neq 0$ alors $\overrightarrow{A_1A_2}$ et $\overrightarrow{A_1B_1}$ sont non colinéaires donc les deux segments sont sur des droites parallèles distinctes et ne peuvent s'intersecter.
- Sinon, les segments reposent sur une même droite et il s'agit de vérifier leurs positions sur la droite. Pour cela, on exprime $A_2 = A_1 + t_A \overline{A_1B_1}$ de même pour $B_2 = A_1 + t_B \overline{A_1B_1}$. Plus précisement, on calcule $\overline{A_1A_2} \cdot \overline{A_1B_1} = t_A ||\overline{A_1B_1}||^2$ à l'aide du produit scalaire et on a $t_A = \frac{\overline{A_1A_2} \cdot \overline{A_1B_1}}{||\overline{A_1B_1}||^2}$. De même, $t_B = \frac{\overline{A_1B_2} \cdot \overline{A_1B_1}}{||\overline{A_1B_1}||^2}$. On doit alors vérifier si l'intervalle $[t_A, t_B]$ (ou $[t_B, t_A]$ selon leur position) intersecte [0, 1].

Voici une fonction OCaml qui correspond à ce raisonnement

```
let intersecte (a1,b1) (a2,b2) =
    let vec (x1,y1) (x2,y2) = (x2-.x1,y2-.y1) in
    let cross (x1,y1) (x2,y2) = x1 *. y2 -. y1 *. x2 in
    let dot (x1,y1) (x2,y2) = x1 *. x2 +. y1 *. y2 in
    let proche0 x = let eps = 1e-20 in
        if x < 0. then -.x < eps else x < eps in
    let a1b1 = vec a1 b1 in let a2b2 = vec a2 b2 in
    let ala2 = vec al a2 in let alb2 = vec al b2 in
    let delta = cross a1b1 a2b2 in
    if proche0 delta
    then
         if proche0 (cross ala2 alb1)
         then let na1b1 = dot a1b1 a1b1 in (* colinéaires *)
              let tA = (dot ala2 alb1) /. nalb1 in
              let tB = (dot a1b2 a1b1) /. na1b1 in
              if tA < tB
              then not (tB < 0. || tA > 1.)
              else not (tA < 0. || tB > 1.)
         else false (* parallèles *)
    else let t = (cross a1a2 a2b2) /. delta in (* se croisent *)
         let u = (cross a1a2 a1b1) /. delta in
         t >= 0. && t <= 1. && u >= 0. && u <= 1.
```

■ Note 11.2 réécrire cela avec le déterminant de deux vecteurs du plan qui est au programme de mathématiques de seconde.

La recherche par force brute va alors énumérer l'ensemble des paires de segments distincts et tester deux à deux les intersections. On peut ainsi écrire le programme suivant qui est assez simple et effectuera effectivement $O(|v|^2)$ itérations dans le pire cas, i.e. lorsqu'il n'y a pas d'intersections.

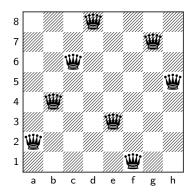
TODO approche par droite de balayage: algorithme de Shamos et Hoey (1976)

I.3 Recherche par retour sur trace (backtracking)

Dans des problèmes admettant des solutions partielles, on peut construire une solution par essai de toutes les possibilités en complétant tant qu'on a bien une solution partielle. La recherche par retour sur trace repose sur ce constat pour énumérer l'ensemble des solutions en utilisant la récursivité (d'où la notion de *retour sur trace*) pour les essais.

L'exemble classique de ce problème est celui des huit reines : étant donné un échiquier, peuton placer huit reines de sorte qu'aucune reine ne puisse prendre une autre reine? Plus précisément : sur un plateau de 8x8 cases, peut-on placer huit pions tels que deux pions quelconques ne soient jamais sur la même ligne ou la même diagonale?

Exemple de solution :



Ce problème admet effectivement des solutions partielles en ne considérant que k reines à placer. Pour énumérer les solutions, on peut même se contenter de solutions partielles où les k reines sont placées sur les k premières rangées.

Voici ainsi un algorithme pour énumérer les solutions :

- Supposons que k reines aient été placées et qu'on dispose d'une solution partielle.
 - $\star\,$ Si k=8 alors toutes les reines sont placées et la solution est complète, on la comptabilise

 \star Sinon, on continue la recherche pour chaque position de la k+1 reine sur la k+1 rangée qui préserve le fait d'être une solution partielle.

Ici, quand on dit qu'on continue la recherche, ce qu'on signifie c'est qu'on effectue un appel récursif.

Pour programmer cette méthode, on va définir une fonction récursive de signature :

```
val resout_reines : (int * int) list -> (int * int) list list
```

Un appel à resout_reines part va ainsi renvoyer la liste des solutions complètes construites à partir de la solution partielle part. Les solutions sont représentées par des listes de couples de coordonnées sur l'échiquier, donc dans $[|0;7|]^2$

Voici une implémentation où on explore les solutions à l'aide d'une boucle impérative dans l'appel récursif. La fonction valide permet de tester si le placement d'une reine est possible avant d'effectuer un appel.

```
let rec valide (x1,y1) l =
   match l with
    | [] -> true
    | (x2,y2)::q \rightarrow
        x1 <> x2 && abs (x2-x1) <> abs(y2-y1) && valide (x1,y1) q
let rec resout_reines part =
    let k = List.length part in
    if k = 8
    then [ part ]
    else begin
        let resultats = ref [] in
        for x = 0 to 7 do
            let essai = (x,k) :: part in
            if valide (x,k) part
            then begin
                resultats := (resout_reines essai) @ !resultats;
            end
        done;
        !resultats
    end
```

et, ici, une autre implémentation purement récursive à l'aide d'une fonction récursive.

Une partie de l'arbre de recherche est présenté sur l'image suivante :

Arbre de recherche pour les huit reines

L'arbre complet comporte 2057 noeuds dont 92 feuilles correspondant aux solutions du problème. A titre de comparaison, l'arbre exhaustif correspondant à faire tous les choix de placement à raison d'une reine par ligne compterait $8^8 = 16777216$ noeuds. On voit bien que le backtracking est plus économe en exploration.

I.3.i Problème : résolution de Sudoku

La recherche par retour sur trace se prête très bien à la résolution de problèmes comme le Sudoku. On va ici tout simplement tenter de remplir chaque case du haut vers le bas tant qu'on satisfait les contraintes du Sudoku. Le programme sera ainsi très proche de la résolution des huit reines.

Commençons par rappeler le principe du Sudoku:

• On part d'une grille de 81 cases réparties en une grille de 3x3 sous-grilles de 3x3 cases et comportant des chiffres de 1 à 9 dans certaines cases.

1								6
		6		2		7		
7	8	9	4	5		1		3
			8		7			4
				3				
	9				4	2		1
3	1	2	9	7			4	
	4			1	2		7	8
9		8						

- L'objectif est de remplir chaque case avec un chiffre de 1 à 9 de sorte que chaque ligne, chaque colonne et chaque sous-grille 3x3 comporte une et une seule fois chaque chiffre.
- Un sudoku admet une unique solution.

Pour représenter une grille de Sudoku en OCaml on utilise un (int option) array array, la valeur None signifiant que la case est vide et la valeur Some $\,$ x qu'elle est remplie avec la valeur x.

```
type grille = (int option) array array
```

On fait le choix de représenté la grille par un tableau de lignes, ce qui signiie que pour accèder à la case de coordonnée (x,y) dans g il faut écrire ${\bf g.(y).(x)}$.

Le problème donnée précédemment est alors représenté par la valeur suivante :

```
let probleme = [|
    [| Some 1; None; None; None; None; None; None; Some 6 |];
    [| None; None; Some 6; None; Some 2; None; Some 7; None; None; None |];
    [| Some 7; Some 8; Some 9; Some 4; Some 5; None; Some 1; None; Some 3 |];
```

```
[ | None; None; None; Some 8; None; Some 7; None; None; Some 4 |];
[ | None; None; None; None; Some 3; None; None; None; None; None; None; None; None; Some 2; None; Some 1 |];
[ | Some 3; Some 1; Some 2; Some 9; Some 7; None; None; Some 4; None |];
[ | None; Some 4; None; None; Some 1; Some 2; None; Some 7; Some 8 |];
[ | Some 9; None; Some 8; None; None; None; None; None; None; None |];
]
```

Afin de définir la fonction de résolution, on définit une première fonction suivant de signature :

```
val suivant : grille -> (int * int) -> (int * int) option
```

telle que l'appel à suivant g (x,y) renvoie Some (xi,yi) quand (x_i,y_i) sont les coordonnées de la prochaine case libre, dans l'ordre gauche à droite puis haut vers bas, après (x,y) ou None quand il n'existe pas de telle case libre. Cela signifie alors que la grille est entièrement remplie.

```
let rec suivant g (x,y) =
    if y > 8
    then None
    else if g.(y).(x) = None
    then Some (x,y)
    else if x < 8 then suivant g (x+1, y)
    else suivant g (0, y+1)</pre>
```

On définit également une fonction valide de signature

```
val valide : grille -> int -> bool
```

telle que l'appel à valide g x y renvoie true si et seulement si la valeur placée en coordonnée (x,y) n'invalide pas la grille. Ne pas prendre cette valeur en paramètre permettant d'écrire un peu plus simplement cette fonction. La fonction est assez directe, étant donné (x,y) on va parcourir sa ligne, sa colonne et sa sous-grille pour vérifier qu'un nombre n'a pas été placé deux fois à l'aide d'un tableau de drapeaux :

```
None -> ()
      Some k ->
            if vus_ligne.(k-1)
            then v := false;
            vus_ligne.(k-1) <- true</pre>
done:
let vus_grille = Array.make 9 false in
let xb = (x / 3) * 3 in
let yb = (y / 3) * 3 in
for xd = 0 to 2 do
    for yd = 0 to 2 do
        match g.(yb+yd).(xb+xd) with
        | None -> ()
        | Some k ->
                 if vus_grille.(k-1)
                 then v := false;
                 vus_grille.(k-1) <- true</pre>
    done
done;
ŀ٧
```

On peut alors définir la fonction resout qui va résoudre le Sudoku en effectuant tous les remplissages tant qu'on a une grille valide. Dès qu'une solution est trouvé, on s'arrête. Pour cela, on utilise le mécanisme des exceptions pour permettre une sortie prématurée. On a fait le choix de travailler en place dans la grille, ainsi à la fin de l'exécution de la fonction, la grille correspond à la solution.

```
exception Solution
let resout g =
    let rec aux xi yi = match suivant g (xi, yi) with
         | None -> raise Solution
          Some (x,y) \rightarrow
             for i = 1 to 9 do
                  g.(y).(x) \leftarrow Some i;
                  if valide g x y
                  then begin
                      aux x y
                  end
             done;
             g.(y).(x) \leftarrow None
    in
    try
         aux 0 0
    with Solution -> ()
```

II Algorithmes gloutons

II.1 Principe

On considère ici un problème d'énumération comme dans la section précédente muni d'une fonction d'objectifs qui attribue une valeur numérique aux solutions et aux solutions partielles.

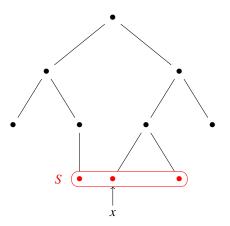
Soit $f:P\to\mathbb{R}$ une telle fonction, où $S\cup P$ est l'ensemble des solutions du problème d'énumération et P l'ensemble des solutions partielles, on se pose maintenant le problème de l'optimalité vis-à-vis de f: déterminer $x\in S$ tel que $f(x)=\max_{u\in S}f(u)$ on note souvent

 $x = \operatorname{argmax}_{y \in S} f(y)$. On parle alors de problème d'optimisation combinatoire.

- Remarque 11.3 En considérant $g: y \mapsto -f(y)$, on transforme un problème de maximisation en un problème de minimisation.
 - Il y a une ambiguïté sur $\arg\max_{y\in S} f(y)$ quand plusieurs éléments de S réalisent ce maximum. Dans la plupart des algorithmes gloutons qu'on va considérer, on commence par donner un ordre sur S et on considère le plus petit y pour cet ordre réalisant le maximum. L'ordre choisi est alors crucial dans la preuve de correction. C'est aussi une des raisons pour lesquelles les algorithmes gloutons sont souvent de complexité temporelle $O(n\log_2 n)$.

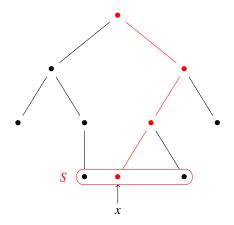
Une première stratégie très élémentaire consiste alors à énumérer S, de manière exhaustive ou avec une stratégie plus fine comme le retour sur trace, puis à déterminer un élément maximal de manière directe.

Cela revient donc à déterminer l'arbre des solutions puis à trouver une feuille maximisant l'objectif :



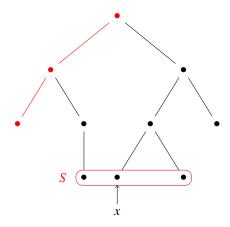
Un algorithme glouton va suivre une approche beaucoup plus efficace : à chaque étape de construction de la solution, on choisit la branche qui maximise la fonction d'objectif. C'est-à-dire que si en partant d'une solution partielle $x \in P$ il est possible de l'étendre en d'autres solutions partielles $p_x = \{y_1, ..., y_n\}$, on va choisir $y = \operatorname{argmax}_{t \in p_x} f(t)$ la solution qui maximise localement f.

Sur l'arbre précédent, cela reviendrait à n'emprunter qu'une seule branche :



_

Cela a l'air très efficace mais il y a un problème majeur : il n'y a aucune garantie qu'on aboutisse ainsi à une solution, encore moins à une solution optimale. En effet, on aurait très bien pu faire les choix suivants :



et ne pas aboutir à une solution.

Considérons par exemple le problème du **rendu de monnaie** : étant donné, une liste de valeurs faciales de pièces $P=(v_1,\ldots,v_p)\in(\mathbb{N}^*)^p$ avec $1=v_1<\cdots< v_p$ et une somme $n\in\mathbb{N}^*$, on cherche la manière d'exprimer cette somme avec le plus petit nombre de pièces possible.

Plus précisément, l'ensemble des solutions $S = \{(k_1, \dots, k_p) \in N^p \mid k_1v_1 + \dots + k_pv_p = n\}$ et la fonction d'objectif est $f: (k_1, \dots, k_p) \mapsto k_1 + \dots + k_p$. Les solutions partielles ici sont les réalisations de valeur < n. On cherche alors $x = argmin_{u \in S} f(y)$.

Comme
$$1 = v_1, S \neq \emptyset$$
 car $(n, 0, \dots, 0) \in S$ et ainsi $f(x) \leq n$.

L'algorithme glouton va utiliser la plus grande pièce possible à chaque étape puis on applique l'algorithme glouton sur la somme restante sauf si elle est nulle, ce qui constitue la condition d'arrêt.

Exemple 1

- P = (1, 2, 5, 10)
- n = 14
- On utilise la plus grande pièce possible $10 \le 14$ puis on exprime 4 = 14 10
- Ici, la plus grande pièce est 2 et on continue avec 2=4-2
- La plus grande pièce est encore 2 et on s'arrête car 0 = 2 2.
- En conclusion, on a obtenu x = (0, 2, 0, 1).
- Une exploration exhuastive permet de s'assurer qu'on a effectivement obtenu une décomposition minimale. En effet, ici l'ensemble des décompositions est : { (14,0,0,0), (12,1,0,0), (8,3,0,0), (6,4,0,0), (4,5,0,0), (2,6,0,0), (0,7,0,0), (9,0,1,0), (7,1,1,0), (5,2,1,0), (3,3,1,0), (1,4,1,0), (4,0,2,0), (2,1,2,0), (0,2,2,0), (4,0,0,1), (2,1,0,1), (0,2,0,1) }.

Exemple 2

- P = (1, 2, 7, 10)
- n = 14
- L'algorithme glouton va ici procéder comme dans l'exemple 1 et on va obtenir x = (0, 2, 0, 1).
- Mais on remarque que ce n'est pas un minimum car x' = (0,0,2,0) convient avec f(x') = 2 < 3 = f(x).

Conclusion l'algorithme glouton n'a effectivement pas de raisons d'être optimal.

On peut se poser la question des algorithmes pour lesquels l'algorithme glouton aboutit nécessairement à une solution optimale.

■ Note 11.3 TODO - Ajouter un paragraphe simple sur les matroïdes qui puisse se décliner sous la forme d'un problème.

II.2 Construction de l'arbre de Huffman

■ Remarque 11.4 Ce paragraphe décrit l'étape cruciale du principe de compression de Huffman. Celui-ci sera présenté complétement dans le chapitre Algorithmique des textes.

On va étudier ici un principe de compression parfaite (sans perte d'information à la décompression) de données appelé l'algorithme de Huffman et qui repose sur ce principe simple : coder sur moins de bits les caractères les plus fréquents.

Par exemple si on considère le mot abaabc, en le codant avec un nombre de bits fixes, par exemple 2 avec le code a=00, b=01, c=10, on aurait besoin de 12 bits pour représenter le mot. Mais si on choisit le code suivant : a=0, b=10, c=11, il suffit de 9 bits. On a donc gagné 3 bits soit un facteur de compression de 75%.

On remarque que pour pouvoir décompreser, il n'aurait pas été possible de faire commencer le code de b ou c par un 0, sinon on aurait eu une ambiguité avec la lecture d'un a. On parle alors de code préfixe :

Définition II.1 Soit $X \subset \{0,1\}^*$, on dit que X est un code préfixe lorsque pour tous $x,y \in X$, x n'est pas un préfixe de y et y n'est pas un préfixe de x.

On se pose alors la question du code préfixe optimal pour un texte donné.

Plus précisément, étant donné un alphabet fini Σ et une application $f:\Sigma\to [0,1]$ associant à chaque lettre son nombre d'occurences dans le texte considéré. Ainsi $\sum_{x\in\Sigma}f(x)$ est la longueur du texte. On cherche un code préfixe X et une application $c:\Sigma\to X$ telle que $\sum_{x\in\Sigma}f(x)|c(x)|$ soit minimale car cela correspond au nombre de bits après codage.

■ Remarque 11.5 On utilise aussi la notion de fréquence du lettre qui est son nombre d'occurence rapporté à la longueur du texte. Un des avantages de la notion de fréquence est qu'il est possible de considèrer une table de fréquence déjà construite comme celle de la langue française.

L'application de codage c peut être représenté par un arbre binaire où les arêtes gauches correspondent à 0, les arêtes droites à 1 et les feuilles aux éléments de Σ dont les étiquettes des chemins y menant depuis la racine de l'arbre correspondent à leur image par c.

Par exemple, pour le code a=0, b=10, c=11 on aurait l'arbre :



Avec un tel arbre, il est très simple de décoder le texte codé car il suffit de suivre un chemin dans l'arbre jusqu'à tomber sur une feuille, produire la lettre correspondante, puis repartir de la racine de l'arbre. La longueur du code associé à une lettre est alors égale à la profondeur de la feuille correspondante. L'optimalité du codage préfixe est ainsi équivalente à la minimalité de l'arbre vis-à-vis de la fonction d'objectif $\varphi(t) = \sum_{x \in \Sigma} f(x) p(t,x)$ où p(t,x) est la profondeur de la feuille d'étiquette x dans l'arbre t ou 0 si x n'est pas une des étiquettes, cet extension permettant d'étendre la fonction d'objectif aux solutions partielles.

L'algorithme d'Huffman va construire un arbre correspondant à un codage optimal à l'aide d'une file de priorité d'arbres. On étend pour cela l'application f à de tels arbres en définissant que si t est un arbre de feuilles x_1, \ldots, x_n alors $f(t) = f(x_1) + \cdots + f(x_n)$.

- Au départ, on place dans la file des arbres réduits à une feuille pour chaque élément $x \in \Sigma$ et dont la priorité est f(x).
- Tant que la file contient au moins deux éléments
 - \star on retire les deux plus petits éléments x et y de la file de priorité f(x) et f(y)
 - \star on ajoute un arbre z = Noeud(x, y) de priorité f(z) = f(x) + f(y).
- On renvoie l'unique élément restant dans la file.

L'implémentation de cet algorithme est alors assez directe avec une file de priorité. On réutilise ici la structure de tas implementée en FIXME. Comme il s'agit d'un tas max, on insère avec -f(x) comme valeur.

ython

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does not exist

L'algorithme de Huffman est un algorithme glouton car si on considère pour solution partielle la fôret présente dans la file et pour objectif la fonction φ étendue aux fôrets en sommant la valeur de φ sur chaque arbre, alors fusionner dans la fôret F deux arbres x et y en la transformant en une fôret F' va avoir l'impact suivant sur la fonction d'objectif :

$$\varphi(F') = \varphi(F) + f(x) + f(y)$$

car, en effet, on va rajouter 1 à la profondeur de chaque feuille et donc on passe pour la contribution de x de $\varphi(x) = \sum_{c \in \Sigma} f(c) p(x,c)$ à $\sum_{c \in \Sigma} f(c) (p(x,c)+1) = \varphi(x) + \sum_{c \in \Sigma} f(c) = \varphi(x) + f(x)$.

On remarque ainsi que la fusion qui minimise localement φ est celle qui fusionne les deux arbres de plus petite valeur pour f.

Pour montrer que l'algorithme glouton produit ici un codage minimal, on va utiliser une technique classique qui consiste à montrer qu'étant donné une solution optimale, on peut toujours la transformer sans augmenter sa valeur pour obtenir, de proche en proche, la solution renvoyée par le glouton.

Théorème II.1 Supposons que les lettres les moins fréquentes soient a et b, il existe un arbre optimal dont les deux feuilles étiquettées par a et b descendent du même noeud et sont de profondeur maximale.

Démonstration. Considérons un arbre optimal t et soient c l'étiquette d'une feuille de profondeur maximale. On remarque qu'elle a forcément une feuille sœur car sinon, on pourrait omettre le noeud et l'arbre obtenu serait de plus petite valeur par φ .

FIXME: dessin

Soit d l'étiquette de cette feuille sœur. Sans perte de généralités, on suppose que $f(c) \leq f(d)$ et $f(a) \leq f(b)$. Comme a a le plus petit nombre d'occurences, a $f(a) \leq f(c)$ et comme b est la deuxième, on a $f(b) \leq f(d)$. De plus, $p(t,a) \geq p(t,c)$ et $p(t,b) \geq p(t,d)$.

Si on échange les étiquettes a et c, seule les termes associées à ces lettres changent dans l'évaluation de φ . Si on note t' le nouvel arbre obtenu après cet échange, on a

$$\varphi(t') = \varphi(t) - f(a)p(t, a) - f(c)p(t, c) + f(a)p(t, c) + f(c)p(t, a)$$

Or, $f(c) \ge f(a)$ et $p(t, a) \ge p(t, c)$ donc

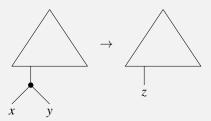
$$\varphi(t') = \varphi(t) + (f(c) - f(a))(p(t, a) - p(t, c)) \le \varphi(t)$$

L'échange préserve le caractère optimal. En fait, ici, on a nécessairement une égalité pour ne pas aboutir à une contradiction, donc soit les feuilles étaient à même profondeur, soit les lettres avaient le même nombre d'occurrences.

Comme on a les mêmes relations entre b et d, on peut effectuer le même argument et échanger les étiquettes en préservant le caractère optimal.

Le théorème suivant permet de raisonner par récurrence en diminuant le nombre de lettres.

Théorème II.2 Soit t un arbre ayant x et y comme feuilles soeurs et t' l'arbre obtenu en remplaçant le noeud liant x et y par une feuille étiquettée par z où z est une nouvelle lettre telle que f(z) = f(x) + f(y).



On a alors $\varphi(t) = \varphi(t') + f(z)$.

Démonstration. Seule les termes portant sur x, y et z sont influencés par le changement et on a :

$$\begin{split} \varphi(t) &= \varphi(t') + f(x)p(t,x) + f(y)p(t,y) - f(z)p(t',z) \\ &= \varphi(t') + f(z)(p(t',z)+1) - f(z)p(t',z) \\ &= \varphi(t') + f(z) \end{split}$$

Théorème II.3 L'algorithme de Huffman renvoie un arbre optimal.

Démonstration. Par récurrence sur $|\Sigma|$.

Initialisation: si Σ ne contient qu'une lettre, il n'y a qu'un arbre qui est nécessairement optimal.

Hérédité : si la propriété est vraie pour un alphabet de $n-1 \geq 1$ lettres, alors soit Σ contenant n lettres et x et y les deux lettres les moins fréquentes.

On pose Σ' obtenue en remplaçant x et y par une nouvelle lettre z et on suppose que f(z) =f(x) + f(y). L'hypothèse de récurrence assure qu'on obtient un arbre optimal t' en appliquant l'algorithme d'Huffman sur Σ' . Comme la première étape d'Huffman va fusionner les feuilles x et y, on sait que l'arbre t obtenu en partant de Σ se déduit de t' en remplaçant z par Noeud(x,y). Le théorème précédent assure alors que $\varphi(t) = \varphi(t') + f(z)$.

Soit t_o un arbre optimal pour Σ dans lequel x et y sont soeurs, possible en vertu du premier théorème, et soit t'_o l'arbre obtenue en remplaçant dans t_o le noeud liant x et y par une feuille étiquettée par z. On a ici encore $\varphi(t_o) = \varphi(t'_o) + f(z) \ge \varphi(t') + f(z) \ge \varphi(t)$ car t' est optimal. Ainsi, on a bien l'égalité $\varphi(t_0) = \varphi(t)$ et t est optimal.

II.3 Preuve d'optimalité

Dans le paragraphe précédent, on retrouve un schéma de preuve classique pour les preuves d'optimalité des algorithmes gloutons :

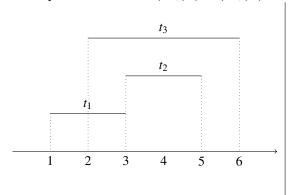
- Montrer qu'à partir d'une solution optimale, il est possible de déterminer une solution optimale ayant fait le même choix que l'algorithme glouton. Pour Huffman c'était le fait d'avoir un arbre optimal ayant les deux lettres les moins fréquentes comme sœurs à profondeur maximale.
- Montrer qu'une solution optimale se comportant comme le résultat de l'algorithme glouton à une étape ne peut être meilleure que le résultat de l'algorithme glouton.

II.4 Sélection d'activités

II.4.i Description

Étant donné un ensemble d'activités données par leur temps de début et leur temps de fin (on considère les temps comme des entiers pour simplifier), on se pose la question du nombre maximal d'activité que l'on puisse sélectionner sans que deux activités soient en conflits. Cela correspond par exemple à l'organisation du planning d'un employé.

On dit que deux activités (d_1, f_1) et (d_2, f_2) sont en conflits quand $[d_1, f_1] \cap [d_2, f_2] \neq \emptyset$.



Ici, t_1 et t_2 sont en conflits avec t_3 . Mais t_1 et t_2 ne sont pas en conflit. On considère que deux activités peuvent se succéder directement : $f_1=d_2$.

On considère donc en entrée de ce problème une suite finie $((d_1, f_1), \ldots, (d_n, f_n))$ et on cherche un sous-ensemble $I \subset [\![1,n]\!]$ de plus grand cardinal tel que pour tous $i,j \in I$, si $i \neq j$ alors (d_i,f_i) et (d_j,f_j) ne sont pas en conflits. On dit que I est un **ensemble indépendant**.

II.4.ii Algorithme glouton et implémentation

Pour résoudre ce problème, on considère l'algorithme glouton associé à la fonction d'objectif cardinal et **en triant les activités** ordre croissant de temps de fin.

Cet algorithme est implémenté dans le programme suivant :

```
#include <stdio.h>
#include <stdlib.h>

typedef struct {
    unsigned int id;
    unsigned int debut;
    unsigned int fin;
    unsigned char selectionnee;
} activite;

int compare_activites(const void *t1, const void *t2)
{
    return ((activite *)t1)->fin - ((activite *)t2)->fin;
```

```
}
void selectionne(activite *activites, size_t nb_activites)
    size_t derniere_activite = 0;
    /* on commmence par trier en O(n log2 n) les activites
    * selon le temps de fin */
    qsort(activites, nb_activites,
        sizeof(activite), compare_activites);
    activites[0].selectionnee = 1;
    for (size_t i = 1; i < nb_activites; i++)</pre>
        if (activites[i].debut >= activites[derniere_activite].fin)
        {
            activites[i].selectionnee = 1;
            derniere_activite = i;
    }
}
int main()
    activite activites[] = {
        \{0, 1, 3, 0\}, \{1, 3, 4, 0\}, \{2, 2, 5, 0\},\
        {3, 5, 9, 0}, {4, 11, 12, 0}, {5, 8, 10, 0},
        { 6, 0, 7, 0 }
    };
    size_t nb_activites = sizeof(activites) / sizeof(activite);
    selectionne(activites, nb_activites);
    for (size_t i = 0; i < nb_activites; i++)</pre>
        printf("Activité %d (%d,%d) : %d\n",
                activites[i].id, activites[i].debut,
                activites[i].fin, activites[i].selectionnee);
    }
    return 0;
```

Ce programme produit alors la sortie :

```
Activité 0 (1,3): 1
Activité 1 (3,4): 1
Activité 2 (2,5): 0
Activité 6 (0,7): 0
Activité 3 (5,9): 1
Activité 5 (8,10): 0
Activité 4 (11,12): 1
```

■ Remarque 11.6 Comme l'algorithme commence par effectuer un tri, on a rajouté dans la structure activite un champ permettant d'identifier une activité autrement que par son

indice.

II.4.iii Preuve d'optimalité

On va prouver que l'algorithme glouton renvoie un ensemble indépendant optimal. Le fait que l'ensemble soit indépendant étant direct, on se concentre sur la preuve d'optimalité en présentant un schéma de preuve qui correspond à celui identifié dans le paragraphe précédent.

Théorème II.4 Si a_1, \ldots, a_n sont des activités énumérées dans l'ordre croissant de leur temps de fin, alors il existe un ensemble indépendant optimal contenant a_1 .

■ **Remarque 11.7** Cela signifie qu'il fait le même choix que l'algorithme glouton à la première étape.

Démonstration. Soit I un ensemble indépendant optimal ne contenant pas $a_1=(d_1,f_1)$ (sinon c'est direct). Si $a_k=(d_k,f_k)$ est l'activité de plus petit indice dans I, alors $f_k\geq f_1$ donc pour tout $a_i=(d_i,f_i)$ dans $I'=I\setminus\{a_k\}$ on a $d_i\geq f_k\geq f_1$ et ainsi a_1 et a_i ne sont pas en conflit. Ainsi $I'\cup\{a_1\}$ est un ensemble indépendant contenant a_1 de même cardinal que I donc optimal.

Théorème II.5 Soit $A = \{a_1, \ldots, a_n\}$ des activités ordonnées par ordre croissant de temps de fin et I un ensemble indépendant optimal contenant $a_1 = (d_1, f_1)$ (ce qui est possible selon le théorème précédent).

 $I' = I \setminus \{a_1\}$ est optimal pour $A' = \{ (d, f) \in A \mid d \geq f_1 \}$.

Démonstration. Si, par l'absurde, I' est pas optimal pour A' alors $J \subset A'$ est un ensemble indépendant de cardinal strictement plus grand que celui de I'. Or, $A' \cup \{a_1\}$ est indépendant pour l'ensemble des activités et est de cardinal strictement plus grand que I. Contradiction.

Théorème II.6 L'algorithme glouton renvoie un ensemble indépendant optimal.

Démonstration. Par récurrence forte sur le nombre d'activités.

- Initialisation : Pour une activité a_1 , le glouton renvoie $\{a_1\}$ qui est directement optimal.
- Hérédité : Si la propriété est vérifiée pour $k \leq n$ activités, soit $A = \{a_1, \ldots, a_n\}$ des activités ordonnées par temps de fin. Soit I un ensemble indépendant optimal contenant a_1 et $I' = I \cap \{a_1\}$. Le théorème précédent assure que I' est optimal sur $A' = \{(d, f) \in | d \geq f_1 \}$.

Par hypothèse de récurrence, l'algorithme glouton sur A' produit un ensemble indépendant optimal G', donc tel que |G'| = |I'|. Par construction l'algorithme glouton sur A renvoie $G = G' \cup \{a_1\}$ de même cardinal que I, donc optimal.

II.5 Ordonnancement de tâches

II.5.i Description

On considère ici un problème voisin du problème précédent. On considère n tâches $T = \{t_1, \ldots, t_n\}$ prenant une unité de temps pour être traitées sur une unité de calcul.

Chaque tâche t dispose d'une date limite $f(t) \in [1, n]$ (deadline) à laquelle elle doit être traitée sans quoi on écope d'une pénalité $p(t) \in \mathbb{N}$.

On appelle stratégie d'ordonnancement une application $d:T\to [\![0,n-1]\!]$ qui associe à chaque tache un unique temps de début d(t). Selon cette stratégie, on déduit une séparation de T en deux ensembles disjoints :

- $T^+(d)$ l'ensemble des tâches traitées dans les délais : $t \in T^+(d) \iff d(t) < f(t)$.
- $T^-(d)$ l'ensemble des tâches traitées en retard : $t \in T^-(d) \iff d(t) \geq f(t)$. On note alors $P(d) = \sum_{t \in T^-(d)} p(t)$ la somme des pénalités des tâches en retard.
- Exemple 11.1 On considère l'ensemble de tâches :

$\overline{t_i}$	1	2	3	4	5	6	7
$f(t_i)$	1	2	3	4	4	4	6
$p(t_i)$	3	6	4	2	5	7	1

Une stratégie d'ordonnancement (les tâches en retard sont en gras) est donnée dans le tableau suivant :

$\overline{t_i}$	1	2	3	4	5	6	7
$d(t_i)$	6	0	1	4	3	2	5

On a alors P(d) = 5.

On cherche à obtenir une stratégie d'ordonnancement de valeur $\mathcal{P}(d)$ minimale.

On remarque que l'ordonnancement des tâches en retard n'a aucune importance, et on peut donc se contenter de déterminer une stratégie d'ordonnancement pour les tâches traitées dans les délais et la compléter par n'importe quel ordonnancement des autres tâches. On peut ainsi reformuler le problème : déterminer un sous-ensemble $T^+ \subset T$ de tâches **pouvant** être traitées dans les délais tel que $\sum_{t \in T^+} p(t)$ soit **maximale**.

II.5.ii Algorithme glouton et implémentation

On résout maintenant ce problème de maximisation des pénalités T^+ par un algorithme glouton :

- $\bullet\,$ On commence avec $T^+=\emptyset$ et tous les temps de $[\![0,n-1]\!]$ sont marqués comme étant disponibles.
- On parcourt les tâches dans l'ordre décroissant des pénalités.
 - * Quand on considère la tâche t s'il existe un temps i disponible tel que i < d(t) alors on marque comme indisponible le temps $i_0 = \max \{ i \in [0, n-1] \mid i < d(t) \text{ et } i \text{ disponible } \}$ et on rajoute alors t à T^+ en commençant t au temps i_0 .
- On place les tâches restantes aux temps disponibles.

Pour les structures de données, on utilise une représentation en tableaux de booléens (des unsigned char à 0 ou 1 en C) pour la disponibilités des temps. L'ensemble T^+ est alors implicite car il correspond aux tâches ordonnancé dans la première étape. Utiliser un tableau implique qu'une recherche linéaire soit faite pour chercher un plus grand temps disponible, et donc, la complexité temporelle globale sera en $O(n^2)$.

■ Remarque 11.8 Il est possible d'améliorer cela pour passer en $O(n \log_2 n)$ (exercice).

Le programme C suivant implémente cet algorithme.

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
typedef struct {
    unsigned int id;
    unsigned int date_limite;
    unsigned int penalite;
    int debut; /* -1 tant que la tâche n'est pas ordonnancée */
} tache;
int compare_taches(const void *t1, const void *t2)
    return ((tache *)t2)->penalite - ((tache *)t1)->penalite;
}
void *ordonnancement(tache *taches, size_t nb_taches)
    unsigned char *temps_occupe = malloc(sizeof(unsigned char) * nb_taches);
    memset(temps_occupe, 0, nb_taches);
    /* tri des activités par ordre décroissant des pénalités */
    qsort(taches, nb_taches, sizeof(tache), compare_taches);
    /* T+ par algorithme glouton */
    for (size_t k = 0; k < nb_taches; k++)</pre>
        int i0 = -1;
        for (size_t i = 0; i < nb_taches; i++)</pre>
            if (temps_occupe[i] == 0 && i < taches[k].date_limite)</pre>
                i0 = i;
        if (i0 >= 0)
            taches[k].debut = i0;
            temps_occupe[i0] = 1;
        }
    }
    /* Complétion par les tâches en retard */
    int i = 0; // indice du dernier temps disponible utilisé
    for (size_t k = 0; k < nb_taches; k++)</pre>
    {
        if (taches[k].debut == -1)
        {
            while(temps_occupe[i] == 1)
                i++;
            taches[k].debut = i;
            temps_occupe[i] = 1;
        }
```

Il produit la sortie:

```
T6 (f:4,p:7) @ 3
T2 (f:2,p:6) @ 1
T5 (f:4,p:5) @ 2
T3 (f:3,p:4) @ 0
T1 (f:1,p:3) @ 4
T4 (f:4,p:2) @ 6
T7 (f:6,p:1) @ 5
```

Ce qui correspond à l'ordonnancement $t_3, t_2, t_5, t_6, t_1, t_7, t_4$. Les tâches t_1 et t_4 sont en retard, donc la pénalité totale est de 5.

II.5.iii Preuve d'optimalité

On va montrer que cet algorithme glouton renvoie un ensemble T^+ optimal. Pour cela, on procède comme précédemment. Tout d'abord, on montre qu'il existe une solution optimale qui effectue le premier choix de l'algorithme glouton.

Théorème II.7 Soit T un ensemble de tâches et $t \in T$ une tâche de pénalité maximale. Il existe un ensemble T^+ de tâches pouvant être traitées dans les délais, maximal pour les pénalités et tel que $t \in T^+$.

Démonstration. Soit $T^+ \subset T$ un ensemble maximal. S'il contient t, il convient directement. Sinon, il existe une tâche t' de T^+ qui est traitée à un moment où on pourrait traiter t à temps (sinon $T^+ \cup \{t\}$ conviendrait et T^+ ne pourrait être maximal). On a $p(t') \leq p(t)$ par maximalité de t. L'ensemble T' déduit de T^+ en remplaçant t' par t convient car on a forcément $P(T') = P(T^+)$ (en fait \geq mais = par optimalité de T^+) et par construction toutes ses tâches peuvent être traitées à temps.

On montre maintenant qu'en enlevant le choix glouton, on obtient une solution optimale du sous-problème.

Théorème II.8 Soit $T^+ \subset T$ ensemble de tâches pouvant être traitées, maximal pour les pénalités et contenant une tâche t de plus grande pénalité. Soit i l'instant auquel la tâche tcommence dans un ordonnancement de T^+ .

On pose $T' = T \setminus \{t\}$ avec des dates limites modifiées :

$$\forall t' \in T', d_{T'}(t') = \begin{cases} d_T(t') & \text{si } d_T(t') \le i \\ d_T(t') - 1 & \text{sinon} \end{cases}$$

 $T^+\setminus\{t\}$ est alors maximal pour T'.

Démonstration. Dans T', on a à la fois enlevé t et supprimé l'instant i. Tout ordonnancement de T' peut alors être relevé en un ordonnancement de T en décalant d'un instant les tâches commençant à partir de l'instant i et en ordonnançant là la tâche t. Réciproquement d'un ordonnancement dans T, on déduit directement un ordonnancement de T^\prime

Ainsi, s'il existait T'^+ maximal pour T' tel que $P(T'^+) > P(T^+ \setminus \{t\}) = P(T^+) - p(t)$ alors $T'^+ \cup \{t\}$ serait de somme de pénalités strictement plus grande que celle de T^+ supposé maximal.

Donc, $T^+ \setminus \{t\}$ est maximal.

On conclut alors directement par récurrence sur le nombre de tâches comme on l'a fait précédemment pour la sélection d'activités:

Théorème II.9 L'algorithme glouton renvoie un ordonnancement optimal.

Ш Diviser pour régner

III.1 Principe

Le principe des algorithmes dits Diviser pour régner est de décomposer un problème en plusieurs sous-problèmes disjoints et de déduire des solutions de ces sous-problème une solution au problème de départ.

Le point clé pour ce principe est de pouvoir fusionner les solutions de sous-problèmes pour en faire une solution, et de pouvoir le faire dans un temps/espace raisonnable. On procède alors par récursivité en appliquant ce principe pour résoudre les sous-problèmes eux-mêmes jusqu'à tomber sur des sous-problèmes très simples.

111.2 Tri fusion

L'algorithme du tri fusion est un des exemples les plus important d'algorithmes Diviser pour régner:

- Étant donnée une liste l de taille $n \geq 2$, on va considérer les sous-listes l_p des valeurs d'indice pair et l_i des valeurs d'indice impair.
- On trie ensuite l_1 et l_2 pour obtenir l'_1 et l'_2 .
- On fusionne ces deux listes pour obtenir $l' = \text{fusion}(l'_1, l'_2)$ liste triée déduite de l.

Comme expliqué dans le paragraphe précédent, les tris de l_1 et l_2 s'effectuent eux-aussi à l'aide d'un tri fusion.

■ Note 11.4 TODO: dessin

Voici une implémentation en OCaml de cet algorithme :

```
let rec separe_en_deux l =
    match l with
    | [] -> ([], [])
    | [x] \rightarrow ([x], [])
    | x::y::q -> let l1, l2 = separe_en_deux q in
        (x::l1, y::l2)
let rec fusionne l1 l2 =
    match l1, l2 with
    | [], _ -> l2
      _, [] -> l1
    | x::q1, y::q2 ->
        if x < y
        then x :: (fusionne q1 l2)
        else y :: (fusionne l1 q2)
let rec tri_fusion l =
    match l with
    | [] -> []
      [x] \rightarrow [x]
        let l1, l2 = separe_en_deux l in
        let l1p = tri_fusion l1 in
        let l2p = tri_fusion l2 in
        fusionne l1p l2p
```

La correction et la terminaison de cet algorithme ne posant aucune difficulté, on va se concentrer sur le calcul de la complexité temporelle :

- separe_en_deux consiste en un parcours linéaire de la liste l donc O(|l|).
- fusionne supprime un élément d'une des deux listes à chaque appel récursif, donc une complexité en $O(|l_1| + |l_2|)$.
- Pour tri_fusion la situation est plus complexe en raison du double appel récursif. On va d'abord traiter le cas des listes contenant 2^k éléments.

Notons t_n la complexité temporelle pour |l| = n.

```
Lemme III.1 t_{2^n} = O(2^n \log_2 2^n)
```

Démonstration. Par l'analyse de complexité des deux fonctions auxiliaires, on a pour $n \in \mathbb{N}$

$$t_{2^{n+1}} = 2t_{2^n} + O(2^n) \le 2t_{2^n} + M2^n$$

où on peut supposer que $M \geq 1$.

On va montrer par récurence sur $n \in \mathbb{N}^*$ que $t_{2^n} \leq 2Mn2^n$.

- Initialisation: $t_{2^1} = 2t_1 + M2 = 2M + 2 \le 4M = 2 \times 1 \times 2^1 M$.
- Hérédité : si $n \in \mathbb{N}^*$ et l'hypothèse est vérifiée pour t_{2^n} , alors $t_{2^{n+1}} \leq 4n2^n M + M2^n =$ $(4n+1)M2^n \le 4(n+1)M2^n \le 2M(n+1)2^{n+1}.$ Ainsi $t_{2^n} = O(n2^n)$.

```
Théorème III.2 t_n = O(n \log_2 n)
```

Démonstration. Le lemme assure qu'il existe M' tel que $\forall p \in \mathbb{N}^*, t_{2^p} \leq M'p2^p$.

Soit $n \in \mathbb{N}^*$ et p minimum tel que $n \leq 2^p$. On a $\log_2 n \leq p$ par croissance de \log_2 et ainsi $t_n \le t_{2^p} \le M'p2^p = M'n \log_2 n.$

Ainsi, $t_n = O(n \log_2 n)$.

Remarque 11.9 On a utilisé implicitement la croissance de t_n ici : plus la liste est longue, plus on effectue d'opérations.

Le programme suivant présente une implémentation du tri fusion reposant sur des tableaux. Les sous-tableaux sont manipulés à l'aide de leurs indices de début et de fin comme pour la recherche dichotomique.

```
let rec separe_en_deux l =
    match l with
      [] -> ([], [])
      [x] \rightarrow ([x], [])
    | x::y::q -> let l1, l2 = separe_en_deux q in
        (x::l1, y::l2)
let rec fusionne l1 l2 =
    match l1, l2 with
    | [], _ -> l2
| _, [] -> l1
    | x::q1, y::q2 ->
        if x < y
        then x :: (fusionne q1 l2)
        else y :: (fusionne l1 q2)
let rec tri_fusion l =
    match l with
      [] -> []
      [x] \rightarrow [x]
        let l1, l2 = separe_en_deux l in
        let l1p = tri_fusion l1 in
        let l2p = tri_fusion l2 in
        fusionne l1p l2p
```

■ Note 11.5 TODO: exercice tri avec un tableau et tri en place

111.3 Nombre d'inversions

Définition III.1 Soit t une structure séquentielle (tableau, liste,) contenant des valeurs comparables $a_0, ..., a_{n-1}$ et énumérées dans cet ordre au sein de t .

Une paire $(i, j) \in [0, n-1]^2$ où i < j est appelée une inversion de t lorsque $a_i > a_j$. On note I(t) le nombre d'inversion de t.

- Remarque 11.10 Le nombre d'inversions permet de mesurer à quel point t est non triée dans l'ordre croissante.
 - Ce concept d'inversion est exactement celui utilisé pour les permutations en mathématiques : si $\sigma \in \mathfrak{S}_n$, il suffit de considérer $(\sigma(1), \ldots, \sigma(n))$.

On cherche dans ce paragraphe à calculer I(t) efficacement. Remarquons tout d'abord qu'un algorithme na \ddot{i} f est en $O(n^2)$ où |t|=n en explorant toutes les paires :

```
size_t inversions(int *t, size_t taille)
{
    size_t inv = 0;
    for (size_t i = 0; i < taille; i++)
    {
        for (size_t j = i+1; j < taille; j++)
        {
            if (t[i] > t[j]) inv++;
            }
      }
    return inv;
}
```

On va maintenant donner un algorithme type Diviser pour régner :

- On sépare t en deux moitiés t_1 et t_2 .
- On calcule $I(t_1)$ et $I(t_2)$ par des appels récursifs.
- ullet On compte les inversions entre des éléments de t_1 et des éléments de t_2
 - \star Cela ne dépend pas de leur position dans t_1 ou dans t_2 .
 - \star On peut donc trier t_1 en t'_1 et t_2 en t'_2 .
 - * On compte $N(t_1, t_2) = N(t'_1, t'_2)$ le nombre d'inversions entre t'_1 et t'_2 .
- ullet On en déduit que $I(t)=I(t_1)+I(t_2)+N(t_1,t_2)$.

Pour calculer le nombre d'inversions entre deux tableaux triés t_1' et t_2' on peut utiliser l'algorithme en $O(|t_1'| + |t_2'|)$ suivant : pour j parcourant les indices de t_2' , on cherche le plus petit i tel que $t_1'[i]$.

- III.4 Points les plus proches
- III.5 Sous-ensemble de somme donnée
- III.6 Recherche dichotomique
- III.7 Couverture par des segments égaux

On considère ici n points sur la droite réelle. Le i-ème point est identifié par sa coordonnée x_i . On se pose alors, dans un premier temps, la question de savoir si on peut trouver k segments de longueur l tels que chaque point appartienne à au moins un de ces segments. Dans un second temps, on se posera la question de la longueur l minimale de ces segments.

III.7.i Couverture par des segments de longueur donnée

On va ici résoudre le premier problème :

```
Problème - EXISTENCECOUVERTURESEGMENT

• Entrées :

\star n points sur la droite réelle x_1,...,x_n
```

- \star un entier $k \geq 1$
- \star un réel l
- Sortie : existe-t-il k segments S_1, \ldots, S_k de longueur l tels que $\forall i \in [1, n], \exists j \in [1, k], x_i \in S_j$?

On remarque qu'un segment de longueur l est uniquement caractérisé par son extrémité gauche. Pour chaque x_i , il doit ainsi exister une extrémité gauche dans le segment $S_i = [x_i - l, x_i]$. On peut ainsi renverser le problème et en faire un problème de couverture de segments par des points : on cherche k points tel que chaque segment S_i contienne au moins un de ces points.

Problème - ENSEMBLEINTERSECTANTLIGNE

- Entrées:
 - \star *n* segments $S_i = [l_i, r_i]$
 - \star un entier k > 1.
- Sortie : Un ensemble P de k points tels que $\forall p \in P, \exists i \in [\![1,n]\!], p \in S_i$ en cas de succès

Ce problème peut se résoudre par un algorithme glouton :

- on commence avec $P = \emptyset$
- on trie les segments par r_i croissant
- pour chaque segment $S_i = [l_i, r_i]$, s'il ne contient aucun élément de P, on rajoute r_i à P.
- on répond avec un succès si $|P| \le k$ (on peut alors compléter avec des points quelconques pour avoir exactement k points).

Cet algorithme est en $O(n \log n)$ en raison du tri initial.

III.7.ii Longueur minimale

On considère maintenant le problème suivant :

Problème - COUVERTURESEGMENTSMINIMALE

- Entrées:
 - $\star n$ points à coordonnées entières sur la droite réelle $x_1,...,x_n$
 - \star un entier $k \geq 1$
- ullet Sortie : la longueur l minimale pour laquelle il existe une couverture des points par k segments de longueur l.

On peut résoudre ce problème par dichotomie à l'aide de l'algorithme précédent

- on considère $L=\frac{\max_{1\leq i< j\leq n}|x_j-x_i|}{k}=\frac{D}{k}$ où le diamètre D se calcule en O(n) et correspond à répartir de manière uniforme les segments pour couvrir les points. Une telle couverture existe toujours.
- on peut considérer, sans avoir besoin de le calculer au préalable, le tableau V de booléen de longueur L+1 tel que V[l] indique s'il est possible de couvrir les points par k segments de longueur l. Pour obtenir la valeur V[l] il suffit d'appliquer l'algorithme précédent.
- on effectue alors une recherche dichotomique du plus petit indice l tel que V[l] soit vrai. On obtient ainsi un algorithme en $O\left(n\log n\log\frac{D}{k}\right)$ qu'on peut considérer comme étant en $O(n\log n)$ en supposant que D est une constante.

Cette dichotomie est en fait une instance d'un principe fondamental permettant de transformer un problème de décision (existe-t-il?) en un problème d'optimisation (quelle est ... minimal/maximal?).

- III.7.iii Implémentation
 - **IV** Programmation dynamique
 - IV.1 Principe
 - IV.2 Somme de sous-ensembles
 - IV.3 Ordonnancement de tâches
 - IV.4 Plus longue sous-suite commune
 - IV.5 Distance d'édition



12. Algorithmique des textes

Source image: justgrims, https://www.flickr.com/photos/notbrucelee/8016192302

■ Note 12.1 Roadmap:

- Des exercices.
- Les extensions à la fin.

Sources

- Algorithms Robert Sedgewick, Kevin Wayne
- Éléments d'algorithmique D. Beauquier, J. Berstel, Ph. Chrétienne
- 125 Problems in Text Algorithms with Solutions Maxime Crochemore, Thierry Lecroq, Wojciech Rytter

I Recherche dans un texte

I.1 Principe de la recherche

On s'intéresse ici au problème suivant:

Problème - RECHERCHETEXTE

- Entrées:
 - $\star\,$ une chaîne de caractère s sur l'alphabet Σ
 - $\star\,$ un autre chaîne de caractère m sur ce même alphabet appelé motif et de longueur plus petite que s
- Sortie : un résultat partiel correspondant à l'indice de la première occurrence du motif dans la chaîne s'il est présent.

La différence fondamentale entre ce problème et celui de la recherche d'un sous-tableau dans un tableau est le fait qu'on considère un alphabet fini et dont le nombre d'éléments est le plus souvent négligeable par rapport à la taille des chaînes de caractères. Cela permet d'effectuer des optimisations qui ne sont pas sans rappeler les tris linéaires comme le tri par comptage.

On parle alors d'algorithmique du texte pour désigner des algorithmes tirant partie de cette contrainte sur les données. La plupart des algorithmes que l'on présente peuvent ainsi s'adapter aisément au cas de tableaux dont les éléments sont pris dans un ensemble fini de petit cardinal.

Avant d'entamer ce chapitre, remarquons qu'il existe, outre l'alphabet usuel, trois alphabets très importants :

- celui des caractères ASCII usuels
- celui contenant les deux éléments 0 et 1, ce qui permet de travailler sur des recherche en binaire.
- et enfin, très important pour la biologie, l'alphabet à quatre lettres A, T, G et C correspondant aux bases d'un brin d'ADN et qui ouvre la porte à beaucoup d'applications en bio-informatique.
- Note 12.2 Il y aura sûrement des applications bio-info dans la partie programmation dynamique, faire le lien ici.

1.2 Algorithme naïf en force brute

Une solution na \ddot{i} ve consiste à parcourir chaque position de s afin de tester si le motif est présent à partir de cette position.

indices	0	1	2	3	4	5	6	7	8
S	t	0	t	a	t	0	t	0	u
recherche à l'indice 0	t	0	t	0					
à l'indice 1		t	O	t	O				
à l'indice 2			t	0	t	0			
à l'indice 3				t	0	t	0		
à l'indice 4					(t	0	t	0	
					motit	trouve	é à l'ind	dice 4	

Cela donne l'implémentation assez directe suivante :

La complexité temporelle en pire cas de cet algorithme correspond au maximum de comparaisons. On peut naturellement en déduire par majoration une borne en O(np) mais on peut remarquer qu'il est assez difficile d'obtenir un exemple concret, ce qui fait penser que ce pire cas est rare.

I Recherche dans un texte

Remarque 12.1 Considérons la chaîne $s = aa...a = a^n$ qui contient n fois la lettre a et le motif $m = a^{p-1}b$ qui contient p-1 a et finit par un b. Dans l'algorithme, on va donc à chaque étape de la première boucle effectuer p itérations dans la seconde avant de se rendre compte que le motif n'est pas présent en comparant b et a. On a donc exactement $(n-p+1)p = \Theta(np)$ comparaisons et on retombe ainsi sur la complexité O(np) pour ces exemples.

Ce qui va se passer dans une application usuelle de cet algorithme, c'est qu'au bout d'une ou deux comparaisons, on pourra invalider la position et passer à la suivante. On va alors avoir une complexité en O(n+p) en considérant en plus la validation du motif dans le cas où il est présent. Ici $p \le n$ donc O(n+p) = O(n) mais c'est important de garder en tête cette complexité en O(n+p)p) qu'on retrouvera car elle s'appliquera à des algorithmes où on effectue un prétraitement sur le motif pour l'appliquer ensuite sur plusieurs chaînes.

Algorithme de Boyer-Moore

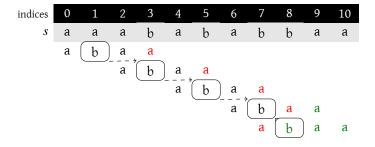
Dans un premier temps, on va présenter la variante usuelle de cet algorithme appelée algorithme de Boyer-Moore-Horspool. On présentera ensuite l'algorithme de Boyer-Moore en tant que tel.

I.3.i Principe de Boyer-Moore-Horspool

Le principe de l'algorithme de Boyer-Moore-Horspool est d'effectuer une recherche du motif comme précédemment mais en partant de la fin. On va alors tenter de trouver des suffixes de plus en plus grand du motif. Si on trouve ainsi le motif, on renvoie la position. Sinon, c'est qu'on a lu dans s un mot de la forme xm' où m' est un suffixe strict de m mais xm' n'en est pas un. Si x n'est pas présent dans m, alors on peut relancer la recherche juste après x dans s. Si x est présent dans m, on peut relancer la recherche en alignant ce caractère avec sa position la plus à droite dans m.

■ Remarque 12.2 Il faut tenir compte différemment du dernier caractère du motif, car il n'est pas utile de le réaligner. On considère alors, quand elle existe, l'occurrence précédente de ce caractère.

On obtient ainsi une stratégie de saut qui en cas d'échec relance la recherche plus loin. Voici un premier exemple où on effectue une recherche de abaa dans le mot aabababbaa. Cette stratégie a permis d'éviter une recherche inutile à partir de l'indice 1.



1.3.ii Implémentation par table de saut

Pour réaliser ces sauts, on construit une table droite indexée par Σ et telle que droite [c] indique l'indice de l'occurrence la plus à droite dans le motif m du caractère c, en ignorant le dernier caractère du motif.

Ainsi, dans l'exemple précédent du motif abaa, on obtient la table suivante :

С	ʻa'	'b'	'c'	···
droite[c]	2	1	Ø	

On a indiqué ici \emptyset quand un caractère de Σ n'est pas présent dans le motif, car il peut être présent dans s.

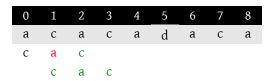
Cette table contient donc de l'ordre de Σ éléments. On peut la réaliser par un tableau direct de taille $|\Sigma|$ étant donné un ordre d'énumération. On peut aussi la réaliser par un dictionnaire, ce qui est plus économe en espace si le motif contient peu de lettres différentes. On a choisit ici, pour des raisons pédagogiques, de considérer la numérotation ASCII naturelle associées au caractère de cette table.

Afin d'implémenter l'algorithme lui-même, il est nécessaire de faire des calculs élémentaires mais précis pour déterminer le saut à effectuer. Si à la position i+j on a un échec après avoir lu le caractère c où droite [c] contient la valeur k.

• Si $k=\emptyset$, c'est que le motif ne pourra jamais être trouvé tant que ce caractère c sera présent. On relance donc la recherche juste après à l'indice i+j+1.

ı									
	0	1	2	3	4	5	6	7	8
	a	b	b	a	a	d	a	С	a
	d	a	С						
				d	a	С			

• Si $k \geq j$, cela signifie que c est présent plus à droite dans le motif, donc aligner cette occurrence ne permettrait pas d'avancer la recherche. Rien ne nous permet de savoir si c est présent ou non ailleurs dans le motif, on relance alors prudemment la recherche en i+1.



• Sinon, on veut aligner ce c avec le caractère correspondant du motif, si on relance à l'indice i', on souhaite ainsi avoir i' + k = i + j donc i' = i + j - k.

```
def recherche_BMH(motif, droite, chaine):
    '''Cherche motif dans chaine en utilisant la table de saut
    précalculée droite'''
    n, p = len(chaine), len(motif)
    i = 0
    while i <= n-p:</pre>
        present = True
        for j in reversed(range(p)):
            if chaine[i+j] != motif[j]:
                present = False
                k = droite[ord(chaine[i+j])]
                 if k is None:
                     i = i + j + 1
                 elif k < j:
                     i = i + j - k
                     i = i + 1
        if present:
            return i
    return None
```

I.3.ii.a Correction

Tout d'abord, remarquons que la terminaison ne pose pas de questions dans la mesure où on le nouvel indice auquel on relance la recherche est toujours strictement plus grand que le précédent.

Au sujet de la correction, il suffit de s'assurer que les indices écartés correspondent nécessairement à des recherches infructueuses. Sans perte de généralité, on peut supposer que la recherche s'effectue depuis le premier indice de s. Comme seul les sauts d'au moins deux indices sont ceux pour lesquels il est nécessaire de faire une preuve, cela correspond au cas où $m=m_1cm_2dm_3x$ et $s=s_1cm_3s'$ avec c,d et x des caractères, $d\neq c$ et c non présent dans m_2dm_3 .

Ainsi, toute recherche démarrant à des indices inférieurs échouera systématiquement, au plus tard, en comparant le caractère c de cm_3 avec un caractère du motif dans m_2dm_3 donc différent de c.

I.3.ii.b Complexité

Tout d'abord, on remarque que la table de saut se construit en $O(\max(|m|, |\Sigma|))$ pour un motif m sur un alphabet Σ .

Sans chercher à rentrer dans les détails, on peut raisonnablement penser si l'alphabet contient assez de caractères que les motifs auront peu de répétitions et qu'ainsi, les sauts seront presque toujours maximaux, ce qui permet d'obtenir de l'ordre de $\frac{n}{p}$ comparaisons où n est la longueur de la chaîne et p la longueur du motif.

Cependant, en pire cas, cet algorithme n'est pas meilleur que le précédent. Pour s'en convaincre, on va considérer un exemple proche de celui introduit poru l'algorithme naı̈f. Si on cherche ba^{p-1} dans a^n à l'indice i, il est nécessaire d'attendre de comparer au caractère b pour constater un échec et devoir relancer l'algorithme à l'indice i+1. On va donc faire ici aussi $(n-p+1)p=\Theta(np)$ comparaisons.

La complexite temporelle en pire cas de Boyer-Moore-Horspool est donc de O(np), même si, en pratique, elle est sous-linéaire.

■ Remarque 12.3 Si l'alphabet contient peu de caractères, ce qui est le cas en particulier du binaire, il y a de grandes chances qu'on soit dans ce cas pire cas. Ainsi, Boyer-Moore-Horspool n'est pas adapté pour ce type de texte.

I.3.iii Principe de Boyer-Moore

Considérons le cas suivant de l'algorithme précédent : on cherche abbcabc dans cbacbbcabc.



On remarque qu'en raison du fonctionnement de cet algorithme, on est forcé de faire de tous petits sauts et on est ramené à l'algorithme naïf. Cependant, après la première étape, on sait qu'on a lu un suffixe du motif bc qui est précédé d'un caractère a en sorte que bbc ne soit pas un suffixe du motif.

Il y a un autre endroit dans le motif où on peut trouver *bc avec * un autre caractère que a. On pourrait donc relancer la recherche en alignant cette occurrence de bc avec celle qu'on vient de lire. Cela revient à sauter directement à la dernière étape dans cet exemple :

0	1	2	3	4	5	6	7	8	9
С	b	a	С	b	b	С	a	b	С
a	b	b	С	a	b	С			
			a	h	h	С	a	h	С

Pour pouvoir réaliser ce décalage, il est nécessaire de calculer une nouvelle table en parcourant le motif pour identifier de telles apparitions de suffixes.

On peut aller plus loin en considérant également le plus long préfixe du motif qui soit un suffixe du suffixe considéré. Par exemple, pour le motif bcabc on remarque que bc étant un préfixe, on peut effectuer un saut comme dans l'exemple suivant :

0	1	2	3	4	5	6	7	8
С	a	a	b	С	С	b	b	С
b	С	a	b	С				
			b	С	a	b	С	

I.3.iii.a Table des bons suffixes

■ Note 12.3 Tout cela sera redéfini proprement plus tard dans le chapitre sur les langages. Je laisse cette partie en attendant pour que la présentation soit complète.

Il est nécessaire d'introduire des définitions précises pour formaliser la stratégie qu'on vient de présenter. Dans le contexte des langages, on parle plus souvent de mot que de chaîne de caractères, qui sont un type de données permettant de les représenter. Un mot sur l'alphabet Σ est donc une suite finie $a_1 \ldots a_n$ de lettres dans l'alphabet. On note μ l'unique mot vide, c'està-dire ne contenant aucune lettre. L'ensemble des mots sur Σ est noté Σ^* . Si u et v sont des mots, uv est le mot obtenu par concaténation.

_

- Remarque 12.4 Σ^* muni de cette loi de composition a une structure proche de l'ensemble des entiers naturels N muni de l'addition :
 - on a: $\forall u, v, w \in \Sigma^*, u(vw) = (uv)w = uvw$, on dit que la loi est associative;
 - elle possède un élément neutre $\mu : \forall u \in \Sigma^*, \mu u = u\mu = u$.

On dit alors que Σ^* est un **monoïde**. Cette structure très simple est cruciale en informatique.

Définition I.1 Soit $u, v \in \Sigma^*$, on dit que v est :

- un **suffixe** de u s'il existe $w \in \Sigma^*$ tel que u = wv
- un **préfixe** de u s'il existe $w \in \Sigma^*$ tel que u = vw

Lorsque $w \neq \mu$, on parle de suffixe ou de préfixe **propre**.

On dit que v est un **bord** de u lorsque v est suffixe et préfixe propre de u.

Exemple 12.1 Soit u = abacaba. abac est un préfixe de u, caba un suffixe et aba un bord.

Définition I.2 Soit $x = x_1 \dots x_n$ et u, v deux suffixes **distincts** de x. On dit que u et v sont des suffixes disjoints quand on est dans l'un des cas suivants :

- $\begin{array}{ll} \bullet & v = x \\ \bullet & u \neq x, v \neq x \text{ et } x_{|x|-|u|} \neq x_{|x|-|v|}. \end{array}$

Des suffixes disjoints sont donc des suffixes précédés par des lettres différentes dans x. On définit de même la notion de préfixes disjoints.

On considère un motif $x = x_0 \dots x_{n-1}$ et on va reprendre, en la précisant, la description précédente. Se faisant, on va construire une table bonsuffixe appelée la table des bons suffixes du motif x et telle que, pour $i \in [0, n-1]$, bonsuffixe[i] donne le nombre de positions dont on doit décaler le motif vers la droite pour relancer la recherche après la lecture du suffixe $x_{i+1}\ldots x_{n-1}$.

Supposons qu'on vient de lire avec succès un suffixe propre u. Ainsi $x = x_0 \dots x_i u$ et on vient de lire dans la chaîne où on effectue la recherche au avec $a \neq x_i$.

- Soit il existe un autre suffixe buv de x où $b \neq x_i$ et alors on appelle bon suffixe pour u un tel suffixe de longueur minimale et on pose alors bonsuffixe [i] = |v|
- Sinon, on cherche v de longueur minimale tel que x soit un suffixe de uv et on pose également bonsuffixe[i]=|v|.

On remarque que si x est suffixe de uv et qu'on a également buv' suffixe de x, alors |uv| = $|u|+|v|\geq |x|\geq |buv'|\geq |u|+|v'|$ donc $|v|\geq |v'|$ ce qui permet de considérer le plus petit vsur l'ensemble des cas.

Table des suffixes I.3.iii.b

Afin de calculer efficacement bonsuffixe on va commencer par calculer la table des suffixes du motif, il s'agit de la table suffixe où suffixe[i] contient la longueur du plus long suffixe de x de la forme $x_i \dots x_i$. Ainsi, si on note S_i les suffixes de cette forme, on a :

$$\mathrm{suffixe}[i] = \begin{cases} 0 & \mathrm{si}\,S_i = \emptyset \\ \max\left\{\; |s| \mid s \in S_i \;\right\} & \mathrm{sinon} \end{cases}$$

Nécessairement, suffixe[n-1]=n car x convient.

 \blacksquare Exemple 12.2 Pour x=bcabc on a :

i	0	1	2	3	4
suffixe[i]	0	2	0	0	5

et pour x = abbabba:

i	0	1	2	3	4	5	6
suffixe[i]	1	0	0	4	0	0	7

Il est possible de construire suffixe avec un simple parcours linéaire en tirant partie de l'information déjà calculée. Pour cela, on va remplir suffixe de droite à gauche.

A tout moment, on va conserver le meilleur suffixe rencontré, c'est-à-dire celui pour lequel on est allé le plus loin à gauche avant d'avoir un échec de comparaison. On note s la position la plus à droite de ce suffixe et k sa longueur, il s'agit donc de $u=x_{s-k+1}...x_s$ et il y a eu un échec de comparaison en x_{s-k} . Par définition de suffixe on a suffixe [s] = k. Le mot x s'écrit alors :

$$x = x_0 \cdots \underbrace{x_{s-k}}_{x_{s-k+1}} \underbrace{x_{s-k+1}}_{x_s} \cdots \underbrace{x_{n-1-k}}_{x_{n-k}} \underbrace{x_{n-k}}_{x_{n-k}} \cdots \underbrace{x_{n-1}}_{x_{n-k}}$$

Ce qu'on peut représenter schématiquement ainsi :

2	s-l	k .	S	n-k	'с —	1 n-1
	a	и		ŀ	5	и

Maintenant, on considère la position s-i où s>s-i>s-k, cela signifie qu'on cherche un suffixe depuis une position interne au mot u de gauche. Le point clé permettant d'obtenir un algorithme linéaire est de remarquer que la situation est la même que dans le mot u de droite. Or, comme on procède de gauche à droite, on a déjà calculé la valeur correspondante suffixe[n-1-i]. Là, on a deux cas :

• soit quand on a cherché le plus grand suffixe à partir de n-i, on s'est heurté à une erreur de comparaison à la position n-k. Dans ce cas, on a suffixe[n-1-i]=k-i et on peut regarder, en partant de la position s-k, si on peut prolonger le suffixe finissant à la position s-i.

s-k	s-i	s n-1	-k $n-1$	-i $n-1$
a		b		

Pour effectuer ce prolongement, il suffit de comparer, caractère par caractère, vers la gauche en partant de la position s-k. On aboutira alors à une nouvelle position du suffixe finissant le plus à gauche qui finira en s-i.

s -	- i -	- <i>l</i>		s-i	n -	- 1 -	-l		n -	- 1
	d		a			c		a		

Remarquons qu'il n'est pas nécessaire que $s-i-l \neq s-k$. C'est-à-dire que même si a ne permet pas de prolonger le suffixe déduit de la position n-i, on considère tout de même que la nouvelle position de référence est s-i. On en déduit également la valeur suffixe[s-i]= l.

- soit suffixe $[n-1-i] = p \neq k-i$ et alors
 - * soit p < k i, on a alors poru ce suffixe un échec dans u, ce qui limite de la même manière la valeur en s i: suffixe [s-i] = p.
 - * soit p > k i, donc on doit avoir un b après avoir le suffixe dans u depuis s i pour le prolonger, or, c'est impossible car il y a un $a \neq b$. Ainsi, le suffixe est limité par u: suffixe [s-i] = k i.

Il reste à traiter le cas où $s-i \leq s-k$, ce qui revient à considérer qu'on a dépassé le précédent suffixe pouvant apporter une information. On procède donc naïvement pour trouver le plus grand suffixe depuis cette position.

On en déduit l'implémentation suivante :

```
def calcule_suffixe(x):
    '''Prend en entrée un mot non vide x et renvoie son tableau de suffixe'''
    n = len(x)
    suffixe = [ None ] * n
    suffixe[n-1] = n
    plus_a_gauche = n-1
    depart = None
    for j in reversed(range(0,n-1)):
        if plus_a_gauche < j and suffixe[n-1-depart+j] != j-plus_a_gauche:</pre>
            suffixe[j] = min(suffixe[n-1-depart+j],j-plus_a_gauche)
            plus_a_gauche = min(plus_a_gauche, j)
            depart = j
            while plus_a_gauche >= 0 \
                    and x[plus_a_gauche] == x[n-1-j+plus_a_gauche]:
                plus_a_gauche = plus_a_gauche - 1
            suffixe[j] = depart - plus_a_gauche
    return suffixe
```

■ Remarque 12.5 Cette implémentation est optimisée par rapport à la description précédente en calculant directement sans introduire i ou k, et en fusionnant deux cas qui reviennent à dupliquer du code.

On donne ici le code maladroit qui correspond à la traduction exacte de la description précédente :

```
def calcule_suffixe_rep(x):
    '''Prend en entrée un mot non vide x et renvoie son tableau de suffixe'''
    n = len(x)
    suffixe = [ None ] * n
    suffixe[n-1] = n
    plus_a_gauche = n-1
    depart = None
    for j in reversed(range(0,n-1)):
        if plus_a_gauche < j:</pre>
            \# on a j = depart - i avec
            i = depart - j
            # et plus_a_gauche = depart - k avec
            k = depart - plus_a_gauche
            if suffixe[n-1-i] != k-i:
                suffixe[j] = min(suffixe[n-1-i],k-i)
            else:
                depart = j
                while plus_a_gauche >= 0 \
                        and x[plus_a_gauche] == x[n-1-j+plus_a_gauche]:
                    plus_a_gauche = plus_a_gauche - 1
                suffixe[j] = depart - plus_a_gauche
        else:
            plus_a_gauche = depart = j
            while plus_a_gauche >= 0 \
                    and x[plus_a_gauche] == x[n-1-j+plus_a_gauche]:
                plus_a_gauche = plus_a_gauche - 1
            suffixe[j] = depart - plus_a_gauche
    return suffixe
```

On remarque que dans ce code, $plus_a_gauche$ ne peut que diminuer, on effectue donc au plus n itérations dans la boucle while pour tout l'algorithme. Donc, en considérant la boucle for, on effectue au plus 2n comparaisons de caractères : au plus une pour chaque itération de la boucle for pour voir si on entre dans le while, puis en tout au plus n avant de sortir du while.

L'algorithme qu'on a obtenue est bien linéaire en |x|.

1.3.iii.c Obtention de bonsuffixe à partir de suffixe

On reprend maintenant le calcul de bonsuffixe[i] dans le mot $x = x_0 \dots x_{n-1}$.

On cherche à obtenir des suffixe de la forme buv de x où $b \neq x_i$ et $u = x_{i+1} \dots x_{n-1}$ est un suffixe de x. Mais si suffixe [k] = n-1-i cela signifie que ce suffixe est exactement u et qu'il est soit préfixe, soit précédé d'une lettre différente de x_i , sinon n-1-i ne serait pas maximal. On a donc

$$\begin{array}{lll} \mathsf{bonsuffixe}[n-1-i] &=& \min \left\{ \right. n-1-k \left. \right| \right. \mathsf{suffixe}[k] = n-1-i \left. \right\} \\ &=& n-1-\max \left\{ \right. k \left. \right| \right. \mathsf{suffixe}[k] = n-1-i \left. \right\} \end{array}$$

On remarque qu'on peut ainsi faire croitre k et poser :

$$\mathsf{bonsuffixe}[n-1-\mathsf{suffixe}[k]] = n-1-k$$

On a aura alors naturellement, à la fin de la boucle, la valeur minimale placée en dernier.

Reste à considérer les valeurs non remplies ainsi dans le tableau bonsuffixe. Elles correspondent aux positions i telles qu'il n'existe pas de suffixe de la forme buv. On doit donc chercher

un mot uv de longueur minimale dont x est suffixe. Mais u étant un suffixe de x, cela revient à considérer les bords de x. La table suffixe permet également de détecter les bords : si $x_0...x_k$ est un bord c'est que suffixe[k] = k+1.

Soit k < n-1 maximal vérifiant cette condition. Pour tout $u = x_{i+1} \dots x_n$ suffixe de x, pour qu'il ait $x_0 \dots x_k$ comme suffixe, il faut qu'il soit strictement plus long (sinon on est dans le cas précédent), donc que $n-i>k+1\iff i< n-1-k$. Dans ce cas, x est alors suffixe de uv où $v=x_{k+1}\dots x_{n-1}$ donc |v|=n-1-k. Les k plus petits ne pourront alors que faire augmenter |v|, on peut ainsi poser bonsuffixe [i]=n-1-k.

On en déduit un remplissage en parcourant les k dans l'ordre décroissant de n-2 à 0, tout en maintenant l'indice i de la prochaine valeur à remplir dans bonsuffixe. Dès qu'on détecte un bord, on place n-1-k jusqu'à ce que $i \geq n-1-k$.

En sortie de boucle, il est possible que i < n donc qu'il reste des valeurs à remplir. On remarque dans ce cas là que pour que x soit un suffixe de uv il faut que v = x. On a donc pour ces valeurs restantes bonsuffixe [i] = n.

Comme ce second cas est toujours plus long que le premier quand les deux se produisent en i, on implémente successivement les remplissages de sorte à obtenir la valeur minimum. On en déduit le programme suivant :

```
def calcule_bonsuffixe(x):
    '''Prend en entrée un mot non vide x et renvoie son tableau de suffixe'''
    n = len(x)
    suffixe = calcule_suffixe(x)
    bonsuffixe = [ n ] * n

    suivant = 0
    for k in reversed(range(0,n-1)):
        if suffixe[k] == k+1: # c'est un bord
            for i in range(suivant,n-1-k):
                bonsuffixe[i] = n-1-k
        suivant = n-1-k

    for k in range(0,n-1):
        bonsuffixe[n-1-suffixe[k]] = n-1-k

    return bonsuffixe
```

Il est facile de constater que cet algorithme est de complexité temporelle linéaire en |x|.

I.3.iii.d Algorithme de Boyer-Moore

On incorpore naturellement la table precédente à l'algorithme de Boyer-Moore en choisissant le meilleur décalage entre cette table et la stratégie précédente.

Supposons que le motif est de longueur p, que la chaîne dans laquelle on recherche est de longueur n et que la taille de l'alphabet est une constante indépendante des entrées. La première partie de l'algorithme consiste à construire les tables de sauts, comme on l'a vu, elle est en complexité en temps et en espace en pire cas en O(p).

On admet que l'algorithme Boyer-Moore complet, étant donné les deux tables de saut et d'autres modifications mineures non présentées ici, est en complexité temporelle en pire cas en O(n).

Il est assez raisonnable de penser que soit $p \leq n$ quand on effectue une recherche, soit on compte chercher un même motif dans plusieurs textes et on réutilise ainsi les tables de sauts. Il n'est donc pas forcément très pertinent de parler de la complexité globale de l'algorithme, mais lorsqu'on le fait, on dit qu'elle est en O(p+n). On rappelle ici le rôle de l'addition dans les complexités qui fait référence à la succession de deux traitements, un en O(p) suivi d'un en O(n).

I.4 Algorithme de Rabin-Karp

I.4.i Principe

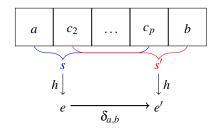
L'algorithme de Rabin-Karp est un algorithme de recherche d'un motif dans un texte qui utilise une notion d'empreinte pour déterminer, en temps constant, si il est probable que la position actuelle corresponde à une occurrence du motif.

Pour cela, si on cherche un motif de longueur p sur l'alphabet Σ , on considère une **fonction** de hachage $h:\Sigma^p\to X$. Les éléments de l'ensemble X sont appelés des empreintes et on suppose que l'égalité entre deux empreintes se vérifie en temps constant contrairement à l'égalité dans Σ^p qui se vérifie en O(p) dans le pire des cas. Le plus souvent, on choisit pour X un type entier machine.

■ Note 12.4 Sûrement mettre ici des renvois vers la partie portant le plus sur la notion de fonction de hachage pour la définition la plus complète.

Bien qu'il soit normalement aussi coûteux de calculer l'image par h d'une sous-chaîne de longueur p que de tester l'égalité entre cette sous-chaîne et le motif, le point essentiel de l'algorithme de Rabin-Karp est d'utiliser une fonction de hachage permettant un calcul incrémental en temps constant :

•



Ici, on considère donc, pour $a,b \in \Sigma$, une fonction de mise à jour $\delta_{a,b}: X \to X$ telle que pour tout $c_2, \ldots, c_p \in \Sigma$ on ait $\delta_{a,b}(h(ac_2 \ldots c_p)) = h(c_2 \ldots c_p b)$.

L'algorithme de Rabin-Karp procède alors ainsi pour chercher m de longueur p dans la chaîne $s=c_0\dots c_{n-1}$ où $n\geq p$:

- calcul de $e_m = h(m)$ et $e = h(c_0..c_{p-1})$.
- Pour i allant de 0 à n-p:
 - $\star \,$ Si $e_m=e$, on renvoie un succès pour la recherche à la position i si $m=c_i\ldots c_{i+p-1}$
 - \star si i < n-p on met à jour l'empreinte $e \leftarrow \delta_{c_i,c_{i+n}}(e)$.

La complexité temporelle liée à la gestion des empreintes est donc en O(n+p)=O(n) car $n\geq p$. Par contre, pour calculer la complexité liée à la recherche $m=c_i\ldots c_{i+p-1}$, il est nécessaire d'estimer la proportion de faux positifs, c'est-à-dire de positions i telles que $e_m=e$ mais $m\neq c_i\ldots c_{i+p-1}$. On va voir dans la partie suivante qu'on peut supposer qu'elle est négligeable, ce qui permet de considérer que l'algorithme de Rabin-Karp est linéaire.

I.4.ii Choix d'une fonction de hachage

Réaliser une bonne fonction de hachage est une question très complexe qui dépasse le cadre du cours d'informatique de MPI. Cependant, il est possible de réaliser ici une fonction de hachage répondant aux contraintes de Rabin-Karp assez facilement.

Pour cela, on considère que les caractères sont des entiers compris entre 0 et 255, ce qui correspond au type des caractères non signés sur un octet. On peut alors identifier une chaîne de longueur p avec un nombre entre 0 et r^p-1 où $r=2^8$, on note ainsi

$$P(c_0 \dots c_{p-1}) = \sum_{i=0}^{p-1} c_i r^{p-1-i} = c_0 r^{p-1} + c_1 r^{p-2} + \dots + c_{p-1}$$

On considère de plus un entier premier q et on pose $h(s)=P(s)\mod q$ c'est-à-dire le reste de P(s) dans la division euclidienne par q. On peut ainsi définir $\delta_{a,b}(e)=(r(e-ar^{p-1})+b)\mod q$.

Si on précalcule $r^{p-1} \mod q$ il suffit d'un nombre d'opération constant, et indépendant de p, pour calculer la nouvelle empreinte à l'aide de $\delta_{a,b}$.

Le point essentiel est alors de déterminer un nombre premier q tel qu'il soit peu probable d'obtenir des faux positifs. Une analyse mathématique permet d'affirmer que chaque élément de [|0;q-1|] a de l'ordre de $\frac{r^p}{q}$ antécédents par h. Ainsi, si on choisit deux chaînes aléatoirement dans Σ^p , il y aura collision avec probabilité proche de $\frac{1}{q}$. En considérant q proche de la taille maximale pour le type entier considéré, on minimise donc cette probabilité.

■ Remarque 12.6 On peut également s'intéresser à des nombres q pour lesquels le modulo soit rapide à calculer. Un exemple classique est $q=2^{31}-1$ car on peut déduire la division euclidienne de a par q de l'écriture de a en base 2^{31} . En effet, si $a=\sum_{k=0}^n a_k 2^{31k}$ comme $2^{31}-1|2^{31k}-1$ pour $k\geq 1$, on a $2^{31k}\equiv 1$ [q] et ainsi $a\equiv\sum_{k=0}^n a_k[q]$. On remarque que $a_k=(a>>31k)\&2^{31}$, on a alors soit $a_k< q$ et alors $a_k\mod q=a_k$, soit $a_k=q$ et

Le programme suivant implémente na \ddot{i} vement les calculs de h et de $\delta_{a,b}$:

```
def hash(r,q,s):
    e = 0
    p = 1
    for c in reversed(s):
        e = (ord(c) * p + e) % q
        p = (r * p) % q
    return e

def delta(r,q,rp,a,b,e):
    return (r * (e - rp * ord(a)) + ord(b)) % q
```

I.4.iii Implémentation

Une implémentation directe de l'algorithme de Rabin-Karp est donnée dans le programme qui suit. On se sert ici du caractère paresseux du && pour n'effecuter le test coûteux d'égalité des chaînes qu'en cas d'égalité des empreintes.

```
def rabin_karp(m, s):
    p, n = len(m), len(s)
    r, q = 256, 0x7ffffffff
    rp = (r ** (p-1)) % q
    me, e = hash(r,q,m), hash(r,q,s[:p])
    for i in range(0,n-p+2):
        if me == e and m == s[i:i+p]:
            return i
        if i+p < n:
            e = delta(r,q,rp,s[i],s[i+p],e)
    return None</pre>
```

Si on suppose qu'il est improbable d'obtenir un faux positif, il est possible de renvoyer un succès dès que les empreintes sont égales. L'avantage d'une telle version est alors d'être un algorithme sans retour sur les données. C'est-à-dire qu'il n'est pas nécessaire de garder en mémoire ou de réaccéder à un caractère.

I.4.iv L'algorithme originel de Rabin et Karp

Si on regarde l'article originel de Rabin et Karp décrivant cette méthode, on peut être étonné du fait que la méthode précédemment décrite était considérée comme déjà connue dans la littérature par les auteurs. En fait, ce qu'ils décrivent et annoncent comme étant novateur est l'utilisation d'un algorithme probabiliste en choisissant aléatoirement une fonction de hachage à chaque lancement de l'algorithme. En pratique, il s'agit de choisir aléatoirement un nombre premier q parmi un ensemble précalculé de nombres premiers.

L'algorithme que l'on vient de décrire a un pire cas qui est très improbable car on considère que la probabilité d'un faux positif est à peu près de 1/q, donc moins de 5.10^{-10} pour $q=2^{31}-1$. Le problème ici est la notion de probabilité sur les entrées : est-on certain que l'algorithme recevra une entrée choisie uniformément? Rabin et Karp parlent d'un adversaire intelligent qui aurait connaissance de la fonction de hachage choisie pour produire des entrées en pire cas. On pourrait ainsi imaginer une attaque sur serveur effectuant une recherche avec Rabin-Karp suite à l'entrée d'un utilisateur. Un adversaire pourrait construire une entrée en pire cas et tenter de surcharger le serveur en l'effectuant de manière répétée.

Pour bien mettre en lumière ce phénomène, nous allons ici construire, dans un cas très simple de fonction de hachage, une telle chaîne problématique. Pour cela, considérons la fonction de hachage précédemment décrite dans le cas de motif de taille 2, avec Σ contenant les lettres de a à z, r=26 et q=17. On considère une recherche du motif aa dont l'empreinte est 0, la même que celle des chaînes ar et ra. On peut donc considérer la chaîne arar...ar qui produira un faux positif à chaque étape.

■ Remarque 12.7 Détail des calculs. Ici on associe à a la valeur 0, ..., à z la valeur 25. On a donc

$$h(aa) = (0 \times 26 + 0) \mod 17 = 0$$

 $h(ar) = (0 \times 26 + 17) \mod 17 = 0$
 $h(ra) = (17 \times 26 + 0) \mod 17 = 0$

L'empreinte reste ainsi nulle tout au long de l'algorithme de Rabin-Karp et on a un faux positif à chaque itération.

II Compression

II.1 Principe

On s'intéresse ici à la compression parfaite d'un texte, c'est-à-dire, étant donné un alphabet fixé Σ , qu'on cherche à réaliser un couple de fonctions $comp, dec: \Sigma^* \to \Sigma^*$ telles que :

- pour tout mot $m \in \Sigma^*$, dec(comp(m)) = m
- pour la plupart des mots m qui correspondent aux données qu'on cherche à compresser, |comp(m)| < |m|.
- Remarque 12.8 Le fait que $dec \circ comp = id_{\Sigma^*}$ implique, comme on a pu le voir dans le cours de mathématique, que comp est injective : deux mots différents ont nécessairement des images distinctes.

Si A et B sont deux ensembles finis tels que |A| < |B|, il n'existe pas de fonction injective de A dans B. Ainsi, si on note L_n les mots de Σ^* de longueur au plus n, il ne peut exister de

II Compression 133

fonction injective de L_n dans L_m où n < m.

Autrement dit : il est impossible d'espérer pouvoir compresser toutes les données de L_n . Si certains mots vont diminuer de longueur après compression, d'autres vont nécessairement augmenter.

Tout l'enjeu des algorithmes de compression parfaites est alors de diminuer les longueurs des mots qui nous intéressent. Par exemple, si on s'intéresse à des mots issus de textes en français, il est plus important d'arriver à compresser une phrase comme "ceci est un texte" plutôt qu'une suite de caractères non signifiante comme "c2#\$%1ajdn //@#3d!fn".

II.2 Algorithme d'Huffman

La définition et la construction de l'arbre de Huffman ont été présentées au paragraphe Algorithme d'Huffman - Compression. On va s'intéresser ici au processus complet permettant de compresser et décompresser des fichiers avec cet algorithme.

II.2.i Calcul de la table d'occurences

Par souci d'efficacité, on calcule une table d'occurences pour l'ensemble des valeurs d'octets entre 0 et 255. Il suffit alors de parcourir le fichier pour incrémenter les valeurs correspondant aux octets lus.

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does not exist

II.2.ii Sérialisation de l'arbre de Huffman

Afin de décompresser, il est nécessaire de connaître l'arbre de Huffman donnant le code préfixe. Pour cela, il faut stocker cet arbre dans le fichier comme une série d'octet, on parle de sérialisation. Cette notion sera prolongée dans le chapitre FIXME.

On choisit ici la représentation récursive repr(a) de l'arbre a définie ainsi:

- Si a = Noeud(g,d), repr(a) = 0 repr(g) repr(d)
- Sia = Feuille(c), repr(a) = 1 c.
- Exemple 12.3 Sia = Noeud(Feuille 42, Noeud(Feuille 16, Feuille 64)), on obtient la suite d'octets: 0 1 42 0 1 16 1 64.

La lecture et l'écriture de la séralisation s'effectue alors simplement par récurrence :

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does **not** exist

II.2.iii Écriture dans un fichier un bit à la fois

■ **Note 12.5** À déplacer éventuellement dans une partie spécifique sur la gestion de fichiers.

Le propre de l'algorithme de Huffman est d'associer à chaque caractère un codage binaire de longueur variable. Afin de pouvoir écrire ce codage dans un fichier, il est nécessaire de grouper les bits par paquet de huit (octet en français, byte en anglais).

Ainsi, par exemple, si on a le codage suivant:

С	'a'	'b'	'c'
code(c)	0	100	101

et qu'on doit encoder "abbaca", on obtient le mot binaire 010010001010 qu'on complète avec des 0 à la fin et qu'on sépare en octets : 01001000 10100000. On obtient donc les deux octets, convertis en décimal, 72 et 160. Ce sont eux qu'on va écrire dans un fichier.

Une technique usuelle pour cela est de garder un accumulateur qui correspond à l'octet en train d'être construit ainsi que le nombre de bits qui ont été accumulé. Dès qu'on accumulé 8 bits, on peut construire l'octet, l'écrire dans le fichier, puis reinitialiser ces variables.

Quand on rajoute un bit b à l'accumulateur, on veut passer de $acc = b_1 \dots b_k$ à $b_1 \dots b_k b = 2acc + b$.

On en déduit l'implémentation assez directe suivante :

```
class Bitpacking:
    '''La classe Bitpacking se comporte comme un fichier Python
    tout en fournissant des méthodes spécifiques à la lecture
    et à l'ecriture de bit.'''
    def __init__(self, filename, mode):
        self.file = open(filename, mode)
        self.accumulateur = 0
        self.bits_accumules = 0
        self.input = mode[0] == 'r'
        if self.input:
            self.init_input()
    def write_bit(self, b):
        if self.bits_accumules == 8:
            self.write(bytes([self.accumulateur]))
            self.accumulateur = 0
            self.bits_accumules = 0
        self.accumulateur = 2 * self.accumulateur \
                + (1 if b else 0)
        self.bits_accumules += 1
```

Il reste à traiter la question des zéros finaux, si l'accumulateur contient k bits au moment de la fermeture du fichier, où 0 < k < 8, il faut ajouter 8 - k zéros. On appelle cela du padding de l'anglais pour rembourrage. Ici, cela correspond à faire un décalage binaire vers la gauche d'autant (shift left en anglais). Comme il sera nécessaire de se souvenir que ces zéros ne sont pas signifiants à la lecture, on rajoute un octet final contenant cette valeur k.

On obtient alors la fonction de fermeture de fichier suivante :

```
def close(self):
    if not self.input:
        self.close_output()
    self.file.close()

def close_output(self):
    if self.bits_accumules == 0:
        self.file.write(b'\x00')
    else:
```

II Compression 135

```
padding = 8 - self.bits_accumules
self.file.write(bytes([
         self.accumulateur << padding,
         padding ]))</pre>
```

■ Remarque 12.9 Une autre possibilité consiste à ajouter un entier décrivant la taille des données non compressées. C'est d'ailleurs parfois un problème avec les formats car si la taille est stockée sur 4 octets cela limite la taille d'un fichier pouvant être compressé.

Pour la lecture, on procède de même en faisant attention à deux points :

- on va lire les bits dans l'octet de la gauche vers la droite, c'est-à-dire du bit de poids le plus fort au bit de poids le plus faible. Ainsi, si l'accumulateur contient $acc = b_1 \dots b_8$, il suffit de faire un et bit à bit avec b10000000=0x80=128 pour obtenir $acc \& 0x80 = b_1 0 \dots 0$ donc un nombre qui vaut 0 si et seulement si $b_1 = 0$. Après avoir effectué cette lecture, il suffit de décaler vers la gauche en multipliant l'accumulateur par $2: 2acc = b_2 \dots b_8 0$.
- on doit tenir compte des zéros finaux, pour ça, on a besoin de savoir qu'on est en train de lire le dernier caractère du fichier. On calcule donc la taille du fichier à son ouverture et on test si l'octet lu est l'avant-dernier, auquel cas on lit le dernier octet et on diminue d'autant le nombre de bits signifiants dans l'accumulateur.

On obtient alors le programme suivant pour la lecture :

```
def init_input(self):
    self.file.seek(0, os.SEEK_END)
    self.taille = self.file.tell()
    self.file.seek(0, os.SEEK_SET)
def read_bit(self):
    if self.bits_accumules == 0:
        c = self.file.read(1)
        if len(c) == 0: # fin de fichier
            return b''
        self.accumulateur = ord(c)
        self.bits_accumules = 8
        if self.file.tell() == self.taille - 1:
            pad = ord(self.file.read(1))
            self.bits_accumules -= pad
    bit = (self.accumulateur & 0x80) != 0
    self.accumulateur *= 2
    self.bits_accumules -= 1
    return bit
```

II.2.iv Compression d'un octet

Pour pouvoir compresser un octet, il est nécessaire d'obtenir le chemin qui mène jusqu'à la feuille dont il est l'étiquette dans l'arbre de Huffman. Pour cela, on commence par calculer l'ensemble des chemins de l'arbre de Huffman sous forme d'une table à 256 entrées qui contient le chemin associé à un octet s'il est présent dans l'arbre ou un chemin vide sinon. On parlera de représentation plate de l'arbre de Huffman.

Il suffit de faire un parcours exhaustif de l'arbre (FIXME référence aux parcours d'arbres) pour réaliser cette table :

ython

 ${\tt ERROR: src/algorithmique/.../snippets/algorithmique/huffman.py\ does\ \textbf{not}\ exist}$

Afin de compresser un octet, on va donc aller lire le chemin dans cette table puis écrire le mot binaire correspond grâce aux fonctions d'écriture bit à bit :

ython

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does not exist

■ Remarque 12.10 A chaque fois qu'on va compresser un octet, on va parcourir la liste correspondant à son chemin. Comme les chemins les plus longs sont les moins fréquents, cela ne pose pas vraiment de problèmes.

Cependant, il est possible d'optimiser cela en ne stockant pas le chemin mais la fonction d'écriture elle-même. Ainsi, on ne va plus stocker des listes de booléens mais des fonctions du type Bitpacking.out_channel_bit -> unit qui vont réaliser l'écriture compressé de l'octet correspondant.

Au cours du parcours de l'arbre, on maintient une fonction correspondant à l'écriture du préfixe du chemin chemin. Si on l'appel est effectué sur un noeud, on remplace chemin par la fonction qui appelle chemin puis écrit le bit correspondant au côté gauche ou droit.

Cela correspond au programme suivant :

ython

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does **not** exist

Cette représentation des chemins partiels par des fonctions est très classique dans le style de programmation fonctionnelle par passage de continuations.

II.2.v Décompression d'un octet

Pour décompresser un octet, il suffit de parcourir l'arbre de Hufmann en lisant bit à bit le fichier compressé en descendant à gauche ou à droite selon que le bit lu soit 0 ou non. Dès qu'on arrive sur une feuille, on écrit dans le nouveau fichier le caractère correspondant.

Python

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does not exist

II.2.vi Compression et décompression de fichiers

En mettant bout à bout l'ensemble des fonctions, on obtient la fonction suivante qui réalise la compression complète d'un fichier :

ython

 ${\tt ERROR: src/algorithmique/.../snippets/algorithmique/huffman.py\ does\ not\ exist}$

On obtient de même la fonction de décompression suivante :

ython

ERROR: src/algorithmique/../../snippets/algorithmique/huffman.py does not exist

II Compression 137

■ Exemple 12.4 En compressant ainsi l'intégrale de Proust, on passe de 7543767 octets à 4249758 octets. A titre de comparaison, l'outil unix zip permet d'obtenir un fichier de 2724213 octets.

■ Remarque 12.11 Le format de fichier présenté ici est rudimentaire. Les formats usuels sont en général plus complexes pour gérer

- l'identification : c'est-à-dire pouvoir déterminer qu'un fichier est un fichier compressé par un certain programme. Les fichiers zip commencent ainsi par les deux lettres PK.
- l'extensibilité: il est possible qu'on souhaite changer le format de sérialisation de l'arbre, ou même l'algorithme. En rajoutant un système de version sur les différentes parties, on peut permettre de faire évoluer un type de fichier en préservant la compatibilité avec les versions précédentes.

II.3 Algorithme de Lempel-Ziv-Welch

L'algorithme d'Huffman est efficace, mais il présente un désavantage majeur : il nécessite de lire le contenu d'un fichier dans son intégralité pour pouvoir déterminer un code préfixe optimal. Il est toutefois possible de modifier l'algorithme pour lever cette limitation. Dans ce paragraphe, nous allons plutôt étudier une autre technique de compression qui, bien que moins efficace en pratique que Huffman, se programme assez facilement et permet de compresser des flux plutôt que des fichiers. C'est-à-dire qu'on peut compresser et décompresser des données au fur et à mesure qu'elles sont transmises.

Il s'agit de l'algorithme de Lempel-Ziv-Welch, appelé communément compression LZW, et qui est une modification faite en 1984 par Welch de l'algorithme de LZ78 de Lempel et Ziv.

II.3.i Principe de la compression

L'idée de l'algorithme LZW est de faire avancer une fenetre sur le texte en maintenant une table des motifs déjà rencontrés. Quand on rencontre un motif déjà vu, on le code avec une référence vers la table et quand on rencontre un nouveau motif, on le code tel quel en rajoutant une entrée dans la table.

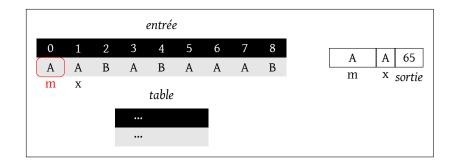
Pour la table, on peut utiliser un tableau dynamique de motifs (ref FIXME) dont la taille ne pourra pas dépasser 2^d éléments ou directement un tableau de 2^d valeurs optionnelles, dans la mesure où d est en général petit. Ainsi, on pourra référencer chaque motif avec un mot de d bits. Afin de pouvoir retrouver efficacement l'indice associé à un motif, on utilise une table de hachage (ref FIXME) réalisant l'inverse de la table.

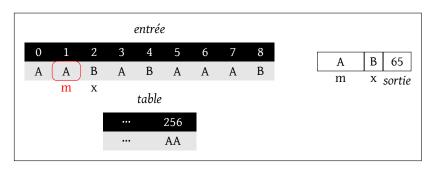
L'algorithme procède alors ainsi pour compresser :

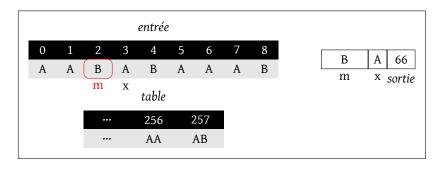
- on initialise la table avec une entrée pour chaque caractère, donc chaque octet, en considérant des caractères 8bit.
- on maintient une variable contenant le plus long suffixe m du texte lu qui soit présent dans la table, il est initialisé avec la première lettre du texte.
- on lit alors chaque caractère x:
 - \star Soit mx est dans la table, et alors on remplace le motif courant par $m \leftarrow mx$
 - * Soit mx n'est pas dans la table, par construction m y est nécessairement on produit alors le code correspondant à m, on rajoute une entrée dans la table pour mx si elle contient moins de 2^d éléments et on repart de $m \leftarrow x$.
- quand tous les caractères ont été lus, on produit le code correspondant à m.

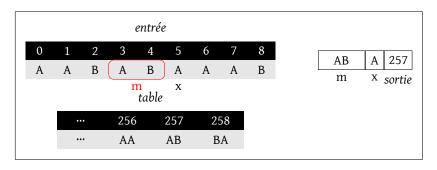
Voici les diffèrentes étapes pour la compression de la chaîne AABABAAAB qui produit la suite d'entiers 65,256,66,65,258,257 qui seront alors codés dans un fichier sur d bits. Les 256 premières entrées de la table ont été volontairement ignorées. On remarque juste que A correspond

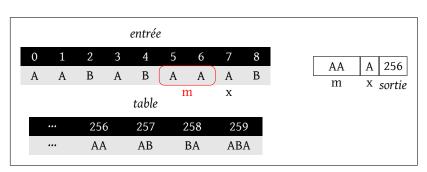
à l'index 65 et B à l'index 66.



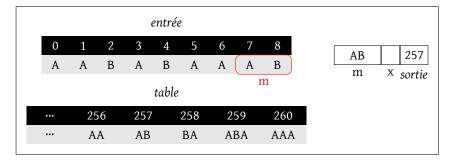








II Compression 139



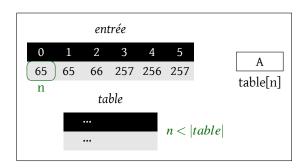
II.3.ii Principe de la décompression

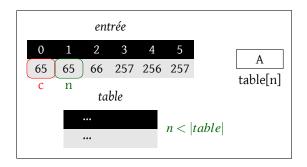
Pour décompresser, on effectue la procédure précédente en sens inverse. Cependant, il faut reconstruire la table en même temps qu'on lit le fichier compressé. Dans la majorité des cas, c'est assez immédiat. Pour le premier code lu, il s'agit forcément d'un réfèrence à un des 256 caractères, donc on le reprouduit. A partir du second code lu:

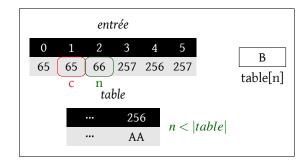
- on lit un code n où n < |table| et table[n] = xm', x est un caractère et m' un mot.
- on écrit xm' dans le fichier de sortie.
- on rajoute ensuite mx dans la table où c et le précédent code lu et table [c]=m

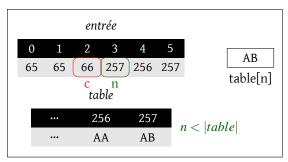
En faisant ainsi, on reproduit le processus de compression mais en remplissant la table avec un temps de retard. En effet, si on reprend le principe exposé plus haut, une entrée pour mx est ajoutée dans la table quand on lit le caractère x et que le motif lu précèdemment est m, on repart alors avec x pour motif lu. C'est exactement ce qu'on fait ici en tenant compte du premier caractère de table [n]. Contrairement à la compression, il est inutile ici de retrouver l'indice associé à un motif. On peut donc ignorer la table de hachage utilisée par la compression.

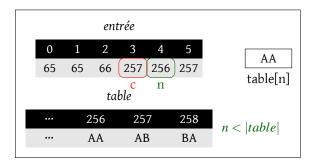
Voici les étapes de décompression de l'exemple précédent :

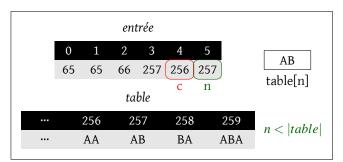












Il reste toutefois un cas à traiter, celui où $n=|{\sf table}|$, c'est-à-dire quand on lit un code qui n'est pas encore présent dans la table. Pour comprendre ce cas, il est important d'identifier précisèment quand il se produit dans le processus de compression. Comme on vient de le voir, on rajoute une entrée pour mx après avoir produit le code c correspondant à m. Pour que le code n ne soit pas présent dans la table, il faut donc que n corresponde à cette entrée mx. Or, quand on a compressé, on est reparti du motif x à ce moment là, donc nécessairement m commence par x. Cela signifie qu'on peut reconstruire table [n] en décompressant avec mx où x est la première lettre de table [c]=m.

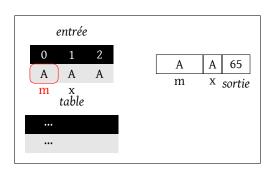
On en déduit alors la procédure complète suivante :

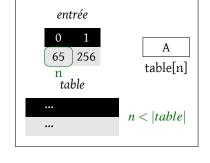
- on initialise la table avec une entrée pour chaque caractère, donc chaque octet, en considérant des caractères 8bit.
- ullet on maintient une variable c contenant le dernier code lu qu'on intialise avec le premier code en produisant le caractère correspondant.

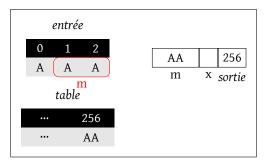
II Compression 141

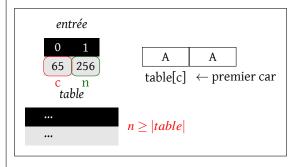
- pour chaque code n:
 - \star Soit $n < |\mathsf{table}|$ et $\mathsf{table}[n] = xm'$ où x est un caractère, alors on écrit xm' en sortie
 - \star Soit $n=|\mathsf{table}|$ et alors on écrit en sortie $\mathsf{table}[c]x$ où x est le premier caractère de $\mathsf{table}[c]$
 - \star Dans tous les cas, on remplace $c \leftarrow n$ et on ajoute table [c]x à la table.

Il y a un exemple classique où on a besoin de traiter ce cas : celui où le même caractère est présent plusieurs fois en début de fichier. Comme LZW est utilisé pour compresser des formats d'images où les pixels sont des indices dans une palette de 256 couleurs avec une couleur pour la transparence, le cas où la même couleur est présente au début du fichier est fréquent. Voici ici un exemple de compression et de décompression pour AAA:









■ Remarque 12.12 On peut pousser un peu plus l'analyse précédente afin d'identifier précisément les situations menant à ces cas problèmatiques. Comme on vient de le voir, il est nécessaire que le texte à compresser contienne un motif de la forme xwxwx où w est un mot et x une lettre. Mais pour que le motif lu contienne xw au moment où on ajoute l'entrée xwx il faut que xw lui même soit dans la table, ce qui signifie que chaque préfixe de xw est également dans la table au moment où on commence à le lire, mais que si le motif précédent est w' alors w'x n'était pas dans la table.

On considère un mot $w=a_1\dots a_n a$ où toutes les lettres sont distinctes, et on va essayer de construire un mot p tel que la compression de p permettra avoir $a_1, a_1 a_2, a_1 a_2 a_3, ..., a_1 \dots a_n$ dans la table.

Si on lit a_1a_2 , on va ajouter a_1 puis a_1a_2 dans la table. On continue alors en partant de a_2 comme motif, pour pouvoir ajouter $a_1a_2a_3$ à la table, il faut lire $a_1a_2a_3$ ensuite car à la lecture de a_1 , comme a_2a_1 n'est pas dans la table on l'ajoute et m devient a_1 , puis a_1a_2 . Ainsi $a_1a_2a_1a_2a_3$ va ajouter a_1 , a_1a_2 , $a_1a_2a_3$ dans la table. En continuant ainsi avec $a_1a_2a_3a_4$, comme a_3a_1 n'est pas dans la table, on va procèder de même.

Le mot $p=a_1a_2a_1a_2a_3a_1a_2a_3a_4\dots a_1a_2\dots a_n$ va donc permettre d'ajouter tous les préfixes de m dans la table.

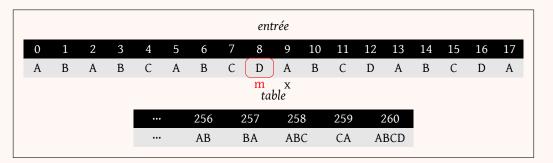
Maintenant, pour obtenir le cas précèdent, il suffit de lire le texte $pwwa_1x = pa_1w_0a_1w_0a_1x$ où $w_0 = a_2 \dots a_n$ et x n'est pas l'un des a_i . En effet, on lit d'abord p ce qui permet d'ajouter tous les préfixes. Comme a_na_1 n'est pas dans la table, on continue avec a_1 comme motif, on l'augmente jusqu'à lire a_1w_0 puis on ajoute une entrée pour $a_1m_0a_1$ en ayant a_1 comme motif, et là on va lire $a_1w_0a_1x$ et à la lecture de x, produire le code de $a_1w_0a_1$ qui est le dernier saisi dans la table.

Remarquons qu'on peut aussi ne considèrer que $pwwa_1$ dans la mesure où la fin du fichier provoquera aussi l'écriture du code.

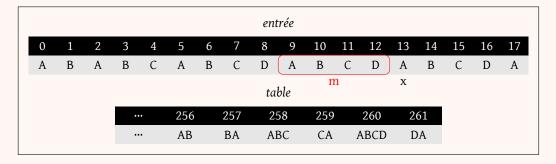
Si on considère $w={\sf ABCD},$ on a $p={\sf ABABCABCD}$ et on pourra ainsi compresser le texte

 $pwwA = pAw_0Aw_0A = \mathsf{ABABCABCDABCDABCDA}$

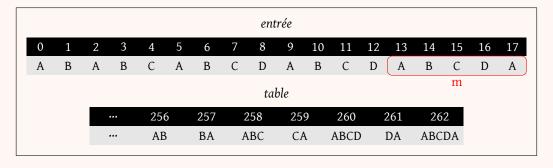
Après lecture de p on est dans la configuration suivante :



Puis après lecture de $wA = Aw_0A$:

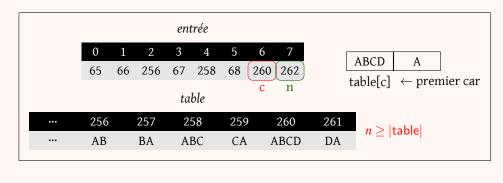


Enfin, la lecture du reste du texte va déclencher l'ajout de ABCDA dans la table et l'écriture de son code.



II Compression 143

A la décompression, on produira bien le texte correspondant avec le principe présenté plus haut :



II.3.iii Implémentation

Avant de commencer à implémenter l'algorithme, il est nécessaire de définir des fonctions de manipulation des entiers sur d bits et de lecture/écriture dans un fichier.

Tout d'abord, on définit des fonctions d'écriture d'entiers sous forme codée sur d bits à l'aide des fonctions vues précédemment :

```
def read_code(self, longueur_code):
    acc = 0
    for i in range(longueur_code):
        b = self.read_bit()
        if b == b'':
            assert(i == 0) # pas au milieu d'un code
            return None
        if b:
            acc += 1 << i
        return acc

def write_code(self, code, longueur_code):
        assert(code < 1 << longueur_code)
        for i in range(longueur_code):
            self.write_bit( code % 2 == 1 )
            code //= 2</pre>
```

On implèmente alors assez directement la compression:

```
def compresse_(nom_in, nom_out, longueur_code=12):
    table = [ bytes([c]) for c in range(256) ]
    indices = { bytes([c]) : c for c in range(256) }

with open(nom_in, 'rb') as fin, \
    Bitpacking(nom_out, 'wb') as fout:
    m = fin.read(1)
    while True:
        c = fin.read(1)
        if c == b'': break
        if m+c in indices:
            m = m+c
        else:
```

```
fout.write_code(indices[m], longueur_code)
    if len(table) < 1 << longueur_code:
        indices[m+c] = len(table)
        table.append(m+c)
    m = c

# code final
fout.write_code(indices[m], longueur_code)</pre>
```

Et on procède de même pour la décompression :

```
def decompresse_(nom_in, nom_out, longueur_code=12):
    table = [ bytes([c]) for c in range(256) ]
    with Bitpacking(nom_in, 'rb') as fin, \
            open(nom_out, 'wb') as fout:
        code = fin.read_code(longueur_code)
        fout.write(table[code])
        while True:
            nouveau = fin.read_code(longueur_code)
            if nouveau is None:
                break
            if len(table) == nouveau:
                x = table[code][0:1] # car bytes
                s = table[code]+x
                s = table[nouveau]
                x = s[0:1] # car bytes
            fout.write(s)
            if len(table) < 1 << longueur_code:</pre>
               table.append(table[code]+x)
            code = nouveau
```

II.3.iv Impact de la longueur du code

Afin d'étudier l'impact de la longueur du code sur la taille des fichiers compressés, on considère deux fichiers :

- proust.txt contenant, en 7543768 octets, l'intégrale de à la recherche du temps perdu de Marcel Proust
- code.py contenant 8566 octets de code source Python

On note np la taille en nombre d'octets après compression du fichier proust.txt et tp le nombre d'entrées dans la table à la fin du processus. De même, on note nc et tc les valeurs respectives pour le fichier code.py.

On obtient alors les valeurs suivantes en fonction du nombre d de bits du code :

d	np	nc	tp	tc
8	7543768	8566	256	256
9	5056398	5709	512	512
10	4195124	4431	1024	1024
11	3864174	3948	2048	2048
12	3612505	4039	4096	2947
13	3434424	4376	8192	2947

d	np	nc	tp	tc
14	3262145	4712	16384	2947
15	3131790	5049	32768	2947
16	2998639	5385	65536	2947
17	2682264	5722	131072	2947
18	2554323	6058	262144	2947
19	2500314	6395	524288	2947
20	2557656	6731	1023317	2947

On constate qu'il est nécessaire d'avoir un texte riche pour bénéficier d'une grande longueur de code. Le fichier code. py ne contenant pas plus que 2947 motifs. Même si le fichier proust.txt en contient plus que les tailles considérées ici, il y a un compromis qui s'établit entre la richesse de la table et la taille du code. Ainsi, il semble que le fichier proust.txt soit compressé de manière optimale avec un code de longueur 19.

- III Problèmes supplémentaires
- III.1 Transformation de Burrows-Wheeler
- III.2 Move to front
- III.3 La structure de données corde
- III.4 L'algorithme de Knuth-Morris-Pratt
- III.5 Extensions à l'analyse d'images



Systèmes

13	Gestion de la mémoire dans un programme
	compilé 149
1	Organisation de la mémoire
П	Pointeurs
Ш	Portée d'un identificateur

Piles d'exécution, variables locales et paramètres

Allocation dynamique

IV



13. Gestion de la mémoire dans un programme compilé

■ Note 13.1 Roadmap:

- reprendre les exemples en C en utilisant des int suite au changement dans le programme.
- rajouter la présentation des pointeurs ici

■ Remarque 13.1 Ce chapitre se concentre sur la manière dont un programme compilé gère la mémoire. Il est question, en particulier, de la notion de variable. Le modèle dans lequel on se place est celui du langage C où une variable est un emplacement mémoire.

Organisation de la mémoire

■ **Note 13.2** Ici, je fais le choix d'une présentation assez informelle pour ne pas qu'elle soit trop liée à la réalité d'un compilateur en particulier.

Un programme compilé gère la mémoire d'un ordinateur de deux manières très différentes

- statiquement : c'est le cas des variables locales ou globales définies dans le programme. Au moment de la compilation, le compilateur dispose de l'information suffisante pour prévoir de la place en mémoire pour stocker ces données.
- dynamiquement : c'est le cas des objets dont la taille n'est connue qu'à l'exécution et peut varier selon l'état du programme. C'est alors au moment de l'exécution que le programme va faire une demande d'allocation pour obtenir une place mémoire.

En terme d'allocation statique, on peut distinguer plusieurs types de mémoire :

- les variables globales initialisées qui seront stockées dans le binaire et placées en mémoire dans une zone spécifique chargée avec le binaire
- les variables globales non initialisées dont seule la déclaration sera dans le binaire et qui seront allouées, placées en mémoire et initialisées à 0 au moment du chargement du binaire
- les variables locales et les paramètres qui sont placés dans une pile afin de les allouer uniquement au moment de l'exécution du bloc ou de la fonction

L'allocation dynamique utilise une zone mémoire appelée tas dont une possible organisation est développée dans la partie sec. V.4.



Structure de la mémoire associée à un programme

Considérons le programme c suivant.

```
const int a = 42;
int b[] = { 1, 2, 3 };
int c;

int f(int x, int y) {
    int z = x;
    z = z * y;
    return z;
}

int main(int argc, char **argv) {
    const int d = 1664;
    c = f(a, d);
    return 0;
}
```

Il est possible d'observer la manière dont sa mémoire sera répartie en utilisant la commande objdump :

```
$ gcc -c memoire.c
$ objdump -x memoire.o
memoire.o:
            file format elf64-x86-64
memoire.o
architecture: i386:x86-64, flags 0x00000011:
HAS_RELOC, HAS_SYMS
start address 0x00000000000000000
Sections:
Idx Name
                                                     File off Algn
               Size
                       VMA
                                      LMA
 0 .text
```

```
CONTENTS, ALLOC, LOAD, RELOC, READONLY, CODE
                 00000000 0000000000000000
 1 .data
                                           00000000000000000
                                                            0000093
                 CONTENTS, ALLOC, LOAD, DATA
                 00000004 0000000000000000
 2 .bss
                                           00000000000000000
                                                            00000094
                                                                      2**2
                 ALLOC
 3 .rodata
                 00000014 0000000000000000
                                           00000000000000000
                                                            00000098
                 CONTENTS, ALLOC, LOAD, READONLY, DATA
                 000000ac
 4 .comment
                 CONTENTS, READONLY
 5 .note.GNU-stack 00000000 0000000000000000
                                             00000000000000000
                                                              000000bf
                 CONTENTS, READONLY
                 000000c0
 6 .eh_frame
                 CONTENTS, ALLOC, LOAD, RELOC, READONLY, DATA
SYMBOL TABLE:
0000000000000000000001
                    df *ABS*
                              0000000000000000 orga.c
                    d .text 000000000000000 .text
000000000000000000001
000000000000000000001
                    d .data 00000000000000 .data
0000000000000000 l
                    d .bss
                              000000000000000 .bss
000000000000000000001
                    d .rodata
                                  0000000000000000 .rodata
                    d .note.GNU-stack
                                         0000000000000000 .note.GNU-stack
0000000000000000000 l
                    d .eh_frame 00000000000000 .eh_frame
000000000000000000001
                    d .comment
                                  0000000000000000 .comment
0000000000000000 g
                     0 .rodata
                                  00000000000000004 a
0000000000000000 g
                     O .data 000000000000000 b
00000000000000000 g
                     0 .bss
                              00000000000000004 c
00000000000000000 g
                     F .text
                              000000000000001f f
000000000000001f g
                     F .text
                              00000000000000034 main
RELOCATION RECORDS FOR [.text]:
                                 VALUE
OFFSET
                TYPE
0000000000000042 R_X86_64_PLT32
                                 f-0x000000000000000004
0000000000000048 R_X86_64_PC32
                                 c-0x000000000000000004
RELOCATION RECORDS FOR [.eh_frame]:
OFFSET
                TYPE
                                 VALUE
00000000000000020 R_X86_64_PC32
                                 .text
00000000000000040 R_X86_64_PC32
                                 .text+0x000000000000001f
```

On retrouve dans les sections mémoire :

- .text contenant le programme binaire
- .data contenant les variables globales initialisées et non constantes
- .bss contenant les variables non initialisées
- .rodata contenant les variables globales initialisées mais constantes.

Ici, le schéma mémoire est un peu plus compliqué car une zone mémoire distincte est prévue pour les variables constantes initialisées pour des raisons de sécurité.

La pile et le tas sont automatiques et n'ont pas besoin de figurer dans le binaire, c'est pour cela qu'on ne les trouve pas dans la liste.

Dans cette description mémoire, on trouve la table des symboles qui décrit où vont se trouver

en mémoire certaines variables.

Nom de variable	Sorte de déclaration	Section mémoire	
a	constante globale initialisée	rodata	
b	globale initialisée	data	
С	globale non init.	bss	

La section suivante permettra de compléter le tableau en étudiant comment les paramètres et variables locales sont gérés. On remarque cependant qu'il n y a pas de symboles pour ceux-ci. En effet, le nom des variables locales est a priori perdu après la compilation contrairement aux variables globales.

II Pointeurs

III Portée d'un identificateur

En ce qui concerne une variable dans un programme, on peut définir deux notions d'apparence assez similaire.

D'une part la portée d'un identificateur qui correspond au texte du programme :

Définition III.1 La **portée** d'un identificateur est définie par la zone du texte d'un programme dans laquelle il est possible d'y faire référence sans erreurs.

■ Remarque 13.2 Dans le langage C, un identificateur peut être utilisé dès sa déclaration mais tant que la variable n'est pas initialisée, le comportement n'est pas spécifié et il faut considérer cela comme une erreur. Le compilateur produit ainsi un avertissement quand on utilise le paramètre -Wall.

Dans le cas d'une définition, il est ainsi possible de faire référence à l'identificateur dans l'expression de son initialisation: int x = x. Ce cas est pathologique et le fait qu'on compte la ligne de déclaration dans la portée ne devrait pas inciter à écrire ce genre de code qui produira, de toutes façons, une erreur avec les options -Wall -Werror.

Dans le programme:

```
int a = 1;
2
    int f (int x)
3
         int y = x + a;
5
         return y;
6
    }
\bigcirc
    int g()
    {
10
         int z = 3;
11
         return z + f(z);
12
13
```

La portée des identificateurs est :

Identificateur	Portée
a	1-13
X	3-7
у	5-7
f	4-13
g	10-13
Z	11-13

Pour une fonction, afin de pouvoir écrire des fonctions récursives, l'identificateur est utilisable dans le corps de la fonction.

Comme la portée est une notion associée aux identificateurs, elle est indépendante de la notion de variables. Si on considère le programme suivant :

```
int f()
{
    int i = 3;

    return i;
}

int g()
{
    int i = 5;

    return i+1;
}
```

L'identificateur i a pour portée les lignes 3-6 et 10-13.

Un autre phénomène plus complexe peut se produire quand on redéfinit un identificateur dans sa portée.

Considérons le programme suivant

```
int f()
{
    int i = 3;

    for (int j = 0; j < 3; j++)
    {
        int i = 4;

        i += j;
    }

return i;
}</pre>
```

Ici, l'identificateur i a pour portée les lignes 3-13 mais dans les lignes 7-10 il y a un phénomène dit de masquage où la première définition est cachée par la seconde.

L'identificateur associé à une variable globale a pour portée l'ensemble des lignes suivant sa déclaration.

■ Remarque 13.3 En C, la portée d'un identificateur est statique : elle dépend uniquement du texte du programme au moment de la compilation.

En Python, la portée d'un identificateur est **dynamique** : elle peut dépendre de l'exécution d'un programme. Par exemple si on considère le programme Python

Python

```
if condition:
```

La portée de l'identificateur x dépend ici du fait que la condition soit réalisée ou non.

IV Piles d'exécution, variables locales et paramètres

On a vu qu'en raison de leur durée de vie, les variables globales étaient allouées dès le chargement du programme. Pour les variables locales ainsi que la mécanique des appels, on utilise une **pile**.

Cette pile d'exécution est représentée en mémoire par un tableau et un indicateur de fond de pile.

Le remplissage de ce tableau s'effectue souvent des adresses hautes vers les adresses faibles : on empile en faisant diminuer les adresses.

■ Remarque 13.4 En fait, il existe des architectures où les adresses sont croissantes. Ce qui importe est que le tas et la pile aient des comportements opposées pour qu'ils puissent grandir dans la même zone mémoire.

Un compilateur peut faire le choix d'utiliser directement des registres processeurs pour les variables locales ou pour passer des paramètres à une fonction. Ici, pour simplifier, on va supposer que ce n'est pas le cas et que tout passe par la pile d'exécution.

■ Remarque 13.5 Afin de pouvoir appeler une fonction dans une bibliothèque potentiellement compilée avec un autre compilateur, il est nécessaire d'avoir une convention d'appels de fonctions. Une telle convention est appelée une *interface applicative binaire* (Application Binary Interface).

La convention System V AMD64 ABI qui est celle de Linux et macOS sur des architectures 64bits consiste à utiliser des registres entiers pour les six premiers arguments entiers ou pointeurs et des registres flottants pour les huit premiers arguments flottants. Les arguments suivants sont alors passés sur la pile (donc dès le septième entier/pointeur ou neuvième flottant).

La convention cdecl qui est assez répandue sur les architectures 32bits consiste à utiliser la pile. Par contre la valeur de retour est présente dans des registres comme pour la convention System V AMD64 ABI.

Lors d'un appel d'une fonction passant par la pile, on commence par empiler les paramètres (souvent de la droite vers la gauche) puis on empile l'adresse à laquelle doit revenir l'exécution une fois que la fonction aura terminé son exécution.

Au début de l'exécution de cette fonction, on place sur la pile l'adresse du fond de pile et on déplace celui-ci pour réserver de la place pour les variables locales.

L'empreinte sur la pile d'un appel de fonction est appelée une structure pile (**stack frame** en anglais). La pile est alors organisée, depuis l'appel au point d'entrée du programme, par empilement et dépilement de structures piles.



Structure pile associée à un appel de fonction

Voici un exemple possible de l'état de la pile d'exécution lors de l'exécution d'un programme compilé avec la norme cdecl (Il suffit d'ajouter l'argument -m32 pour compiler en 32bits).

```
int f(int a, int b)
2
                                                                      3 (x)
         int c = 3;
                                                                 sauvegarde registre
         /* pile ici après l'appel en l‡3 */
                                                                 adresse de retour
         c = c + b;
                                                                     10 (a)
         c = c * a;
         return c;
                                                                     12 (b)
    int main()
11
12
         int x = f(10,12);
13
```

A chaque appel de fonction, on va donc empiler une structure de pile complète, puis la dépiler à la sortie. Ce mécanisme est essentiel pour permettre la récurrence car il permet d'effectuer plusieurs appels d'une même fonction sans risquer que la mémoire utilisée lors d'un des appels interfère avec un autre. On comprend également les limites de la récursivité ici car cet empilement successif de structures de piles peut dépasser la taille maximale de la pile d'exécution : on parle alors de *dépassement de pile* ou **stack overflow** en anglais.

■ Remarque 13.6 Il est possible de définir des variables locales qui soient situées au même emplacement mémoire pour tous les appels d'une fonction, c'est ce qu'on appelé des variables *statiques* dans le paragraphe précédent.

Ce mécanisme est essentiellement géré comme les variables globales et il ne sera pas développé dans la suite.

■ **Note 13.3** Je me demande s'il faudrait parler plus précisement de la manière dont la pile est gérée avec les registres ebp/esp. Mais ça ne me semble pas apporter grand chose ici.

V Allocation dynamique

Comme cela a été vu dans la section sec. I, il est possible d'allouer dynamiquement de la mémoire. Pour gérer cette allocation dynamique, on passe par une zone mémoire appelé le *tas* ainsi que par un mécanisme d'allocation et de libération de mémoire au niveau du système.

Pour l'utilisateur, cette gestion interne est transparente et on peut se contenter de considérer qu'il y a deux mécanismes :

- l'allocation mémoire où on demande à ce qu'une zone mémoire d'une certaine taille soit allouée
- la **libération** mémoire où on signale que la zone mémoire peut être récupérée par le système.

Naturellement, la mémoire d'un ordinateur étant finie, il est très important de libérer au plus tôt la mémoire non utilisée pour éviter d'épuiser la mémoire. Quand un programme ne libère pas toute la mémoire qu'il alloue, on parle de **fuite mémoire**. L'empreinte mémoire d'un tel programme peut alors croître jusqu'à rendre le programme ou le système inutilisable.

V.1 Allocation

Pour allouer une zone mémoire, on utilise la fonction malloc dans stdlib.h de signature:

```
void *malloc(size_t size)
```

Ici size indique le nombre d'octets à allouer et la fonction renvoie un pointeur vers le premier octet alloué. Comme la fonction ne connait pas le type d'objets alloués, on utilise ainsi le type void *.

Ce type joue un rôle spécial et on peut changer directement le type de la valeur de retour sans rien avoir à écrire d'autre l'appel à malloc :

```
char *t = malloc(n);
```

■ Remarque 13.7 Dans le langage C++ qui peut être vu comme un successeur de C, il est obligatoire de préciser ici le nouveau type à l'aide d'un un transtypage. Pour convertir la valeur x vers le type char * on écrit alors (char *) x. Ainsi, pour allouer un tableau de n caractères, on utilisera:

```
char *t = (char *) malloc(n);
```

Bien que ce ne soit pas nécessaire en C, il est fréquent de rencontrer des programmes présentant de tels transtypages qui sont superflus mais corrects syntaxiquement en C.

Pour obtenir la taille à allouer, il peut être utile d'utiliser l'opérateur sizeof qui prend en entrée un type ou une valeur et renvoie sa taille. Ainsi si on peut allouer un tableau de n entiers non signés ainsi :

```
unsigned int *t = malloc( sizeof(unsigned int) * n );
```

et cet appel ne dépend de la taille prise par un unsigned int sur l'architecture.

Une autre raison de l'utilisation de sizeof est l'extensibilité. Par exemple, si on a un struct point représentant des points en 2D :

```
struct point {
    float x;
    float y;
};
```

on peut allouer un tableau de n points ainsi :

```
struct point *t = malloc( sizeof(struct point) * n );
```

Si jamais on change la structure pour représenter des points en 3D ainsi :

```
struct point {
    float x;
    float y;
    float z;
};
```

il sera inutile de changer le code d'allocation du tableau car sizeof(point) tiendra compte automatiquement du changement.

Si jamais une erreur empêche d'allouer la mémoire - ce qui peut être le cas s'il n'y a plus de mémoire disponible - le pointeur renvoyé par malloc a la valeur spéciale NULL.

■ Remarque 13.8 La zone mémoire renvoyée par malloc n'est pas initialisée. On ne peut pas supposer qu'elle soit remplie de la valeur 0. Il faut donc manuellement initialiser la mémoire après le retour de malloc.

V.2 Libération

Pour libérer la mémoire, on utilise la fonction free également présente dans stdlib.h et dont la signature est :

```
void free(void *ptr);
```

■ Remarque 13.9 Il est très important d'utiliser uniquement un pointeur obtenu précédemment par un appel à malloc et de ne pas l'utiliser plus d'une fois.

Le programme suivant provoque une erreur free(): invalid pointer à l'exécution mais est détécté par un avertissement du compilateur : warning: attempt to free a non-heap object 'a'.

```
#include <stdlib.h>
int main()
{
    int a;
    free(&a);
    return 0;
}
```

Le programme suivant alloue un tableau de deux char et appelle free sur l'adresse de la seconde case. En faisant cela, il n'y a pas d'avertissement car on appelle free sur un objet qui est effectivement sur le tas. On obtient alors à nouveau une erreur à l'exécution free (): invalid pointer.

```
#include <stdlib.h>
    char *a = malloc(2);
    free(&(a[1]));
    return 0;
```

Le programme suivant libère deux fois la mémoire et provoque l'erreur free (): double free detected in tcache 2 à l'exécution.

```
#include <stdlib.h>
int main()
   char *a = malloc(2);
    free(a);
   free(a);
    return 0;
```

V.3 Protection mémoire

Comme on l'a vu dans la première partie, quand un programme s'exécute il a un environnement mémoire constitué de plusieurs zones, parfois appelées segments, avec le droit d'écriture dans certaines d'entre elles.

Le système d'exploitation protège ainsi la mémoire et, au niveau matériel, l'unité de gestion de la mémoire connait les adresses accessibles à un programme. En cas d'accès anormal, le matériel provoque une erreur qui remonte au système d'exploitation qui termine l'exécution du programme avec une erreur souvent intitulée Segmentation fault.

Voici quelques exemples commentés produisant des erreurs de type segmentation fault à l'exécution.

```
Lecture à l'adresse 0, ce qui provoque toujours une erreur.

Même problème avec une adresse inaccessible ou invalide.

int main()
{
   int main()
{
   int *a = 0;
   return a[0];
}
```

Écriture dans une zone en lecture seule comme le segment du code.

```
int main()
{
    int *a = (int*) (&main);
    // a pointe sur le corps de la fonction main
    *a = 0;
    return 0;
}
```

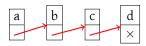
V.4 Réalisation d'un système d'allocation de mémoire

■ Note 13.4 Prérequis : listes chaînées

Afin de comprendre comment fonctionne le tas, et en particulier malloc et free, on va simuler ici ce comportement en allouant une grande plage de mémoire avec malloc et en gérant le découpage et l'allocation de celle-ci.

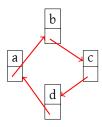
Pour gérer les blocs mémoires libres, on utilise une liste circulaire. Une liste circulaire est une liste chaînée avec un lien supplémentaire entre le premier et le dernier maillon, ce qui fait qu'on peut considérer n'importe quel maillon comme étant la *tête* de la liste.

Une liste chaînée:



Ici le dernier maillon comprend un pointeur qui ne pointe sur rien indiqué par \times , en pratique il a la valeur NULL

Une liste circulaire:



Le seul changement est donc de faire pointer le dernier maillon sur le premier. Le fait d'avoir preserver les valeurs dans les maillons permet ici de voir ce qu'est devenu le premier maillon, mais on peut accéder à cette liste par n'importe lequel de ces maillons.

Les noeuds de la liste circulaire de blocs libres auront pour valeur un triplet (adresse, taille, libre) qui indique qu'à l'adresse adresse il y a un bloc de taille octets et le booléen libre indique si ce bloc a été alloué ou non.

Pour cela on commence par définir une structure bloc et une fonctiond de création d'un bloc :

```
struct bloc {
    void *adresse;
    uint32_t taille;
    bool libre;
    struct bloc *suivant;
};
```

```
struct bloc *cree_bloc(void *adresse, uint32_t taille, bool libre)
{
    struct bloc *b = malloc(sizeof(struct bloc));
    b->adresse = adresse;
    b->taille = taille;
    b->libre = libre;
    return b;
}
```

On définit ensuite deux variables globales :

- bloc_libres qui va pointer sur un maillon de la liste circulaire des blocs
- plage_memoire qui pointe sur l'adresse de la plage mémoire que l'on va gérer et servira à la libérer en sortie de programme.

```
struct bloc *blocs_libres;
void *plage_memoire;
```

La fonction creation_blocs_libres permet de créer la liste circulaire avec un premier bloc qui pointe sur lui-même et qui correspond à l'adresse que l'on va placer dans plage_memoire.

```
void creation_blocs_libres(uint32_t taille_bloc_initial)
{
    plage_memoire = malloc(taille_bloc_initial);
    blocs_libres = cree_bloc(plage_memoire, taille_bloc_initial, true);
    blocs_libres->suivant = blocs_libres; // boucle initiale
}
```

Pour libérer la liste à la sortie du programme, on définit la fonction destruction_blocs_libres qui présente ainsi le parcours usuel d'une liste circulaire: on procède comme pour une liste chaînée classique mais, au lieu d'utiliser un test bloc_courant->suivant == NULL pour l'arrêt, il faut se souvenir du premier bloc et tester pour voir si on est revenu au point de départ. On n'oublie pas de libérer l'espace plage_memoire à la fin.

```
void destruction_blocs_libres()
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;

    // on boucle pour libérer chaque maillon
    while (true) {
        struct bloc *bloc_suivant = bloc_courant->suivant;
        free(bloc_courant);
        if (bloc_suivant == premier_bloc) return;
        bloc_courant = bloc_suivant;
    }

    // on libère la plage mémoire initiale
    free(plage_memoire);
}
```

Pour allouer t octets, on parcourt la liste des blocs jusqu'à trouver un bloc b libre de taille b.t telle que $b.t \geq t$. Si un tel bloc n'existe pas, on renvoie le pointeur NULL signe d'un échec d'allocation. Sinon, on indique que le bloc est occupé, on va renvoyer l'adresse du bloc obtenu

mais, si b.t > t on insère après b un nouveau bloc libre de taille b.t - t. Dans tous les cas, on fait pointer la liste des blocs libres vers le bloc qui suit b, qui est peut-être le bloc nouvellement créé et a de grandes chances d'être libre.

Ce mécanisme est implementé dans la fonction allocation:

```
void *allocation(uint32_t taille)
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;
    while (!bloc_courant->libre || bloc_courant->taille < taille)</pre>
    {
        bloc_courant = bloc_courant->suivant;
        if (bloc_courant == premier_bloc)
            // Retour au point de départ : échec d'allocation
            return NULL;
        }
    }
    // bloc_courant pointe sur un bloc libre de bonne taille
    void *adresse = bloc_courant->adresse;
    bloc_courant->libre = false;
    if (bloc_courant->taille > taille) {
        // on le sépare en deux pour récupérer la place
        struct bloc *bloc_libre = cree_bloc(adresse+taille,
                bloc_courant->taille-taille, true);
        bloc_courant->taille = taille;
        bloc_libre->suivant = bloc_courant->suivant;
        bloc_courant->suivant = bloc_libre;
    }
    // On pointe sur le bloc suivant qui est sûrement libre
    blocs_libres = bloc_courant->suivant;
    return adresse;
```

Pour libérer un bloc, on parcourt la liste jusqu'à trouver le bloc correspondant à l'adresse à libérer et on indique que le bloc est libre. Ici, il y a deux assert permettant de s'assurer que l'adresse est bien celle d'un bloc et que le bloc n'a pas déjà été libéré.

```
void liberation(void *adresse)
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;

    while (bloc_courant->adresse != adresse)
    {
        bloc_courant = bloc_courant->suivant;
        // adresse invalide
        assert(bloc_courant != premier_bloc);
    }
}
```

```
// pas de double libération
assert(!bloc_courant->libre);

// on libère l'adresse
bloc_courant->libre = true;
}
```

Voici un premier programme de test de ces fonctions qui alloue 10 octets puis effectue plusieurs allocations. L'allocation de c échoue car il n'y a plus de place libre.

```
int main(void)
   {
2
        creation_blocs_libres(10);
3
4
        uint8_t *a = allocation(5);
5
        uint8_t *b = allocation(3);
6
        uint8_t *c = allocation(3);
7
        liberation(b);
        uint8_t *d = allocation(2);
<u>ن</u>
10
        printf("Allocation a:%p b:%p c:%p d:%p\n",
11
                 (void *)a, (void *)b, (void *)c, (void *)d);
12
13
        destruction_blocs_libres();
14
15
        return 0;
16
17
```

Ce programme affiche alors

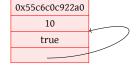
```
Allocation a:0x55c6c0c922a0 b:0x55c6c0c922a5 c:(nil) d:0x55c6c0c922a5
```

Voici l'évolution de la liste circulaire en présentant les maillons sous la forme :

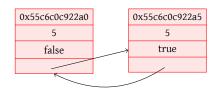


L'évolution de la liste des blocs entre les lignes 3 et 9 est alors :

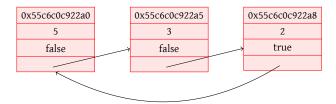
• Ligne 3



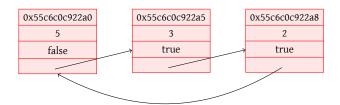
• Ligne 5



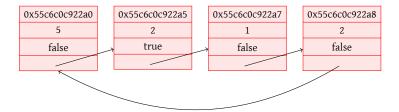
• Ligne 6



• Ligne 8



• Ligne 9



Cette méthode d'allocation a un défaut majeur : elle fragmente l'espace libre. Dans le programme suivant, il sera impossible d'allouer b car la liste circulaire contient deux blocs libres de 5 octets et non une bloc libre de 10 octets.

```
creation_blocs_libres(10);

uint8_t *a = allocation(5)
liberation(a);
uint8_t *b = allocation(10);
```

■ Remarque 13.10 On peut observer ce phénomène sur le diagramme précédent à la ligne 8 où deux blocs contigus sont libres et pourraient être fusionnés en un unique bloc de 5 octets.

On peut éviter cela en effectuant une phase de coalescence des blocs libres à la libération. En vertu de la nature de la liste circulaire, il est nécessaire de fusionner un bloc libre avec les blocs suivants. En utilisant une liste circulaire doublement chaînée, on pourrait également fusionner avec les blocs précédents.

Pour cela on change la fonction liberation ainsi:

```
void liberation(void *adresse)
{
    struct bloc *premier_bloc = blocs_libres;
    struct bloc *bloc_courant = premier_bloc;
```

```
while (bloc_courant->adresse != adresse)
    bloc_courant = bloc_courant->suivant;
    // adresse invalide
    assert(bloc_courant != premier_bloc);
}
// pas de double libération
assert(!bloc_courant->libre);
// on libère l'adresse
bloc_courant->libre = true;
premier_bloc = bloc_courant;
bloc_courant = bloc_courant->suivant;
while (bloc_courant != premier_bloc && bloc_courant->libre)
    struct bloc* actuel = bloc_courant;
    premier_bloc->taille += bloc_courant->taille;
    bloc_courant = bloc_courant->suivant;
    free(actuel); // on libere le bloc inutile
}
premier_bloc->suivant = bloc_courant;
```